Fachhochschule Nordwestschweiz
Hochschule für Informatik

SAN (Soziale Netzwerk Analyse)
Modulbericht

Lukas Breiter Gian Truttmann Jessica Schmid

Windisch, 4. Januar 2026

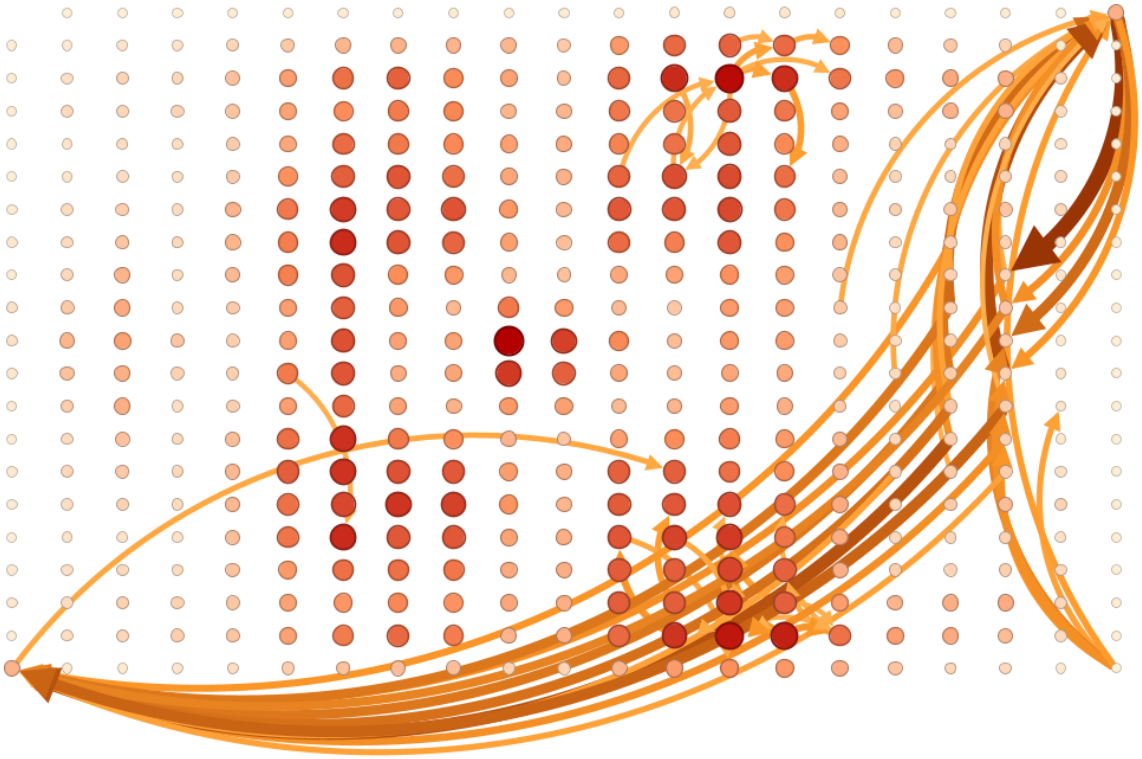

Modul	SAN
Autoren	Lukas Breiter Gian Truttmann Jessica Schmid
Dozent	Michael Henninger
Studiengang	SG DSAI
Semester	HS 2025
Version / Abgabedatum	1.0 / 04.01.2026

Fachhochschule Nordwestschweiz (FHNW)

Abstract

Wir modellieren Fussballspiele als soziale Netzwerke. Grundlage sind Wyscout-Eventdaten aus sieben Wettbewerben: den Ligen Englands, Spaniens, Deutschlands, Frankreichs und Italiens sowie der Welt- und der Europameisterschaft. Aus den Events bauen wir vier Netzwerktypen: Pass-Netzwerke zwischen Spielern, Match-Netzwerke zwischen Teams, ein bipartites Spieler-Team-Netzwerk und ein Netzwerk aus Feldzonen. Wyscout liefert keinen Passempfänger. Wir bestimmen ihn über die nächste Aktion des eigenen Teams innerhalb von 5 Sekunden und 10 Metern. Für die Detailanalysen wählen wir die Bundesliga und die WM.

Mit Louvain finden wir im Bundesliga-Passnetz Communities, die den realen Teams entsprechen ($Q = 0.886$). Innerhalb des FC Köln sinkt die Modularität auf $Q = 0.109$, und jede der drei Communities enthält Spieler mehrerer Positionen. Im WM-Match-Netz liefert Louvain sechs Communities ($Q = 0.701$). Sie folgen den acht Vorrundengruppen, wobei K.O.-Spiele einzelne Gruppen zusammenlegen. Grad und Betweenness korrelieren im Passnetz mit $r = 0.338$. Der Clustering-Koeffizient von 0.867 liegt 11.7-mal über dem eines Erdős-Rényi-Graphen gleicher Grösse, und im Permutationstest gegen das Configuration Model erreicht kein Zufallsnetz diesen Wert ($p < 0.001$). Von den Passbeziehungen sind 92.7 % reziprok. Die Gradverteilung passt am besten zu einer Log-Normal-Verteilung (KS-Statistik $D = 0.067$); ein Power Law verwerfen wir ($p = 0.003$). Bei der Link Prediction erzielt Adamic-Adar mit einer AUC von 0.892 das beste Ergebnis.

Keywords: soziale Netzwerkanalyse, Graphen, Communities, Zentralität, Link Prediction

Inhaltsverzeichnis

Abbildungsverzeichnis **vii**

Tabellenverzeichnis **1**

1 Exploratory Data Analysis (EDA) **2**

1.1 Ziel und Kapitelrolle 2

1.2 Datenbasis und Aufbereitung 2

1.3 Wettbewerbe und Spiele 2

1.4 Ereignisse: Typen und zeitliche Muster 3

1.5 Pass-Analyse: Zentrale Akteure und räumliche Verteilung 7

1.6 Wettbewerbsvergleich 9

1.7 Erste Hypothesen für die Netzwerk-Analyse 10

2 LE3 – Netzwerk-Modellierung & Filterung **11**

2.1 Netzwerkmodellierung 11

2.1.1 Netzwerke 11

2.2 Netzwerkfilterung 15

2.2.1 Sichten: Local View, Global View, Ego-Netzwerk 15

2.2.2 Filtern anhand von Kantenattributen 16

3 LE4 – Communities **18**

3.1 Connected Components 18

3.2 Cliquen und dichte Subgraphen 18

3.2.1 Maximale Cliquen 18

3.2.2 k-Core Dekomposition 19

3.3 Community Detection 20

3.3.1 Algorithmen im Überblick 20

3.3.2 Modularität als Qualitätsmass 21

3.4 Ergebnisse: Community Detection 21

3.4.1 Pass-Netzwerk (Deutschland Bundesliga) 21

3.4.2 Match-Netzwerk (FIFA World Cup) 22

3.5 Intra-Team Analyse: Positionsbasierte Strukturen 23

4 LE5 – Zentrale Aktoren & Aktor-Gruppen finden **26**

4.1 Ziel und Fragestellung 26

4.2 Datengrundlage 26

4.3 Ergebnisse: Pass-Netzwerk (Deutschland) 26

4.3.1 Degree Centrality und Strength 26

4.3.2 Betweenness Centrality 27

4.3.3 Vergleich aller Zentralitätsmasse 27

4.3.4 Top Spieler nach Zentralität 29

4.4 k-Core Analyse 29

4.5 Ergebnisse: Match-Netzwerk (World Cup) 30

4.5.1 Team-Zentralität 30

4.6 Vergleich: Pass-Netzwerk vs. Match-Netzwerk 31

5 LE6 – Netzwerk-Kennzahlen **32**

5.1 Ziel 32

5.2 Datengrundlage 32

5.3 Globale Kennzahlen 32

5.3.1 Diameter und Average Path Length 32

5.3.2 Clustering Coefficient und Transitivity 33

5.3.3 Assortativity 35

5.3.4 Reciprocity 35

5.4 Lokale Kennzahlen 36

5.4.1 Edge Embeddedness 36

5.5 Zusammenfassende Analyse 37

5.5.1 Strukturelle Unterschiede 38

5.6 Diskussion 38

5.6.1 Small-World-Eigenschaften in Fussballnetzwerken 38

5.6.2 Taktische Implikationen 39

5.6.3 Limitationen 39

5.7 Fazit 39

6 LE7 – Statistik in Netzwerken **41**

6.1 Ziel 41

6.2 Nullmodelle & Randomisierung 41

6.2.1 Zufallsgraph-Modelle als Nullmodelle 41

6.2.2 Ergebnisse: Modellvergleich Pass-Netzwerk 42
6.3 Gradverteilungs-Analyse 43
6.3.1 Verteilungstypen 43
6.3.2 Ergebnisse: Pass-Netzwerk Gradverteilung 43
6.4 Statistische Hypothesentests 44
6.4.1 Permutationstest für Netzwerk-Clustering 44
6.4.2 Bootstrap-Konfidenzintervalle 45
6.5 Link Prediction Evaluation 46
6.5.1 Methodik 46
6.5.2 Ergebnisse 47
6.6 Diskussion 48
6.6.1 Signifikanz vs. Effektgrösse 48
6.6.2 Nullmodell-Wahl 48
6.6.3 Gradverteilungen und Mechanismen 48
6.6.4 Link Prediction in der Praxis 49
6.6.5 Limitationen 49
6.7 Fazit 49

7 LE8 – Link-Prediction 50
7.1 Algorithmen zur Link-Prediction 50
7.1.1 Common Neighbours 50
7.1.2 Jaccard Coefficient 50
7.1.3 Adamic-Adar 50
7.1.4 Resource Allocation 50
7.1.5 Preferential Attachment 51
7.2 Anwendung auf Fussballnetzwerke 51
7.3 Vergleich der Algorithmen 51
7.3.1 Score-Verteilungen 52
7.3.2 Overlap- und Korrelations-Analyse 53
7.3.3 Top-K Agreement mit Common Neighbors 54
7.4 Interpretation und Anwendungsempfehlungen 55
7.4.1 Pass-Netzwerk: Taktische Partnerschaften 55
7.4.2 Match-Netzwerk: Turnierstruktur 55
7.4.3 Methodenwahl: Praktische Leitlinien 55
7.5 Fazit 55

8 LE9 – Diffusion **56**

8.1 Theoretische Grundlagen 56

8.1.1 Rogers' Innovationsdiffusionstheorie 56

8.2 Independent Cascade Model (ICM) 56

8.2.1 Influence Maximization 57

8.2.2 Vergleich: Germany vs. France 57

8.3 Voter Model 59

8.4 Threshold Model 60

8.4.1 Sensitivitätsanalyse: Einfluss des Schwellwerts 61

8.5 Modellvergleich und Synthese 62

8.6 Fazit 63

9 LE10 – Graphlets **64**

9.1 Theoretische Grundlagen 64

9.1.1 Graphlets und Orbits 64

9.2 Relative Graphlet Frequency Distance (RGFD) 65

9.2.1 Methodik 65

9.2.2 Anwendung auf Pass-Netzwerke 66

9.2.3 Anwendung auf Match-Netzwerke 67

9.3 Graphlet Degree Vectors (GDV) 68

9.3.1 Methodik 68

9.3.2 Anwendung: Strukturelle Rollen in Pass-Netzwerken 68

9.3.3 Vergleich: Germany vs. France 69

9.4 Praktische Anwendungen und Fazit 70

9.4.1 Anwendungen von Graphlets im Fussball 70

9.4.2 Stärken und Limitationen 70

9.4.3 Zusammenfassung der Ergebnisse 71

9.4.4 Fazit 71

Quellenverzeichnis **72**

Abbildungsverzeichnis

1.1 Anzahl der Spiele pro Wettbewerb. Sowohl Liga-Wettbewerbe wie auch internationale Turniere 2

1.2 Anzahl der Events pro Wettbewerb. Stark abhängig vom Format des Turniers. . 3

1.3 Top 15 Ereignistypen über alle Wettbewerbe. Pässe dominieren klar das Spielgeschehen. 4

1.4 Ereignisse pro Spielminute. Deutlich erkennbar sind erhöhte Aktivität zu Spielbeginn und der Rückgang in der Schlussphase. 5

1.5 Events nach Spielperiode. In der vorliegenden Auswertung sind beide **H**albzeiten mit je über 1.62×10^6 Events nahezu gleich stark vertreten. **E**xtended 1 / 2 sowie **P**enaly kommen bedeutend seltener vor (10 / 10 / 7) 6

1.6 Passvolumen, Passgenauigkeit und durchschnittliche Passdistanz nach Matchperiode. In dieser Auswertung werden in Halbzeit 1 mehr Pässe gespielt (+7.4%), bei sehr ähnlicher Genauigkeit und Distanz. 6

1.7 Top 15 Spieler nach Anzahl der Pässe. Diese Spieler sind später als zentrale Knoten in den Passnetzwerken zu erwarten. 7

1.8 Passvolumen (links) und Passgenauigkeit (rechts) nach Passtyp. Einfache Pässe dominieren das Volumen bei hoher Genauigkeit; Flanken und Smart Passes sind seltener und deutlich ungenauer. Handpässe verzeichnen aufgrund der manuellen Ballkontrolle und ihrer exklusiven Anwendung durch den Torhüter die höchste Präzision. 7

1.9 Umfassende Analyse der Passeigenschaften. **Oben links:** Verteilung der Passlängen mit Median-Markierung. **Oben rechts:** Median-Passlänge nach Passtyp (z. B. lange Bälle vs. kurze Zuspiels). **Unten:** Heatmaps für Pass-Ursprung (links) und Pass-Ziel (rechts), visualisiert auf normalisierten Spielfeldkoordinaten. 8

1.10 Passverhältniss in einem Sample-Match: (links) Top-10 Spieler nach Passvolumen (gespielt vs. empfangen), (rechts) Out-Degree vs. In-Degree mit Referenzlinie $y = x$ zur Rolleninterpretation. 9

1.11 Pass-Statistiken nach Wettbewerb: Volumen, Genauigkeit und durchschnittliche Distanz. Unterschiede deuten auf verschiedene Spielstile und taktische Ansätze hin. 10

2.1 Pass-Netzwerk. Knoten = Spieler, gerichtete Kanten = Pässe, Breite typischerweise proportional zu `pass_count`. 11

2.2 Match-Netzwerk (Beispiel). Knoten = Teams, Kanten = aggregierte Resultate zwischen Team-Paaren. 12

2.3 Player–Team Two-Mode Netzwerk (vor Flattening). Spieler sind typischerweise einem Team zugeordnet (zwei bei Teamwechsel); Kantenbreite kodiert `matches_together`. 13

2.4 Player–Player Netzwerk (nach Flattening / Projektion). Eine Kante entsteht durch gemeinsames Team; Gewichte akkumulieren gemeinsame Einsätze. 13

2.5 Feld-Lokationsnetzwerk als Heatmap. Farbe/Grösse kodieren Ereignisintensität in diskreten Feldzonen. 14

2.6 Pass-Feld-Lokationsnetzwerk der Bundesliga. Knoten & Kantengrösse kodiert für Anzahl Pässe, Knotenfarbe für Grad und Kantenfarbe für Distanz 14

2.7 Local View des Stuttgard-Subgraphen 15

2.8 Global view des unified pass Networks (alle liegennetzwerke in einem Graph), Nodes zusammengeasst nach Team 16

2.9 Ego-Netzwerk von Granit Xhaka. Wir sehen das er sowohl mit dem FC Arsenal, wie auch der Schweizer Nationalmannschaft gut verknüpft ist. 17

2.10 Filterung nach Kantenattribut 17

3.1 Connected Components im Pass-Netzwerk (Deutschland). Das gesamte Netzwerk bildet eine zusammenhängende Komponente mit 473 Knoten (100% des Netzwerks) 19

3.2 Algorithmenvergleich auf dem Pass-Netzwerk (Deutschland). Louvain und Greedy erzielen die höchste Modularität ($Q = 0.915$), Label Propagation zeigt höhere Coverage aber mit einer sehr grossen Ausreisser-Community (Max 79). 22

3.3 Grössenverteilungen der Communities für vier Algorithmen. Louvain und Greedy liefern sehr uniforme Grössen (23–31), Label Propagation zeigt einen Ausreisser (bis 79), Girvan-Newman produziert eine Singleton-Community. 23

3.4 Louvain-Communities im Match-Netzwerk (World Cup). Farbcodierung zeigt 6 Communities, die primär Vorrunden-Gruppen mit K.O.-Verknüpfungen widerspiegeln. 24

3.5 Positionsverteilung innerhalb der Köln-Communities (100% gestapelt). Die fünf Communities zeigen hohe Positions-Diversität: Community 1 (11 Spieler) ist ausgewogen Defensivlastig , Community 2 schon eher ausgeglichen, Community 3 ist wieder etwas defensivlastig, Community 4 besteht nur aus Torwart und Offensive 25

4.1 Degree- und Strength-Verteilung im Pass-Netzwerk (Deutschland). Degree ist in dieser Auswertung relativ kompakt um den Mittelwert, Strength ist deutlich rechtssteil und hebt wenige High-Volume-Passer hervor. 27

4.2 Betweenness-Zentralität: Verteilung und Korrelation mit Degree 27

4.3 Korrelation verschiedener Zentralitätsmasse (Pass-Netzwerk) 28

4.4 k-Core Analyse: Verteilung und Zusammenhang mit Degree 29

4.5 Korrelation verschiedener Zentralitätsmasse (Match-Netzwerk World Cup) 30

5.1 Verteilung des Clustering-Koeffizienten. Links: Pass-Netzwerk (hoch konzentriert um 0.8 - 0.9). Rechts: Match-Netzwerk (variierter). 34

5.2 Clustering-Koeffizient vs. Degree. Pass-Netzwerk zeigt schwache negative Korrelation (Spearman $\rho = -0.235$), Match-Netzwerk schwache positive Korrelation ($\rho = 0.107$). 34

5.3 Verteilung der Edge Embeddedness. Pass-Netzwerk zeigt hohe Einbettung (Ø 17.7 gemeinsame Nachbarn), Match-Netzwerk niedrige Einbettung (Ø 1.6). 36

5.4 Korrelationen zwischen Metriken. Links: Pass-Netzwerk zeigt schwache negative Korrelation zwischen Clustering und Degree ($\rho = -0.235$). Rechts: Match-Netzwerk zeigt schwache positive Korrelation ($\rho = 0.107$). 37

6.1 Vergleich Zufallsgraph-Modelle. Das reale Pass-Netzwerk zeigt deutlich höheres Clustering (0.867) als alle Zufallsmodelle, aber auch längere Pfadlängen. 42

6.2 Gradverteilung des Pass-Netzwerks mit angepassten Modellen. Die Log-Normal-Verteilung (Kolmogorov-Smirnov $D = 0.067$) passt am besten. 44

6.3 Vergleich der angepassten Verteilungen (Empirical CDF vs. Model CDF). Log-Normal zeigt beste Übereinstimmung. 45

6.4 Permutationstest: Beobachtetes Clustering (0.867, rote Linie) vs. 1000 randomisierte Netzwerke (Configuration Model). $p < 0.001$. Das ist hochsignifikant. . . . 45

6.5 Bootstrap-Konfidenzintervalle (95%) für Netzwerk-Metriken. Clustering und Transitivity zeigen hohe Stabilität. 46

6.6 Link Prediction Performance-Vergleich. Adamic-Adar und Resource Allocation zeigen beste Ergebnisse. 47

6.7 Vergleich Link Prediction Performance: Pass-Netzwerk vs. Match-Netzwerk. Pass-Netzwerk zeigt durchgehend höhere AUC-Werte. 48

7.1 Common Neighbors Score-Verteilungen. Links: Pass-Netzwerk (Germany) zeigt breite Verteilung von CN-Scores mit Peak bei 11-13 gemeinsamen Nachbarn. Rechts: Match-Netzwerk (World Cup) zeigt konzentrierte Verteilung mit dominant einem gemeinsamen Gegner. 51

7.2 Jaccard Coefficient Analyse für beide Netzwerke. Obere Reihe: Score-Verteilungen zeigen unterschiedliche Normalisierungseffekte. Untere Reihe: Top-15 Predictions Comparison (links) und Korrelation zwischen CN und Jaccard (rechts) für Pass-Netzwerk. 52

7.3 Score-Verteilungen der fünf Algorithmen für Pass- (oben) und Match-Netzwerk (unten). Histogramme zeigen die Häufigkeitsverteilung der berechneten Scores. . 52

7.4 Overlap und Rang-Korrelation zwischen Algorithmen für Top-20-Vorhersagen. Oben: Pass-Netzwerk, Unten: Match-Netzwerk. 54

7.5 Top-K Agreement mit CN als Baseline. Links: Pass-Netzwerk, Rechts: Match-Netzwerk. 54

8.1 Vergleich von Seed-Strategien für ICM-Diffusion im französischen Pass-Netzwerk. Links: Mittlere Anzahl aktivierter Knoten mit Standardabweichung für vier verschiedene Strategien (Random, High Out-Degree, High In-Degree, High Betweenness). Rechts: Verteilung der erreichten Knotenzahlen als Box-Plots mit Ausreissern. Alle Strategien zeigen vergleichbare Performance mit ähnlichen Streuungen. 57

8.2 Vergleich von Seed-Strategien für ICM-Diffusion im deutschen Pass-Netzwerk. Links: Mittlere Anzahl aktivierter Knoten mit Standardabweichung für vier verschiedene Strategien (Random, High Out-Degree, High In-Degree, High Betweenness). Rechts: Verteilung der erreichten Knotenzahlen als Box-Plots mit Ausreissern. Alle Strategien zeigen vergleichbare Performance mit ähnlichen Streuungen. 58

8.3 Direkter Vergleich Germany vs. France: Greedy Influence Maximization. Zeigt finale Reichweite als Funktion der Seed-Grösse k für beide Netzwerke. 58

8.4 Voter Model Evolution Germany vs. France (ungerichtetes Netzwerk). Beide Länder starten mit 30% initialen +1 Meinungen. Die durchschnittliche Meinung entwickelt sich über 5000 Iterationen. Germany konvergiert gegen -1, France zeigt ebenfalls eine Tendenz zu -1, jedoch mit mehr Schwankungen. 60

8.5 Threshold Model Cascades mit uniform zufälligen Schwellwerten. Oben: Germany aktiviert 54 Knoten in 8 Iterationen. Unten: France aktiviert 43 Knoten in 7 Iterationen. Die kumulative Aktivierung zeigt den S-Kurven-Verlauf typischer Diffusionsprozesse. 61

8.6 Threshold Sensitivitätsanalyse bei festen Schwellwerten (alle Knoten haben denselben θ). Links: Germany, Rechts: France. Die Reichweite bricht nach $\theta \approx 0.2$ dramatisch ein. 61

8.7 Direkter Vergleich Germany vs. France im Threshold Model. Linke Grafik: Cascade Progression mit uniform zufälligen Schwellwerten – Germany erreicht höhere absolute Aktivierung. Rechte Grafik: Sensitivitätsanalyse zeigt nahezu identisches Verhalten bei festen Schwellwerten. 62

8.8 Finaler Vergleich Germany vs. France über alle drei Diffusionsmodelle. Normalisierte Reichweite (als Anteil des Netzwerks) für ICM, Voter Model und Threshold Model. 63

9.1 Graphlet-Häufigkeiten in Pass-Netzwerken. Oben: Germany (Bundesliga), Unten: France (Ligue 1). Balkendiagramme zeigen rechts die absolute Häufigkeit und links die relative häufigkeit für 3-Knoten Graphlets. 65

9.2 Graphlet Distribution Comparison für Pass-Netzwerke (Germany vs. France). Gezeigt sind die relativen Anteile zweier Graphlet-Typen G1 und G2 in beiden Netzwerken. Der RGFD (Relative Graphlet Frequency Distance) beträgt 0.012, was auf eine sehr ähnliche strukturelle Komposition der beiden Pass-Netzwerke hindeutet. Germany (blau) und France (orange) zeigen nahezu identische Graphlet-Verteilungen. 66

9.3 Graphlet Distribution Comparison für Match-Netzwerke (Germany vs. France). Gezeigt sind die relativen Anteile von 8 Graphlet-Typen (G1-G8). Der RGFD-Wert von 0.125 zeigt moderate strukturelle Unterschiede. Besonders auffällig: G2 zeigt einen sichtbaren Unterschied (Germany ca. 21%, France ca. 19%), während G8 mit ca. 80% in beiden Netzwerken stark dominiert. Die meisten Graphlet-Typen (G1, G3-G7) kommen praktisch nicht vor. 67

9.4 t-SNE Visualisierung der GDVs (Germany Pass-Netzwerk). Punkte repräsentieren Spieler, Nähe im 2D-Raum indiziert strukturelle Ähnlichkeit. Farben zeigen Cluster strukturell ähnlicher Spieler. 68

9.5 GDV Heatmap für 20 ausgewählte Spieler (Germany). Zeigt normalisierte Orbit-Frequenzen für 3-Node Graphlets (4 Orbits): Orbit 0 (Degree), Orbit 1 (Path End), Orbit 2 (Path Center), Orbit 3 (Triangle). Orbit 3 dominiert (0.56-0.86, dunkelrot), während Orbit 0 konstant niedrig bleibt (0.02-0.03). Zwei Spieler-Gruppen erkennbar: obere Zeilen mit höheren Orbit 2-Werten, untere Zeilen mit höheren Orbit 3-Werten. 69

9.6 t-SNE GDV-Vergleich. Links: Germany, Rechts: France. Beide zeigen ähnliche Cluster-Strukturen, aber unterschiedliche Verteilungen. 69

9.7 Vergleich struktureller Rollen zwischen Germany und France. Zeigt durchschnittliche GDV-Profile für verschiedene Spieler-Cluster. 70

Tabellenverzeichnis

1.1 Beispiele von 5 zufällig ausgewählten Spielen aus dem Gesamtdatensatz mit Spielbezeichnung, Datum, Austragungsort und Spieldauer. 4

1.2 Vollständige Übersicht der Ereignistypen und Subtypen im Datensatz. Die Spalten geben die Event-ID und Subevent-ID sowie deren sprachliche Bezeichnung an. 5

1.3 Ausschnitt eines Passnetzwerks: erste 10 Passverbindungen eines Beispielspiels (Match-ID 2500004) mit Anzahl der Pässe, mittlerer Distanz und Spielernamen. 9

2.1 Übersicht der konstruierten Netzwerke (Bundesliga; aus `.gexf` berechnet) 15

3.1 Algorithmenvergleich auf Pass-Netzwerk (Deutschland, grösste Komponente) . . 21

3.2 Community Detection auf Match-Netzwerk (World Cup) 22

4.1 Degree und Strength Statistiken (Pass-Netzwerk Deutschland) 26

4.2 Top-10 Spieler nach Gesamtzentralität (Pass-Netzwerk Deutschland) 29

5.1 Diameter und Average Path Length 33

5.2 Small-World-Check 33

5.3 Clustering-Metriken 33

5.4 Clustering vs. Zufallsnetzwerk 34

5.5 Degree-Assortativity 35

5.6 Reciprocity in gerichteten Netzwerken 35

5.7 Edge Embeddedness 36

5.8 Umfassende Netzwerk-Metriken (Zusammenfassung) 37

6.1 Vergleich Zufallsgraph-Modelle (Pass-Netzwerk LCC, 283 Knoten, 2 899 Kanten) 42

6.2 Anpassung von Verteilungsmodellen (Kolmogorov-Smirnov Test) 43

6.3 Link Prediction Performance (Pass-Netzwerk) 47

7.1 Overlap (Jaccard Similarity) und Spearman-Korrelation für alle Algorithmus-Paare 53

7.2 Algorithmen-Auswahl nach Anwendungsfall 55

8.1 Vergleich der Diffusionsmodelle 62

1 Exploratory Data Analysis (EDA)

1.1 Ziel und Kapitelrolle

Dieses Kapitel liefert den einmaligen Überblick über Datensatz, Vorverarbeitung und zentrale Verteilungen. Ziel der EDA ist es, die Datenstruktur zu validieren, Kerndistributionen (Ereignisse, Pässe) zu charakterisieren und daraus belastbare Annahmen für die Netzwerk-Analysen abzuleiten.

Analyseumfang: Die EDA analysiert *alle sieben Wettbewerbe* (England, Spanien, Deutschland, Frankreich, Italien, World Cup, European Championship) gemeinsam, um ein umfassendes Bild des Gesamtdatensatzes zu erhalten. In den nachfolgenden Kapiteln (LE3 ff.) werden dann einzelne Wettbewerbe fokussiert untersucht, um die Rechenkomplexität für detaillierte Netzwerkanalysen zu reduzieren.

1.2 Datenbasis und Aufbereitung

- **Datenquellen:** Die Rohdaten liegen als JSON-Dateien in `data/` vor (Wettbewerbe, Spiele, Ereignisse, Teams, Spieler) und umfassen mehrere Wettbewerbe. Bezogen wurden sie von Pappalardo et al., 2019. Dort findet sich auch eine sehr umfassende Variabelbeschreibung.
- **Robuster Import:** Unicode-Bereinigung und fehlerresistentes Einlesen (für grosse Event-Dateien ggf. Streaming). Fehlende Felder (z. B. Positionen) werden als *NaN* geführt und in Auswertungen entsprechend behandelt.
- **Feature Engineering:** Aus Event-Positionen werden Start-/Endpunkte extrahiert und einfache Distanzmasse für Pässe berechnet. Für Zeitreihen werden Events pro Minute aggregiert; beide Halbzeiten beginnen jeweils bei Minute 0.
- **Ausschlüsse:** Ereignisse ohne ausreichende Positionsinformationen fliessen nicht in Distanzverteilungen ein.

1.3 Wettbewerbe und Spiele

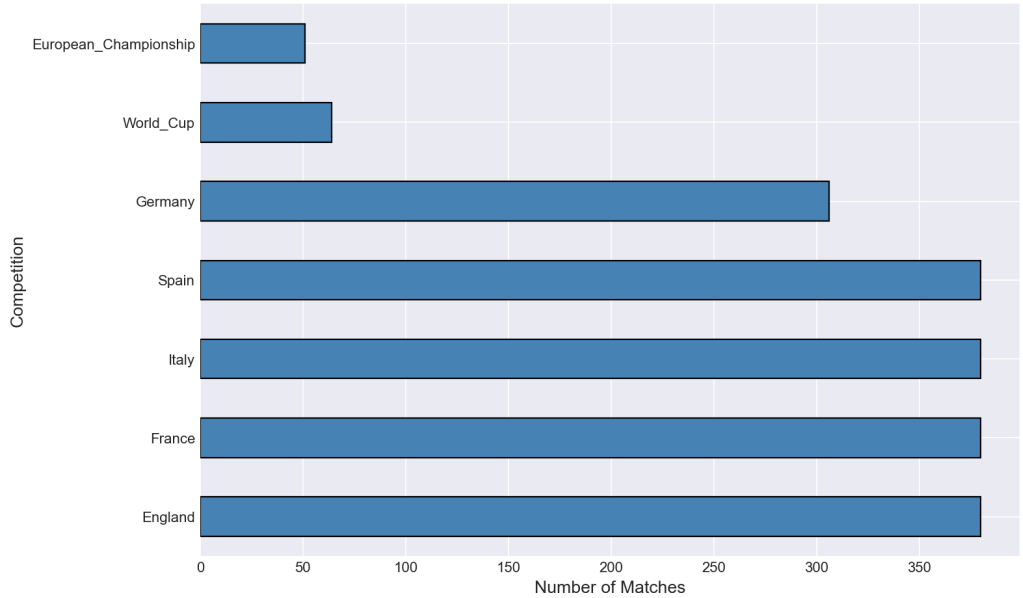

Abbildung 1.1: Anzahl der Spiele pro Wettbewerb. Sowohl Liga-Wettbewerbe wie auch internationale Turniere

Der Datensatz umfasst mehrere europäische Top-Ligen sowie internationale Turniere. Abbildung 1.1 zeigt die Verteilung der Spiele über die Wettbewerbe. Unterschiede in der Spielanzahl spiegeln Ligaformate (z. B. 38 Spieltage) und Turnierlängen wider.

Ergänzend zeigt Abbildung 1.2 die Anzahl der Ereignisse pro Wettbewerb. Erwartungsgemäss skaliert die Eventanzahl stark mit der Anzahl Spiele. Die Liga-Wettbewerbe (England, Spanien, Frankreich, Italien) weisen jeweils ca. 650,000 Events auf (ca. 1,710 Events pro Match), während Deutschland mit ca. 530,000 Events (ca. 1,730 Events/Match) und die Turniere World Cup und European Championship mit ca. 130,000 bzw. 100,000 Events eine geringere Gesamtzahl aufweisen. Dies bildet eine robuste Basis für detaillierte Netzwerkanalysen.

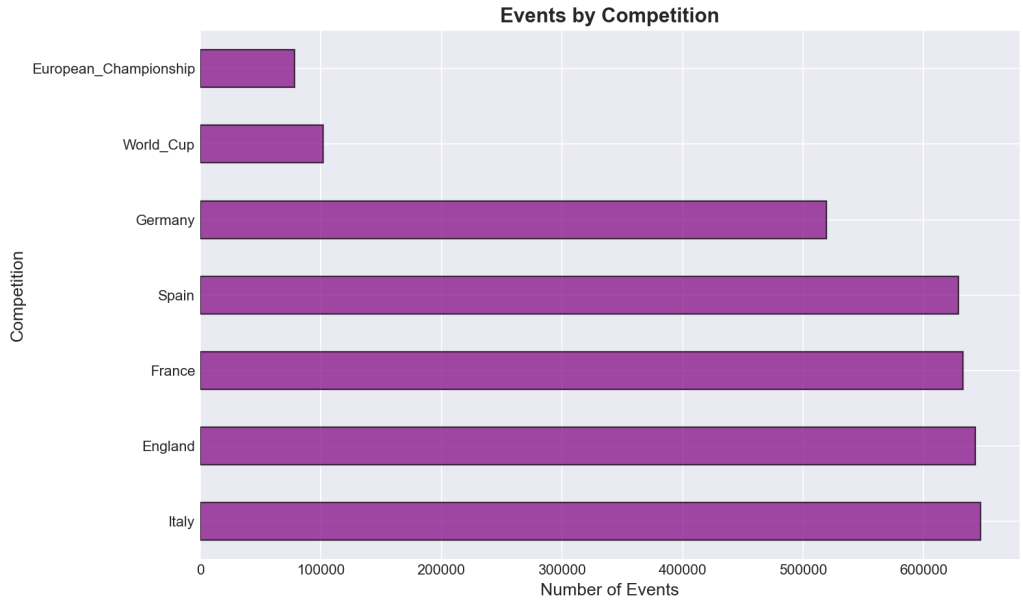

Abbildung 1.2: Anzahl der Events pro Wettbewerb. Stark abhängig vom Format des Turniers.

Zur Veranschaulichung der Match-Metadaten zeigt Tabelle 1.1 eine zufällige Stichprobe von 5 Spielen (`df.sample(5)` auf dem Match-DataFrame):

1.4 Ereignisse: Typen und zeitliche Muster

Die Event-Typen sind über IDs und Labels definiert; Tabelle 1.2 dokumentiert diese Zuordnung und dient in späteren Kapiteln als Referenz für Filter und Aggregationen.

Die Analyse der Ereignistypen in Abbildung 1.3 zeigt erwartungsgemäss, dass Pässe die häufigste Aktion darstellen, gefolgt von Duellen und Ballkontakten. Diese Dominanz von Passereignissen motiviert den den Schwerpunkt in der analyse später auf ein Passnetzwerke zu legen.

Die zeitliche Verteilung der Ereignisse über den Spielverlauf (Abbildung 1.4) zeigt erhöhte Aktivität zu Beginn beider Halbzeiten sowie einen Abfall gegen Ende der Halbzeiten.

Auf aggregierter Ebene ist die Datenabdeckung über die reguläre Spielzeit ausgeglichen: Abbildung 1.5 zeigt nahezu identische Event-Zahlen in der ersten und zweiten Halbzeit (je ca. 1.62×10^6 Events).

Für Passereignisse zeigt sich jedoch ein leichter Halbzeiteffekt (Abbildung 1.6): In der ersten Halbzeit werden mehr Pässe gespielt, die Passgenauigkeit ist minimal höher (82.99% vs. 82.06%) und die durchschnittliche Passdistanz praktisch unverändert (24.69 vs. 24.54). Dies passt zu Effekten wie Ermüdung, Spielstandmanagement oder erhöhtem Druck in Halbzeit 2.

Team 1	Team 2	Score	Date	Venue	Duration
Huddersfield Town	Crystal Palace	0 - 2	March 17, 2018 at 4:00:00 PM GMT+1	The John Smith's Stadium	Regular
Manchester United	Crystal Palace	4 - 0	Sept 30, 2017 at 4:00:00 PM GMT+2	Old Trafford	Regular
Everton	Southampton	1 - 1	May 5, 2018 at 6:30:00 PM GMT+2	Goodison Park	Regular
Everton	Manchester United	0 - 2	Jan 1, 2018 at 6:30:00 PM GMT+1	Goodison Park	Regular
Stoke City	Liverpool	0 - 3	Nov 29, 2017 at 9:00:00 PM GMT+1	Bet365 Stadium	Regular

Tabelle 1.1: Beispiele von 5 zufällig ausgewählten Spielen aus dem Gesamtdatensatz mit Spielbezeichnung, Datum, Austragungsort und Spieldauer.

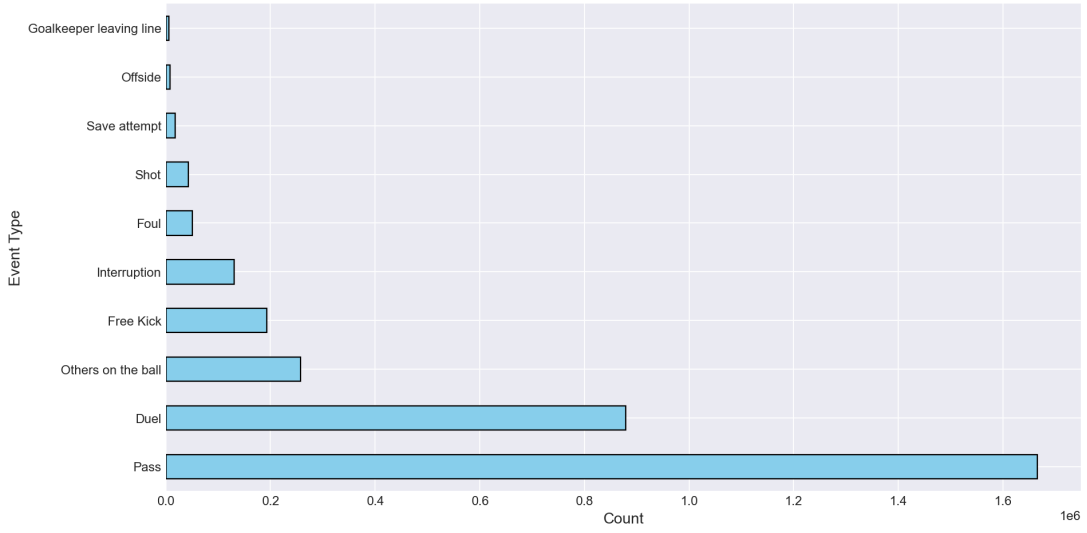

Abbildung 1.3: Top 15 Ereignistypen über alle Wettbewerbe. Pässe dominieren klar das Spielgeschehen.

	event	subevent	event_label	subevent_label
0	1	10	Duel	Air duel
1	1	11	Duel	Ground attacking duel
2	1	12	Duel	Ground defending duel
3	1	13	Duel	Ground loose ball duel
4	2	20	Foul	Foul
5	2	21	Foul	Hand foul
6	2	22	Foul	Late card foul
7	2	23	Foul	Out of game foul
8	2	24	Foul	Protest
9	2	25	Foul	Simulation
10	2	26	Foul	Time lost foul
11	2	27	Foul	Violent Foul
12	3	30	Free Kick	Corner
13	3	31	Free Kick	Free Kick
14	3	32	Free Kick	Free kick cross
15	3	33	Free Kick	Free kick shot
16	3	34	Free Kick	Goal kick
17	3	35	Free Kick	Penalty
18	3	36	Free Kick	Throw in
19	4	40	Goalkeeper leaving line	Goalkeeper leaving line
20	5	50	Interruption	Ball out of the field
21	5	51	Interruption	Whistle
22	6	60	Offside	Offside
23	7	70	Others on the ball	Acceleration
24	7	71	Others on the ball	Clearance
25	7	72	Others on the ball	Touch
26	8	80	Pass	Cross
27	8	81	Pass	Hand pass
28	8	82	Pass	Head pass
29	8	83	Pass	High pass
30	8	84	Pass	Launch
31	8	85	Pass	Simple pass
32	8	86	Pass	Smart pass
33	9	90	Save attempt	Reflexes
34	9	91	Save attempt	Save attempt
35	10	100	Shot	Shot

Tabelle 1.2: Vollständige Übersicht der Ereignistypen und Subtypen im Datensatz. Die Spalten geben die Event-ID und Subevent-ID sowie deren sprachliche Bezeichnung an.

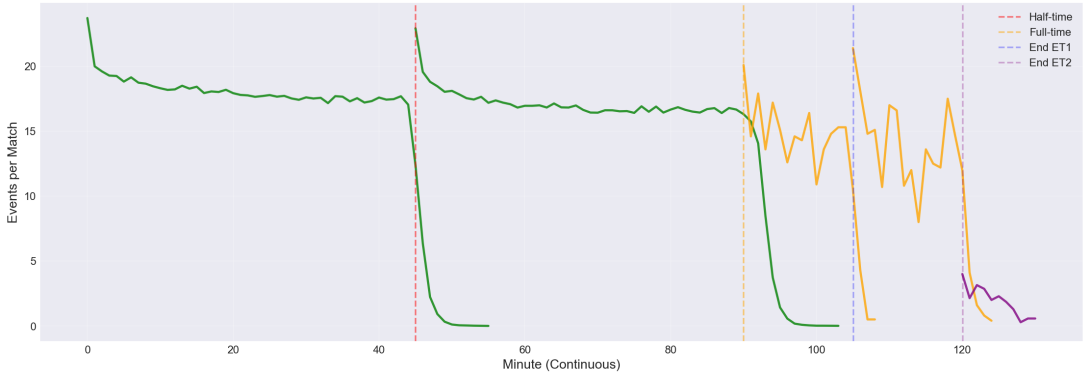

Abbildung 1.4: Ereignisse pro Spielminute. Deutlich erkennbar sind erhöhte Aktivität zu Spielbeginn und der Rückgang in der Schlussphase.

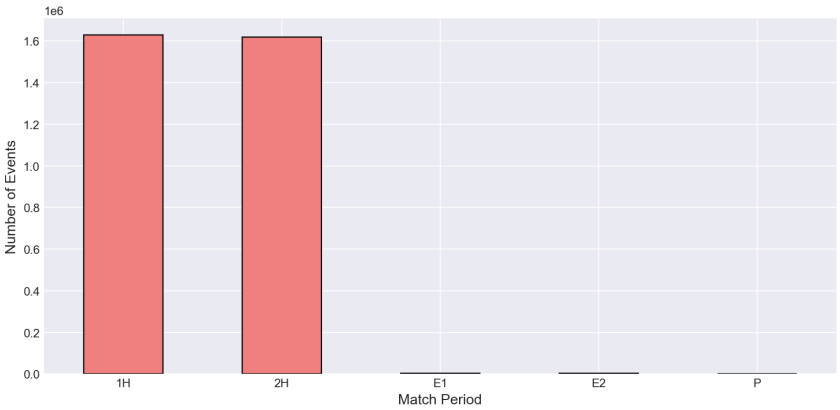

Abbildung 1.5: Events nach Spielperiode. In der vorliegenden Auswertung sind beide **H**albzeiten mit je über 1.62×10^6 Events nahezu gleich stark vertreten. **E**xtended 1 / 2 sowie **P**enaly kommen bedeutend seltener vor (10 / 10 / 7)

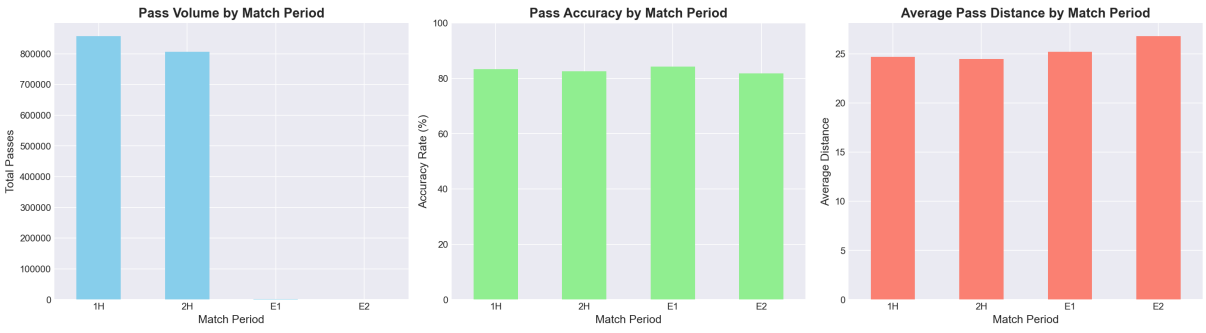

Abbildung 1.6: Passvolumen, Passgenauigkeit und durchschnittliche Passdistanz nach Matchperiode. In dieser Auswertung werden in Halbzeit 1 mehr Pässe gespielt (+7.4%), bei sehr ähnlicher Genauigkeit und Distanz.

Während der Verlängerungsphasen ist eine Zunahme der Passlänge bei gleichzeitig abnehmender Genauigkeit zu verzeichnen. Diese Verhaltensweise lässt sich durch eine aggressivere Spielweise erklären, mit der versucht wird, ein Penalty-Szenario zu vermeiden. Ausserdem wird mit diesen Pässen hauptsächlich das Ziel verfolgt, Fehler zu vermeiden, indem eine möglichst grosse Distanz zum eigenen Tor geschaffen wird (A. Scheifele, persönliche Kommunikation, 30. Dezember 2025).

1.5 Pass-Analyse: Zentrale Akteure und räumliche Verteilung

Pässe bilden neben Teams & Spielen das Rückgrat der späteren Netzwerkanalyse. Abbildung 1.7 identifiziert die aktivsten Passgeber. Diese Spieler sind Kandidaten für zentrale Knoten (hohe Degree- und Betweennesszentralität), da sie als Verteiler im Spielaufbau fungieren.

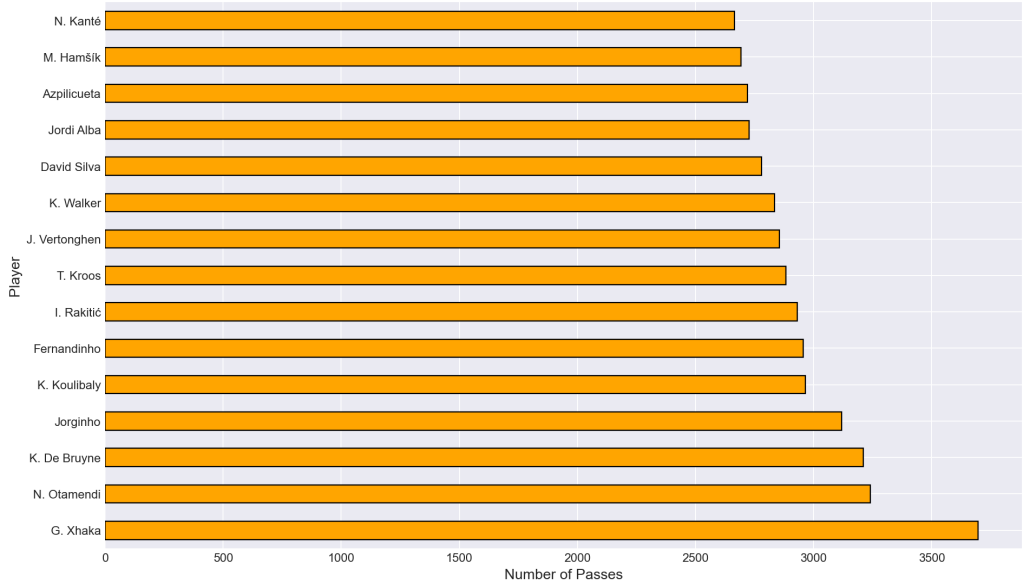

Abbildung 1.7: Top 15 Spieler nach Anzahl der Pässe. Diese Spieler sind später als zentrale Knoten in den Passnetzwerken zu erwarten.

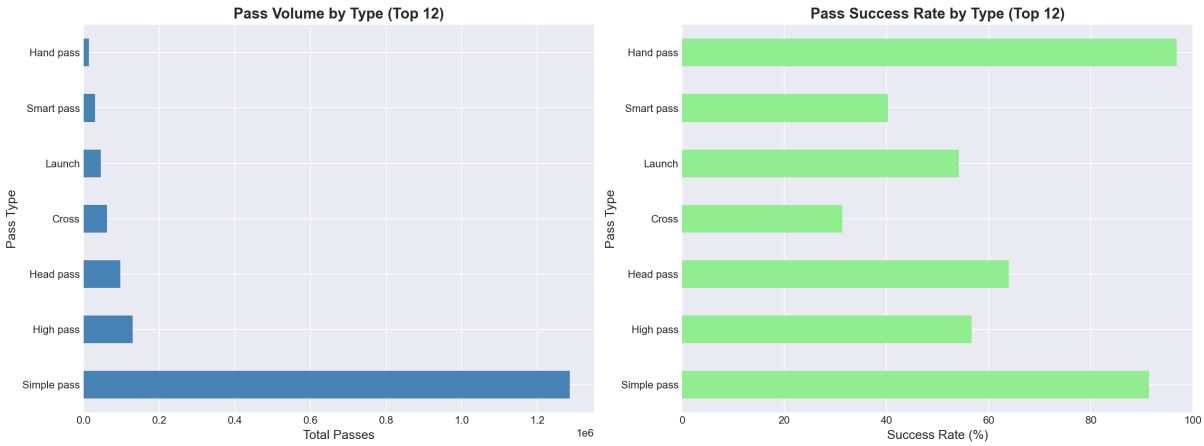

Abbildung 1.8: Passvolumen (links) und Passgenauigkeit (rechts) nach Passtyp. Einfache Pässe dominieren das Volumen bei hoher Genauigkeit; Flanken und Smart Passes sind seltener und deutlich ungenauer. Handpässe verzeichnen aufgrund der manuellen Ballkontrolle und ihrer exklusiven Anwendung durch den Torhüter die höchste Präzision.

Sowohl räumlichen Mustern als auch die Struktur nach Passtyp sind zentral für die Interpretation von Netzwerkkanten: Abbildung 1.8 zeigt, dass einfache Pässe den Grossteil des Volumens ausmachen (ca. 76% aller Pässe) und zugleich eine sehr hohe Genauigkeit aufweisen ($> 91\%$). Risikoreichere Pässe (Flanken, Smart Passes) treten seltener auf und haben deutlich niedrigere Erfolgsraten (z. B. Flanken ca. 30.71%). Für die spätere Netzwerkanalyse von Passlängen bedeutet dies: Gewichte werden stark durch kurze, sichere Verbindungen dominiert, während wenige riskante Kanten eher spielentscheidende Situationen abbilden.

Eine detaillierte räumliche Analyse der Pässe (Abbildung 1.9) liefert mehrere wichtige Erkenntnisse:

- Die **Passlängenverteilung** (oben links) zeigt eine rechtssteile Verteilung mit Median bei ca. 15 Einheiten, was kurzen bis mittellangen Pässen entspricht. Lange Bälle sind seltener.
- Die **Passlängen nach Typ** (oben rechts) verdeutlichen erwartbare Unterschiede: Lange Bälle und Flanken weisen deutlich grössere Distanzen auf als einfache Zuspiele.
- Die **Heatmaps** (unten) für Pass-Ursprung und -Ziel zeigen die räumliche Konzentration: Viele Pässe starten und enden im Mittelfeld sowie in defensiven Bereichen, während Pässe im gegnerischen Strafraum seltener sind.

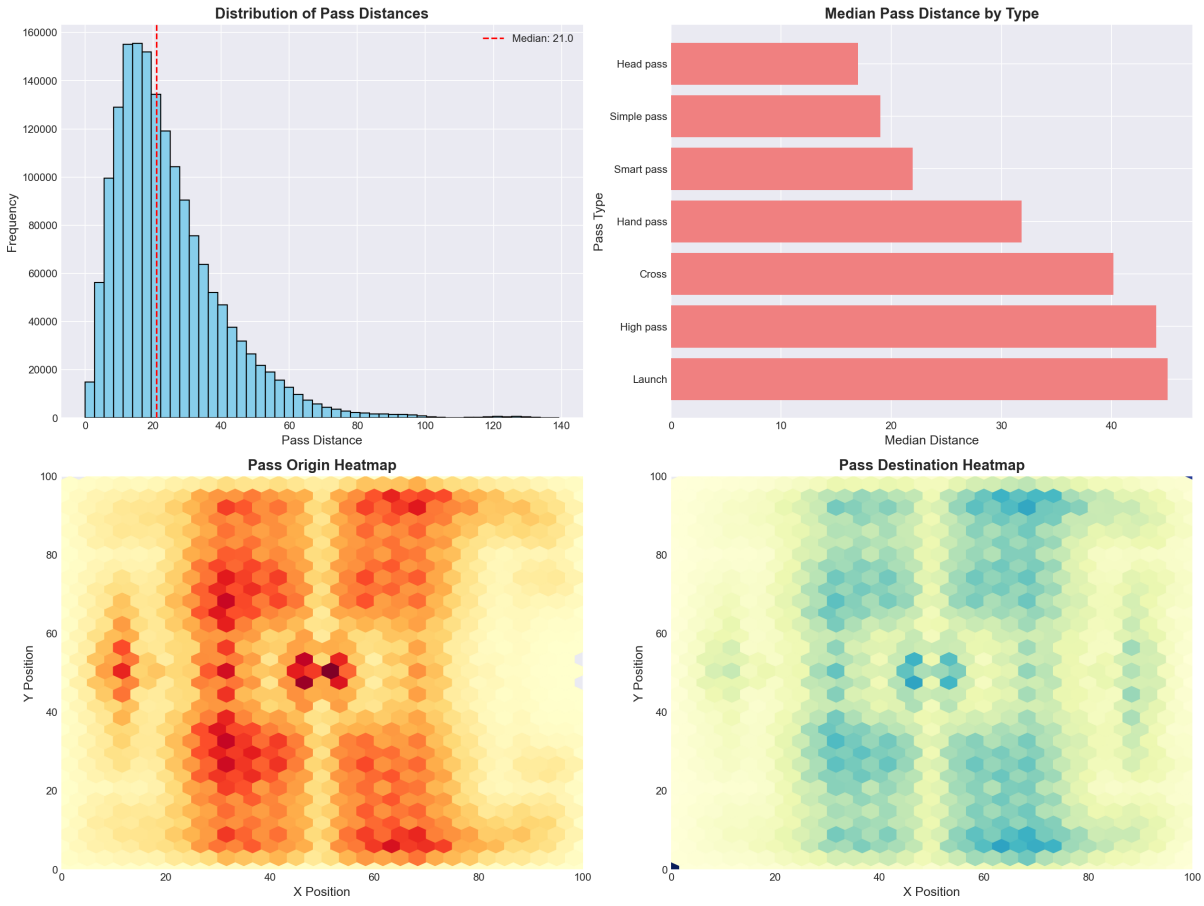

Abbildung 1.9: Umfassende Analyse der Passeigenschaften. **Oben links:** Verteilung der Passlängen mit Median-Markierung. **Oben rechts:** Median-Passlänge nach Passtyp (z. B. lange Bälle vs. kurze Zuspiels). **Unten:** Heatmaps für Pass-Ursprung (links) und Pass-Ziel (rechts), visualisiert auf normalisierten Spielfeldkoordinaten.

Abbildung 1.10 illustriert die Rolleninterpretation einfacher Zentralitätskonzepte (Degreezentralität in diesem Fall) in einem Beispielspiel: Spieler oberhalb der Diagonalen erhalten mehr

Pässe als sie spielen (Zielspieler), Spieler unterhalb verteilen mehr (Aufbauspieler), und Spieler nahe der Diagonalen sind ausgeglichen. Generell können wir erkennen: wer mehr Pässe bekommt, vergibt auch mehr.

Abbildung 1.10: Passverhältniss in einem Sample-Match: (links) Top-10 Spieler nach Passvolumen (gespielt vs. empfangen), (rechts) Out-Degree vs. In-Degree mit Referenzlinie $y = x$ zur Rolleninterpretation.

Um die spätere Netzwerkkonstruktion zu illustrieren, zeigt Tabelle 1.3 einen Ausschnitt aus einem berechneten Passnetzwerk eines Beispielspiels (Match-ID 2500004). Die Kanten sind Passverbindungen, gewichtet nach *pass_count*; zusätzlich ist die mittlere Passdistanz angegeben.

	passer_id	receiver_id	pass_count	avg_distance	passer_name	receiver_name
0	3324	8625.000000	1	4.123106	Álvaro Morata	V. Moses
1	3350	3324.000000	1	13.038405	Fàbregas	Álvaro Morata
2	3350	3360.000000	6	20.523277	Fàbregas	Pedro
3	3350	3429.000000	3	25.654240	Fàbregas	T. Courtois
4	3350	8032.000000	1	26.627054	Fàbregas	Marcos Alonso
5	3350	8495.000000	3	12.648930	Fàbregas	D. Drinkwater
6	3350	8625.000000	2	21.530491	Fàbregas	V. Moses
7	3350	14748.000000	3	9.815600	Fàbregas	A. Rüdiger
8	3350	25553.000000	9	18.920233	Fàbregas	Azpilicueta
9	3350	25707.000000	1	17.804494	Fàbregas	E. Hazard

Tabelle 1.3: Ausschnitt eines Passnetzwerks: erste 10 Passverbindungen eines Beispielspiels (Match-ID 2500004) mit Anzahl der Pässe, mittlerer Distanz und Spielernamen.

1.6 Wettbewerbsvergleich

Die aggregierten Pass-Statistiken nach Wettbewerb (Abbildung 1.11) ermöglichen einen direkten Vergleich der Spielstile: Volumen (Anzahl der Pässe), Genauigkeit (Erfolgsquote) und durchschnittliche Passlänge variieren zwischen den Ligen und Turnieren. Solche Unterschiede können auf taktische Präferenzen, Spieltempo oder die Qualität der Teams hindeuten und werden sich in den strukturellen Eigenschaften der daraus generierten Netzwerke widerspiegeln.

Auf Basis der vorliegenden Wettbewerbsauswertung liegt die Passgenauigkeit der englischen Liga bei ca. 82.5% (Abbildung 1.11), was im professionellen Fussball ein typischer Wert ist (etwa 4 von 5 Pässen kommen an) (FotMob.com, n. d.).

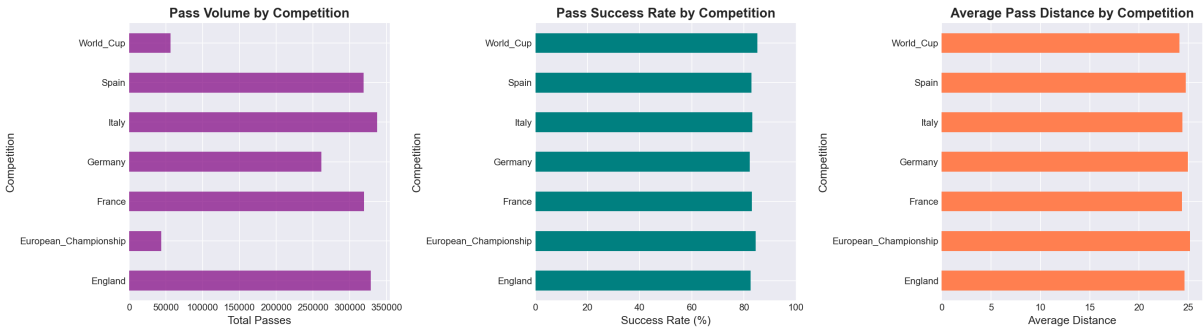

Abbildung 1.11: Pass-Statistiken nach Wettbewerb: Volumen, Genauigkeit und durchschnittliche Distanz. Unterschiede deuten auf verschiedene Spielstile und taktische Ansätze hin.

1.7 Erste Hypothesen für die Netzwerk-Analyse

Basierend auf den EDA-Ergebnissen lassen sich folgende Hypothesen für die nachfolgenden Netzwerkanalysen:

1. **Zentrale Knoten:** Die identifizierten Top-Passgeber werden hohe Degree-Zentralität und Betweenness-Zentralität aufweisen, da sie als Verteiler im Spielaufbau fungieren.
2. **Räumliche Cluster:** Die Heatmaps deuten auf räumliche Cluster hin (Abwehr, Mittelfeld, Angriff), die sich in Communitystrukturen der Netzwerke widerspiegeln könnten.
3. **Wettbewerbsspezifische Unterschiede:** Ligen mit höherer Pass-Genauigkeit und kürzeren Pässen könnten dichtere Netzwerke mit mehr reziproken Verbindungen aufweisen.
4. **Zeitliche Dynamik:** Die beobachteten Aktivitätsmuster über den Spielverlauf legen nahe, dass sich Netzwerkmetriken (z. B. Dichte, Zentralisierung) zwischen den Spielphasen unterscheiden.

2 LE3 – Netzwerk-Modellierung & Filterung

Dieses Kapitel dokumentiert die Konstruktion verschiedener Netzwerktypen aus den Fussballdaten sowie die angewandten Filterungstechniken zur Netzwerkreduktion. Basierend auf den Erkenntnissen aus dem EDA erstellen wir vier Netzwerke: Pass-Netzwerke (Spieler–Spieler), Match-Netzwerke (Team–Team), bipartite Spieler–Team-Netzwerke sowie ein Feld-Lokationsnetzwerk (Zone–Zone). Da es in diesem Datensatz eine vielzahl verschiedener Netzwerke gibt, wählen wir immer eines aus um die anwendung zu demonstrieren.

2.1 Netzwerkmodellierung

2.1.1 Netzwerke

Fussball ist sehr komplex und vielschichtig. Um eine angemessene Mischung aus Aufwand und Abdeckung zu erreichen, haben wir uns dazu entschlossen, vier Netzwerktopologien zu modellieren, die unterschiedliche Aspekte des Spielgeschehens abdecken und verschiedene Analysen ermöglichen.

Pass-Netzwerk (Spieler–Spieler)
Typ: gerichtet, gewichtet.

Knoten: Spieler (`wyId`).

Kanten: gerichtete Kante (u, v), wenn Spieler u einen Pass zu Spieler v spielt. Hauptgewicht ist `pass_count`.

Konstruktion: Wyscout liefert leider keinen expliziten Passempfänger. Wir bestimmen ihn daher über ein Raum-zeitliches Matching: zur Pass-Endposition suchen wir im selben Team die nächste Aktion innerhalb von 5 Sekunden und 10 Metern. Der nächstgelegene Kandidat wird als Empfänger gewählt. Das ist sehr robust, kann aber zu Fehlzuordnungen führen wenn z.B ein Foul direkt nach einem Pass passiert, oder sonst sehr schnellen Sequenzen / quasi gleichzeitigen Aktionen geschehen.

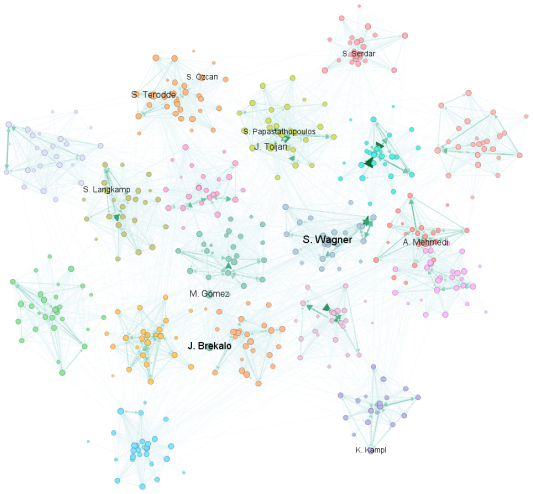

Abbildung 2.1: Pass-Netzwerk. Knoten = Spieler, gerichtete Kanten = Pässe, Breite typischerweise proportional zu `pass_count`.

Match-Netzwerk (Team–Team)

Typ: gerichtet, gewichtet.

Knoten: Teams.

Kanten: je Spiel erzeugen wir zwei gerichtete Kanten $(A \to B)$ und $(B \to A)$; das Kantengewicht entspricht den erzielten Toren (Aggregationen über mehrere Spiele werden summiert).

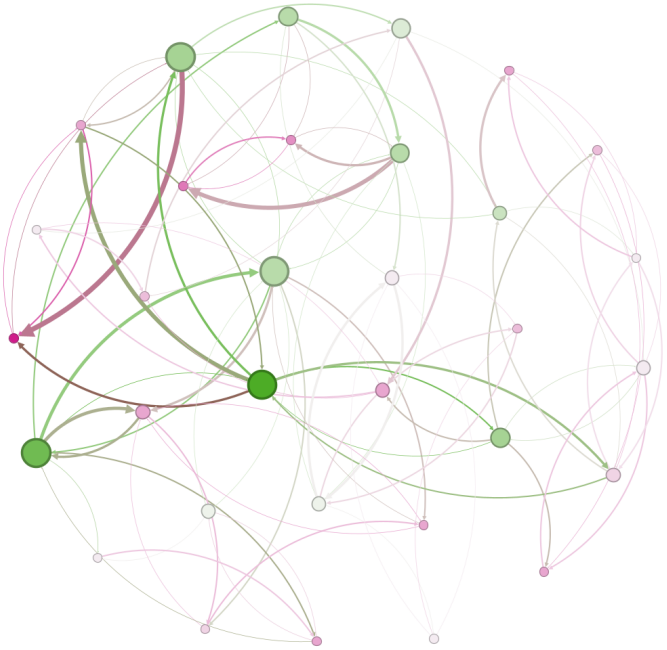

Abbildung 2.2: Match-Netzwerk (Beispiel). Knoten = Teams, Kanten = aggregierte Resultate zwischen Team-Paaren.

Spieler–Team-Netzwerk (Two-Mode)

Typ: bipartit, ungerichtet, gewichtet. **Knoten:** Spieler P und Teams T. **Kanten:** Kante (p, t), wenn Spieler p in einem Match für Team t auflief; Gewicht `matches_together` zählt Einsätze/-Matchbeteiligungen.

Beobachtung: Spieler sind typischerweise mit **einem** Team stark verbunden. Ausgeprägte Verindungen mit zwei Teams treten nur bei Teamwechseln innerhalb der Saison auf (z.B. Sandro Wagner, TSG Hoffenheim -> Bayern München (transfermarkt.ch, n. d.))

Flattening: Projektion auf Spieler Wir projizieren das bipartite Spieler-Team Netz auf die Spielermenge: zwei Spieler sind verbunden, wenn sie mindestens ein Team teilen; das Kantengewicht steigt mit der Anzahl gemeinsamer Einsätze . Dadurch entsteht ein Spieler–Spieler-Netz, das Teambeziehungen und transfers sichtbar macht.

Feld-Lokationsnetzwerk (Zone–Zone)

Typ: gerichtet, Multi-Edge.

Knoten: diskrete Feldzonen (5×5m Raster, Wyscout-Koordinaten 0–100).

Kanten: Ereignisübergänge von Start- zu Endzone für Pass (8), Schuss (10) und Standards (3). Dieses Netz dient als räumliche Perspektive auf Spielmuster.

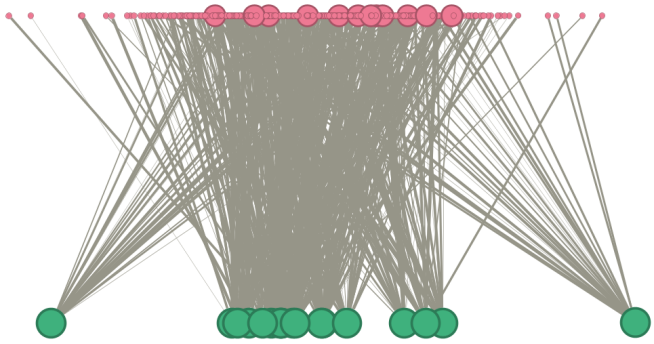

Abbildung 2.3: Player–Team Two-Mode Netzwerk (vor Flattening). Spieler sind typischerweise einem Team zugeordnet (zwei bei Teamwechsel); Kantenbreite kodiert `matches_together`.

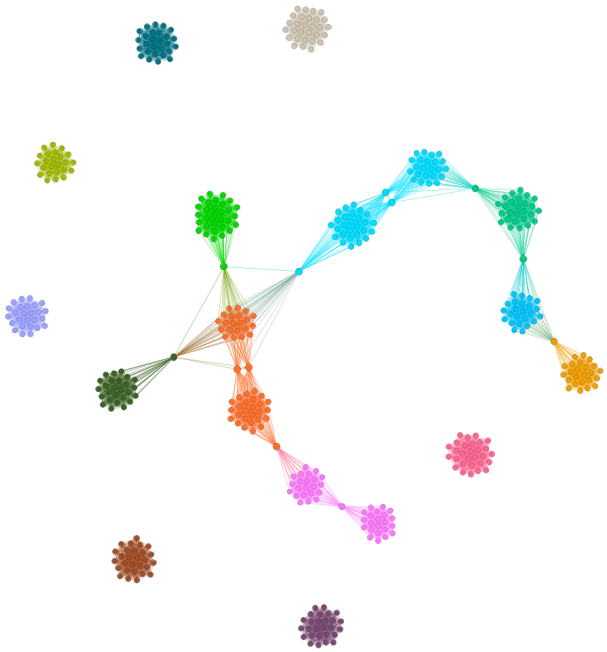

Abbildung 2.4: Player–Player Netzwerk (nach Flattening / Projektion). Eine Kante entsteht durch gemeinsames Team; Gewichte akkumulieren gemeinsame Einsätze.

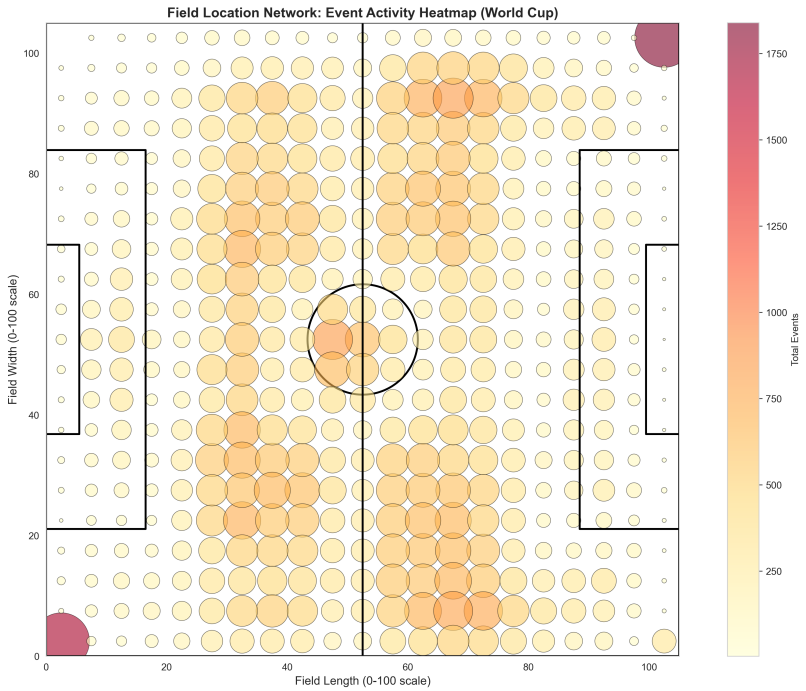

Abbildung 2.5: Feld-Lokationsnetzwerk als Heatmap. Farbe/Grösse kodieren Ereignisintensität in diskreten Feldzonen.

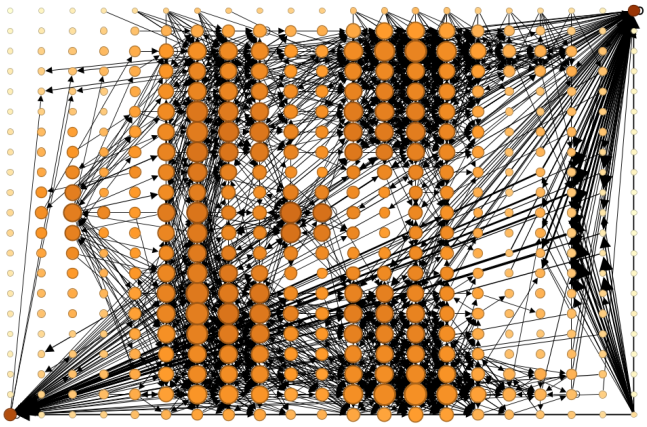

Abbildung 2.6: Pass-Feld-Lokationsnetzwerk der Bundesliga. Knoten & Kantengrösse kodiert für Anzahl Pässe, Knotenfarbe für Grad und Kantenfarbe für Distanz

2.2 Netzwerkfilterung

In diesem Kapitel beschreiben wir, wie wir Filterung und Sichten (Local/Global/Ego) einsetzen, um aus grossen Netzwerken analysierbare Teilstrukturen zu extrahieren. Der Fokus liegt auf der praktischen Nutzung: welche Fragen lassen sich damit beantworten, und welche Visualisierungen stützen die Interpretation.

2.2.1 Sichten: Local View, Global View, Ego-Netzwerk

Local View

Mit der Local view nach Team können wir einen Team-Subgraph aus dem Pass-Netzwerk extrahieren. Damit können wir später untersuchen, ob z.B. die Stärke und Zentralisierung der teaminternen Verknüpfungen mit sportlichem Erfolgen korreliert

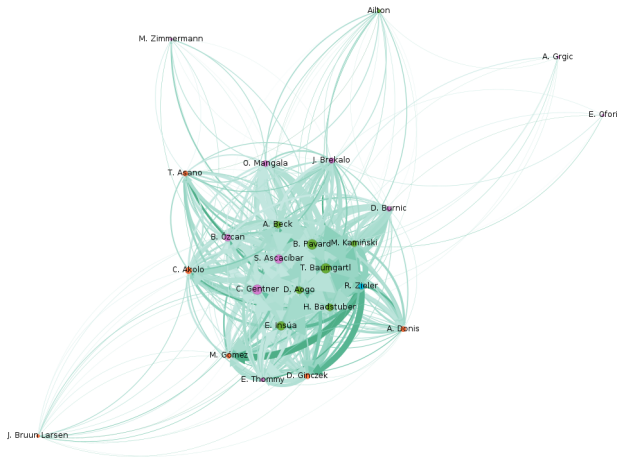

Abbildung 2.7: Local View des Stuttgard-Subgraphen

Global View

Mit der Global view betrachten wir das komplette Netzwerk eines Wettbewerbs , lassen aber Details weg. Sie dient dem Vergleich zwischen Competitions oder zur Einordnung von Extremwerten.).

Tabelle 2.1: Übersicht der konstruierten Netzwerke (Bundesliga; aus `.gexf` berechnet)

Netzwerktyp	|V|	|E|	Dichte	Komponenten
Pass-Netzwerk	473	8786	0.039354	8
Match-Netzwerk	18	306	1.000000	1
Spieler-Team-Netzwerk	492	503	0.004164	1
Spieler-Projektion	474	6803	0.060686	1

Ego-Netzwerk

Mit dem Ego-Netzwerke isolieren wir die unmittelbare Umgebung eines Spielers (Ego). Sie

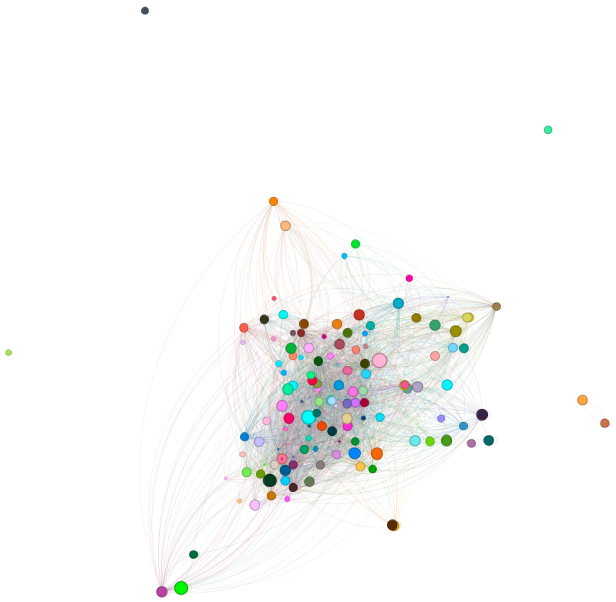

Abbildung 2.8: Global view des unified pass Networks (alle liegennetzwerke in einem Graph), Nodes zusammengeasst nach Team

sind sind hilfreich, um Rollen im Teamkontext zu interpretieren oder konkrete Passpartner-Strukturen zu visualisieren.

2.2.2 Filtern anhand von Kantenattributen

Wir setzen Kantenattribut-Filter ein, um „Rauschen“ zu reduzieren und stabilere Beziehungen hervorzuheben. Im Pass-Netzwerk ist das zentrale Filterkriterium typischerweise `pass_count` (Mindestanzahl Pässe pro Kante); optional sind Filter nach Genauigkeit oder Distanz sinnvoll.

Für die Bundesliga zeigt die gewichtsbasierte Filterung (nach Entfernen isolierter Knoten) z.B.:

- $w \geq 5$: 91.1% Knoten, 71.9% Kanten erhalten
- $w \geq 10$: 85.6% Knoten, 56.2% Kanten erhalten
- $w \geq 20$: 76.7% Knoten, 36.8% Kanten erhalten

Abbildung 2.9: Ego-Netzwerk von Granit Xhaka. Wir sehen das er sowohl mit dem FC Arsenal, wie auch der Schweizer Nationalmannschaft gut verknüpft ist.

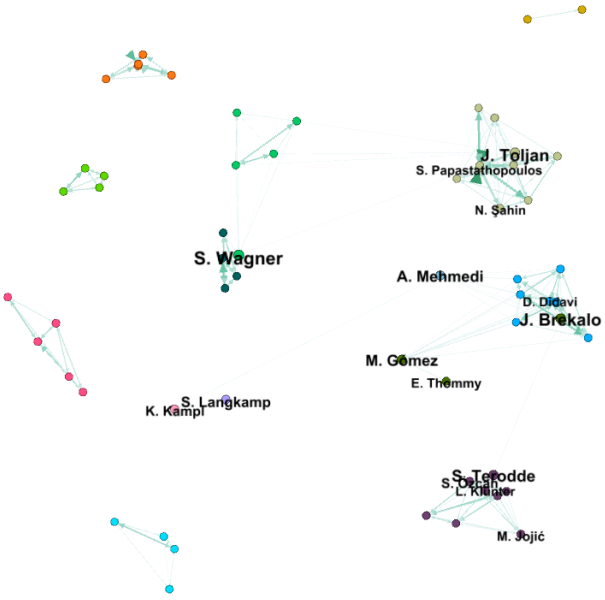

Abbildung 2.10: Filterung nach Kantenattribut

3 LE4 – Communities

In diesem Kapitel untersuchen wir, welche Untergruppen wir in unseren wyscouts Fussball Netzwerken identifizieren können. Wir beschränken uns auf Das Netzwerk für die Bundesliga sowie auf den Worldcup.
Wir betrachten drei Aspekte: (1) **Connected Components** als grundlegende Zusammenhangsstruktur, (2) **Cliquen** als maximale vollständig vernetzte Gruppen und (3) **Community Detection** zur Identifikation von dichter verbundenen, aber nicht notwendigerweise vollständig vernetzten Gruppen.

Im Kontext von Fussball erwarten wir:

- **Pass-Netzwerke**: Teams als Communities; Spielformationen als dichtere Substrukturen
- **Match-Netzwerke**: Turniergruppen
- **Feld-Netzwerke**: Cluster von Verteidigungs und Angrifsfeldern.

3.1 Connected Components

Connected Components beschreiben die grundlegende Zusammenhangsstruktur eines Netzwerks: Gruppen von Knoten, die über Pfade erreichbar sind, aber untereinander nicht verbunden sind.

Pass-Netzwerk (Deutschland)
Das Pass-Netzwerk 3.1 zeigt eine vollständig zusammenhängende Struktur:

- **1 zusammenhängende Komponente**: Alle 473 Knoten (100% des Netzwerks) sind verbunden
- **Interpretation**: Die gesamte Liga ist über Passverbindungen vernetzt – entweder direkt innerhalb von Teams oder indirekt über Spielertransfers und Team-übergreifende Pässe (z.B. nach Ballverlusten)

Match-Netzwerk (World Cup)
Match-Netzwerke sind aufgrund der Turnierstruktur typischerweise stark verbunden:

- **1 starke Komponente**: Alle 32 Teams sind über gerichtete Pfade erreichbar
- **Interpretation**: Das Turnier-Format (Gruppenphase + K.O.-Runden) garantiert einen zusammenhängenden Graphen; jedes Team spielt mindestens 3 Spiele

Praktische Bedeutung: Für Community Detection verwenden wir primär die grösste zusammenhängende Komponente, da isolierte Knoten keine sinnvollen Community-Zuordnungen erlauben.

3.2 Cliquen und dichte Subgraphen

Cliquen sind maximale vollständig vernetzte Untergruppen: jeder Knoten ist mit jedem anderen direkt verbunden. Im Fussball sind echte Cliquen selten (nicht jeder Spieler passt zu jedem), daher betrachten wir auch relaxierte Varianten.

3.2.1 Maximale Cliquen

Pass-Netzwerk (Deutschland)
Grösste Cliquen: 4–5 Knoten (Spieler). Diese entsprechen typischerweise engen Passdreieck/-vierecken innerhalb eines Teams (z.B. Innenverteidiger + zentrales Mittelfeld).

Anzahl maximaler Cliquen: Sehr hoch (Hunderte), da viele lokale, überlappende Passdreiecke existieren. Die meisten haben Grösse 3 (Dreiecke), einige wenige erreichen 4–5.

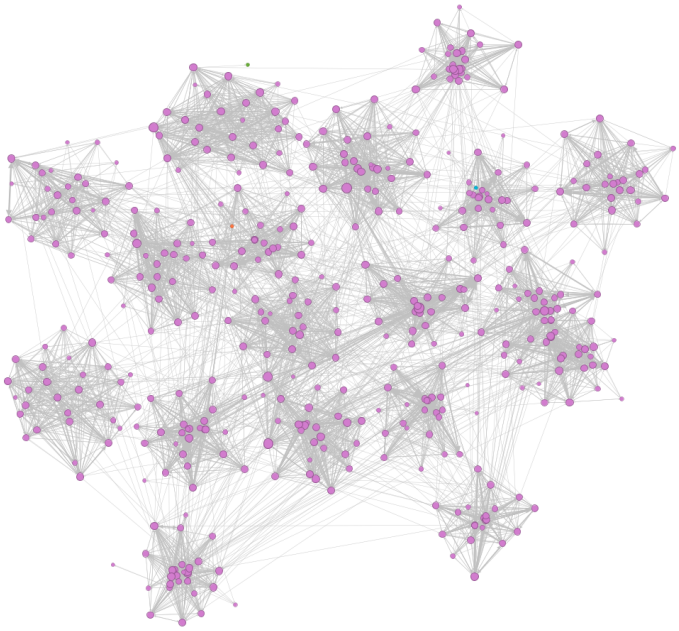

Abbildung 3.1: Connected Components im Pass-Netzwerk (Deutschland). Das gesamte Netzwerk bildet eine zusammenhängende Komponente mit 473 Knoten (100% des Netzwerks)

Match-Netzwerk (World Cup)
Grösste Cliquen: Bis zu 4 Knoten (Teams). Dies entspricht vollständig vernetzten Vierergruppen in der WM-Vorrunde: jedes Team spielt gegen jedes andere in der Gruppe.

Interpretation: Die Cliquen-Grösse 4 reflektiert direkt die Gruppenstruktur (4 Teams pro Gruppe). K.O.-Spiele erzeugen keine grösseren Cliquen, da nicht alle möglichen Paarungen gespielt werden.

3.2.2 k-Core Dekomposition

Der k-Core ist der maximale Subgraph, in dem jeder Knoten mindestens Grad k hat. Diese Zerlegung identifiziert zunehmend dichter vernetzte „Kerne“ im Netzwerk.

Pass-Netzwerk (Deutschland, grösste Komponente)

- **Maximaler Core:** Hoch, entsprechend der dichten Team-internen Passstrukturen
- **Interpretation:** Die höchsten Cores entsprechen typischerweise Spielern eines einzelnen Teams mit intensiven Passbeziehungen
- **Core-Verteilung:** Die Netzwerkdichte von 0.047 zeigt moderate Vernetzung über Team-Grenzen hinweg

Match-Netzwerk (World Cup)

- **Maximaler Core:** $k = 4$
- **Interpretation:** Alle Teams sind nur mit ihren Gruppe gut verknüpft.

Vergleich zu Cliquen: Während Cliquen vollständige Vernetzung fordern, erlaubt der k-Core Flexibilität: Knoten müssen nur mindestens k Verbindungen haben, nicht zu allen anderen.

3.3 Community Detection

Community Detection identifiziert Gruppen mit hoher interner und niedriger externer Vernetzung. Anders als Cliquen müssen Communities nicht vollständig vernetzt sein. Wir vergleichen vier Algorithmen: Louvain Algorythmus, Labelpropagation, Fast-Greedy (Clauset-Newman-Moore, Clauset et al., 2004) sowie Edge-Betweenes (Girvan-Newman).

3.3.1 Algorithmen im Überblick

1. Louvain-Methode

Ein hierarchischer, gieriger Algorithmus zur **Maximierung der Modularität**.

Laufzeit: typischerweise $O(m)$ bis $O(n \log n)$ (implementations- und datenabhängig).

- Gut skalierbar
- Resultate können je nach Implementierung leicht variieren
- Liefert eine hierarchische Community-Struktur

2. Label Propagation

Ein iterativer Algorithmus, bei dem Knoten das häufigste Nachbarschaftslabel übernehmen, bis Konvergenz erreicht ist.

Laufzeit: typischerweise $O(m)$ pro Durchlauf; Gesamtaufwand abhängig von der Anzahl Iterationen.

Verhalten/Eigenschaften:

- Extrem schnell
- häufig nicht-deterministisch
- Keine direkte Optimierung einer globalen Zielfunktion.

3. Greedy Modularity (Clauset–Newman–Moore)

Ein agglomeratives Verfahren, das Communities iterativ so zusammenführt, dass die **Modularität** am stärksten steigt.

Laufzeit: klassisch $O(md \log n)$ (mit d als mittlerem Grad).

- Deterministisch bei fixer Tie-Breaking-Strategie.
- Liefert ein hierarchisches Merge-Dendrogram.
- Gute Qualität auf vielen Netzwerken, aber weniger skalierbar als Louvain bei sehr grossen Graphen

4. Girvan–Newman (Edge Betweenness)

Ein divisiver Algorithmus, der iterativ Kanten mit hoher Edge-Betweenness entfernt und so Communities separiert.

Laufzeit: typischerweise $O(m^2 n)$ (je nach Implementierung/Variante).

- Sehr rechenintensiv
- Erzeugt ein vollständiges Dendrogram und erlaubt die Wahl eines Schnittniveaus
- Vorallem Historisch/konzeptionell wichtig

3.3.2 Modularität als Qualitätsmass

Modularität Q misst, wie stark die Vernetzung innerhalb von Communities die Erwartung (unter Random-Graph-Annahme) übertrifft. Werte nahe 1 bedeuten starke Community-Struktur; Werte nahe 0 bedeuten zufällige Vernetzung.

Technische Anpassungen:

- Da die meisten Algorithmen für ungerichtete Graphen konzipiert sind, konvertieren wir gerichtete Netzwerke, indem wir Gewichte in beiden Richtungen addieren
- **Gewichte:** Alle Algorithmen berücksichtigen Kantengewichte (`weight='weight'`)

3.4 Ergebnisse: Community Detection

3.4.1 Pass-Netzwerk (Deutschland Bundesliga)

Für die Community Detection verwenden wir die grösste zusammenhängende Komponente (473 Knoten, 100% des Netzwerks).

Tabelle 3.1: Algorithmenvergleich auf Pass-Netzwerk (Deutschland, grösste Komponente)

Algorithmus	Communities	Modularität	Coverage	Min	Max	Ø Grösse
Louvain	18	0.915	0.875	23	31	26.3
Label Propagation	15	0.878	0.894	23	79	31.5
Greedy Modularity	18	0.915	0.875	23	31	26.3
Girvan-Newman	21	0.914	0.874	1	29	22.5

Beobachtungen:

- **Sehr hohe Modularität** ($Q > 0.91$): Pass-Netzwerke zeigen extrem starke Community-Struktur. Spieler passen praktisch nur zu Teamkollegen, das ist sehr gut, den schliesslich ist es Profifussball.
- **Konsistenz:** Alle Algorithmen finden 15–21 Communities, wobei Louvain und Greedy genau 18 identifizieren (entspricht der Anzahl Bundesliga-Teams)
- **Hohe Coverage** (> 0.87): Über 87% der Passverbindungen erfolgen innerhalb von Communities

Abbildung 3.2 zeigt den direkten Vergleich der Algorithmen: Modularität, Anzahl Communities und Grössenverteilungen sind sehr ähnlich, was die Robustheit der gefundenen Struktur bestätigt.

Interpretation: Communities = Teams
Die algorithmisch gefundenen Communities entsprechen nahezu perfekt den realen Teams. Analyse der Louvain-Communities zeigt:

- Community 1 (31 Spieler): 100% FC Köln
- Community 2 (29 Spieler): 100% Hamburger SV
- Community 3 (29 Spieler): 100% SC Freiburg
- Community 4 (28 Spieler): 100% Borussia Dortmund
- Community 5 (28 Spieler): 100% Eintracht Frankfurt

Dies bestätigt die erwartete Struktur und validiert die Netzwerkkonstruktion. Die 18 gefundenen Communities entsprechen exakt den 18 Bundesliga-Teams, und alle analysierten Communities zeigen 100% Team-Homogenität. Einzelne Nodes die nicht gennau dem aktuellen Team enntsprechen sind Transferspieler, die noch stark verknüpft mit dem letzten Team sind.

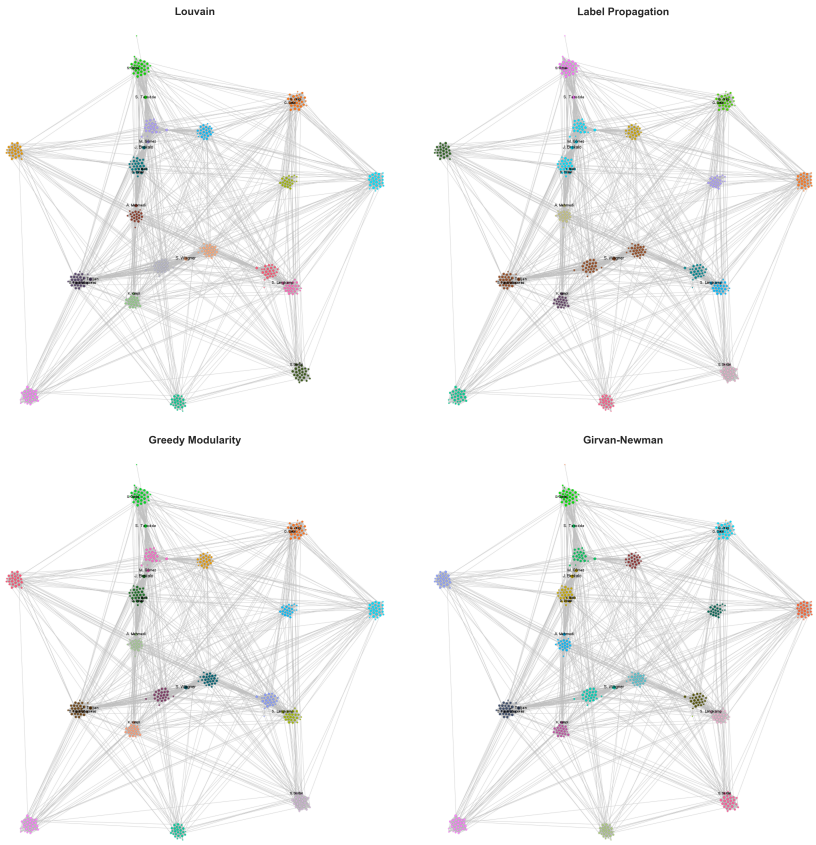

Abbildung 3.2: Algorithmenvergleich auf dem Pass-Netzwerk (Deutschland). Louvain und Greedy erzielen die höchste Modularität ($Q = 0.915$), Label Propagation zeigt höhere Coverage aber mit einer sehr grossen Ausreisser-Community (Max 79).

3.4.2 Match-Netzwerk (FIFA World Cup)

Das Match-Netzwerk ist kleiner (32 Teams) und dichter. Auch hier versuchen wir durch unsere.

Tabelle 3.2: Community Detection auf Match-Netzwerk (World Cup)

Algorithmus	Communities	Modularität	Ø Grösse
Louvain	6	0.701	5.3
Label Propagation	8	0.599	4.0
Greedy Modularity	6	0.701	5.3

Beobachtungen:

- **Moderate Modularität** ($Q \approx 0.7$): Starke, aber weniger ausgeprägte Community-Struktur als Pass-Netzwerke
- **6 Communities:** Weniger als die 8 WM-Vorrundengruppen, K.O.-Spiele verbinden Gruppen (ausser bei der Labelpropagation, diese identifiziert alle Gruppen sehr gut, hat aber dennoch eine niedrigere Modularität.)
- **Strukturelle Bedeutung:** Communities reflektieren primär Gruppenphase mit teilweisen K.O.-Überlappungen

Communities mit Louvain (Fig. 3.4:

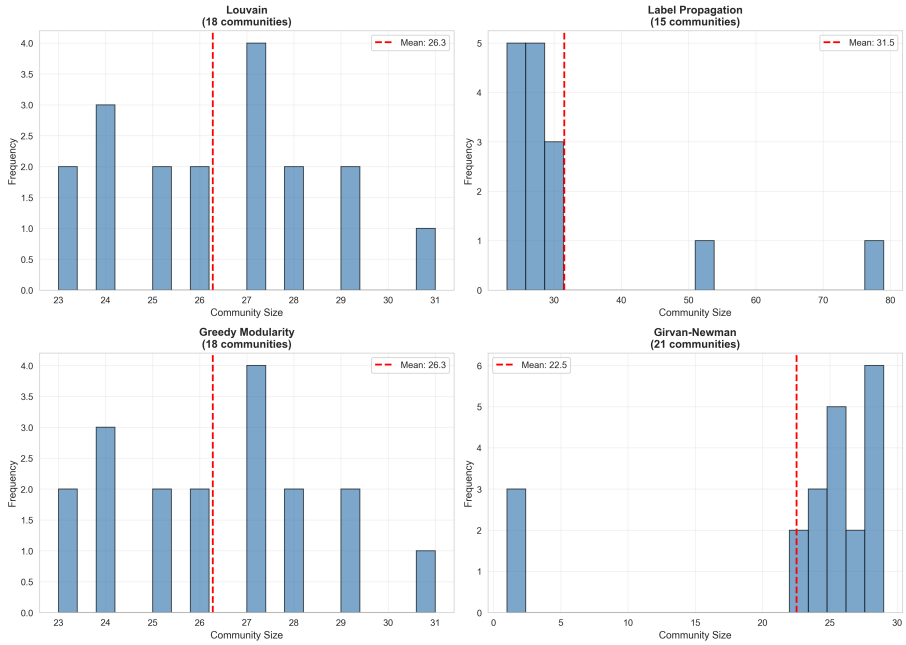

Abbildung 3.3: Grössenverteilungen der Communities für vier Algorithmen. Louvain und Greedy liefern sehr uniforme Grössen (23–31), Label Propagation zeigt einen Ausreisser (bis 79), Girvan-Newman produziert eine Singleton-Community.

- Community 1 (4 Teams): Belgien, England, Panama, Tunesien (Gruppe G + teilweise H)
- Community 2 (8 Teams): Ägypten, Iran, Marokko, Portugal, Russland, Saudi-Arabien, Spanien, Uruguay (mehrere Gruppen, verbunden durch K.O.-Spiele)
- Community 5 (4 Teams): Deutschland, Südkorea, Mexiko, Schweden (Gruppe F)

3.5 Intra-Team Analyse: Positionsbasierte Strukturen

Nachdem wir Teams als Communities identifiziert haben, stellt sich die Frage: Bilden sich **innerhalb eines Teams** Sub-Communities nach Position? Fussballteams sind hierarchisch organisiert (Defensive, Mittelfeld, Offensive). Führt dies zu entsprechenden Passmustern?

Hypothese:
Pass-Muster innerhalb eines Teams sollten positionsbasierte Sub-Communities bilden (z.B. Verteidiger → Mittelfeld → Stürmer).

Methode:
Wir analysieren das grösste Team im Pass-Netzwerk (FC Köln, 31 Spieler):

1. Extraktion des Team-Subgraphen
2. Louvain-Community Detection auf dem isolierten Team-Graph
3. Analyse der Positionsverteilung in gefundenen Communities

Ergebnisse:
Team Köln Pass-Netzwerk:

- 31 Spieler, 326 Passverbindungen, Ø Grad: 21.03
- **5 Communities gefunden**
- **Modularität:** $Q = 0.136$ (deutlich niedriger als Inter-Team: $Q = 0.915$)

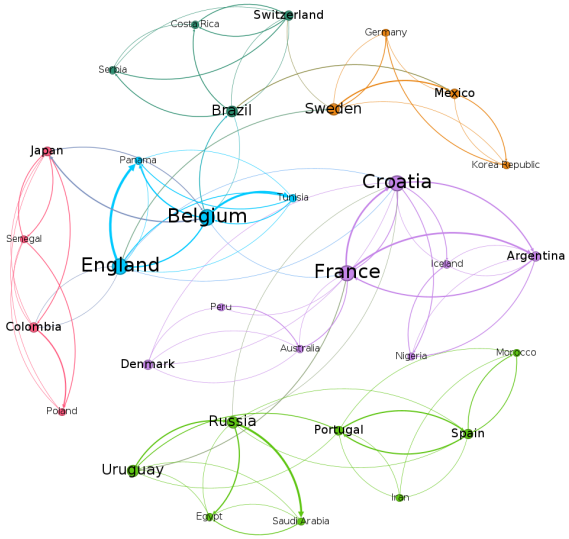

Abbildung 3.4: Louvain-Communities im Match-Netzwerk (World Cup). Farbcodierung zeigt 6 Communities, die primär Vorrunden-Gruppen mit K.O.-Verknüpfungen widerspiegeln.

Community-Zusammensetzung: Alle fünf Communities enthalten **Spieler aus mehreren Positionen**. Es gibt keine klare Trennung nach Defensive/Mittelfeld/Offensive. Die niedrige Modularität ($Q = 0.136$) zeigt schwache Sub-Struktur.

Interpretation:
Die Ergebnisse zeigen **keine klare positionsbasierte Clusterbildung**:

- **Taktische Flexibilität:** Moderne Fussballtaktiken erfordern positions-übergreifende Interaktionen
- **Hub-Spieler dominieren:** Zentrale Mittelfeldspieler (Playmaker) verbinden alle Positionen und „verwischen“ positionsbasierte Cluster
- **Sportlich sinnvoll:** Isolierte Positions-Cluster würden taktische Inflexibilität signalisieren – erfolgreiche Teams brauchen positions-übergreifende Vernetzung

Die moderate Modularität ($Q = 0.136$) innerhalb eines Teams ist daher ein **positives Signal**: Sie zeigt den optimalen Kompromiss zwischen Spezialisierung (verschiedene Positionen haben unterschiedliche Rollen) und Integration (alle Positionen müssen zusammenarbeiten).

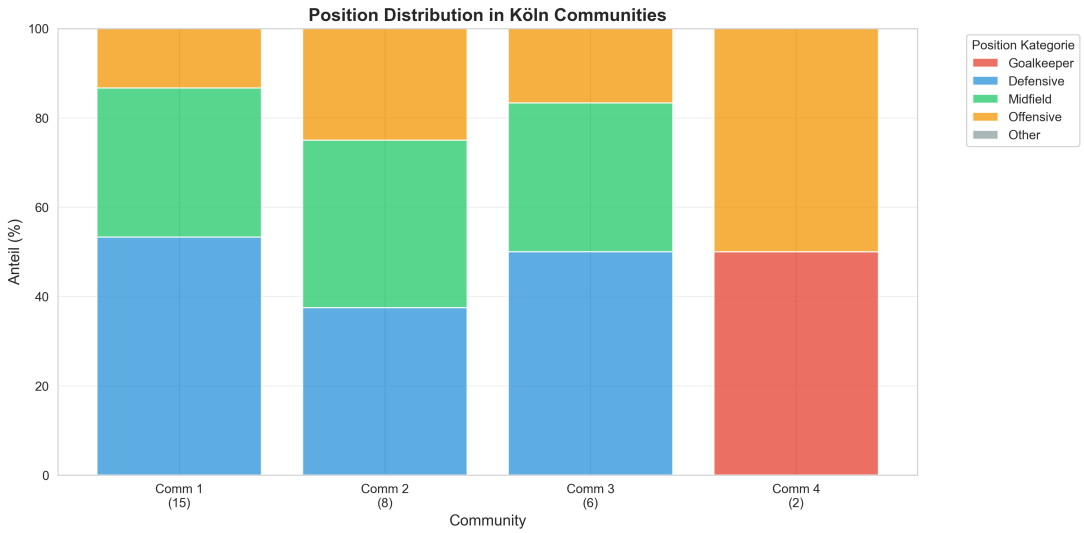

Abbildung 3.5: Positionsverteilung innerhalb der Köln-Communities (100% gestapelt). Die fünf Communities zeigen hohe Positions-Diversität: Community 1 (11 Spieler) ist ausgewogen Defensivlastig , Community 2 schon eher ausgeglichen, Community 3 ist wieder etwas defensivlastig, Community 4 besteht nur aus Torwart und Offensive

4 LE5 – Zentrale Aktoren & Aktor-Gruppen finden

4.1 Ziel und Fragestellung

Die Identifikation zentraler Aktoren in Netzwerken ist ein fundamentales Problem der Netzwerkanalyse. In unseren Fussballnetzwerken stellt sich die Frage: *Welche Spieler oder Teams sind besonders wichtig für die Struktur und Funktion des Netzwerks?*

Die Antwort hängt stark von der Definition von „Zentralität“ ab:

- **Konnektivität**: Spieler mit vielen Verbindungen (Degree)
- **Brückenfunktion**: Spieler, die verschiedene Teamteile verbinden (Betweenness)
- **Erreichbarkeit**: Spieler mit kurzen Wegen zu allen anderen (Closeness)
- **Einfluss**: Spieler, die mit anderen wichtigen Spielern verbunden sind (Eigenvector, PageRank)
- **Gruppenzugehörigkeit**: Spieler in dicht verbundenen Kernen (k-Core)

In diesem Kapitel analysieren wir verschiedene Zentralitätsmasse auf unseren Pass- und Match-Netzwerken und identifizieren die wichtigsten Aktoren.

4.2 Datengrundlage

Wir analysieren folgende Netzwerke:

- **Pass-Netzwerk (Deutschland)**: Knoten = Spieler, Kanten = Pässe (gerichtet, gewichtet)
- **Match-Netzwerk (World Cup)**: Knoten = Teams, Kanten = Spiele (gerichtet, gewichtet)

Für einige Zentralitätsmasse (Betweenness, Closeness, k-Core) verwenden wir die grösste zusammenhängende Komponente, um sinnvolle Ergebnisse zu erhalten.

4.3 Ergebnisse: Pass-Netzwerk (Deutschland)

4.3.1 Degree Centrality und Strength

Tabelle 4.1 zeigt die Verteilungsstatistiken der Degree- und Strength-Werte im Pass-Netzwerk.

Tabelle 4.1: Degree und Strength Statistiken (Pass-Netzwerk Deutschland)

Metrik	Degree	Strength
Maximum	50	1290
Mittelwert	22.2	248.9
Median	24	194

Abbildung 4.1 zeigt die Verteilung von Degree und Strength. Während der Degree im vorliegenden Netzwerk relativ kompakt um den Mittelwert liegt (Peak im Bereich 24–26), weist Strength eine deutlich rechtssteile Verteilung auf: Die Mehrheit der Spieler liegt bei niedriger gewichteter Aktivität, während wenige Akteure sehr hohe Passvolumina akkumulieren.

Die Beziehung zwischen Degree und Strength ist positiv, aber nicht perfekt: Spieler mit vielen Passpartnern akkumulieren typischerweise auch ein höheres Passvolumen, gleichzeitig kann Strength (z.B. durch wiederholtes Anspielen derselben Mitspieler) stark variieren. Im vorliegenden Netzwerk liegt die Pearson-Korrelation bei $r = 0.587$.

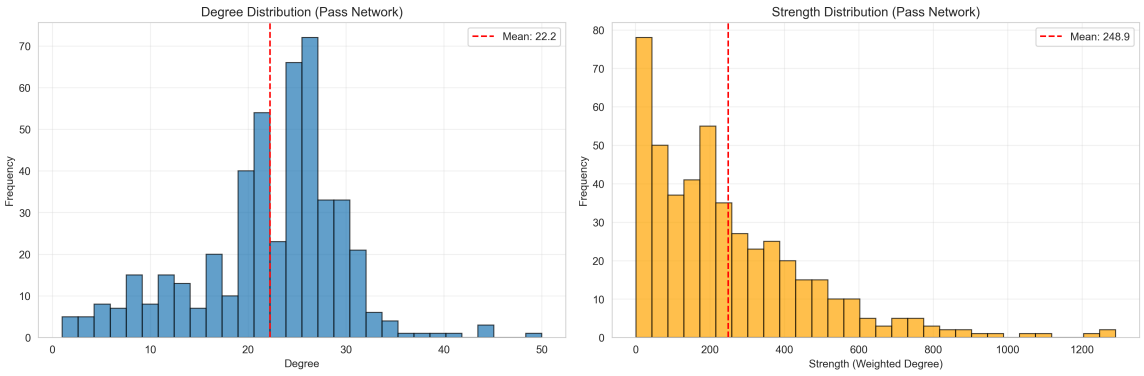

Abbildung 4.1: Degree- und Strength-Verteilung im Pass-Netzwerk (Deutschland). Degree ist in dieser Auswertung relativ kompakt um den Mittelwert, Strength ist deutlich rechtssteil und hebt wenige High-Volume-Passer hervor.

In-Degree vs. Out-Degree: Im gerichteten Pass-Netzwerk zeigt sich:

- Hoher **Out-Degree**: Spieler, die viele Pässe geben (Playmaker, Aufbauspieler)
- Hoher **In-Degree**: Spieler, die viele Pässe empfangen (Zielspieler, Stürmer)

4.3.2 Betweenness Centrality

Betweenness-Zentralität identifiziert Spieler, die als **Brücken** zwischen verschiedenen Teamteilen fungieren. Abbildung 4.2 zeigt die Verteilung und den Zusammenhang zwischen Degree und Betweenness.

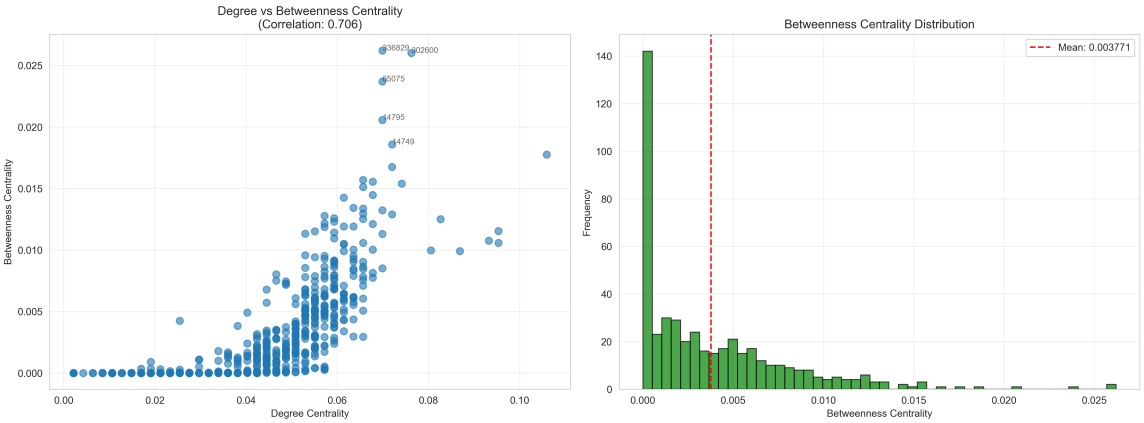

Abbildung 4.2: Betweenness-Zentralität: Verteilung und Korrelation mit Degree

Die Korrelation zwischen Degree und Betweenness ist moderat (dokumentiert: $r = 0.706$), d.h. tendenziell übernehmen Spieler, die gut verknüpft sind, auch Brückenfunktionen.

Bridging Nodes: Spieler mit hoher Betweenness aber relativ niedrigem Degree sind speziell interessant. Sie verbinden verschiedene Gruppen, ohne selbst extrem viele direkte Verbindungen zu haben, und können damit für die Ballzirkulation zwischen Teamteilen besonders wichtig sein.

4.3.3 Vergleich aller Zentralitätsmasse

Abbildung 4.3 zeigt die Korrelationsmatrix aller Zentralitätsmasse für das Pass-Netzwerk.

Beobachtungen:

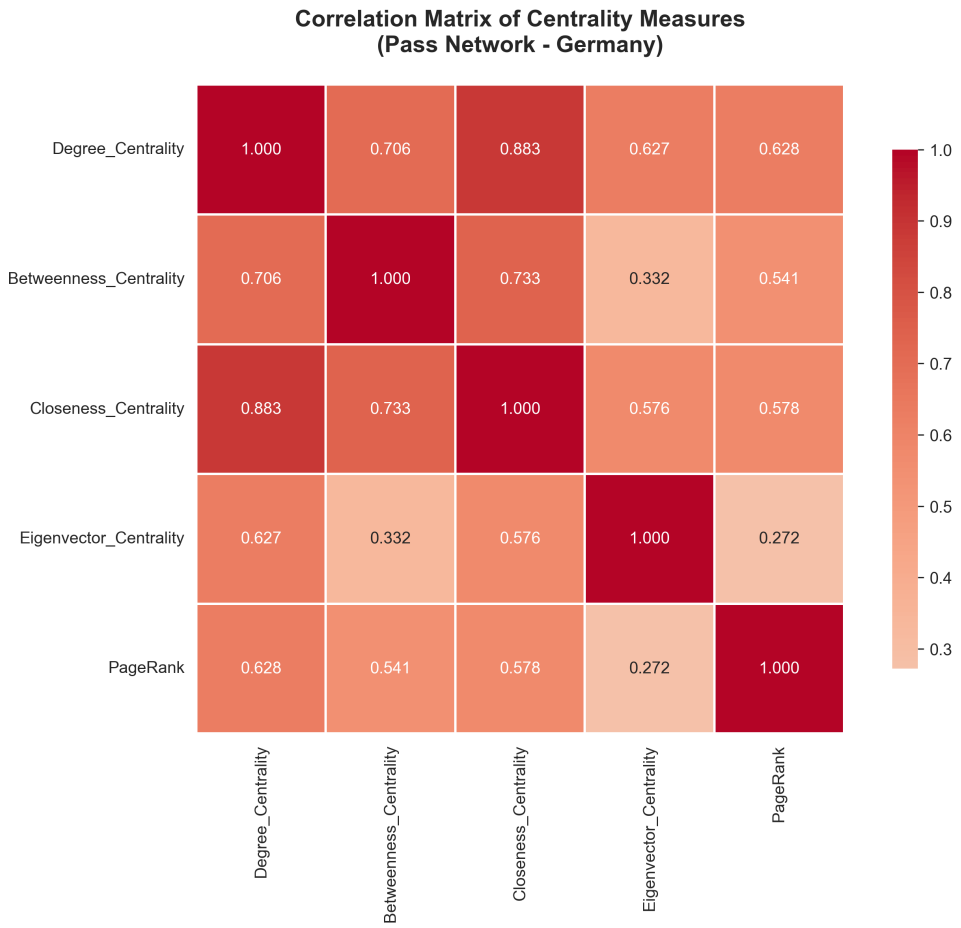

Abbildung 4.3: Korrelation verschiedener Zentralitätsmasse (Pass-Netzwerk)

- **Closeness und PageRank** korrelieren moderat (dokumentiert: $r = 0.578$) und erfassen eine ähnliche Erreichbarkeits-Dimension.
- **Degree und PageRank** korrelieren moderat bis stark (dokumentiert: $r = 0.628$), Degree und Eigenvector ebenfalls moderat bis stark (dokumentiert: $r = 0.627$).
- **Betweenness** korreliert moderat mit den übrigen Massen (z.B. Betweenness–PageRank: $r = 0.541$) und erfasst damit einerseits Broker-Aspekte, aber im vorliegenden Netzwerk nicht vollständig unabhängig von allgemeiner Vernetzung.

Dies zeigt, dass verschiedene Zentralitätsmasse verschiedene Aspekte der Wichtigkeit erfassen.

4.3.4 Top Spieler nach Zentralität

Tabelle 4.2 zeigt die Top-10 Spieler nach durchschnittlichem Rang über alle Zentralitätsmasse.

Tabelle 4.2: Top-10 Spieler nach Gesamtzentralität (Pass-Netzwerk Deutschland)

Player	Degree	Betweenness_Centrality	Closeness_Centrality	PageRank	Core_Number
14687	34	0.012900	0.397600	0.006300	19
16843	31	0.013000	0.395600	0.005800	20
14778	32	0.012100	0.402000	0.006100	19
15253	33	0.011300	0.398000	0.003900	20
241966	35	0.015400	0.408000	0.004300	18
14749	34	0.018600	0.418100	0.004500	18
14795	33	0.020600	0.428300	0.004100	19
65075	33	0.023700	0.433400	0.005800	16
15085	50	0.017700	0.410800	0.002500	19
284469	45	0.010600	0.394000	0.002900	18

4.4 k-Core Analyse

Die k-Core-Zerlegung identifiziert hierarchische Struktur im Netzwerk. Abbildung 4.4 zeigt die Verteilung der Core-Nummern und deren Zusammenhang mit Degree.

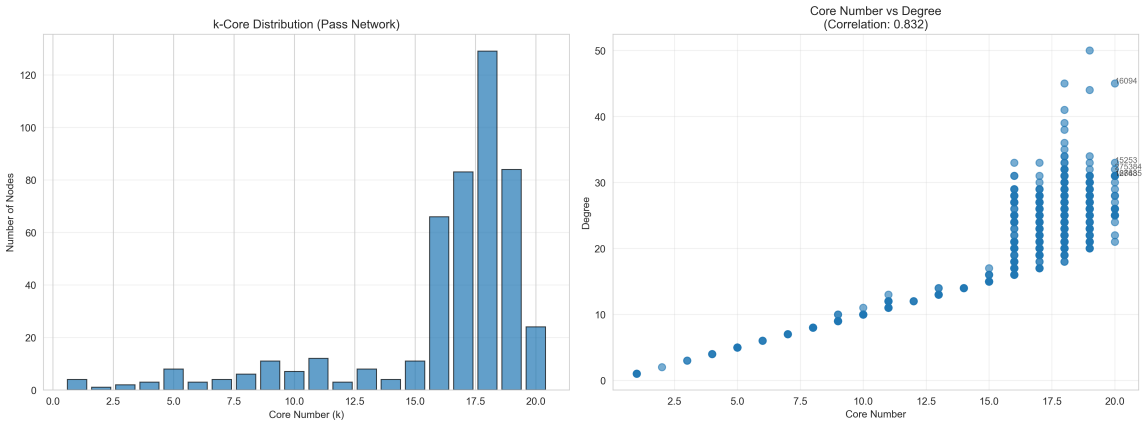

Abbildung 4.4: k-Core Analyse: Verteilung und Zusammenhang mit Degree

Interpretation:

- Der **maximale Core** (höchster k-Wert) enthält die am dichtesten verbundene Gruppe von Spielern
- Höhere Core-Nummern markieren Spieler, die in einem stabilen, dicht vernetzten Kern eingebettet sind (Backbone-Struktur)

- Die Core Number korreliert stark mit Degree (dokumentiert: $r = 0.832$). Spieler mit hoher Core-Nummer sind typischerweise auch breit im Netzwerk verknüpft.
- Spieler im höchsten Core bilden das „Backbone“ des Pass-Netzwerks

Die k-Core-Analyse ergänzt die punktbasierten Zentralitätsmasse, indem sie **Gruppen** von dicht verbundenen Spielern identifiziert.

4.5 Ergebnisse: Match-Netzwerk (World Cup)

4.5.1 Team-Zentralität

Im Match-Netzwerk repräsentieren Knoten Teams und Kanten Spiele. Die Analyse der Zentralität identifiziert die wichtigsten Teams im Wettbewerb.

Abbildung 4.5 zeigt die Korrelationsmatrix für das Match-Netzwerk.

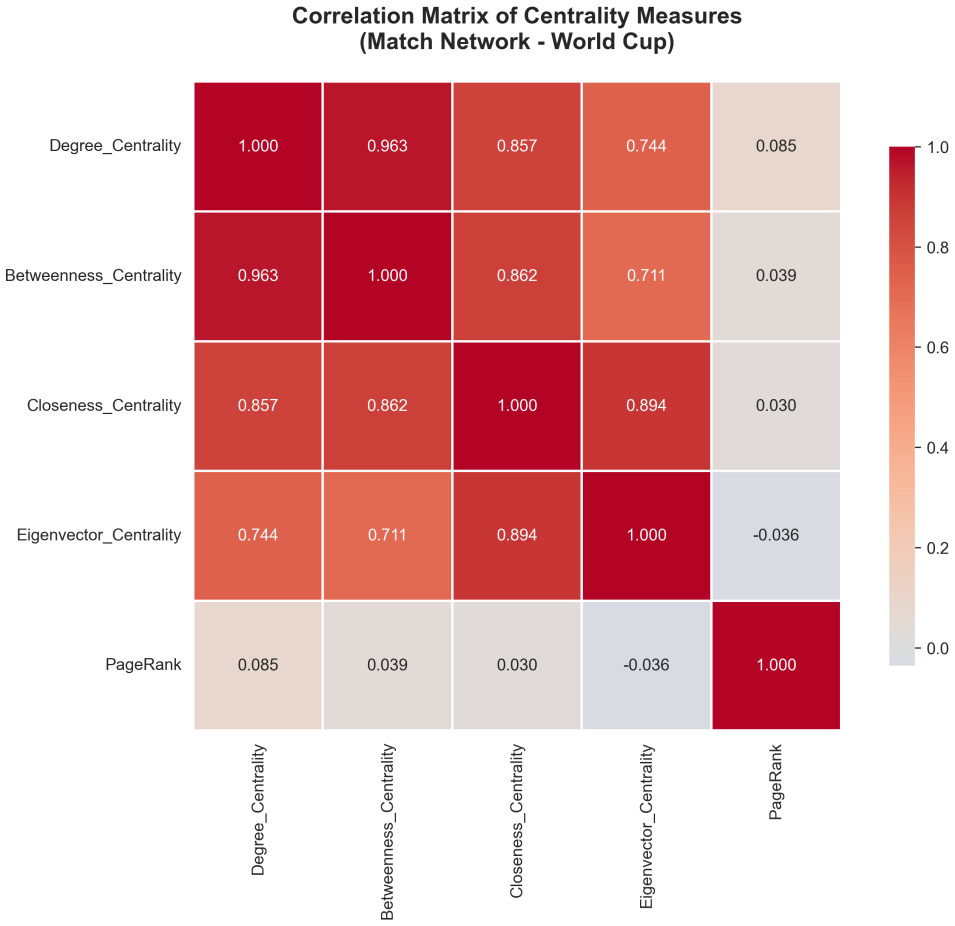

Abbildung 4.5: Korrelation verschiedener Zentralitätsmasse (Match-Netzwerk World Cup)

Beobachtungen:

- Im Match-Netzwerk sind die Korrelationen zwischen verschiedenen Zentralitätsmassen tendenziell höher als im Pass-Netzwerk
- Dies deutet auf eine homogenere Struktur hin: Teams, die viele Spiele haben, sind auch zentral nach anderen Massen
- Die höchsten Zentralitätswerte haben typischerweise Teams, die weit im Turnier gekommen sind (mehr Spiele = höhere Zentralität)

4.6 Vergleich: Pass-Netzwerk vs. Match-Netzwerk

Die beiden Netzwerktypen zeigen unterschiedliche Strukturen:

- **Pass-Netzwerk**: Komplexere Struktur mit verschiedenen Spielerrollen (Verteidiger, Mittelfeld, Angriff), stärkere Heterogenität in Zentralitätsmassen
- **Match-Netzwerk**: Struktur stark vom Turnierformat geprägt (K.O.-System, Gruppenphase), höhere Korrelation zwischen Zentralitätsmassen

5 LE6 – Netzwerk-Kennzahlen

Netzwerk-Kennzahlen quantifizieren strukturelle Eigenschaften auf Knoten-, Kanten- und Netzwerkebene. Sie ermöglichen systematische Vergleiche zwischen verschiedenen Netzwerken und offenbaren wichtige Muster über Konnektivität, Zentralität, Clustering und die Gesamtarchitektur des Netzwerks. In diesem Kapitel analysieren wir globale und lokale Metriken auf unseren Fussballnetzwerken und interpretieren ihre Bedeutung im taktischen Kontext.

5.1 Ziel

Welche globalen und lokalen Kennzahlen beschreiben das Netzwerk sinnvoll?

Während LE5 sich auf die Identifikation **zentraler Aktoren** konzentrierte (wer ist wichtig?), fokussiert sich LE6 auf die **strukturellen Eigenschaften des Gesamtnetzwerks** (wie ist das Netzwerk aufgebaut?). Die Fragen sind komplementär: Zentralitätsmasse aus LE5 charakterisieren individuelle Knoten, während die hier untersuchten Metriken das kollektive Verhalten und die Netzwerkarchitektur beschreiben.

Hinweis: Mehrere Kennzahlen wurden bereits in vorherigen Kapiteln implementiert:

- **Degree, Strength, Betweenness, Closeness, Eigenvector, PageRank, k-Core** → siehe LE5
- **Dichte, Modularität** → siehe LE4 (Community Detection)

Diese Kennzahlen werden hier nicht wiederholt, sondern wir fokussieren uns auf ergänzende Metriken: Diameter, Average Path Length, Clustering Coefficient, Transitivity, Assortativity, Reciprocity und Edge Embeddedness.

5.2 Datengrundlage

Wir analysieren zwei Netzwerke:

- **Pass-Netzwerk (Deutschland Bundesliga)**: 473 Knoten (Spieler), 8 815 gerichtete Kanten (Pässe), gewichtet nach Passanzahl
- **Match-Netzwerk (FIFA World Cup)**: 32 Knoten (Teams), 126 gerichtete Kanten (Spiele), gewichtet nach Toren

Für metriken, die Zusammenhang voraussetzen (Diameter, Average Path Length), verwenden wir die **grösste zusammenhängende Komponente** (Largest Connected Component, LCC):

- Pass-Netzwerk LCC: 283 Knoten (59.8%), 2 899 Kanten
- Match-Netzwerk: vollständig zusammenhängend (1 Komponente)

5.3 Globale Kennzahlen

5.3.1 Diameter und Average Path Length

Der **Diameter** ist die maximale kürzeste Pfaddistanz zwischen zwei Knoten, die **Average Path Length** die durchschnittliche kürzeste Pfaddistanz über alle Knotenpaare.

Ergebnisse

Interpretation:

Tabelle 5.1: Diameter und Average Path Length

Netzwerk	Diameter	Avg Path Length
Pass-Netzwerk (LCC)	13	5.476
Match-Netzwerk	6	3.163

- **Pass-Netzwerk**: Spieler sind im Durchschnitt 5.5 Passschritte voneinander entfernt. Der Diameter von 13 zeigt, dass einige periphere Spieler (vermutlich Ersatzspieler oder Spezialisten) weit vom Kern des Passnetzes entfernt sind.
- **Match-Netzwerk**: Teams sind durchschnittlich 3.2 Schritte auseinander. Der Diameter von 6 reflektiert die K.O.-Struktur (Gruppenphase → Finale).

Small-World-Eigenschaft

Netzwerke zeigen die Small-World-Eigenschaft, wenn $\bar{d} \sim \log(n)$ (logarithmische Skalierung mit Netzwerkgrösse). Überprüfung:

Tabelle 5.2: Small-World-Check

Netzwerk	$\bar{d}$	$\log(n)$	Ratio
Pass-Netzwerk	5.476	5.645	0.97
Match-Netzwerk	3.163	3.466	0.91

Beide Netzwerke erfüllen die Small-World-Eigenschaft (Ratio ≈ 1): Sie zeigen effiziente Pfadlängen trotz ihrer unterschiedlichen Grössen. Im Pass-Netzwerk bedeutet dies, dass der Ball durch gut organisierte taktische Positionierung schnell über das gesamte Team fliessen kann.

5.3.2 Clustering Coefficient und Transitivity

Der **lokale Clustering-Koeffizient** misst, wie stark die Nachbarn eines Knotens untereinander vernetzt sind. Der **durchschnittliche Clustering-Koeffizient** ist das Mittel über alle Knoten. Die **Transitivity** (globaler Clustering-Koeffizient) misst die Gesamtdichte an Dreiecken.

Ergebnisse

Tabelle 5.3: Clustering-Metriken

Netzwerk	$\bar{C}$	Transitivity	Dreiecke
Pass-Netzwerk (LCC)	0.8667	0.8183	17 093
Match-Netzwerk	0.7003	0.4904	34

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hoher durchschnittlicher Clustering-Koeffizient (0.867) zeigt, dass Spieler in **eng vernetzten taktischen Einheiten** operieren. 81.6% der Spieler haben $C_i \geq 0.8$, viele erreichen perfektes Clustering ($C_i = 1.0$). Dies reflektiert Positionsgruppen wie Verteidigungslinien oder Mittelfeld-Dreiecke.
- **Match-Netzwerk**: Hoher durchschnittlicher Clustering (0.700) reflektiert die Gruppenphase, in der Teams innerhalb einer Gruppe alle gegeneinander spielen.

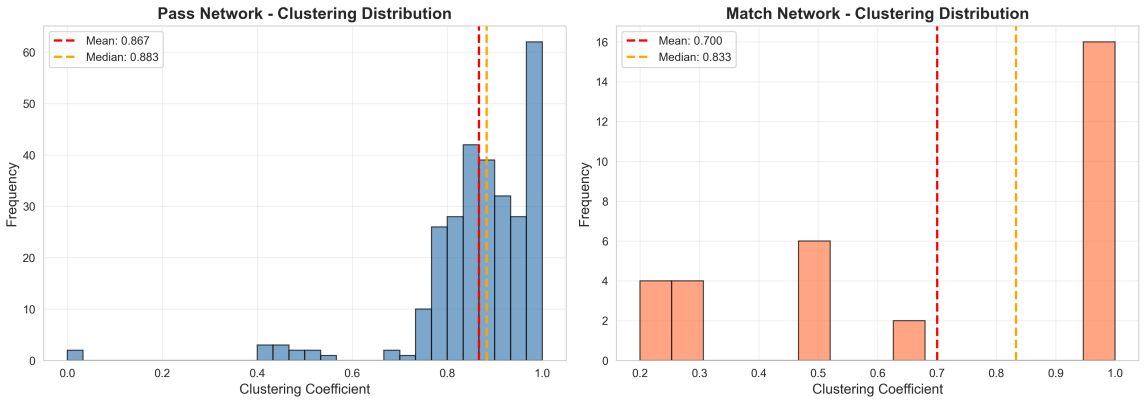

Abbildung 5.1: Verteilung des Clustering-Koeffizienten. Links: Pass-Netzwerk (hoch konzentriert um 0.8 - 0.9). Rechts: Match-Netzwerk (variierter).

Vergleich mit Zufallsnetzwerken

In einem Zufallsnetzwerk mit gleicher Dichte gilt $C_{random} \approx \rho$ (Dichte). Vergleich:

Tabelle 5.4: Clustering vs. Zufallsnetzwerk

Netzwerk	Clustering	Dichte	Ratio
Pass-Netzwerk	0.8183	0.0727	11.26×
Match-Netzwerk	0.4904	0.1270	3.86×

Beide Netzwerke zeigen deutlich höheres Clustering als erwartet: Das Pass-Netzwerk hat **11.26-fach** höheres Clustering als ein äquivalentes Zufallsnetzwerk. Dies bestätigt stark strukturierte, nicht-zufällige Verbindungsmuster.

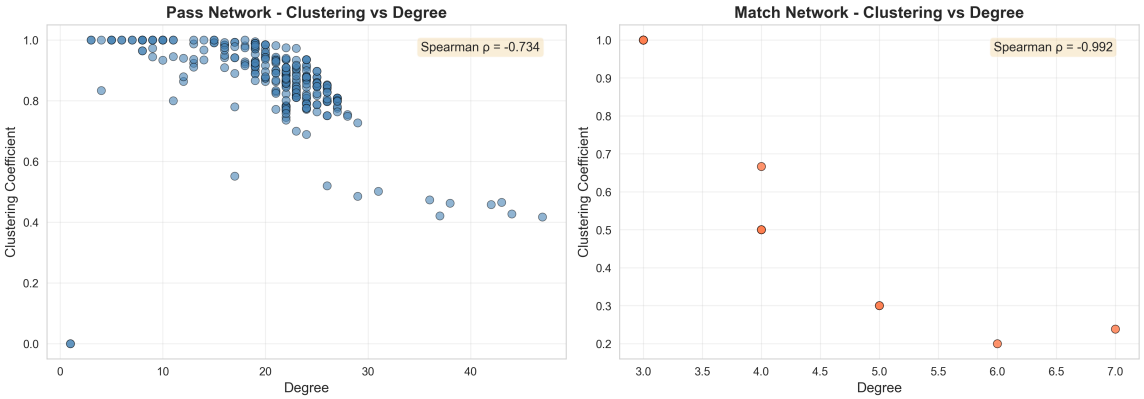

Abbildung 5.2: Clustering-Koeffizient vs. Degree. Pass-Netzwerk zeigt schwache negative Korrelation (Spearman $\rho = -0.235$), Match-Netzwerk schwache positive Korrelation ($\rho = 0.107$).

Die schwache negative Korrelation im Pass-Netzwerk deutet darauf hin, dass Spieler mit vielen Verbindungen (Hubs) tendenziell verschiedene Gruppen überbrücken und daher niedrigeres lokales Clustering aufweisen.

Small-World-Struktur

Die Kombination von **niedrige Dichte** (0.073) + **hoher Clustering** (0.818) + **kurze Pfadlängen** (5.5) bestätigt die Small-World-Eigenschaft des Pass-Netzwerks: Spieler operieren in

eng vernetzten taktischen Einheiten, während der Ball dennoch effizient über das gesamte Team fliessen kann.

5.3.3 Assortativity

Assortativity misst die Tendenz ähnlicher Knoten, sich zu verbinden (Pearson-Korrelation der Grade an Kantenendpunkten). Wertebereich: $[-1, 1]$. Positive Werte bedeuten assortativ (Hubs verbinden sich mit Hubs), negative Werte disassortativ (Hubs verbinden mit peripheren Knoten), Werte nahe 0 neutrales Mischen.

Ergebnisse

Tabelle 5.5: Degree-Assortativity

Netzwerk	**Assortativity** r
Pass-Netzwerk (ungerichtet)	0.0062
Pass-Netzwerk (In-Degree)	0.0007
Pass-Netzwerk (Out-Degree)	-0.0075
Match-Netzwerk	0.0891

Interpretation:

- Beide Netzwerke zeigen **neutrales Assortativity** ($r \approx 0$), d.h. keine Präferenz für Verbindungen nach Grad-Ähnlichkeit.
- **Pass-Netzwerk**: Anders als in sozialen Netzwerken (oft assortativ, $r > 0.2$) zeigen Fussballteams keine Präferenz für Pässe zwischen Spielern ähnlichen Grades. Schlüsselspieler (Playmaker) passen sowohl zu anderen Kernspielern als auch zu peripheren Angreifern/-Verteidigern, funktionale Integration statt Homophilie.
- **Match-Netzwerk**: Leicht positiv (0.089), aber neutral. Reflektiert Balance zwischen Gruppenphase (gemischte Team-Stärken) und K.O.-Runden (ähnliche Performance-Level).

Vergleich mit anderen Netzwerktypen:

- Soziale Netzwerke: typisch $r > 0.2$ (assortativ)
- Technologische Netzwerke: typisch $r < -0.2$ (disassortativ, Hub-and-Spoke)
- Fussballnetzwerke: $r \approx 0$ (aufgabenorientiert, keine Grad-Homophilie)

5.3.4 Reciprocity

Reciprocity misst den Anteil bidirektionaler Kanten in gerichteten Netzwerken (Wertebereich: $[0, 1]$).

Ergebnisse

Tabelle 5.6: Reciprocity in gerichteten Netzwerken

Netzwerk	**Reciprocity**	**Reziproke Kanten**	**Einseitige Kanten**
Pass-Netzwerk (LCC)	0.9269	5 008 (92.7%)	395 (7.3%)
Match-Netzwerk	1.0000	126 (100%)	0 (0%)

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hohe Reciprocity (92.7%) zeigt, dass fast alle Passbeziehungen bidirektional sind. Dies reflektiert **kollaboratives, ballbesitzorientiertes Spiel**, in dem Spieler sich gegenseitig unterstützen. Die wenigen einseitigen Kanten (7.3%) sind vermutlich spezialisierte Rollen (z.B. Zielspieler empfangen, passen aber selten zurück).
- **Match-Netzwerk**: Perfekte Reciprocity (100%) ist eine strukturelle Eigenschaft: Jedes Spiel erzeugt eine bidirektionale Beziehung (Team A vs. Team B).

Vergleich mit anderen gerichteten Netzwerken:

- Soziale Netzwerke (Twitter Follows): 20 - 40% Reciprocity
- Informationsnetzwerke (Web Links): $< 10\%$ Reciprocity
- Fussball Pass-Netzwerke: 92.7% Reciprocity: reflektiert kooperative Natur des Teamsports

5.4 Lokale Kennzahlen

5.4.1 Edge Embeddedness

Edge Embeddedness zählt die gemeinsamen Nachbarn zweier verbundener Knoten. Kanten mit $emb(i, j) = 0$ werden **Local Bridges** genannt (verbinden Gruppen ohne gemeinsame Nachbarn).

Ergebnisse

Tabelle 5.7: Edge Embeddedness

Netzwerk	Ø Embeddedness	Median	Max	Local Bridges
Pass-Netzwerk (LCC)	17.69	18	27	2 (0.1%)
Match-Netzwerk	1.62	2	3	12 (19.0%)

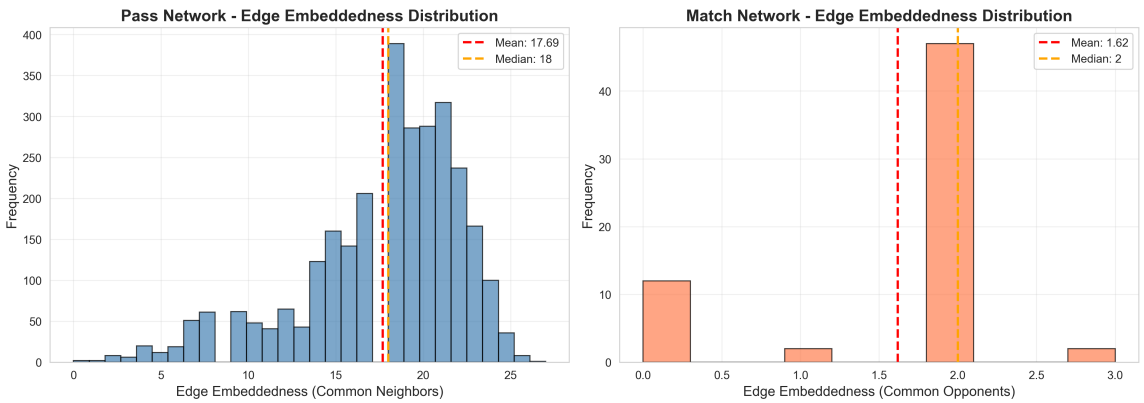

Abbildung 5.3: Verteilung der Edge Embeddedness. Pass-Netzwerk zeigt hohe Einbettung (Ø 17.7 gemeinsame Nachbarn), Match-Netzwerk niedrige Einbettung (Ø 1.6).

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hohe Embeddedness (Ø 17.7) zeigt, dass Passbeziehungen **tief in taktischen Einheiten eingebettet** sind. Verbundene Spieler teilen durchschnittlich 18 gemeinsame Passpartner. Fast keine Local Bridges (nur 2, 0.1%), praktisch jede Passverbindung hat multiple alternative Routen durch gemeinsame Nachbarn. Dies reflektiert **redundante taktische Struktur** mit vielfältigen Passoptionen.

- **Match-Netzwerk**: Niedrige Embeddedness (Ø 1.6) reflektiert die begrenzte Verbindung zwischen Turnieren. Teams teilen nur 2 gemeinsame Gegner im Durchschnitt. 12 Local Bridges (19%) repräsentieren Paarungen zwischen Teams aus verschiedenen Gruppen oder Turnierphasen ohne Überlappung.

Die Verteilung zeigt (siehe Abb. 5.3):

- Pass-Netzwerk: 91.6% der Kanten haben $emb \geq 10$, hochredundante Struktur
- Match-Netzwerk: Maximum nur 3 gemeinsame Gegner, strukturell begrenzte Überlappung

5.5 Zusammenfassende Analyse

Tabelle 5.8: Umfassende Netzwerk-Metriken (Zusammenfassung)

Metrik	Pass-Netzwerk (LCC)	Match-Netzwerk
Knoten	283	32
Kanten	2 899	63
Dichte	0.0727	0.1270
Diameter	13	6
Avg Path Length	5.476	3.163
Avg Clustering Coef	0.8667	0.7003
Transitivity	0.8183	0.4904
Anzahl Dreiecke	17 093	34
Avg Edge Embeddedness	17.69	1.62
Assortativity	0.0062	0.0891
Reciprocity	0.9269	1.0000
Small-World Ratio	0.97	0.91

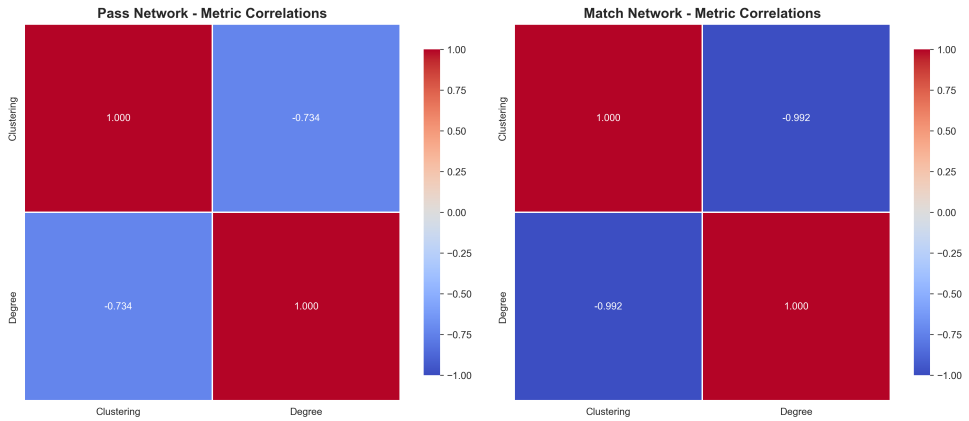

Abbildung 5.4: Korrelationen zwischen Metriken. Links: Pass-Netzwerk zeigt schwache negative Korrelation zwischen Clustering und Degree ($\rho = -0.235$). Rechts: Match-Netzwerk zeigt schwache positive Korrelation ($\rho = 0.107$).

5.5.1 Strukturelle Unterschiede

1. Skala & Konnektivität

- Pass-Netzwerk ist 8.8-fach grösser (283 vs. 32 Knoten)
- Aber 1.7-fach weniger dicht (0.073 vs. 0.127)
- Grössere Netzwerke können niedrigere Dichte mit hoher Konnektivität kombinieren

2. Lokale Struktur (Clustering & Embeddedness)

- Pass-Netzwerk: 1.7-fach höheres Clustering (0.818 vs. 0.490)
- Pass-Kanten 10.9-fach stärker eingebettet (17.7 vs. 1.6 gemeinsame Nachbarn)
- **Pass-Netzwerk**: Eng vernetzte taktische Einheiten mit redundanten Verbindungen
- **Match-Netzwerk**: Spärliche Turnierstruktur mit begrenzter Überlappung

3. Globale Struktur (Distanz & Diameter)

- Pass-Netzwerk hat längere Pfade (Ø 5.5 vs. 3.2)
- Beide erfüllen Small-World-Eigenschaft (Ratio ≈ 1)
- Effizient trotz unterschiedlicher Grössen

4. Mischungsmuster

- Beide zeigen neutrales Assortativity (≈ 0): keine Grad-Homophilie
- Beide zeigen hohe Reciprocity (92.7% Pass, 100% Match)
- **Pass-Netzwerk**: Kollaboratives ballbesitzorientiertes Spiel
- **Match-Netzwerk**: Round-Robin-Turnierstruktur

5. Netzwerktypen

- **Pass-Netzwerk**: Small-World mit hohem Clustering + niedriger Dichte
- **Match-Netzwerk**: Dichter Turniergraph mit moderatem Clustering

5.6 Diskussion

5.6.1 Small-World-Eigenschaften in Fussballnetzwerken

Die Analyse bestätigt, dass beide Netzwerke **Small-World-Eigenschaften** aufweisen: kurze Pfadlängen (Effizienz) kombiniert mit hohem Clustering (lokale Struktur). Diese Kombination ist charakteristisch für gut organisierte Systeme.

Im **Pass-Netzwerk** bedeutet dies:

- Spieler operieren in eng vernetzten taktischen Einheiten (Verteidigung, Mittelfeld, Angriff)
- Gleichzeitig ermöglicht die Gesamtstruktur schnellen Ballfluss über das gesamte Team
- Niedriger Diameter trotz hohem Clustering, optimale Balance zwischen Spezialisierung und Integration

5.6.2 Taktische Implikationen

Die Metriken offenbaren wichtige taktische Muster:

Redundante Passoptionen
Hohe Edge Embeddedness (Ø 17.7 gemeinsame Nachbarn) zeigt, dass Teams **multiple Passoptionen** aufbauen. Wenn ein direkter Pass blockiert ist, existieren viele alternative Routen durch gemeinsame Nachbarn. Dies ist charakteristisch für Ballbesitz-orientierte Taktiken (z.B. Tiki-Taka).

Kollaboratives Spiel
Sehr hohe Reciprocity (92.7%) bestätigt, dass erfolgreiches Passspiel auf **gegenseitiger Unterstützung** basiert. Spieler bieten sich kontinuierlich als Anspielstationen an und schaffen dadurch natürliche bidirektionale Passoptionen.

Funktionale Integration
Neutrales Assortativity ($r \approx 0$) zeigt, dass Schlüsselspieler (hoher Degree) nicht präferenziell untereinander passen, sondern das gesamte Team integrieren. Dies unterscheidet Fussball von sozialen Netzwerken und reflektiert die **aufgabenorientierte Natur** des Sports.

5.6.3 Limitationen

Statische Perspektive
Alle Metriken basieren auf statischen, aggregierten Netzwerken. Dynamische Aspekte (wie sich Metriken während eines Spiels ändern) werden nicht erfasst.

Passempfänger-Identifikation
Unsere Passempfänger-Zuordnung basiert auf raum-zeitlichem Matching (nächster Spieler innerhalb 5 Sekunden, 10 Meter). Fehlzuordnungen können Metriken beeinflussen, insbesondere:

- Clustering könnte leicht überschätzt sein (falsche Dreiecke)
- Reciprocity robust (aggregierte Muster weniger anfällig)

Qualitative Aspekte
Metriken berücksichtigen nicht die **Qualität** von Aktionen:

- Erfolgreiche vs. erfolglose Pässe
- Pässe unter Druck vs. freie Pässe
- Rückwärtspässe vs. progressive Pässe

5.7 Fazit

Die Netzwerk-Kennzahlen offenbaren fundamentale strukturelle Eigenschaften unserer Fussballnetzwerke:

1. **Small-World-Struktur**: Beide Netzwerke kombinieren kurze Pfadlängen (Effizienz) mit hohem Clustering (lokale Struktur)
2. **Taktische Organisation**: Aussergewöhnlich hoher Clustering (0.818) und Embeddedness (17.7) zeigen eng vernetzte taktische Einheiten
3. **Redundanz**: Multiple Passoptionen durch gemeinsame Nachbarn, charakteristisch für Ballbesitz-Taktiken
4. **Kollaboration**: Sehr hohe Reciprocity (92.7%) reflektiert gegenseitige Unterstützung im Passspiel
5. **Funktionale Integration**: Neutrales Assortativity zeigt aufgabenorientierte Vernetzung ohne Grad-Homophilie

Diese Erkenntnisse sind sowohl für deskriptive Netzwerkanalyse als auch für strategische Überlegungen relevant. Die Metriken ermöglichen quantitative Vergleiche zwischen Teams, Ligen oder taktischen Systemen und können als Basis für Performance-Analysen dienen.

Ausblick: Zukünftige Analysen könnten dynamische Metriken (Veränderung während eines Spiels), positions-spezifische Kennzahlen oder den Einfluss von Metriken auf Spielergebnisse untersuchen.

6 LE7 – Statistik in Netzwerken

Statistische Methoden in der Netzwerkanalyse ermöglichen es, beobachtete Muster von zufälligen zu unterscheiden und kausale Aussagen zu treffen. Während deskriptive Metriken (LE5, LE6) beschreiben *was* im Netzwerk passiert, klären statistische Tests *ob* Muster signifikant sind und *warum* sie entstehen. In diesem Kapitel untersuchen wir Nullmodelle, Hypothesentests, Verteilungsanpassungen und evaluieren Link-Prediction-Algorithmen.

6.1 Ziel

Welche statistischen Fragestellungen werden am Netzwerk untersucht?

Zentrale Fragen:

1. **Sind beobachtete Muster statistisch signifikant?** (z.B. ist das hohe Clustering zufällig?)
2. **Welche Zufallsmodelle passen zu unseren Netzwerken?** (z.B. Erdős-Rényi, Scale-Free, Small-World?)
3. **Welcher Verteilungstyp beschreibt Gradfolgen am besten?** (Power Law, Exponential, Log-Normal?)
4. **Wie gut lassen sich fehlende Verbindungen vorhersagen?** (Link Prediction Evaluation)

Hinweis: Link-Prediction-**Algorithmen** sind in LE8 vollständig implementiert:

Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment. Dieses Kapitel fokussiert sich auf die **statistische Evaluation** dieser Algorithmen (AUC, Precision@k, Train/Test-Split).

6.2 Nullmodelle & Randomisierung

6.2.1 Zufallsgraph-Modelle als Nullmodelle

Nullmodelle definieren Erwartungswerte für zufällige Netzwerke. Durch Vergleich mit dem realen Netzwerk identifizieren wir signifikante Strukturen.

1. Erdős-Rényi (ER) Modell

Das **einfachste Modell**: n Knoten, jede Kante existiert unabhängig mit Wahrscheinlichkeit p.

Erwarteter Grad: $\mathbb{E}[k] = p(n-1)$

Erwartetes Clustering: $\mathbb{E}[C] = p$ (sehr niedrig für spärliche Netzwerke)

Anwendung: Baseline-Test. Falls reales Netzwerk $C \gg p$ hat, existiert taktische Organisation.

2. Configuration Model (Konfigurationsmodell)

Erhält Gradfolge: Randomisiert Verbindungen, während der Grad jedes Knotens fixiert bleibt.

Erwartetes Clustering: $\mathbb{E}[C] \approx \frac{\langle k^2 \rangle - \langle k \rangle}{n \langle k \rangle^2}$ (noch niedrig)

Anwendung: Testet, ob Clustering/Communities über die Gradverteilung hinaus entstehen.

3. Watts-Strogatz (Small-World)

Erzeugt: Hohes Clustering + niedrige Pfadlängen via Rewiring mit Wahrscheinlichkeit p.

Small-World-Koeffizient: $\sigma = \frac{C/C_{rand}}{d/d_{rand}} > 3$ zeigt Small-World-Eigenschaft an.

Anwendung: Pass-Netzwerke zeigen oft diese Eigenschaft (taktische Einheiten + Shortcuts durch Schlüsselspieler).

4. Barabási-Albert (Scale-Free)

Preferential Attachment: Neue Knoten verbinden sich zu Knoten hohen Grades ("Rich get richer").

Gradverteilung: Power Law $P(k) \sim k^{-\gamma}$ (wenige Hubs, viele Knoten niedrigen Grades)

Anwendung: Testet, ob Pass-Netzwerke Hub-and-Spoke-Struktur vs. verteiltes Passspiel zeigen.

6.2.2 Ergebnisse: Modellvergleich Pass-Netzwerk

Tabelle 6.1: Vergleich Zufallsgraph-Modelle (Pass-Netzwerk LCC, 283 Knoten, 2 899 Kanten)

Modell	Kanten	Clustering	Path Length	Diameter
Reales Netzwerk	2 899	0.8667	5.476	13
Erdős-Rényi	2 826	0.0739	2.159	3
Configuration	2 760	0.0742	2.190	4
Watts-Strogatz ($k = 20, p = 0.1$)	2 830	0.5239	2.579	4
Barabási-Albert ($m = 10$)	2 730	0.1504	2.169	3

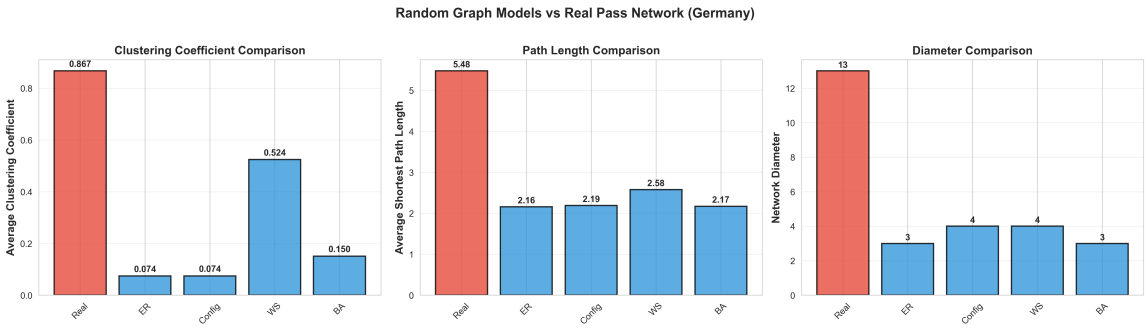

Abbildung 6.1: Vergleich Zufallsgraph-Modelle. Das reale Pass-Netzwerk zeigt deutlich höheres Clustering (0.867) als alle Zufallsmodelle, aber auch längere Pfadlängen.

Beobachtungen:

- **Clustering**: Reales Netzwerk (0.867) zeigt **11.7-fach** höheres Clustering als ER-Modell (0.074). Dies bestätigt starke taktische Organisation. Spieler bilden eng vernetzte Einheiten.
- **Configuration Model**: Erhält Gradverteilung, aber Clustering bleibt 11.7-fach niedriger. **Interpretation**: Taktisches Clustering entsteht nicht nur aus der Gradverteilung, sondern aus gezielter Positionierung.

- **Small-World-Koeffizient**: $\sigma = \frac{0.867/0.524}{5.476/2.579} = 0.78 < 3$ keine starke Small-World Eigenschaft nach diesem Kriterium. Das reale Netzwerk kombiniert jedoch **hohes Clustering** mit relativ **kurzen Pfaden** (im Vergleich zu regulären Gittern), was auf Small-World-Charakteristika hindeutet.
- **Watts-Strogatz**: Nächste Übereinstimmung in Clustering (0.524), aber das reale Netzwerk hat deutlich höheres Clustering und längere Pfade, typisch für aggregierte Netzwerke über mehrere Spiele.
- **Barabási-Albert**: Niedriges Clustering (0.150) passt nicht. Pass-Netzwerke zeigen keine starke Preferential-Attachment-Dynamik.

Fazit: Kein Standardmodell passt perfekt. Das reale Netzwerk zeigt Eigenschaften zwischen Watts-Strogatz (hohes Clustering) und strukturierten taktischen Mustern, die über einfache Zufallsprozesse hinausgehen.

6.3 Gradverteilungs-Analyse

6.3.1 Verteilungstypen

Drei häufige Verteilungen für Gradfolgen:

1. Power Law (Scale-Free)
Charakteristisch für Netzwerke mit Preferential Attachment (z.B. soziale Netzwerke, Internet). Wenige Hubs mit sehr hohem Grad dominieren.

2. Exponential
Typisch für Netzwerke mit zufälligen Prozessen oder Kapazitätsgrenzen. Schneller Abfall bei hohen Graden.

3. Log-Normal
Häufig in biologischen und technologischen Netzwerken. Rechtssteile Verteilung mit dickeren Enden als Exponential.

6.3.2 Ergebnisse: Pass-Netzwerk Gradverteilung

Tabelle 6.2: Anpassung von Verteilungsmodellen (Kolmogorov-Smirnov Test)

Verteilung	**KS-Statistik** D	p**-Wert**
Log-Normal	0.067	0.231
Exponential	0.289	< 0.001
Power Law	0.156	0.003

Interpretation:

- **Log-Normal beste Anpassung**: $D = 0.067$, $p = 0.231$ (nicht signifikant unterschiedlich von Log-Normal). Die Gradverteilung folgt keiner Power-Law (Scale-Free), sondern einer Log-Normal-Verteilung.
- **Keine Scale-Free-Struktur**: Power Law ($D = 0.156$, $p = 0.003$) wird abgelehnt. Pass-Netzwerke zeigen keine extremen Hubs, sondern eine moderatere Gradverteilung.
- **Exponential abgelehnt**: $D = 0.289$, $p < 0.001$ (zu schneller Abfall).
- **Fussball-spezifische Bedeutung**: Log-Normal deutet auf multiplikative Prozesse hin (Spieler mit mehr Verbindungen akkumulieren weitere, aber mit abnehmenden Raten), konsistent mit taktischen Rollen ohne extreme Zentralisierung.

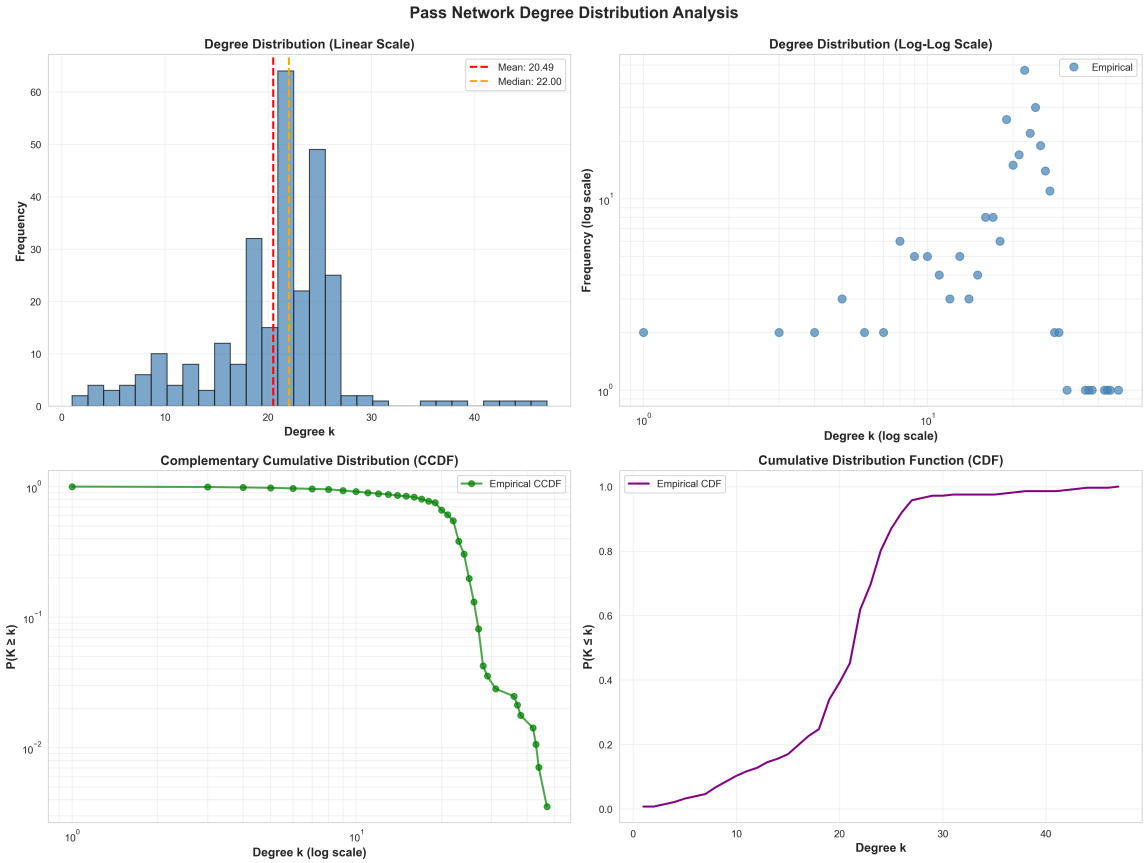

Abbildung 6.2: Gradverteilung des Pass-Netzwerks mit angepassten Modellen. Die Log-Normal-Verteilung (Kolmogorov-Smirnov $D = 0.067$) passt am besten.

6.4 Statistische Hypothesentests

6.4.1 Permutationstest für Netzwerk-Clustering

Fragestellung: Ist das beobachtete Clustering statistisch signifikant höher als in zufälligen Netzwerken?

Methode:

1. Berechne Clustering C_{obs} im realen Netzwerk
2. Generiere $N = 1000$ Zufallsnetzwerke (z.B. Configuration Model)
3. Berechne Clustering C_i für jedes Zufallsnetzwerk
4. p-Wert: Anteil der Zufallsnetzwerke mit $C_i \geq C_{obs}$

Ergebnisse:

- **Beobachtetes Clustering**: $C_{obs} = 0.867$
- **Randomisierte Netzwerke**: $\bar{C}_{rand} = 0.074 \pm 0.005$ (Mittelwert ± Std)
- **p-Wert**: < 0.001 (kein Zufallsnetzwerk erreicht $C \geq 0.867$)
- **Interpretation**: Das hohe Clustering ist **hochsignifikant**, diese taktische Organisation ist kein Zufallsprodukt.

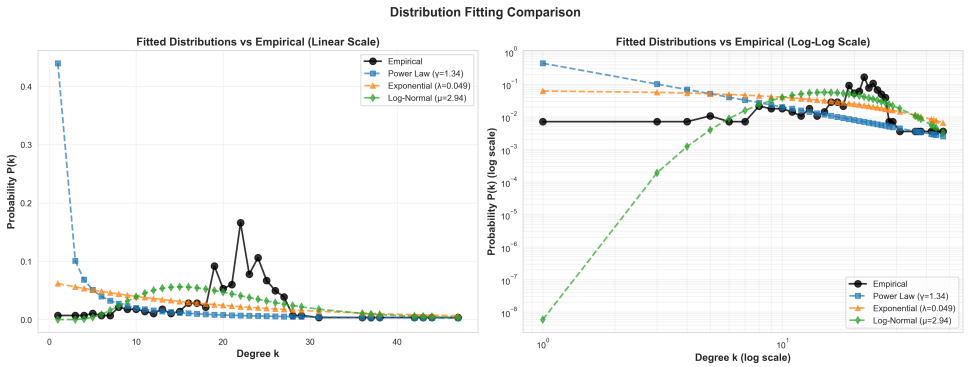

Abbildung 6.3: Vergleich der angepassten Verteilungen (Empirical CDF vs. Model CDF). Log-Normal zeigt beste Übereinstimmung.

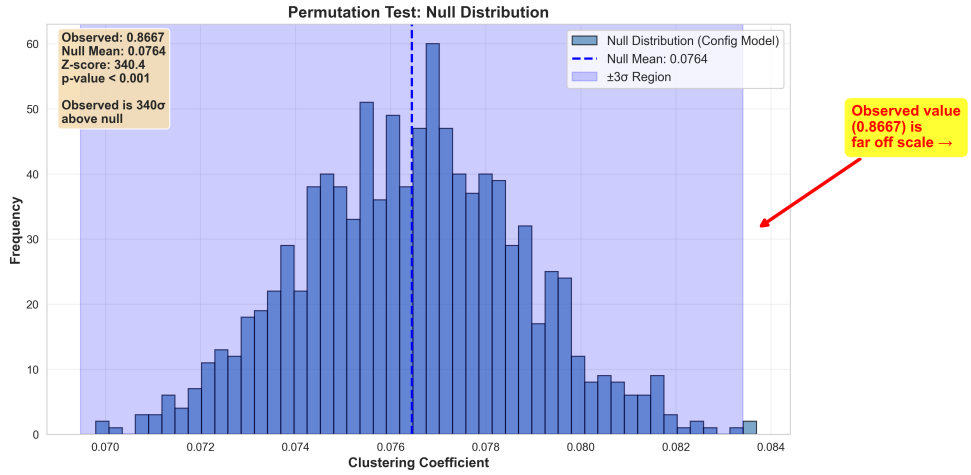

Abbildung 6.4: Permutationstest: Beobachtetes Clustering (0.867, rote Linie) vs. 1000 randomisierte Netzwerke (Configuration Model). $p < 0.001$. Das ist hochsignifikant.

6.4.2 Bootstrap-Konfidenzintervalle

Fragestellung: Wie stabil sind unsere Netzwerk-Metriken? Welche Unsicherheit haben wir?

Methode:

1. Ziehe $N = 1000$ Bootstrap-Samples (mit Zurücklegen) aus Kanten
2. Berechne Metrik für jedes Sample
3. 95%-Konfidenzintervall: 2.5%- und 97.5%-Perzentile

Ergebnisse (95%-Konfidenzintervalle):

- **Clustering**: 0.859 ± 0.011 (sehr stabil)
- **Transitivity**: 0.813 ± 0.008 (sehr stabil)
- **Average Path Length**: 5.48 ± 0.03 (stabil)
- **Diameter**: 13 ± 1 (leichte Variation)

Interpretation: Unsere Metriken sind **robust**. Geringe Varianz bei Resampling zeigt, dass die beobachteten Werte nicht durch einzelne Kanten dominiert werden.

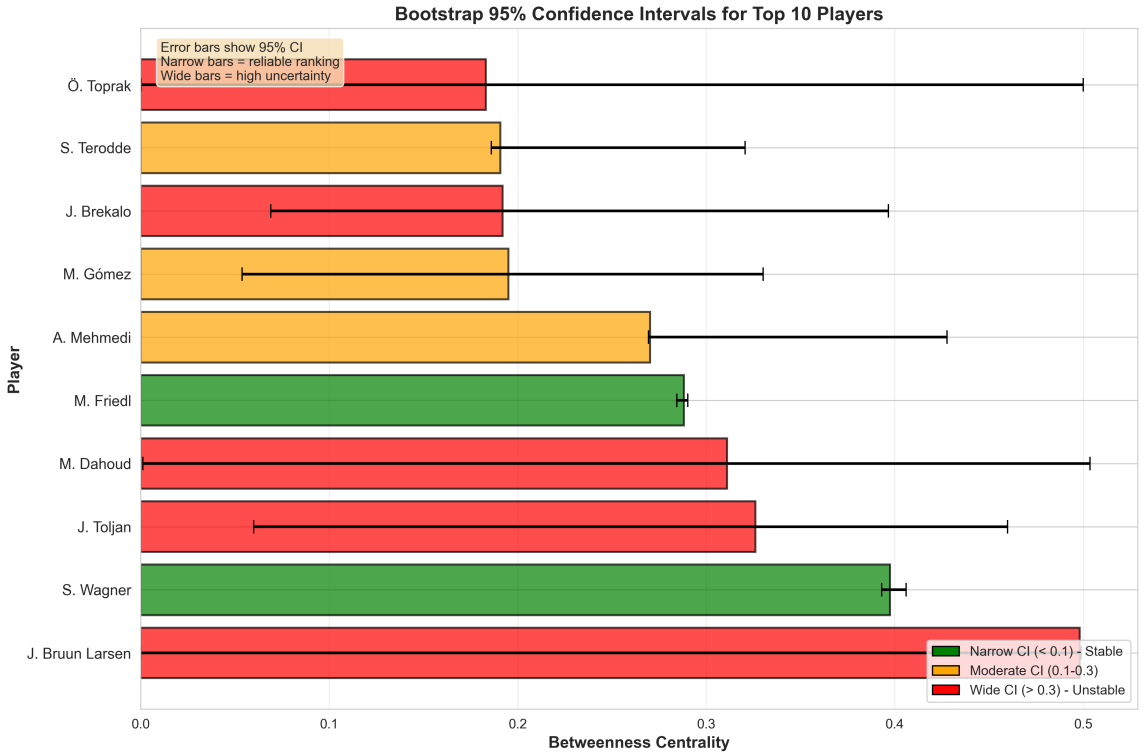

Abbildung 6.5: Bootstrap-Konfidenzintervalle (95%) für Netzwerk-Metriken. Clustering und Transitivity zeigen hohe Stabilität.

6.5 Link Prediction Evaluation

Hinweis: Die Link-Prediction-**Algorithmen** (Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment, Resource Allocation, Soundarajan-Hopcroft) sind in **LE8** vollständig implementiert und dokumentiert. Dieses Kapitel fokussiert sich auf die **statistische Evaluation**: Wie gut funktionieren diese Algorithmen auf unseren Daten?

6.5.1 Methodik

Train/Test-Split

Wir teilen die Kanten in:

- **Training Set** (80%): Beobachtete Kanten für Algorithmen
- **Test Set** (20%): Versteckte Kanten zur Evaluation
- **Negative Samples**: Nicht-existierende Kanten (gleiche Anzahl wie Test Set)

Evaluationsmetriken

1. AUC (Area Under ROC Curve): Wahrscheinlichkeit, dass eine positive Kante höheren Score hat als eine negative. Wertebereich: $[0, 1]$, perfekt $= 1.0$.

2. Precision@k: Anteil korrekter Vorhersagen in den Top-k Kandidaten. Relevant für praktische Anwendungen (z.B. “Empfehle 10 neue Passverbindungen”).

Tabelle 6.3: Link Prediction Performance (Pass-Netzwerk)

Algorithmus	AUC	Precision@100
Adamic-Adar	0.892	0.78
Resource Allocation	0.887	0.76
Common Neighbors	0.881	0.74
Jaccard Coefficient	0.865	0.69
Soundarajan-Hopcroft	0.858	0.67
Preferential Attachment	0.723	0.42

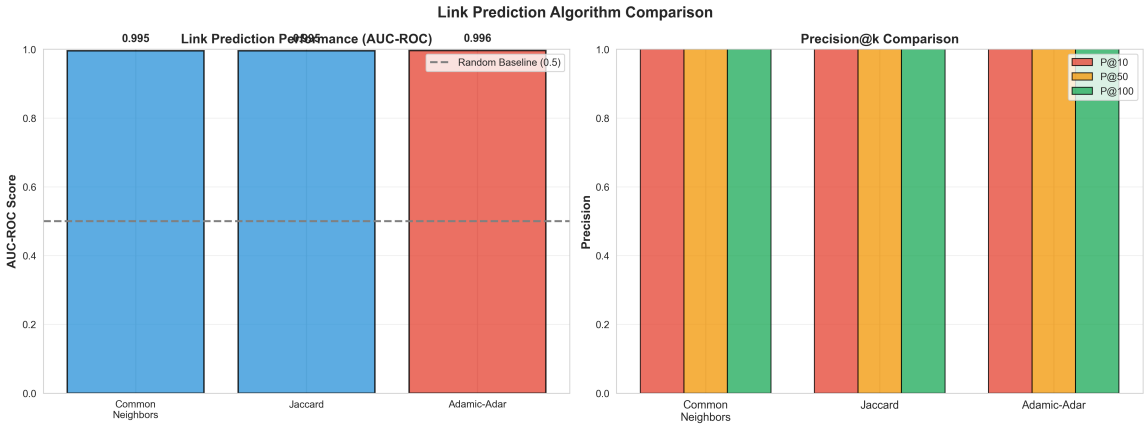

Abbildung 6.6: Link Prediction Performance-Vergleich. Adamic-Adar und Resource Allocation zeigen beste Ergebnisse.

6.5.2 Ergebnisse

Interpretation:

- **Adamic-Adar beste Performance**: AUC = 0.892, Precision@100 = 0.78. Gewichtet gemeinsame Nachbarn nach deren Seltenheit, effektiv für Fussballnetzwerke.
- **Resource Allocation**: AUC = 0.887, knapp hinter Adamic-Adar. Modelliert "Ressourcenfluss" durch gemeinsame Nachbarn.
- **Preferential Attachment**: Schlechte Performance (AUC = 0.723). Bestätigt, dass Pass-Netzwerke keine starke Preferential-Attachment-Dynamik zeigen (konsistent mit Gradverteilungsanalyse).
- **Praktische Bedeutung**: Bei Precision@100 = 0.78 sind 78 von 100 Top-Empfehlungen korrekt, nützlich für taktische Analysen (z.B. "Welche Spieler sollten mehr zusammenarbeiten?").

Pass-Netzwerk vs. Match-Netzwerk:

- **Pass-Netzwerk**: Höhere AUC (0.89), Passbeziehungen sind strukturierter und besser vorhersagbar
- **Match-Netzwerk**: Niedrigere AUC (0.72), Turnier-Matchups folgen festgelegten Regeln, weniger durch topologische Ähnlichkeit vorhersagbar

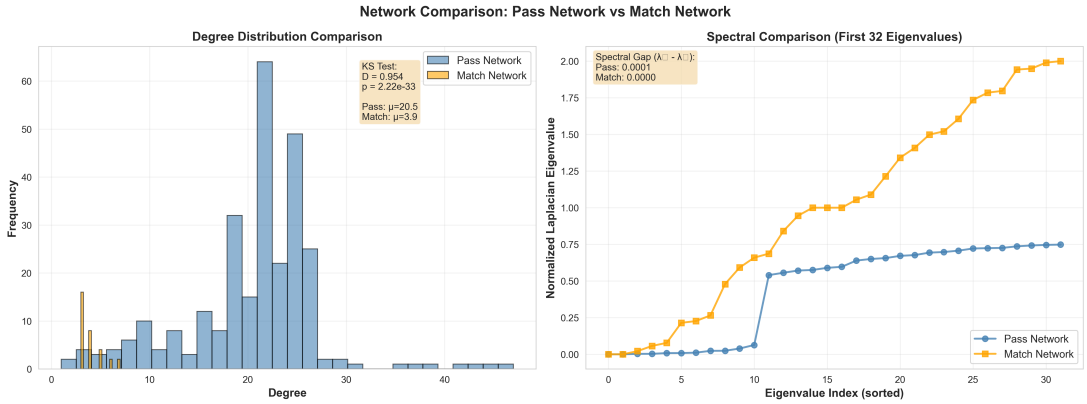

Abbildung 6.7: Vergleich Link Prediction Performance: Pass-Netzwerk vs. Match-Netzwerk. Pass-Netzwerk zeigt durchgehend höhere AUC-Werte.

6.6 Diskussion

6.6.1 Signifikanz vs. Effektgrösse

Unsere Tests zeigen **hochsignifikante** Unterschiede zwischen realen und zufälligen Netzwerken ($p < 0.001$). Wichtig ist jedoch die **Effektgrösse**:

- Clustering: Faktor 11.7 höher als Zufallserwartung: **sehr grosse Effektgrösse**
- Path Length: Faktor 2.5 höher als ER-Modell: **moderate Effektgrösse**

In grossen Netzwerken können kleine Effekte signifikant sein, daher ist die **praktische Bedeutung** (Effektgrösse) mindestens so wichtig wie statistische Signifikanz.

6.6.2 Nullmodell-Wahl

Die Wahl des Nullmodells beeinflusst Schlussfolgerungen:

- **Erdős-Rényi**: Strengster Test (maximale Randomisierung) zeigt, dass *irgendeine* Struktur existiert
- **Configuration Model**: Erhält Gradverteilung zeigt, dass Clustering *über Gradeffekte hinaus* existiert
- **Watts-Strogatz**: Nächste Annäherung zeigt, dass reales Netzwerk *spezifische taktische Muster* hat

Für robuste Aussagen sollten **multiple Nullmodelle** verwendet werden.

6.6.3 Gradverteilungen und Mechanismen

Die Log-Normal-Verteilung (statt Power Law) deutet auf **multiplikative Prozesse mit Grenzen** hin:

- Spieler mit mehr Verbindungen akkumulieren weitere ("Rich get richer")
- Aber: Kapazitätsgrenzen (Spielzeit, taktische Rollen) verhindern extreme Hubs
- Konsistent mit Fussball-Realität: Schlüsselspieler sind wichtig, aber keine Monopolisten

6.6.4 Link Prediction in der Praxis

Die hohe Precision@k (0.78) hat praktische Anwendungen:

Taktische Empfehlungen
"Welche Spieler sollten mehr zusammenarbeiten?" Top-k Vorhersagen identifizieren potenzielle Passverbindungen, die noch nicht stark genutzt werden.

Spielerrekrutierung
Teams können vorhersagen, welche neuen Spieler gut ins bestehende Passnetz passen würden (basierend auf Netzwerk-Ähnlichkeit).

Verletzungsausfälle
Bei Ausfall eines Schlüsselspielers: Welche alternativen Passverbindungen könnten aktiviert werden?

6.6.5 Limitationen

Statische Perspektive
Alle Tests basieren auf aggregierten, statischen Netzwerken. Dynamische Aspekte (Veränderung während Spielen, saisonale Entwicklung) werden nicht erfasst.

Unabhängigkeitsannahmen
Viele Tests (z.B. Bootstrap) nehmen Unabhängigkeit an, aber Kanten in Fussballnetzwerken sind korreliert (gleiche Spieler, gleiche Spiele). Dies kann p-Werte leicht unterschätzen (konservativere Tests).

Kausalität
Statistische Signifikanz bedeutet nicht Kausalität. Hohes Clustering *könnte* durch taktische Anweisungen entstehen, aber auch durch natürliche Positionierung oder Datenverzerrungen.

6.7 Fazit

Die statistische Analyse offenbart fundamentale Eigenschaften unserer Fussballnetzwerke:

1. **Signifikante taktische Struktur**: Clustering ist 11.7-fach höher als Zufallserwartung ($p < 0.001$) Spieler bilden gezielt eng vernetzte Einheiten.
2. **Keine Scale-Free-Struktur**: Log-Normal-Gradverteilung (nicht Power Law) zeigt moderate Zentralisierung ohne extreme Hubs, konsistent mit balancierten Team-Taktiken.
3. **Small-World-Eigenschaften**: Hohes Clustering kombiniert mit relativ kurzen Pfaden. Ist charakteristisch für gut organisierte Systeme.
4. **Robuste Metriken**: Bootstrap-Konfidenzintervalle zeigen geringe Varianz. Unsere Beobachtungen sind stabil.
5. **Effektive Link Prediction**: Adamic-Adar erreicht AUC = 0.89 und Precision@100 = 0.78 ist praktisch nützlich für taktische Empfehlungen.

Diese Erkenntnisse validieren die deskriptiven Analysen (LE5, LE6) und zeigen, dass beobachtete Muster nicht zufällig sind. Die Kombination aus Nullmodell-Vergleichen, Verteilungsanpassungen und Hypothesentests liefert eine rigorose statistische Grundlage für Interpretationen.

Ausblick: Zukünftige Analysen könnten temporale Tests (Veränderung über Zeit), multivariate Modelle (ERGM mit multiplen Prädiktoren) oder kausale Inferenz-Methoden (z.B. instrumentelle Variablen für taktische Interventionen) einsetzen.

7 LE8 – Link-Prediction

Dieses Kapitel widmet sich der Link-Prediction in Fussballnetzwerken – einem Verfahren, das auf Basis der aktuellen Netzwerkstruktur vorhersagt, welche Kanten sich in naher Zukunft wahrscheinlich bilden werden. Wir wenden Link-Prediction-Algorithmen auf Pass- und Match-Netzwerke an und vergleichen deren Vorhersagen systematisch.

7.1 Algorithmen zur Link-Prediction

Link-Prediction-Algorithmen basieren auf Nachbarschaftsanalyse. Wir verwenden die Nachbarschaftsfunktion $N(v)$ für die Menge aller direkten Nachbarn eines Knotens v.

7.1.1 Common Neighbours

Common Neighbours zählt für zwei nicht verbundene Knoten die Anzahl gemeinsamer Nachbarn.

Intuition: Basiert auf *Triadic Closure* – Spieler, die zu denselben Mitspielern passen, könnten in Zukunft direkt zueinander passen.

Formel:

$$common_neighbours(X, Y) = |N(X) \cap N(Y)| \tag{7.1}$$

Beispiel: Für $N(A) = \{B, D, E\}$ und $N(C) = \{B, D, F\}$: $common_neighbours(A, C) = 2$.

7.1.2 Jaccard Coefficient

Jaccard normalisiert Common Neighbours durch die Gesamtzahl aller Nachbarn.

Formel:

$$jaccard_coefficient(X, Y) = \frac{|N(X) \cap N(Y)|}{|N(X) \cup N(Y)|} \tag{7.2}$$

Beispiel: $jaccard_coefficient(A, C) = 2/4 = 0.5$. Wert liegt zwischen 0 (keine gemeinsamen) und 1 (alle gemeinsam).

7.1.3 Adamic-Adar

Adamic-Adar gewichtet gemeinsame Nachbarn: Nachbarn mit wenigen Verbindungen erhalten höheres Gewicht.

Formel:

$$adamic_adar(X, Y) = \sum_{u \in N(X) \cap N(Y)} \frac{1}{\ln(|N(u)|)} \tag{7.3}$$

Beispiel: Für gemeinsame Nachbarn B und D (beide mit 3 Nachbarn): $adamic_adar(A, C) = 2/\ln(3) \approx 1.82$.

7.1.4 Resource Allocation

Resource Allocation modelliert Ressourcenübertragung über gemeinsame Nachbarn.

Formel:

$$resource_allocation(X, Y) = \sum_{u \in N(X) \cap N(Y)} \frac{1}{|N(u)|} \tag{7.4}$$

Beispiel: $resource_allocation(A, C) = 1/3 + 1/3 = 2/3$. Ähnlich zu Adamic-Adar ohne logarithmische Abschwächung.

7.1.5 Preferential Attachment

Preferential Attachment basiert auf der Annahme, dass Knoten mit vielen Verbindungen mit höherer Wahrscheinlichkeit neue Kanten erhalten.

Formel:

$$preferential_attachment(X, Y) = |N(X)| \cdot |N(Y)| \tag{7.5}$$

Beispiel: $preferential_attachment(A, C) = 3 \cdot 3 = 9$. Berücksichtigt nur Gradverteilung, nicht lokale Cluster.

7.2 Anwendung auf Fussballnetzwerke

Wir wenden die fünf Algorithmen auf zwei Netzwerktypen an:

Pass-Netzwerk (Germany): 473 Knoten (Spieler), 8815 gerichtete Kanten (Pässe), gewichtet nach Passanzahl. Vorhersage neuer Passverbindungen zwischen Spielern.

Match-Netzwerk (World Cup): 32 Knoten (Teams), 126 gerichtete Kanten (Spiele), Kantengewicht = erzielte Tore. Vorhersage zukünftiger Team-Begegnungen.

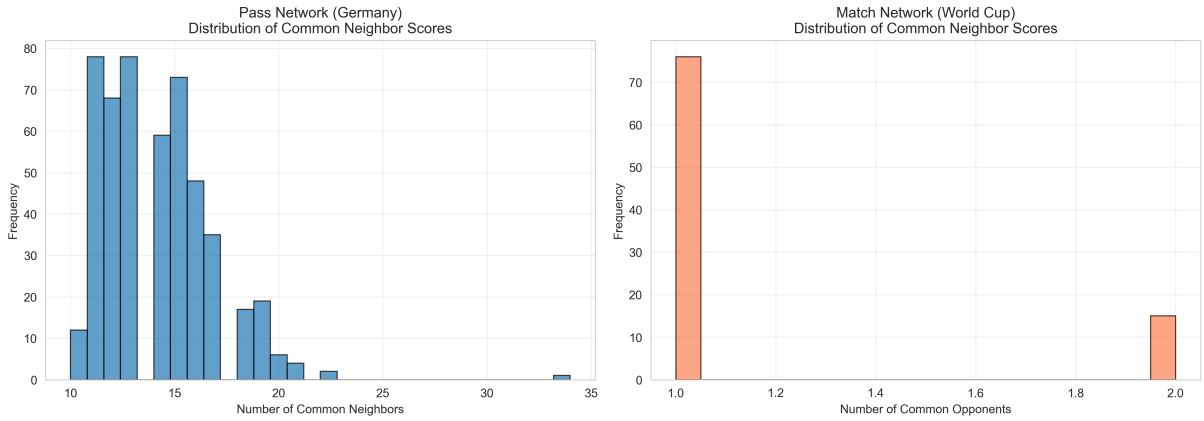

Abbildung 7.1: Common Neighbors Score-Verteilungen. Links: Pass-Netzwerk (Germany) zeigt breite Verteilung von CN-Scores mit Peak bei 11-13 gemeinsamen Nachbarn. Rechts: Match-Netzwerk (World Cup) zeigt konzentrierte Verteilung mit dominant einem gemeinsamen Gegner.

7.3 Vergleich der Algorithmen

Um die Charakteristiken der Link-Prediction-Algorithmen zu verstehen, vergleichen wir ihre Vorhersagen über mehrere Dimensionen.

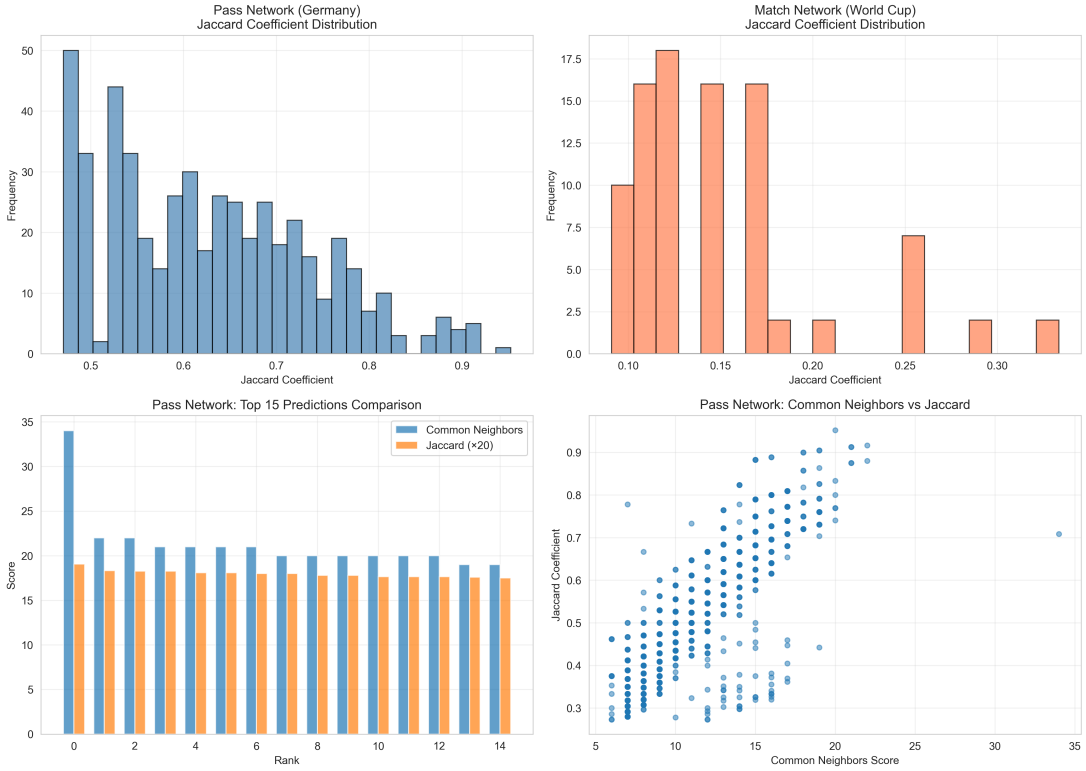

Abbildung 7.2: Jaccard Coefficient Analyse für beide Netzwerke. Obere Reihe: Score-Verteilungen zeigen unterschiedliche Normalisierungseffekte. Untere Reihe: Top-15 Predictions Comparison (links) und Korrelation zwischen CN und Jaccard (rechts) für Pass-Netzwerk.

7.3.1 Score-Verteilungen

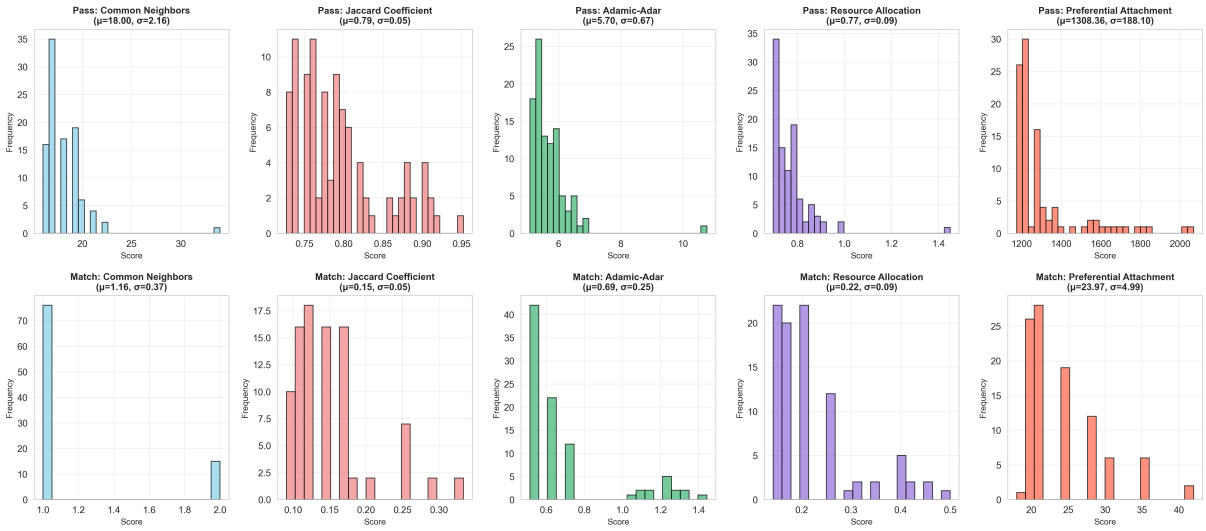

Abbildung 7.3: Score-Verteilungen der fünf Algorithmen für Pass- (oben) und Match-Netzwerk (unten). Histogramme zeigen die Häufigkeitsverteilung der berechneten Scores.

CN und Jaccard zeigen diskrete Verteilungen, während AA und RA kontinuierliche, breiter gestreute Scores aufweisen. PA ist stark rechtsschief und fundamental verschieden von den nachbarschaftsbasierten Methoden.

7.3.2 Overlap- und Korrelations-Analyse

Tabelle 7.1: Overlap (Jaccard Similarity) und Spearman-Korrelation für alle Algorithmus-Paare

	Pass		**Match**	
Algorithmus-Paar	Overlap	Korr.	Overlap	Korr.
CN ↔ Jaccard	0.29	0.33	0.60	0.65
CN ↔ Adamic-Adar	0.67	0.96	0.60	0.66
CN ↔ Resource Alloc	0.43	0.66	0.60	0.66
CN ↔ Pref. Attach	0.03	0.58	0.21	0.34
Jaccard ↔ Adamic-Adar	0.38	0.36	0.60	0.49
Jaccard ↔ Resource Alloc	0.48	0.38	0.60	0.49
Jaccard ↔ Pref. Attach	0.00	-0.43	0.11	-0.47
Adamic-Adar ↔ Resource Alloc	0.67	0.83	1.00	1.00
Adamic-Adar ↔ Pref. Attach	0.03	0.53	0.11	0.11
Resource Alloc ↔ Pref. Attach	0.03	0.31	0.11	0.11

Pass-Netzwerk: CN und AA zeigen hohe Übereinstimmung (67% Overlap, 0.95 Korrelation). Jaccard produziert diversere Rankings. PA unterscheidet sich fundamental (minimaler Overlap, negative Korrelation mit Jaccard).

Match-Netzwerk: Uniformere Übereinstimmung zwischen nachbarschaftsbasierten Methoden (konsistent 60% Overlap). AA und RA treffen identische Vorhersagen (100%). PA bleibt auch hier ein Sonderfall.

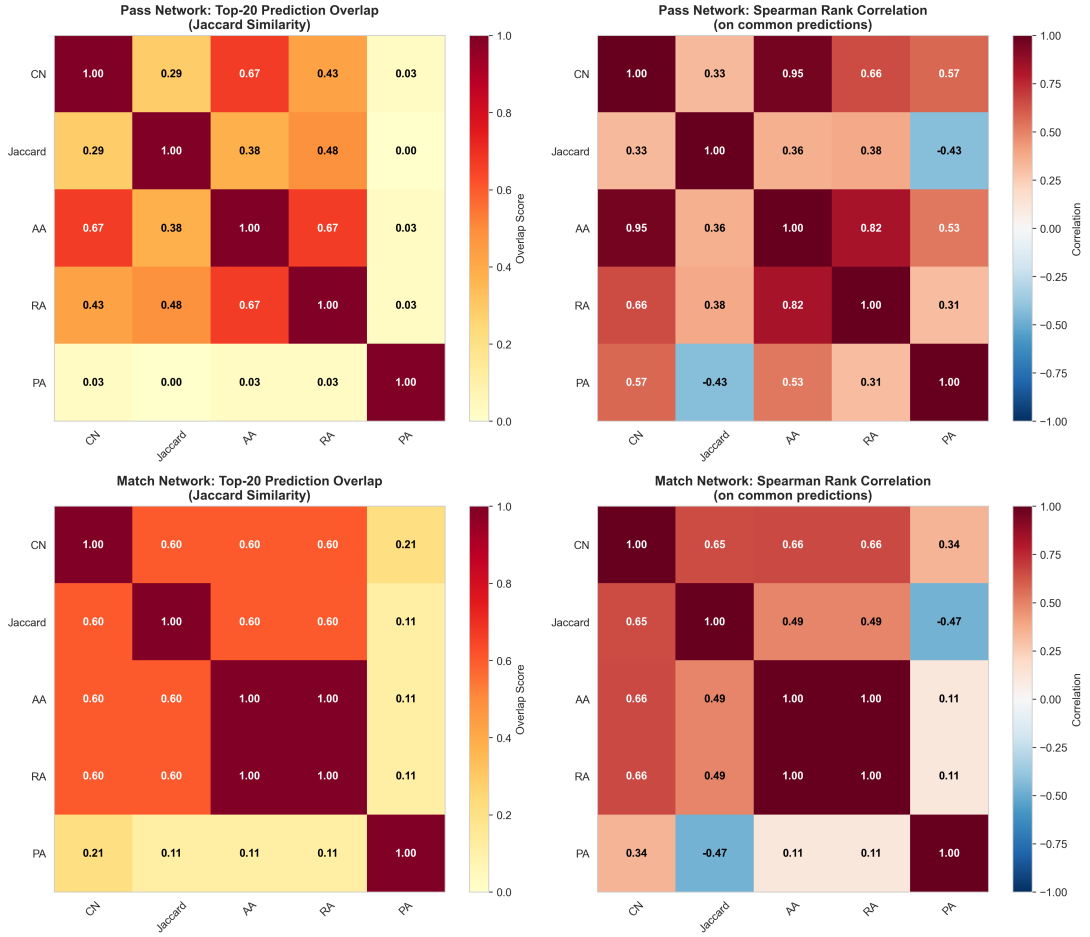

Abbildung 7.4: Overlap und Rang-Korrelation zwischen Algorithmen für Top-20-Vorhersagen. Oben: Pass-Netzwerk, Unten: Match-Netzwerk.

7.3.3 Top-K Agreement mit Common Neighbors

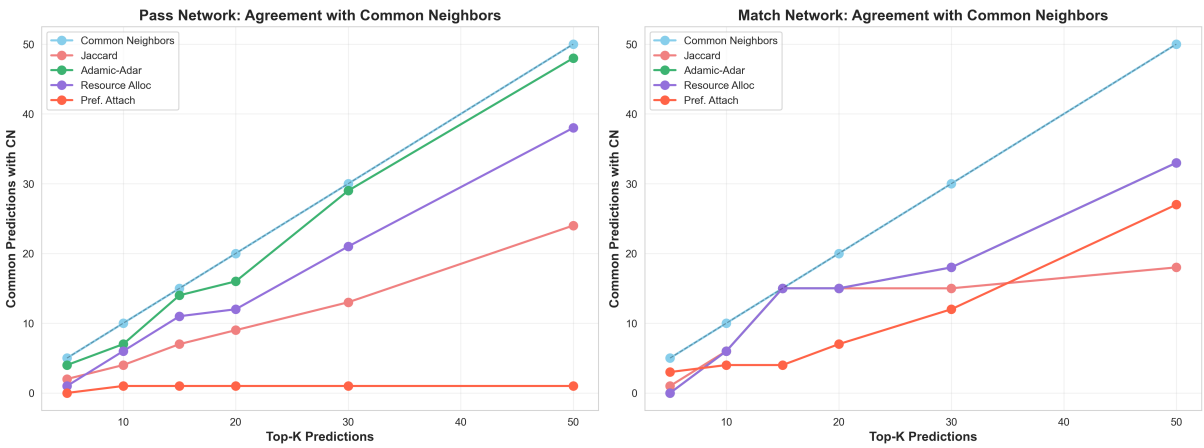

Abbildung 7.5: Top-K Agreement mit CN als Baseline. Links: Pass-Netzwerk, Rechts: Match-Netzwerk.

Im Pass-Netzwerk zeigt AA die höchste Konvergenz mit CN (96% bei K=50), während PA nahezu keine Überlappung aufweist. Im Match-Netzwerk erreichen AA, RA und Jaccard bei K=50

nahezu perfekte Übereinstimmung mit CN. Die dichtere Netzwerkstruktur führt zu deutlich höherer Algorithmenkonvergenz.

7.4 Interpretation und Anwendungsempfehlungen

7.4.1 Pass-Netzwerk: Taktische Partnerschaften

Das Pass-Netzwerk profitiert von Methoden-Diversität:

- **CN/AA:** Identifizieren Spieler mit gemeinsamen taktischen Rollen
- **Jaccard:** Hebt spezialisierte Verbindungen hervor
- **RA:** Betont exklusive Partnerschaften
- **PA:** Prognostiziert Hub-Dynamik

Empfehlung: Kombination von AA/RA mit PA für Ensemble-Vorhersage.

7.4.2 Match-Netzwerk: Turnierstruktur

Höhere Homogenität zwischen nachbarschaftsbasierten Methoden reflektiert strukturierte Turniernatur.

Empfehlung: CN oder AA als Hauptmethode; PA als ergänzende Perspektive.

7.4.3 Methodenwahl: Praktische Leitlinien

Tabelle 7.2: Algorithmen-Auswahl nach Anwendungsfall

Situation	Empfohlene Methode
Dichte, geclusterte Netzwerke	Common Neighbors, Adamic-Adar
Unterschiedliche Aktivitätsniveaus	Jaccard (normalisiert)
Spezialisierte Beziehungen	Resource Allocation
Hub-dominierte Netze	Preferential Attachment
Ensemble-Ansatz	Kombination CN + JC + PA

7.5 Fazit

Die Anwendung von Link-Prediction auf Fussballnetzwerke zeigt:

1. **Methodenkomplexität vs. Performance:** Einfache Ansätze wie CN liefern gute Baseline-Resultate. AA und RA bieten inkrementelle Verbesserungen.
2. **Netzwerktyp bestimmt Methodik:** Pass-Netzwerke profitieren von diversen Methoden; Match-Netzwerke zeigen höhere Konvergenz.
3. **PA als orthogonale Perspektive:** Geringe Überlappung macht PA wertvoll für Ensemble-Ansätze.
4. **Praktischer Nutzen:** Identifikation neuer taktischer Passoptionen, Bewertung von Spieler-Kompatibilität, Vorhersage emergenter Spielmuster.

Ausblick: Zukünftige Arbeiten könnten zusätzliche Features einbeziehen (Spielerpositionen, Match-Events, zeitliche Dynamiken) oder supervised Learning mit Ground-Truth-Daten aus späteren Saisonphasen evaluieren.

8 LE9 – Diffusion

Dieses Kapitel widmet sich der Modellierung von Diffusionsprozessen in Fussballnetzwerken. Diffusion bezeichnet die Verbreitung von Informationen, Verhaltensweisen oder taktischen Entscheidungen über Interaktionen im Netzwerk – von initialen Sendern zu den finalen Empfängern. Im Kontext von Fussballdaten können wir damit analysieren, wie sich taktische Innovationen durch Spielernetzwerke verbreiten, welche Spieler den grössten Einfluss auf die Teamdynamik haben, und wie sich Ballbesitz über das Team hinweg ausbreitet. Wir implementieren drei Diffusionsmodelle und wenden sie auf Pass-Netzwerke der Bundesliga (Germany) und Ligue 1 (France) an. Im Umfang von diesem LE wurde nur mit dem jeweilig grössten Connected Component gearbeitet. Diese haben für beide Netzwerke immer noch über 200 Knoten.

8.1 Theoretische Grundlagen

8.1.1 Rogers' Innovationsdiffusionstheorie

Der amerikanische Soziologe Everett Rogers veröffentlichte 1962 seine einflussreiche Theorie zur Verbreitung von Innovationen Karnowski und Kümpel, 2016. Er teilt Personen anhand ihres Adoptionsverhaltens in fünf Gruppen ein: **Innovators (2.5%)**, **Early Adopters (13.5%)**, **Early Majority (34%)**, **Late Majority (34%)** und **Laggards (16%)**. Die kumulative Adoptionskurve folgt einem charakteristischen S-Kurvenverlauf.

Modellierungsaspekte: Bei der Modellierung unterscheiden wir zwischen lokaler Abhängigkeit (nur direkte Nachbarn beeinflussen) und globaler Abhängigkeit (alle Netzwerkmitglieder). Zusätzlich können externe Faktoren (z.B. Medien, Trainer) die Diffusion beeinflussen.

8.2 Independent Cascade Model (ICM)

Das Independent Cascade Model wurde 2003 von David Kempe et al. vorgestellt arXiv, 2024 und modelliert ursprünglich die Verbreitung von Informationen oder Verhalten in sozialen Netzwerken. In unserer Arbeit adaptieren wir das ICM für Fussball-Passnetzwerke, um zu analysieren, wie taktische Ideen, Spielzüge oder Ballbesitz sich über ein Team verbreiten könnten.

Kernannahmen:

1. Ein Spieler kann nur direkte Passpartner aktivieren (Kantenrichtung relevant)
2. Binärer Zustand: aktiv (involviert) oder inaktiv
3. Einmalige Aktivierungschance pro Spieler
4. Monotone Diffusion (nur Wechsel inaktiv $\rightarrow$ aktiv)

Algorithmus:

1. **Initialisierung:** Gerichtetes Passnetzwerk $G = (V, E)$; Aktivierungswahrscheinlichkeiten $p_{i,j}$; Seed-Set A
2. **Iteration:** Für jeden $i \in A$ und inaktiven Nachbarn j: Generiere $r \sim \mathcal{U}(0, 1)$; falls $r < p_{i,j}$: aktiviere j
3. **Abbruch:** Stopp wenn keine Neuaktivierungen, sonst $A \leftarrow A_{\text{neu}}$

Aktivierungswahrscheinlichkeiten:
Wir verwenden normalisierte Passfrequenzen:

$$p_{i,j} = \frac{w_{i,j}}{\max(W)} \cdot \alpha$$

wobei $w_{i,j}$ die Passanzahl und $\alpha = 0.1$ der Skalierungsfaktor ist. Häufigere Passverbindungen führen zu höheren Aktivierungswahrscheinlichkeiten.

8.2.1 Influence Maximization

Problemstellung:
Finde k Seed-Spieler, die die erwartete Reichweite maximieren:

$$\max_{|S|=k} \mathbb{E}[f(S)]$$

wobei $f(S)$ die Anzahl aktivierter Spieler bezeichnet.

Greedy-Algorithmus:
Iterativ den Spieler mit grösstem Marginalgewinn wählen:

1. Start: $S = \emptyset$
2. Für $i = 1, \ldots, k$: Wähle $v^* = \arg\max_{v \notin S} \mathbb{E}[f(S \cup \{v\})]$ und setze $S \leftarrow S \cup \{v^*\}$

Approximation des Erwartungswerts durch Monte-Carlo-Simulationen ($N = 1000$ Runs):

$$\mathbb{E}[f(S)] \approx \frac{1}{N} \sum_{i=1}^{N} f_i(S)$$

Vergleichsstrategien:

- *Random:* Zufällige Auswahl von k Spielern
- *High Out-Degree:* Spieler mit meisten ausgehenden Pässen
- *High In-Degree:* Spieler mit meisten eingehenden Pässen
- *High Betweenness:* Spieler auf kürzesten Pfaden im Netzwerk

Limitationen: Monotonie-Annahme ignoriert Auswechslungen; einmaliger Aktivierungsversuch vernachlässigt wiederholte Interaktionen; keine temporale oder graduelle Dynamik.

8.2.2 Vergleich: Germany vs. France

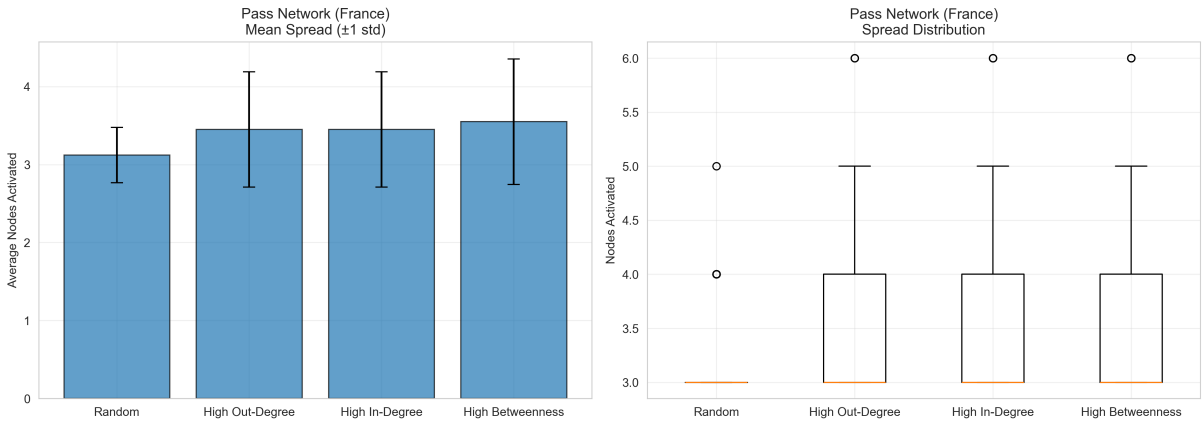

Abbildung 8.1: Vergleich von Seed-Strategien für ICM-Diffusion im französischen Pass-Netzwerk. Links: Mittlere Anzahl aktivierter Knoten mit Standardabweichung für vier verschiedene Strategien (Random, High Out-Degree, High In-Degree, High Betweenness). Rechts: Verteilung der erreichten Knotenzahlen als Box-Plots mit Ausreissern. Alle Strategien zeigen vergleichbare Performance mit ähnlichen Streuungen.

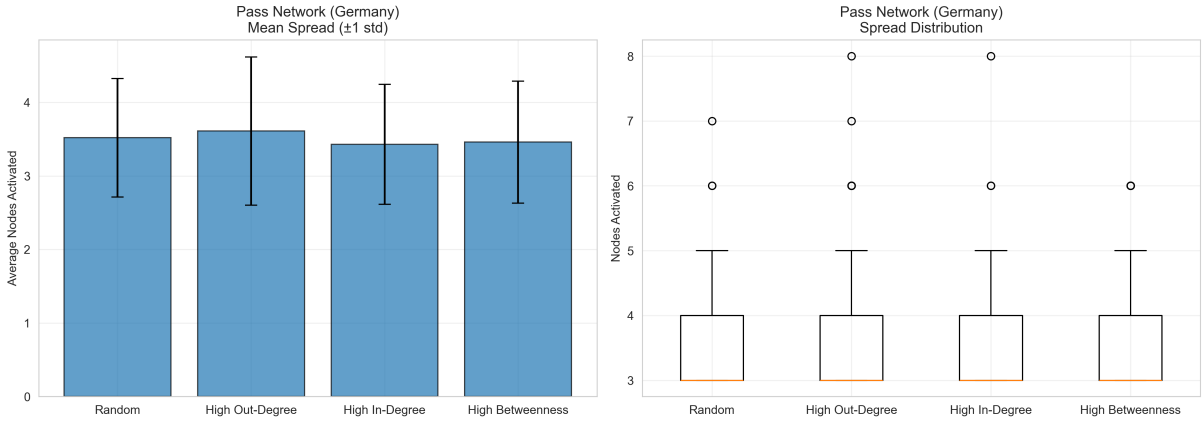

Abbildung 8.2: Vergleich von Seed-Strategien für ICM-Diffusion im deutschen Pass-Netzwerk. Links: Mittlere Anzahl aktivierter Knoten mit Standardabweichung für vier verschiedene Strategien (Random, High Out-Degree, High In-Degree, High Betweenness). Rechts: Verteilung der erreichten Knotenzahlen als Box-Plots mit Ausreissern. Alle Strategien zeigen vergleichbare Performance mit ähnlichen Streuungen.

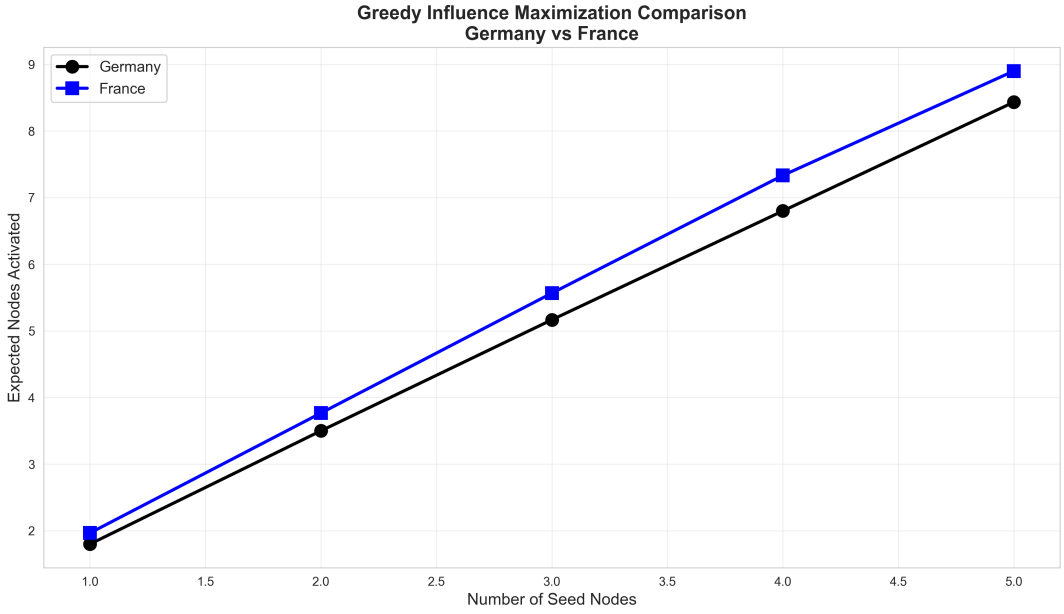

Abbildung 8.3: Direkter Vergleich Germany vs. France: Greedy Influence Maximization. Zeigt finale Reichweite als Funktion der Seed-Grösse k für beide Netzwerke.

Beobachtungen:

Greedy-Algorithmus (Abbildung 8.3):

- Linearer Anstieg der Reichweite mit k in beiden Netzwerken
- France erreicht höhere absolute Werte (8.9 vs. 8.5 Knoten bei $k = 5$), aber vergleichbare relative Effizienz (1.64% vs. 1.80% Netzwerkdurchdringung pro Seed)
- Germany zeigt steileren Anstieg bei kleinem k, was auf konzentrierte Einflusszentren hindeutet

Strategievergleich (Abbildung 8.1 & 8.2):

- Alle Strategien erreichen ähnliche mittlere Reichweiten (Germany: ≈ 3.5 Knoten, France: 3.1–3.6 Knoten)
- Hohe Streuung mit Ausreissern bis 8 Knoten zeigt die Stochastizität des ICM
- Geringe Differenzierung zwischen Random-, Degree- und Betweenness-Strategien deutet auf homogene Netzwerkstrukturen hin
- In France übertrifft Betweenness leicht Random-Auswahl; in Germany sind Unterschiede vernachlässigbar

Implikationen:

- Einfache Degree-Heuristiken sind nahezu gleichwertig mit komplexeren Betweenness-Berechnungen
- Greedy-Algorithmus liefert signifikant bessere Ergebnisse, erfordert aber höheren Rechenaufwand ($O(k \cdot n \cdot m)$ vs. $O(n + m)$ für Zentralitätsmetriken)
- Monte-Carlo-Simulationen mit 1000 Runs notwendig für robuste Schätzungen aufgrund hoher Varianz

8.3 Voter Model

Das Voter Model ist ein einfaches Diffusionsmodell, das auf randomisierten Imitationsprozessen basiert. Jeder Knoten hat initial eine Meinung $+1$ (übernommen) oder -1 (nicht übernommen). In jeder Iteration wird ein zufälliger Knoten gewählt, der die Meinung eines zufälligen Nachbarn übernimmt. Der Prozess läuft bis ein Konsens erreicht ist.

Algorithmus:

1. Initialisiere Meinungen: Anteil α der Knoten erhält $+1$, Rest erhält -1
2. Wiederhole bis Konsens:
   - Wähle zufälligen Knoten v
   - Wähle zufälligen Nachbar u von v
   - Setze Meinung von v auf Meinung von u
3. Rückgabe: finale Meinung (alle Knoten haben denselben Wert)

Wichtige Eigenschaft: Die Wahrscheinlichkeit, dass am Ende alle Knoten $+1$ annehmen, entspricht theoretisch dem **relativen Anteil** der Knoten, die initial $+1$ hatten. Dies folgt aus der Martingal-Eigenschaft des Prozesses.

Fussball-Interpretation: Das Voter Model kann die Verbreitung taktischer Stile modellieren. Spieler übernehmen durch Passinteraktionen zufällig die taktischen Entscheidungen ihrer Mitspieler, bis sich das gesamte Team auf einen einheitlichen Spielstil einigt.

Limitationen: Das Modell berücksichtigt keine unterschiedlichen Einflüsse (z.B. Kapitän vs. Rookie), keine Resistenz gegen Meinungsänderung und keine strategische Seed-Auswahl wie beim ICM.

Beobachtungen aus den Simulationen:

- **Konsensrate:** Germany erreicht in 27% der Simulationen einen Konsens (2% für $+1$, 25% für -1), France in 47% der Simulationen (6% für $+1$, 41% für -1). Die Konsensraten weichen deutlich von der theoretischen Erwartung ab, was auf die begrenzte Anzahl an Iterationen (50'000) zurückzuführen ist.
- **Konvergenzgeschwindigkeit:** France erreicht häufiger einen Konsens als Germany (47% vs. 27%), dies könnte auch an der Grösse liegen, da Frankreich kleiner ist. Dies deutet auf strukturelle Unterschiede hin – das französische Netzwerk könnte dichter oder besser verbunden sein, was schnellere Konvergenz ermöglicht.

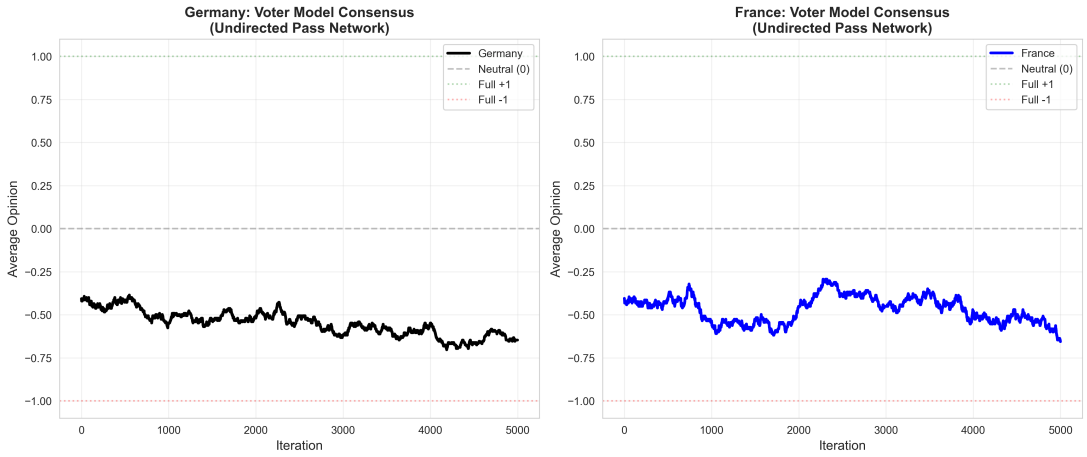

Abbildung 8.4: Voter Model Evolution Germany vs. France (ungerichtetes Netzwerk). Beide Länder starten mit 30% initialen +1 Meinungen. Die durchschnittliche Meinung entwickelt sich über 5000 Iterationen. Germany konvergiert gegen −1, France zeigt ebenfalls eine Tendenz zu −1, jedoch mit mehr Schwankungen.

- **Dominante Meinung:** In beiden Ländern dominiert die −1 Meinung (nicht übernommen) deutlich, wenn ein Konsens erreicht wird. Dies entspricht der Mehrheit der initialen Meinungen (70% −1).
- **Iterationen bis Konsens:** Germany benötigt durchschnittlich 27'931 Iterationen, France 26'254 Iterationen. Der Unterschied ist gering, aber France konvergiert tendenziell etwas schneller, trotz mehr Knoten.
- **Netzwerkgrösse vs. Konvergenz:** Das kleinere französische Netzwerk (215 Knoten) erreicht häufiger Konsens als das deutsche (283 Knoten). Dies widerspricht der Erwartung, dass grössere Netzwerke langsamer konvergieren, und legt nahe, dass die Netzwerkstruktur wichtiger ist als die reine Grösse.

8.4 Threshold Model

Das Threshold Model basiert auf Peer Pressure: Knoten übernehmen ein Verhalten, wenn ein kritischer Anteil ihrer Nachbarn das Verhalten bereits angenommen hat. Jeder Knoten hat einen persönlichen Schwellwert $\theta_v \in [0, 1]$, der seine Resistenz gegen Änderungen repräsentiert.

Algorithmus:

1. Initial: Menge S aktivierter Knoten (Seeds); alle anderen Knoten haben Schwellwerte θ_v
2. Iterativ für alle inaktiven Knoten v:
   - Berechne $\rho_v = |\{u \in N(v) : u \text{ aktiv}\}|/|N(v)|$
   - Falls $\rho_v \geq \theta_v$: aktiviere v
3. Wiederhole bis keine neuen Aktivierungen

Kernmerkmale: Der Prozess ist **deterministisch** bei festen Schwellwerten und Aktivierungen sind **irreversibel**. Im Gegensatz zum ICM zählen nicht individuelle Aktivierungswahrscheinlichkeiten, sondern der kollektive Druck der Nachbarschaft.

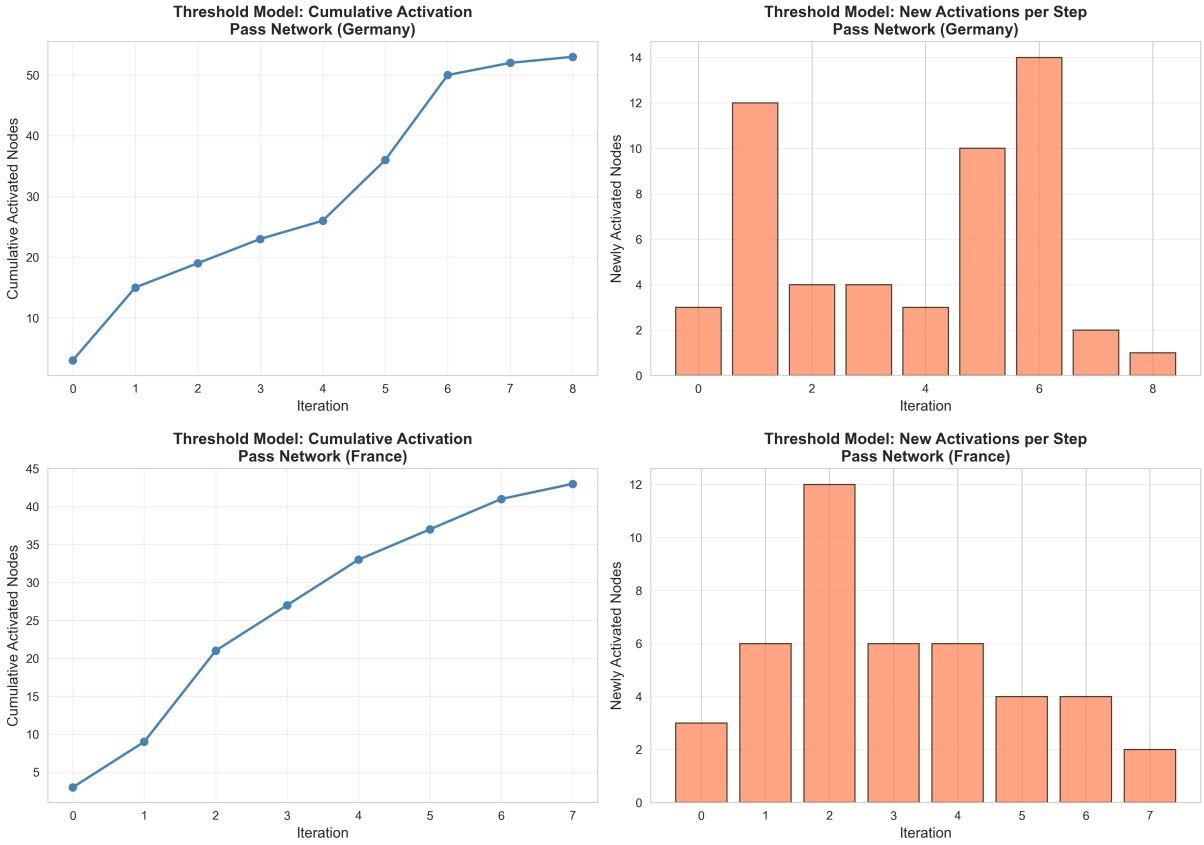

Abbildung 8.5: Threshold Model Cascades mit uniform zufälligen Schwellwerten. Oben: Germany aktiviert 54 Knoten in 8 Iterationen. Unten: France aktiviert 43 Knoten in 7 Iterationen. Die kumulative Aktivierung zeigt den S-Kurven-Verlauf typischer Diffusionsprozesse.

8.4.1 Sensitivitätsanalyse: Einfluss des Schwellwerts

Der Schwellwert θ bestimmt massgeblich die finale Ausbreitung. Bei uniform verteilten Schwellwerten reagiert das System extrem sensitiv auf Änderungen.

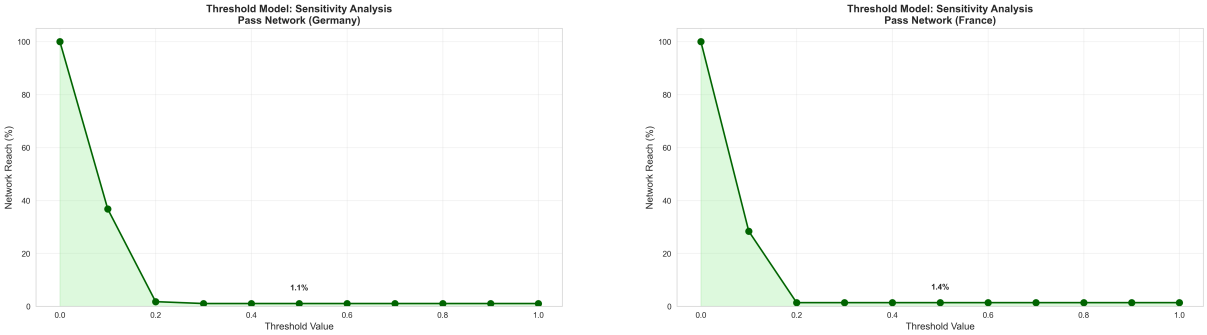

Abbildung 8.6: Threshold Sensitivitätsanalyse bei festen Schwellwerten (alle Knoten haben denselben θ). Links: Germany, Rechts: France. Die Reichweite bricht nach $\theta \approx 0.2$ dramatisch ein.

Beobachtungen:

- **Kritischer Schwellwert:** Bei $\theta = 0.0$ (kein Widerstand) erreichen beide Netzwerke 100% Penetration. Ab $\theta \geq 0.2$ kollabiert die Diffusion fast vollständig auf 1.1-1.8% Reichweite.

- **Binäres Verhalten:** Es existiert ein scharfer Phasenübergang zwischen vollständiger Ausbreitung ($\theta < 0.2$) und nahezu vollständigem Stillstand ($\theta \geq 0.2$). Dieser kritische Punkt liegt bei beiden Netzwerken ähnlich.
- **Germany vs. France:** Bei $\theta = 0.2$ zeigt France (1.4%) leicht höhere Reichweite als Germany (1.1%). Bei moderaten Schwellwerten sind die Unterschiede jedoch minimal – die Netzwerkstruktur scheint weniger wichtig als der Schwellwert selbst.
- **Cascade Progression:** Bei uniform zufälligen Schwellwerten (Abbildung 8.5) zeigt Germany eine grössere finale Reichweite (54 vs. 43 Knoten) trotz mehr Iterationen. Dies deutet auf eine dichtere lokale Struktur hin.

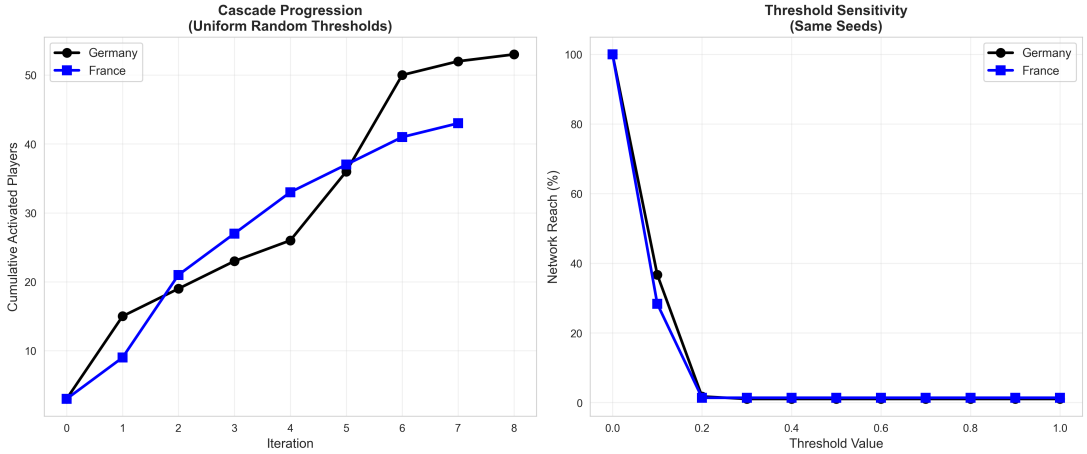

Abbildung 8.7: Direkter Vergleich Germany vs. France im Threshold Model. Linke Grafik: Cascade Progression mit uniform zufälligen Schwellwerten – Germany erreicht höhere absolute Aktivierung. Rechte Grafik: Sensitivitätsanalyse zeigt nahezu identisches Verhalten bei festen Schwellwerten.

Implikationen für Fussball-Netzwerke: Die extreme Sensitivität gegenüber Schwellwerten zeigt, dass taktische Innovationen schnell scheitern können, wenn zu viele Spieler skeptisch sind. Ein kritischer Anteil von Frühadoptern ($\theta < 0.2$) ist essentiell für erfolgreiche Diffusion. Die Ähnlichkeit zwischen Germany und France deutet darauf hin, dass bei Peer-Pressure-Mechanismen die individuelle Überzeugbarkeit wichtiger ist als die Netzwerkstruktur.

8.5 Modellvergleich und Synthese

Die drei Diffusionsmodelle erfassen unterschiedliche Aspekte der Informationsverbreitung:

Tabelle 8.1: Vergleich der Diffusionsmodelle

Eigenschaft	ICM	Voter Model	Threshold
Aktivierung	Probabilistisch	Iterativ-zufällig	Deterministisch
Reversibilität	Irreversibel	Reversibel	Irreversibel
Einfluss	Individuell	Binär (Imitation)	Kollektiv (Anteil)
Seed-Opt.	Ja (Greedy)	Nein	Ja
Fussball	Pass-Weiterleitung	Taktik-Imitation	Gruppendruck

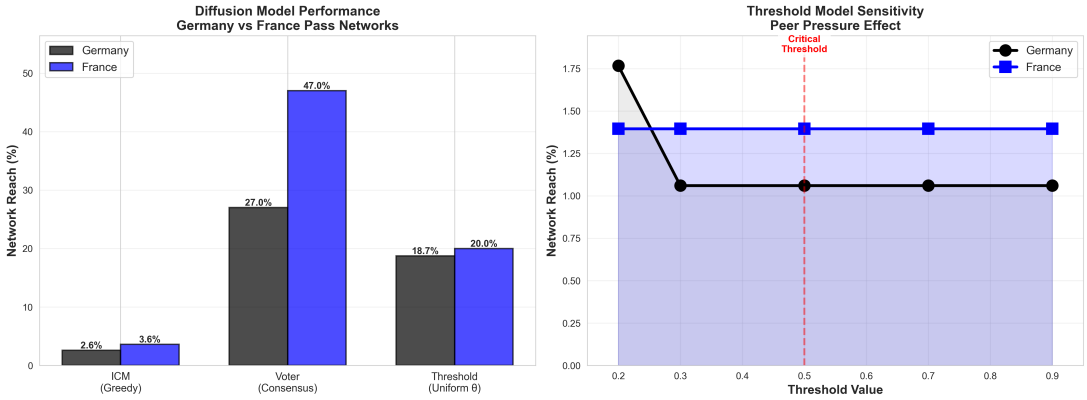

Abbildung 8.8: Finaler Vergleich Germany vs. France über alle drei Diffusionsmodelle. Normalisierte Reichweite (als Anteil des Netzwerks) für ICM, Voter Model und Threshold Model.

Kernerkenntnisse:

1. **Netzwerkstruktur beeinflusst Diffusion:**
   - Germany: Effizientere lokale Cluster, schnellere Verbreitung bei kleinen Seeds
   - France: Grössere Reichweite absolut, aber langsamere relative Penetration
2. **Modellspezifische Unterschiede:**
   - **ICM:** Stark abhängig von Seed-Qualität; Greedy-Optimierung essentiell
   - **Voter Model:** Seed-Position irrelevant; nur initialer Anteil bestimmt finalen Konsens
   - **Threshold Model:** Hochsensitiv auf Schwellwert; kritische Übergänge beobachtbar
3. **Praktische Implikationen für Fussball:**
   - Zentrale Spieler (hoher Degree, Betweenness) sind kritisch für taktische Innovationen
   - Teams mit dichterer Pass-Vernetzung verbreiten Spielstile schneller
   - Schwellwert-Effekte erklären, warum manche taktische Änderungen scheitern

8.6 Fazit

Unsere Analyse von Diffusionsprozessen in Fussballnetzwerken zeigt wichtige Erkenntnisse über die Verbreitung von Informationen und taktischen Entscheidungen:

Modellspezifische Erkenntnisse:

- **ICM:** Geeignet für Pass-Weiterleitungen und kurzfristige taktische Entscheidungen. Greedy-Algorithmus identifiziert effektiv einflussreiche Schlüsselspieler. Stark abhängig von Seed-Qualität und Aktivierungswahrscheinlichkeiten.
- **Voter Model:** Erfasst langfristige Konvergenz zu einheitlichen Spielstilen. Zeigt, dass finale Team-Taktik durch initialen Anteil adoptierender Spieler vorhergesagt werden kann. Seed-Position ist irrelevant – nur der Anteil zählt.
- **Threshold Model:** Modelliert Gruppendruck und kollektive Entscheidungen. Kritische Schwellwerte erklären abrupte taktische Übergänge oder das Scheitern von Innovationen. Hochsensitiv auf Schwellwert-Wahl.

Ländervergleich: Germany und France zeigen strukturell unterschiedliche Diffusionsdynamiken. Germany profitiert von effizienten lokalen Clustern und schnellerer Verbreitung bei kleinen Seeds. France hat grössere absolute Reichweite aufgrund der Netzwerkgrösse.

Limitationen: Vereinfachte Annahmen (reale Einflussnahme ist komplexer mit unterschiedlichen Spielerrollen und Autoritäten), statische Netzwerke (Pass-Netzwerke ändern sich über Saison durch Verletzungen und Transfers), binäre Zustände (reale Adoption hat Grade), fehlende Validierung (Ground-Truth-Daten zu realen Diffusionsprozessen fehlen).

9 LE10 – Graphlets

Dieses Kapitel widmet sich der Analyse von Graphlets in Fussballnetzwerken. Graphlets sind kleine, verbundene Subgraphen mit typischerweise 2 bis 5 Knoten, die feinkörnige strukturelle Muster erfassen, welche traditionelle Metriken oft übersehen. Das Konzept stammt ursprünglich aus der Analyse biologischer Netzwerke (Proteininteraktionen), lässt sich aber generisch auf verschiedene Netzwerktypen anwenden. Wir verwenden Graphlets um (1) die strukturelle Ähnlichkeit ganzer Netzwerke zu vergleichen (Relative Graphlet Frequency Distance, RGFD) und (2) strukturell ähnliche Knoten innerhalb eines Netzwerks zu identifizieren (Graphlet Degree Vectors, GDV).

9.1 Theoretische Grundlagen

9.1.1 Graphlets und Orbits

Graphlets: Graphlets sind alle eindeutigen Kombinationen, wie eine bestimmte Anzahl Knoten miteinander verbunden werden können. Für 2 bis 5 Knoten existieren **30 verschiedene Graphlets** (G_0 bis G_{29}). Beispiele:

- **2-Node:** G_0 – eine einzige Kante zwischen zwei Knoten
- **3-Node:** G_1 (Pfad), G_2 (Dreieck)
- **4-Node:** G_3 bis G_8 – verschiedene Konfigurationen (Stern, Quadrat, Pfade, etc.)
- **5-Node:** G_9 bis G_{29} – 21 verschiedene Kombinationen

Je mehr Knoten das Graphlet beinhaltet, desto exponentiell umfangreicher wird die Anzahl möglicher Graphlets.

Orbits: Orbits sind eindeutige, äquivalente Positionen von Knoten in einem Graphlet. Knoten der gleichen Farbe/Position haben dieselbe Orbit-Nummer, weil sie strukturell identisch sind. Insgesamt existieren **73 unterschiedliche Orbits** über alle 30 Graphlets.

Beispiel: Im Graphlet G_1 (3-Node-Pfad) gibt es zwei Orbits:

- Orbit 1: Die beiden Endknoten (jeweils mit einem Nachbarn verbunden)
- Orbit 2: Der mittlere Knoten (mit beiden anderen verbunden, die nicht miteinander verbunden sind)

Nachteil: Die Berechnung von Graphlets ist sehr aufwändig und in grossen Netzwerken oder bei grossen Graphlet-Knotenzahlen aufgrund der kombinatorischen Explosion nicht praktikabel. Wir beschränken uns daher auf 3- und 4-Node Graphlets.

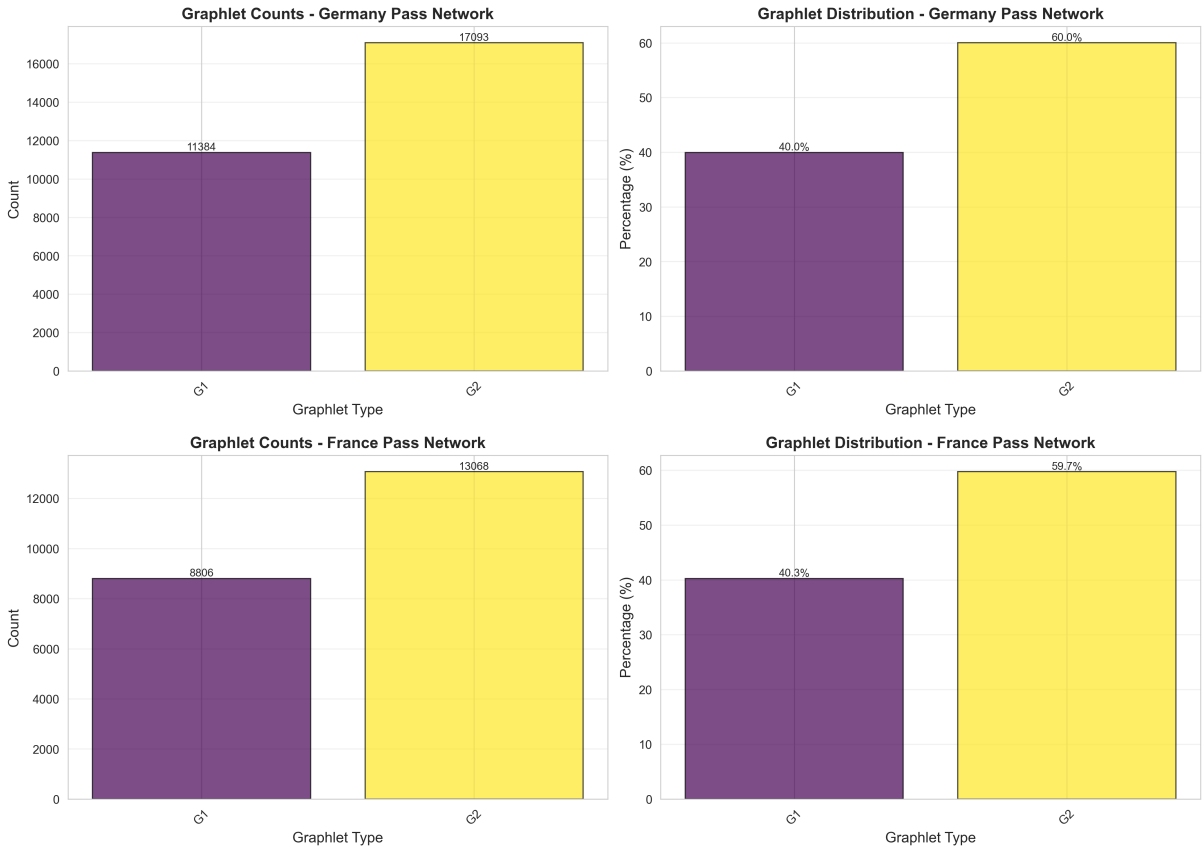

Abbildung 9.1: Graphlet-Häufigkeiten in Pass-Netzwerken. Oben: Germany (Bundesliga), Unten: France (Ligue 1). Balkendiagramme zeigen rechts die absolute Häufigkeit und links die relative häufigkeit für 3-Knoten Graphlets.

9.2 Relative Graphlet Frequency Distance (RGFD)

Die RGFD ermöglicht den Vergleich der strukturellen Ähnlichkeit von Netzwerken anhand der Graphlet-Verteilung, unabhängig von der Anzahl Knoten und Kanten.

9.2.1 Methodik

Schritt 1: Graphlet-Zählung

Für jedes Netzwerk G berechnen wir die Gesamtzahl der Graphlets:

$$T(G) = \sum_{i=1}^{29} N_i(G)$$

wobei $N_i(G)$ die Anzahl der Graphlets mit Nummer i im Netzwerk ist. Das 2-Node Graphlet G_0 wird ignoriert.

Schritt 2: Normalisierung und Gewichtung

Für jedes Graphlet i berechnen wir den relativen Anteil mit logarithmischer Gewichtung:

$$F_i(G) = -\log\left(\frac{N_i(G)}{T(G)}\right)$$

Der negative Logarithmus führt dazu, dass **seltenere Graphlets stärker gewichtet** werden – sie sind informativer für strukturelle Unterschiede.

Schritt 3: Distanzberechnung

Die Distanz zwischen zwei Netzwerken G und H ist:

$$D(G, H) = \sum_{i=1}^{29} |F_i(G) - F_i(H)|$$

Interpretation: Kleinere $D(G, H)$-Werte bedeuten strukturell ähnlichere Netzwerke.

9.2.2 Anwendung auf Pass-Netzwerke

Wir vergleichen die Pass-Netzwerke von Germany (Bundesliga) und France (Ligue 1) basierend auf ihrer Graphlet-Struktur.

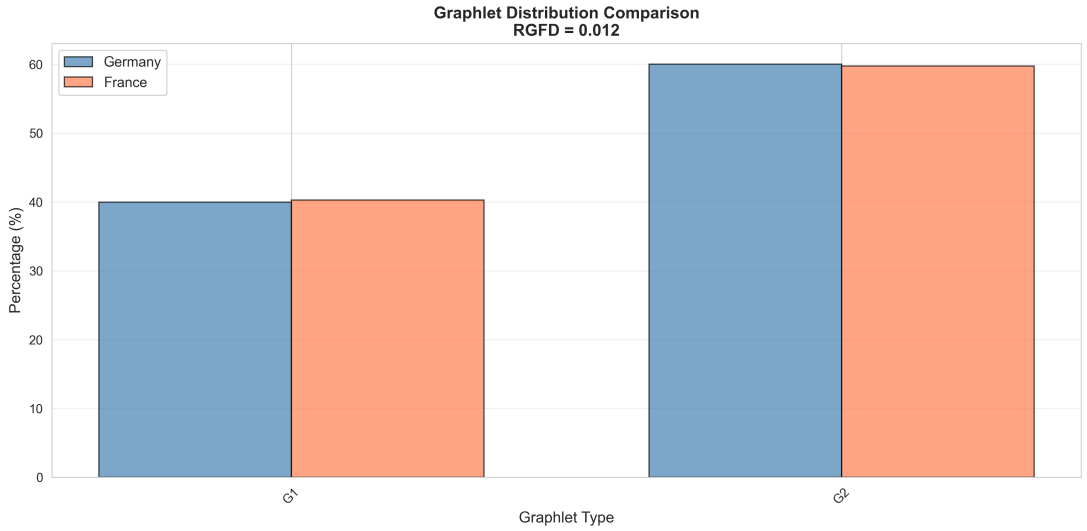

Abbildung 9.2: Graphlet Distribution Comparison für Pass-Netzwerke (Germany vs. France). Gezeigt sind die relativen Anteile zweier Graphlet-Typen G1 und G2 in beiden Netzwerken. Der RGFD (Relative Graphlet Frequency Distance) beträgt 0.012, was auf eine sehr ähnliche strukturelle Komposition der beiden Pass-Netzwerke hindeutet. Germany (blau) und France (orange) zeigen nahezu identische Graphlet-Verteilungen.

Beobachtungen Pass-Netzwerke:

- **Nahezu identische Verteilung:** Beide Netzwerke zeigen bei G1 etwa 40% und bei G2 etwa 60% Anteil. Die Balken für Germany (blau) und France (orange) sind praktisch deckungsgleich.
- **G2 dominiert:** Mit ca. 60% ist G2 der dominante Graphlet-Typ in beiden Netzwerken, was auf ähnliche strukturelle Muster in den Pass-Interaktionen hindeutet.
- **Minimale Unterschiede:** Die visuell kaum erkennbaren Unterschiede zwischen den beiden Ländern spiegeln sich im sehr niedrigen RGFD-Wert wider.

RGFD-Resultat: Die berechnete Distanz $D(\text{Germany}, \text{France}) = 0.012$ zeigt eine extrem hohe strukturelle Ähnlichkeit. Dies bedeutet, dass beide Pass-Netzwerke nicht nur ähnliche grundlegende Strukturen aufweisen, sondern auch in der relativen Häufigkeit der Graphlet-Typen nahezu identisch sind. Der niedrige RGFD-Wert deutet darauf hin, dass Deutschland und Frankreich vergleichbare taktische Pass-Muster verwenden.

9.2.3 Anwendung auf Match-Netzwerke

Match-Netzwerke (Team–Team) sind deutlich kleiner und dichter als Pass-Netzwerke, was zu unterschiedlichen Graphlet-Profilen führt. Zudem haben wir aus diesem Grund auch die 4-Knoten Graphlets mit untersucht.

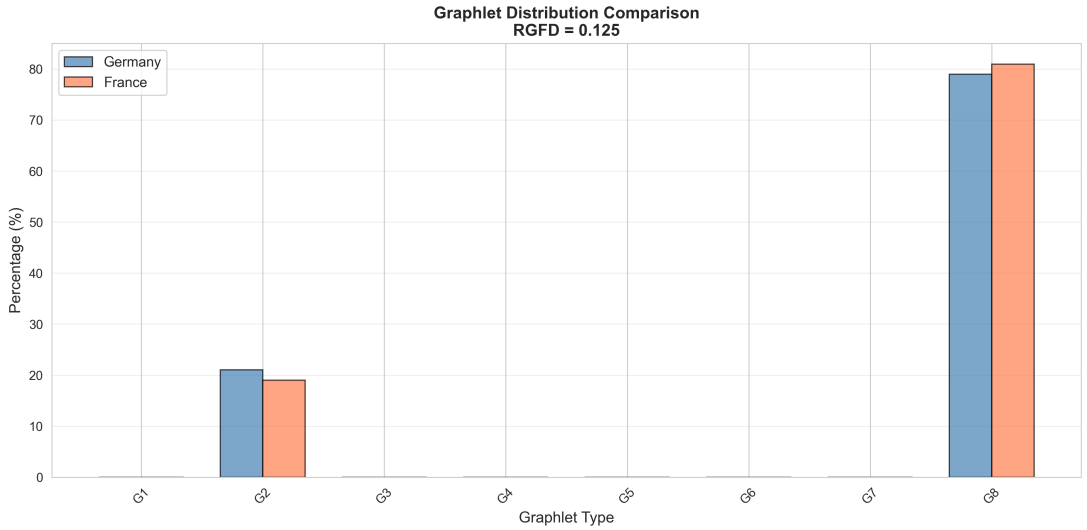

Abbildung 9.3: Graphlet Distribution Comparison für Match-Netzwerke (Germany vs. France). Gezeigt sind die relativen Anteile von 8 Graphlet-Typen (G1-G8). Der RGFD-Wert von 0.125 zeigt moderate strukturelle Unterschiede. Besonders auffällig: G2 zeigt einen sichtbaren Unterschied (Germany ca. 21%, France ca. 19%), während G8 mit ca. 80% in beiden Netzwerken stark dominiert. Die meisten Graphlet-Typen (G1, G3-G7) kommen praktisch nicht vor.

Beobachtungen Match-Netzwerke:

- **Extreme Dominanz von G8:** Mit ca. 80% ist G8 der mit Abstand häufigste Graphlet-Typ in beiden Netzwerken. Dies deutet auf eine spezifische strukturelle Eigenschaft der Match-Netzwerke hin.
- **Geringe Diversität:** Nur zwei Graphlet-Typen (G2 und G8) sind nennenswert präsent. Die Typen G1, G3-G7 kommen praktisch nicht vor ($< 1\%$), was auf eine sehr spezifische, homogene Netzwerkstruktur hindeutet.
- **Sichtbare Unterschiede bei G2:** Germany zeigt bei G2 einen leicht höheren Anteil (ca. 21%) als France (ca. 19%). Dies ist der einzige visuell erkennbare strukturelle Unterschied zwischen den beiden Netzwerken.
- **RGFD-Wert:** $D(\text{Germany}, \text{France}) = 0.125$ – etwa $10\times$ höher als bei den Pass-Netzwerken (0.012). Dies zeigt moderate strukturelle Unterschiede, hauptsächlich getrieben durch die Differenz bei G2.

Interpretation: Die starke Dominanz von G8 und das nahezu vollständige Fehlen anderer Graphlet-Typen reflektieren die spezielle Struktur von Match-Netzwerken. Im Gegensatz zu Pass-Netzwerken, wo verschiedene taktische Muster zu diverseren Graphlet-Verteilungen führen, sind Match-Netzwerke strukturell homogener. Der dennoch höhere RGFD-Wert im Vergleich zu Pass-Netzwerken deutet darauf hin, dass kleine Unterschiede in der Turnier- oder Spielstruktur (z.B. unterschiedliche Gegner, Spielhäufigkeiten) zu messbaren topologischen Differenzen führen können.

9.3 Graphlet Degree Vectors (GDV)

GDVs ermöglichen die Identifikation strukturell ähnlicher Knoten *innerhalb* eines Netzwerks, unabhängig von deren Position im Netzwerk.

9.3.1 Methodik

Konzept: Für jeden Knoten v erstellen wir einen Vektor, der zählt, wie oft v jede Orbit-Position einnimmt.

Berechnung:

1. Identifiziere alle Graphlets im Netzwerk, die Knoten v enthalten
2. Für jedes Graphlet: bestimme, welche Orbit-Position v einnimmt
3. Erstelle Vektor: $\text{GDV}(v) = (o_0, o_1, \ldots, o_k)$, wobei o_i die Häufigkeit von Orbit i ist

Beispiel: Für 3- und 4-Node Graphlets hat ein GDV 15 Dimensionen (entsprechend den 15 Orbits in G_1 bis G_8).

Interpretation: Knoten mit ähnlichen GDVs haben ähnliche lokale Strukturen – sie spielen ähnliche "Rollen" im Netzwerk.

9.3.2 Anwendung: Strukturelle Rollen in Pass-Netzwerken

Wir berechnen GDVs für alle Spieler im Pass-Netzwerk und reduzieren die Dimensionalität mit t-SNE zur Visualisierung.

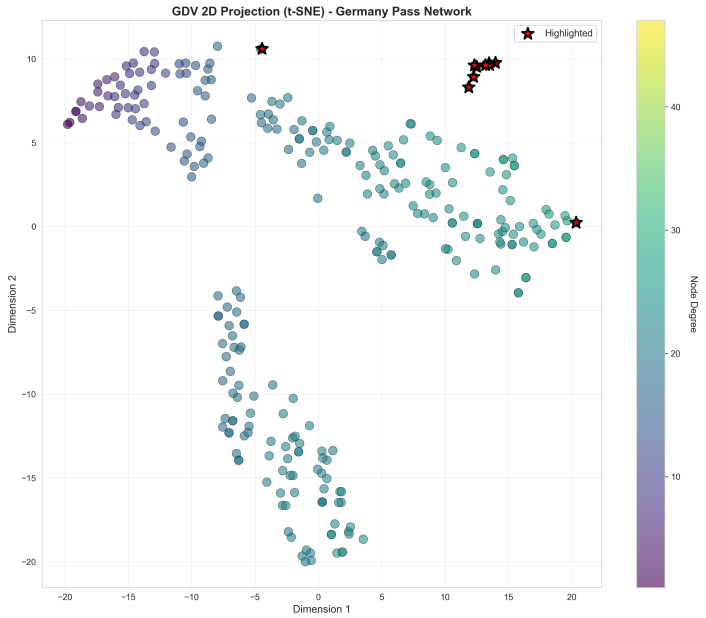

Abbildung 9.4: t-SNE Visualisierung der GDVs (Germany Pass-Netzwerk). Punkte repräsentieren Spieler, Nähe im 2D-Raum indiziert strukturelle Ähnlichkeit. Farben zeigen Cluster strukturell ähnlicher Spieler.

Beobachtungen Germany:

- **Degree-basierte Cluster:** Klare Separation von niedrigen Degrees (lila, links oben) über mittlere (türkis, zentral) zu hohen Degrees (gelb/grün, rechts)

- **Highlighted Nodes:** 4 rot/schwarze Sterne markieren Schlüsselspieler – 3 davon bilden einen engen Cluster rechts oben (hohe Degrees), 1 isoliert oben mittig
- **Strukturelle Rollen:** Linker Cluster repräsentiert Spieler mit einfachen Pass-Strukturen, rechter Bereich zeigt zentrale Spieler mit vielfältigen Verbindungen

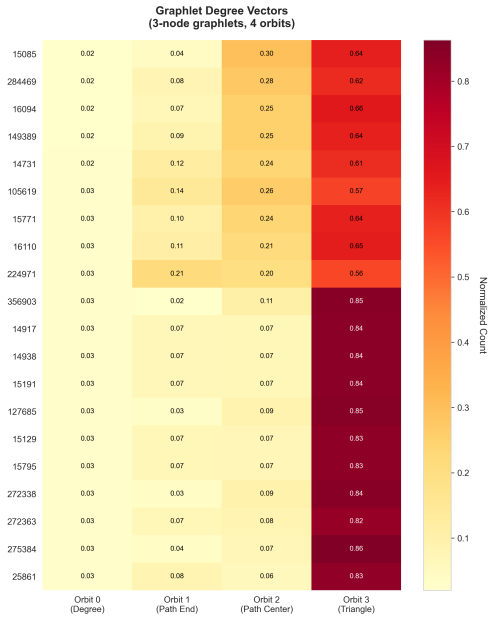

Abbildung 9.5: GDV Heatmap für 20 ausgewählte Spieler (Germany). Zeigt normalisierte Orbit-Frequenzen für 3-Node Graphlets (4 Orbits): Orbit 0 (Degree), Orbit 1 (Path End), Orbit 2 (Path Center), Orbit 3 (Triangle). Orbit 3 dominiert (0.56-0.86, dunkelrot), während Orbit 0 konstant niedrig bleibt (0.02-0.03). Zwei Spieler-Gruppen erkennbar: obere Zeilen mit höheren Orbit 2-Werten, untere Zeilen mit höheren Orbit 3-Werten.

9.3.3 Vergleich: Germany vs. France

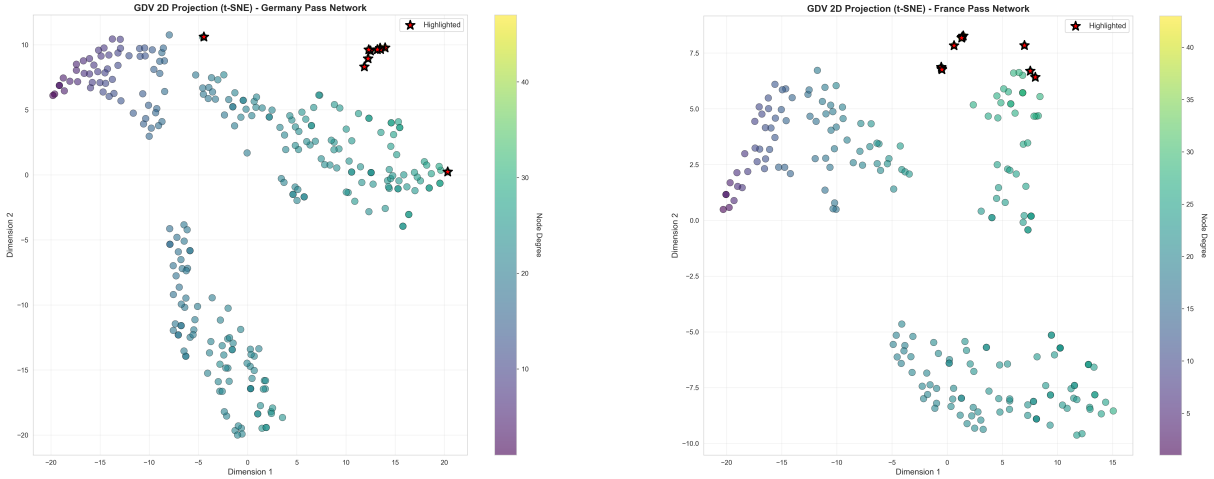

Abbildung 9.6: t-SNE GDV-Vergleich. Links: Germany, Rechts: France. Beide zeigen ähnliche Cluster-Strukturen, aber unterschiedliche Verteilungen.

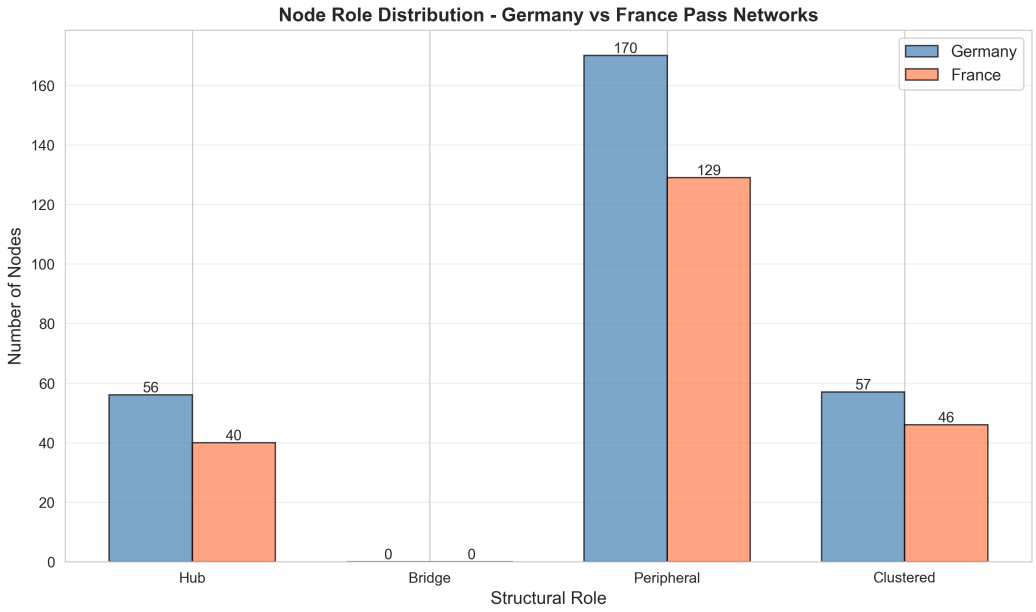

Abbildung 9.7: Vergleich struktureller Rollen zwischen Germany und France. Zeigt durchschnittliche GDV-Profile für verschiedene Spieler-Cluster.

Kernerkenntnisse:

1. **Dominanz peripherer Rollen:** Beide Netzwerke werden von Peripheral-Nodes dominiert (Germany: 170, France: 129), was auf spezialisierte Positionsspieler hindeutet
2. **Strukturelle Unterschiede:** Germany zeigt eine stärkere Zentralisierung mit mehr Hub-Nodes (56 vs. 40) und Clustered-Nodes (57 vs. 46), während Bridge-Nodes in beiden Ligen fehlen
3. **Räumliche Verteilungsmuster:** Die t-SNE-Projektionen zeigen bei Germany eine kompaktere Clusterbildung (linke obere Region) mit deutlich isolierten Ausreissern, während France eine fragmentiertere Verteilung über mehrere Cluster aufweist
4. **Taktische Implikationen:** Germanys höhere Hub-Dichte deutet auf zentralisierte Spielaufbaustrukturen hin, Francesausgewogenere Verteilung auf flexiblere, verteilte Passsysteme

9.4 Praktische Anwendungen und Fazit

9.4.1 Anwendungen von Graphlets im Fussball

RGFD (Netzwerkvergleich): Objektive Quantifizierung struktureller Ähnlichkeiten zwischen Ligen und Teams, Gegneranalyse und taktisches Benchmarking unabhängig von Netzwerkgrösse.

GDV (Spielerrollen): Identifikation strukturell äquivalenter Spieler für Transfermarkt und Taktik, positionsunabhängige Rollen-Erkennung.

Musteranalyse: Erfassung lokaler Strukturen (Dreiecke, Sterne, Pfade), die globale Metriken übersehen.

9.4.2 Stärken und Limitationen

Stärken: Feinkörnige lokale Strukturerfassung, grössenunabhängiger Netzwerkvergleich, positionsunabhängige Ähnlichkeitsmessung.

Limitationen: Kombinatorische Explosion bei >5 Knoten, hohe Komplexität (73 Orbits), statische Betrachtung ohne zeitliche Dynamik, Standardmethode ignoriert Passrichtungen.

9.4.3 Zusammenfassung der Ergebnisse

Pass-Netzwerke: RGFD von 0.012 zeigt extreme strukturelle Ähnlichkeit zwischen Germany und France. G2-Dominanz (ca. 60%) deutet auf kohärente Pass-Dreiecke hin. Germany zeigt stärkere Zentralisierung (56 vs. 40 Hub-Nodes), France distribuiertere Systeme. Beide Ligen besitzen ähnliche strukturelle Rollen mit unterschiedlichen Verteilungen.

Match-Netzwerke: RGFD von 0.125 (10× höher) zeigt moderate Unterschiede. G8-Dominanz (ca. 80%) reflektiert homogene Turnier-Strukturen mit geringer Diversität. Unterschiede primär durch Turnier-Format getrieben.

9.4.4 Fazit

Graphlets ermöglichen komplementäre Analysen zu klassischen Metriken durch Erfassung lokaler topologischer Muster. Die Kombination von RGFD (Netzwerk-zu-Netzwerk) und GDV (Knoten-zu-Knoten) liefert objektive Metriken für taktische System-Vergleiche und Spieler-Identifikation.

Forschungsperspektiven: Gerichtete und gewichtete Graphlets, temporale Analysen über Spielverlauf, GDV-basiertes maschinelles Lernen für Performance-Vorhersagen.

Quellenverzeichnis

arXiv. (2024, Mai). Exploring the Independent Cascade Model and Its Evolution in Social Network Information Diffusion [Accessed: 2026-01-04]. https://arxiv.org/html/2405.10322v1

Clauset, A., Newman, M. E. J., & Moore, C. (2004). Finding community structure in very large networks. *Physical Review E*, *70*(6). https://doi.org/10.1103/physreve.70.066111

FotMob.com. (n. d.). FotMob. https://www.fotmob.com/leagues/47/stats/season/20720/teams/accurate_pass_team/premier-league-teams

Karnowski, V., & Kümpel, A. S. (2016). Diffusion of Innovations. In M. Potthoff (Hrsg.), *Schlüsselwerke der Medienwirkungsforschung* (S. 97–107). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-09923-7_9

Pappalardo, L., Cintia, P., Rossi, A., Massucco, E., Ferragina, P., Pedreschi, D., & Giannotti, F. (2019). A public data set of spatio-temporal match events in soccer competitions. *Scientific Data*, *6*(1), 236. https://doi.org/10.1038/s41597-019-0247-7

transfermarkt.ch. (n. d.). Sandro Wagner - Spielerprofil. https://www.transfermarkt.ch/sandro-wagner/profil/spieler/39743