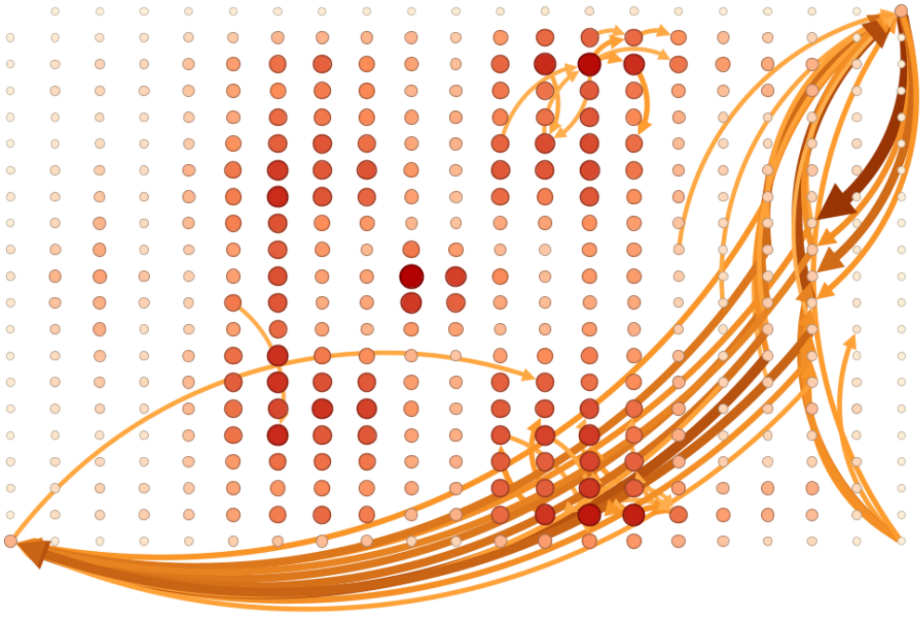
Fachhochschule Nordwestschweiz
Hochschule für Informatik

SAN (Soziale Netzwerk Analyse)
Modulbericht

Lukas Breiter Gian Marco Truttmann Jessica Schmid

Windisch, 12. November 2026



Modul	SAN (Soziale Netzwerk Analyse)
Autoren	Lukas Breiter Gian Truttmann Jessica Schmid
Dozent/in	Michael Henninger
Studiengang	SG DSAI
Semester	HS 2025
Version / Abgabedatum	0.1 / 04.01.2026

Fachhochschule Nordwestschweiz (FHNW)

Abstract

Wir modellieren Fussballspiele als soziale Netzwerke. Grundlage sind Wyscout-Eventdaten aus sieben Wettbewerben: den Ligen Englands, Spaniens, Deutschlands, Frankreichs und Italiens sowie der Welt- und der Europameisterschaft. Aus den Events bauen wir vier Netzwerktypen: Pass-Netzwerke zwischen Spielern, Match-Netzwerke zwischen Teams, ein bipartites Spieler-Team-Netzwerk und ein Netzwerk aus Feldzonen. Wyscout liefert keinen Passempfänger. Wir bestimmen ihn über die nächste Aktion des eigenen Teams innerhalb von 5 Sekunden und 10 Metern. Für die Detailanalysen wählen wir die Bundesliga und die WM.

Mit Louvain finden wir im Bundesliga-Passnetz Communities, die den realen Teams entsprechen ($Q = 0.886$). Innerhalb des FC Köln sinkt die Modularität auf $Q = 0.109$, und jede der drei Communities enthält Spieler mehrerer Positionen. Im WM-Match-Netz liefert Louvain sechs Communities ($Q = 0.701$). Sie folgen den acht Vorrundengruppen, wobei K.O.-Spiele einzelne Gruppen zusammenlegen. Grad und Betweenness korrelieren im Passnetz mit $r = 0.338$. Der Clustering-Koeffizient von 0.867 liegt 11.7-mal über dem eines Erdős-Rényi-Graphen gleicher Grösse, und im Permutationstest gegen das Configuration Model erreicht kein Zufallsnetz diesen Wert ($p < 0.001$). Von den Passbeziehungen sind 92.7 % reziprok. Die Gradverteilung passt am besten zu einer Log-Normal-Verteilung (KS-Statistik $D = 0.067$); ein Power Law verwerfen wir ($p = 0.003$). Bei der Link Prediction erzielt Adamic-Adar mit einer AUC von 0.892 das beste Ergebnis.

Keywords: soziale Netzwerkanalyse, Graphen, Communities, Zentralität, Link Prediction

Inhaltsverzeichnis

Abbildungsverzeichnis **vii**

Tabellenverzeichnis **ix**

1 Exploratory Data Analysis (EDA) **2**

1.1 Ziel und Kapitelrolle . . . 2
1.2 Datenbasis und Aufbereitung . . . 2
1.3 Wettbewerbe und Spiele . . . 2
1.4 Ereignisse: Typen und zeitliche Muster . . . 2
1.5 Pass-Analyse: Zentrale Akteure und räumliche Verteilung . . . 7
1.6 Wettbewerbsvergleich . . . 9
1.7 Erste Hypothesen für die Netzwerk-Analyse . . . 11

2 LE3 – Netzwerk-Modellierung & Filterung **12**

2.1 Netzwerkmodellierung . . . 12
2.1.1 Netzwerke . . . 12
2.2 Netzwerkfilterung . . . 16
2.2.1 Sichten: Local View, Global View, Ego-Netzwerk . . . 16
2.2.2 Filtern anhand von Kantenattributen . . . 17

3 LE4 – Communities **19**

3.1 Connected Components . . . 19
3.2 Cliquen und dichte Subgraphen . . . 19
3.2.1 Maximale Cliquen . . . 19
3.2.2 k-Core Dekomposition . . . 20
3.3 Community Detection . . . 20
3.3.1 Algorithmen im Überblick . . . 20
3.3.2 Modularität als Qualitätsmass . . . 21
3.4 Ergebnisse: Community Detection . . . 21
3.4.1 Pass-Netzwerk (Deutschland Bundesliga) . . . 21
3.4.2 Match-Netzwerk (FIFA World Cup) . . . 22
3.5 Intra-Team Analyse: Positionsbasierte Strukturen . . . 23
3.6 Zusammenfassung & Diskussion . . . 23
3.6.1 Algorithmenvergleich . . . 23
3.6.2 Haupterkenntnisse . . . 24
3.6.3 Anwendungen . . . 24

4 LE5 – Zentrale Aktoren & Aktor-Gruppen finden **30**

4.1 Ziel und Fragestellung 30

4.2 Theoretische Grundlagen 30

4.2.1 Degree Centrality 30

4.2.2 Betweenness Centrality 31

4.2.3 Closeness Centrality 31

4.2.4 Eigenvector Centrality und PageRank 31

4.2.5 k-Core und k-Shell 32

4.3 Datengrundlage 32

4.4 Ergebnisse: Pass-Netzwerk (Deutschland) 32

4.4.1 Degree Centrality und Strength 32

4.4.2 Betweenness Centrality 33

4.4.3 Vergleich aller Zentralitätsmasse 33

4.4.4 Top Spieler nach Zentralität 35

4.5 k-Core Analyse 35

4.6 Ergebnisse: Match-Netzwerk (World Cup) 36

4.6.1 Team-Zentralität 36

4.7 Vergleich: Pass-Netzwerk vs. Match-Netzwerk 37

4.8 Interpretation und Diskussion 37

4.8.1 Verschiedene Zentralitäten erfassen verschiedene Rollen 37

4.8.2 Spielerrollen im Fussball 37

4.8.3 Normalisierung und Vergleichbarkeit 37

4.8.4 Limitationen 37

4.9 Fazit 38

5 LE6 – Netzwerk-Kennzahlen **39**

5.1 Ziel 39

5.2 Datengrundlage 39

5.3 Globale Kennzahlen 39

5.3.1 Diameter und Average Path Length 39

5.3.2 Clustering Coefficient und Transitivity 40

5.3.3 Assortativity 42

5.3.4 Reciprocity 42

5.4 Lokale Kennzahlen 43

5.4.1 Edge Embeddedness 43
5.5 Zusammenfassende Analyse 44
5.5.1 Strukturelle Unterschiede 45
5.6 Diskussion 45
5.6.1 Small-World-Eigenschaften in Fussballnetzwerken 45
5.6.2 Taktische Implikationen 46
5.6.3 Limitationen 46
5.7 Fazit 46

6 LE7 – Statistik in Netzwerken 48
6.1 Ziel 48
6.2 Nullmodelle & Randomisierung 48
6.2.1 Zufallsgraph-Modelle als Nullmodelle 48
6.2.2 Ergebnisse: Modellvergleich Pass-Netzwerk 49
6.3 Gradverteilungs-Analyse 50
6.3.1 Verteilungstypen 50
6.3.2 Ergebnisse: Pass-Netzwerk Gradverteilung 50
6.4 Statistische Hypothesentests 51
6.4.1 Permutationstest für Netzwerk-Clustering 51
6.4.2 Bootstrap-Konfidenzintervalle 52
6.5 Link Prediction Evaluation 53
6.5.1 Methodik 53
6.5.2 Ergebnisse 54
6.6 Diskussion 55
6.6.1 Signifikanz vs. Effektgrösse 55
6.6.2 Nullmodell-Wahl 55
6.6.3 Gradverteilungen und Mechanismen 55
6.6.4 Link Prediction in der Praxis 56
6.6.5 Limitationen 56
6.7 Fazit 56

7 LE8 – Link Prediction 57
7.1 Ziel 57
7.2 Features / Heuristiken 57
7.3 Evaluation 57
7.4 Ergebnisse 57

8 LE9 – Diffusion **58**

8.1 Ziel 58

8.2 Modelle 58

8.3 Simulation & Auswertung 58

8.4 Ergebnisse 58

9 LE10 – Graphlets **59**

9.1 Ziel 59

9.2 Vorgehen 59

9.3 Ergebnisse 59

Quellenverzeichnis **60**

A Ein Anhang **61**

A.1 Aufgabenstellung im Originalwortlaut 61

A.2 Gesamtübersicht 61

A.3 Berechnungen / Resultate Umfrage 62

A.4 Tests – Screenshots 62

Abbildungsverzeichnis

1.1 Anzahl der Spiele pro Wettbewerb. Die Daten decken sowohl Liga-Wettbewerbe (England, Spanien, Deutschland, etc.) als auch internationale Turniere (WM, EM) ab. . . . 3

1.2 Anzahl der Events pro Wettbewerb. Die EDA umfasst alle sieben Wettbewerbe (England, Spanien, Deutschland, Frankreich, Italien, World Cup, European Championship). . . . 3

1.3 Top 15 Ereignistypen über alle Wettbewerbe. Pässe dominieren klar das Spielgeschehen. . . . 5

1.4 Ereignisse pro Spielminute (kontinuierlich über beide Halbzeiten). Deutlich erkennbar sind erhöhte Aktivität zu Spielbeginn und der Rückgang in der Schlussphase. . . . 5

1.5 Events nach Spielhälfte (1H vs. 2H). In der vorliegenden Auswertung sind beide Halbzeiten mit je ca. 320,000 Events nahezu gleich stark vertreten. . . . 6

1.6 Passvolumen, Passgenauigkeit und durchschnittliche Passdistanz nach Halbzeit (1H/2H). In dieser Auswertung werden in Halbzeit 1 mehr Pässe gespielt (+7.4%), bei sehr ähnlicher Genauigkeit und Distanz. . . . 6

1.7 Top 15 Spieler nach Anzahl der Pässe. Diese Spieler sind später als zentrale Knoten in den Passnetzwerken zu erwarten. . . . 7

1.8 Passvolumen (links) und Passgenauigkeit (rechts) nach Passtyp (Top 12). „einfache Pässe“ dominieren das Volumen bei hoher Genauigkeit; Flanken und Smart Passes sind seltener und deutlich ungenauer. . . . 8

1.9 Umfassende Analyse der Passeigenschaften. **Oben links:** Verteilung der Passlängen mit Median-Markierung. **Oben rechts:** Median-Passlänge nach Passtyp (z. B. lange Bälle vs. kurze Zuspiels). **Unten:** Heatmaps für Pass-Ursprung (links) und Pass-Ziel (rechts), visualisiert auf normalisierten Spielfeldkoordinaten. . . . 8

1.10 Beispielhafte Zentralitätsintuition in einem Sample-Match: (links) Top-10 Spieler nach Passvolumen (gespielt vs. empfangen), (rechts) Out-Degree vs. In-Degree mit Referenzlinie $y = x$ zur Rolleninterpretation. . . . 9

1.11 Pass-Statistiken nach Wettbewerb: Volumen, Genauigkeit und durchschnittliche Distanz. Unterschiede deuten auf verschiedene Spielstile und taktische Ansätze hin. 10

1.12 Passgenauigkeit nach Wettbewerb (in %). Die Analyse umfasst alle sieben Wettbewerbe und zeigt eine konsistente Genauigkeit zwischen 82% und 83%. . . . 10

2.1 Pass-Netzwerk. Knoten = Spieler, gerichtete Kanten = Pässe, Breite typischerweise proportional zu `pass_count`. . . . 12

2.2 Match-Netzwerk (Beispiel). Knoten = Teams, Kanten = aggregierte Resultate zwischen Team-Paaren. . . . 13

2.3 Player–Team Two-Mode Netzwerk (vor Flattening). Spieler sind typischerweise einem Team zugeordnet (zwei bei Teamwechsel); Kantenbreite kodiert `matches_together`. . . . 14

2.4 Player–Player Netzwerk (nach Flattening / Projektion). Eine Kante entsteht durch gemeinsames Team; Gewichte akkumulieren gemeinsame Einsätze. . . . 14

2.5 Feld-Lokationsnetzwerk als Heatmap. Farbe/Grösse kodieren Ereignisintensität in diskreten Feldzonen. 15

2.6 Pass-Feld-Lokationsnetzwerk der Bundesliga. Knoten & Kantengrösse kodiert für Anzahl Pässe, Knotenfarbe für Grad und Kantenfarbe für Distanz 15

2.7 Local View des Stuttgard-Subgraphen 16

2.8 Global view des unified pass Networks (alle liegennetzwerke in einem Graph), Nodes zusammengeasst nach Team 17

2.9 Ego-Netzwerk von Granit Xhaka. Wir sehen das er sowohl mit dem FC Arsenal, wie auch der Schweizer Nationalmannschaft gut verknüpft ist. 18

2.10 Filterung nach Kantenattribut (Beispiel). 18

3.1 Connected Components im Pass-Netzwerk (Deutschland). Die grösste Komponente umfasst 473 Knoten (59.8% des Netzwerks), die übrigen sind Teams ohne Transferspieler 25

3.2 Algorithmenvergleich auf dem Pass-Netzwerk (Deutschland). Louvain erzielt die höchste Modularität ($Q = 0.886$), Label Propagation die höchste Coverage aber mit einer sehr grossen Ausreisser-Community (Max 51). 26

3.3 Grössenverteilungen der Communities für vier Algorithmen. Louvain und Greedy liefern sehr uniforme Grössen (23–31), Label Propagation zeigt einen Ausreisser (bis 51), Girvan-Newman produziert eine Singleton-Community. 27

3.4 Louvain-Communities im Match-Netzwerk (World Cup). Farbcodierung zeigt 6 Communities, die primär Vorrunden-Gruppen mit K.O.-Verknüpfungen widerspiegeln. 28

3.5 Positionsverteilung innerhalb der Köln-Communities (100% gestapelt). Die drei Communities zeigen hohe Positions-Diversität: Community 1 (19 Spieler) ist primär Defensive/Mittelfeld, Community 2 (8 Spieler) ebenso defensivlastig, Community 3 (4 Spieler) zeigt leichte offensive Prägung mit Torwartanteil. 29

4.1 Degree- und Strength-Verteilung im Pass-Netzwerk (Deutschland). Degree ist in dieser Auswertung relativ kompakt um den Mittelwert, Strength ist deutlich rechtssteil und hebt wenige High-Volume-Passer hervor. 33

4.2 Betweenness-Zentralität: Verteilung und Korrelation mit Degree 33

4.3 Korrelation verschiedener Zentralitätsmasse (Pass-Netzwerk) 34

4.4 k-Core Analyse: Verteilung und Zusammenhang mit Degree 35

4.5 Korrelation verschiedener Zentralitätsmasse (Match-Netzwerk World Cup) 36

5.1 Verteilung des Clustering-Koeffizienten. Links: Pass-Netzwerk (hoch konzentriert um 0.8 - 0.9). Rechts: Match-Netzwerk (variierter). 41

5.2 Clustering-Koeffizient vs. Degree. Pass-Netzwerk zeigt schwache negative Korrelation (Spearman $\rho = -0.235$), Match-Netzwerk schwache positive Korrelation ($\rho = 0.107$). 41

5.3 Verteilung der Edge Embeddedness. Pass-Netzwerk zeigt hohe Einbettung (Ø 17.7 gemeinsame Nachbarn), Match-Netzwerk niedrige Einbettung (Ø 1.6). 43

5.4 Korrelationen zwischen Metriken. Links: Pass-Netzwerk zeigt schwache negative Korrelation zwischen Clustering und Degree ($\rho = -0.235$). Rechts: Match-Netzwerk zeigt schwache positive Korrelation ($\rho = 0.107$). 44

6.1 Vergleich Zufallsgraph-Modelle. Das reale Pass-Netzwerk zeigt deutlich höheres Clustering (0.867) als alle Zufallsmodelle, aber auch längere Pfadlängen. 49

6.2 Gradverteilung des Pass-Netzwerks mit angepassten Modellen. Die Log-Normal-Verteilung (Kolmogorov-Smirnov $D = 0.067$) passt am besten. 51

6.3 Vergleich der angepassten Verteilungen (Empirical CDF vs. Model CDF). Log-Normal zeigt beste Übereinstimmung. 52

6.4 Permutationstest: Beobachtetes Clustering (0.867, rote Linie) vs. 1000 randomisierte Netzwerke (Configuration Model). $p < 0.001$. Das ist hochsignifikant. . . . 52

6.5 Bootstrap-Konfidenzintervalle (95%) für Netzwerk-Metriken. Clustering und Transitivity zeigen hohe Stabilität. 53

6.6 Link Prediction Performance-Vergleich. Adamic-Adar und Resource Allocation zeigen beste Ergebnisse. 54

6.7 Vergleich Link Prediction Performance: Pass-Netzwerk vs. Match-Netzwerk. Pass-Netzwerk zeigt durchgehend höhere AUC-Werte. 55

Tabellenverzeichnis

1.1 Beispiele von 5 zufällig ausgewählten Spielen aus dem Gesamtdatensatz mit Spielbezeichnung, Datum, Austragungsort und Spieldauer. 3

1.2 Vollständige Übersicht der Ereignistypen und Subtypen im Datensatz. Die Spalten geben die Event-ID und Subevent-ID sowie deren sprachliche Bezeichnung an. 4

1.3 Ausschnitt eines Passnetzwerks: erste 10 Passverbindungen eines Beispielspiels (Match-ID 2500004) mit Anzahl der Pässe, mittlerer Distanz und Spielernamen. 9

2.1 Übersicht der konstruierten Netzwerke (Germany; aus `.gexf` berechnet) 16

3.1 Algorithmenvergleich auf Pass-Netzwerk (Deutschland, grösste Komponente) . . 21

3.2 Community Detection auf Match-Netzwerk (World Cup) 22

4.1 Degree und Strength Statistiken (Pass-Netzwerk Deutschland) 32

4.2 Top-10 Spieler nach Gesamtzentralität (Pass-Netzwerk Deutschland) 35

5.1 Diameter und Average Path Length 40

5.2 Small-World-Check 40

5.3 Clustering-Metriken 40

5.4 Clustering vs. Zufallsnetzwerk 41

5.5 Degree-Assortativity 42

5.6 Reciprocity in gerichteten Netzwerken 42

5.7 Edge Embeddedness 43

5.8 Umfassende Netzwerk-Metriken (Zusammenfassung) 44
6.1 Vergleich Zufallsgraph-Modelle (Pass-Netzwerk LCC, 283 Knoten, 2 899 Kanten) 49
6.2 Anpassung von Verteilungsmodellen (Kolmogorov-Smirnov Test) 50
6.3 Link Prediction Performance (Pass-Netzwerk) 54

1 Exploratory Data Analysis (EDA)

1.1 Ziel und Kapitelrolle

Dieses Kapitel liefert den einmaligen Überblick über Datensatz, Vorverarbeitung und zentrale Verteilungen. Alle nachfolgenden Kapitel (z. B. Netzwerk-Modellierung, Filterung, Metriken) referenzieren diese Ergebnisse und verzichten bewusst darauf, den Datensatz erneut zu erklären. Ziel der EDA ist es, die Datenstruktur zu validieren, Kerndistributionen (Ereignisse, Pässe) zu charakterisieren und daraus belastbare Annahmen für die Netzwerk-Analysen abzuleiten.

Analyseumfang: Die EDA analysiert *alle sieben Wettbewerbe* (England, Spanien, Deutschland, Frankreich, Italien, World Cup, European Championship) gemeinsam, um ein umfassendes Bild des Gesamtdatensatzes zu erhalten. In den nachfolgenden Kapiteln (LE3 ff.) werden dann einzelne Wettbewerbe fokussiert untersucht, um die Rechenkomplexität für detaillierte Netzwerkanalysen zu reduzieren.

1.2 Datenbasis und Aufbereitung

- **Datenquellen:** Die Rohdaten liegen als JSON-Dateien in `data/` vor (Wettbewerbe, Spiele, Ereignisse, Teams, Spieler) und umfassen mehrere Wettbewerbe.
- **Robuster Import:** Unicode-Bereinigung und fehlerresistentes Einlesen (für grosse Event-Dateien ggf. Streaming). Fehlende Felder (z. B. Positionen) werden als *NaN* geführt und in Auswertungen entsprechend behandelt.
- **Feature Engineering:** Aus Event-Positionen werden Start-/Endpunkte extrahiert und einfache Distanzmasse für Pässe berechnet. Für Zeitreihen werden Events pro Minute aggregiert; beide Halbzeiten beginnen jeweils bei Minute 0.
- **Ausschlüsse:** Ereignisse ohne ausreichende Positionsinformationen fliessen nicht in Distanzverteilungen ein.

1.3 Wettbewerbe und Spiele

Der Datensatz umfasst mehrere europäische Top-Ligen sowie internationale Turniere. Abbildung 1.1 zeigt die Verteilung der Spiele über die Wettbewerbe. Unterschiede in der Spielanzahl spiegeln Ligaformate (z. B. 38 Spieltage) und Turnierlängen wider.

Ergänzend zeigt Abbildung 1.2 die Anzahl der Ereignisse pro Wettbewerb. Erwartungsgemäss skaliert die Eventanzahl stark mit der Anzahl Spiele und der Granularität der Erfassung. Die Liga-Wettbewerbe (England, Spanien, Frankreich, Italien) weisen jeweils ca. 650,000 Events auf (ca. 1,710 Events pro Match), während Deutschland mit ca. 530,000 Events (ca. 1,730 Events/-Match) und die Turniere World Cup und European Championship mit ca. 130,000 bzw. 100,000 Events eine geringere Gesamtzahl aufweisen. Dies bildet eine robuste Basis für detaillierte Netzwerkanalysen.

Zur Veranschaulichung der Match-Metadaten zeigt Tabelle 1.1 eine zufällige Stichprobe von 5 Spielen (`df.sample(5)` auf dem Match-DataFrame):

1.4 Ereignisse: Typen und zeitliche Muster

Die Event-Typen sind über IDs und Labels definiert; Tabelle 1.2 dokumentiert diese Zuordnung und dient in späteren Kapiteln als Referenz für Filter und Aggregationen.

Die Analyse der Ereignistypen in Abbildung 1.3 zeigt erwartungsgemäss, dass Pässe die häufigste Aktion darstellen, gefolgt von Duellen und Ballkontakten. Diese Dominanz von Passereignissen motiviert den Schwerpunkt auf Passnetzwerken.

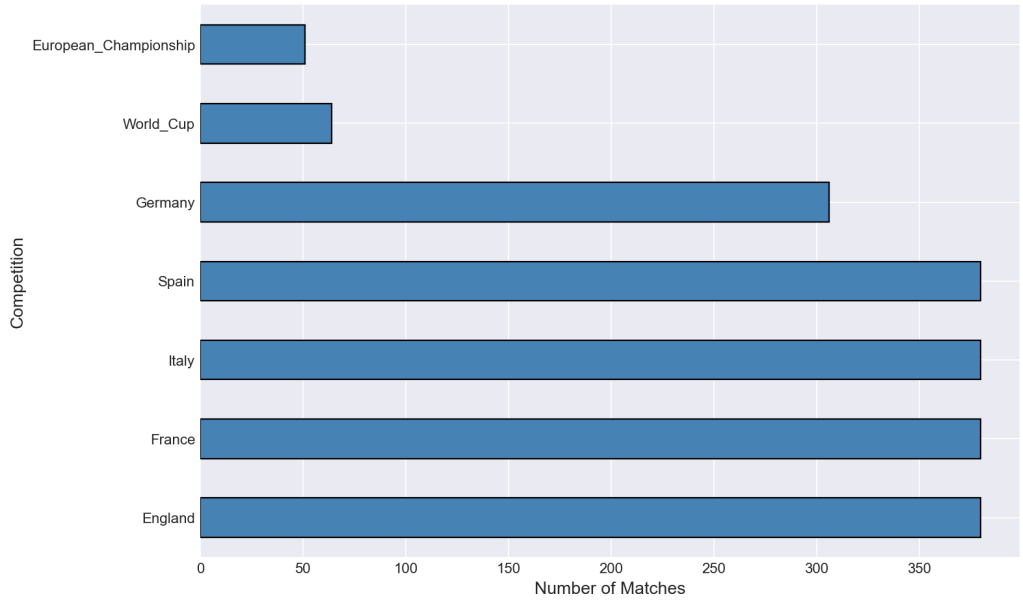


Abbildung 1.1: Anzahl der Spiele pro Wettbewerb. Die Daten decken sowohl Liga-Wettbewerbe (England, Spanien, Deutschland, etc.) als auch internationale Turniere (WM, EM) ab.

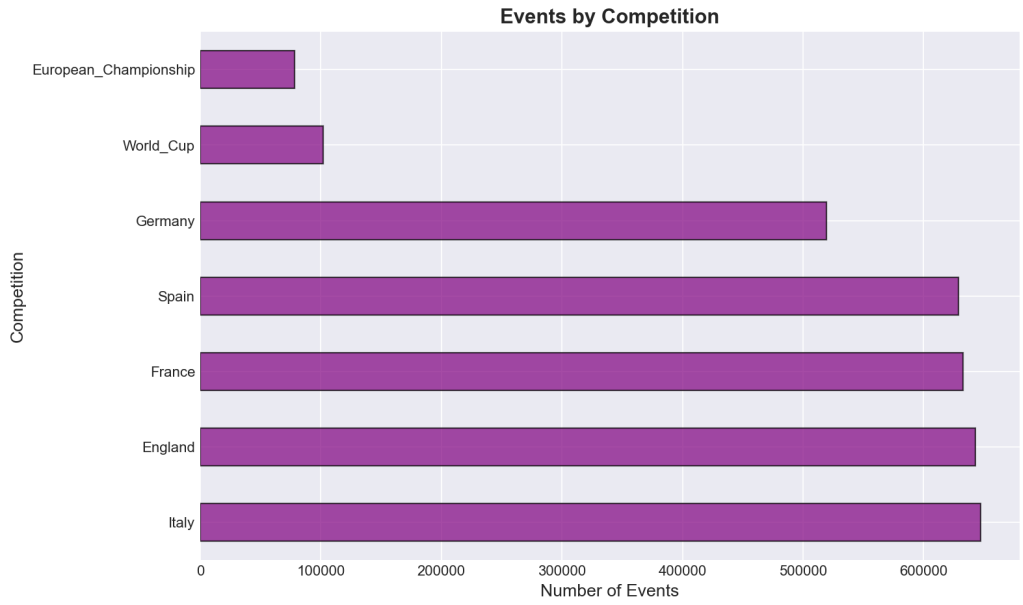


Abbildung 1.2: Anzahl der Events pro Wettbewerb. Die EDA umfasst alle sieben Wettbewerbe (England, Spanien, Deutschland, Frankreich, Italien, World Cup, European Championship).

label	date	venue	duration
Huddersfield Town - Crystal Palace, 0 - 2	March 17, 2018 at 4:00:00 PM GMT+1	The John Smith's Stadium	Regular
Manchester United - Crystal Palace, 4 - 0	September 30, 2017 at 4:00:00 PM GMT+2	Old Trafford	Regular
Everton - Southampton, 1 - 1	May 5, 2018 at 6:30:00 PM GMT+2	Goodison Park	Regular
Everton - Manchester United, 0 - 2	January 1, 2018 at 6:30:00 PM GMT+1	Goodison Park	Regular
Stoke City - Liverpool, 0 - 3	November 29, 2017 at 9:00:00 PM GMT+1	Bet365 Stadium	Regular

Tabelle 1.1: Beispiele von 5 zufällig ausgewählten Spielen aus dem Gesamtdatensatz mit Spielbezeichnung, Datum, Austragungsort und Spieldauer.

	event	subevent	event_label	subevent_label
0	1	10	Duel	Air duel
1	1	11	Duel	Ground attacking duel
2	1	12	Duel	Ground defending duel
3	1	13	Duel	Ground loose ball duel
4	2	20	Foul	Foul
5	2	21	Foul	Hand foul
6	2	22	Foul	Late card foul
7	2	23	Foul	Out of game foul
8	2	24	Foul	Protest
9	2	25	Foul	Simulation
10	2	26	Foul	Time lost foul
11	2	27	Foul	Violent Foul
12	3	30	Free Kick	Corner
13	3	31	Free Kick	Free Kick
14	3	32	Free Kick	Free kick cross
15	3	33	Free Kick	Free kick shot
16	3	34	Free Kick	Goal kick
17	3	35	Free Kick	Penalty
18	3	36	Free Kick	Throw in
19	4	40	Goalkeeper leaving line	Goalkeeper leaving line
20	5	50	Interruption	Ball out of the field
21	5	51	Interruption	Whistle
22	6	60	Offside	Offside
23	7	70	Others on the ball	Acceleration
24	7	71	Others on the ball	Clearance
25	7	72	Others on the ball	Touch
26	8	80	Pass	Cross
27	8	81	Pass	Hand pass
28	8	82	Pass	Head pass
29	8	83	Pass	High pass
30	8	84	Pass	Launch
31	8	85	Pass	Simple pass
32	8	86	Pass	Smart pass
33	9	90	Save attempt	Reflexes
34	9	91	Save attempt	Save attempt
35	10	100	Shot	Shot

Tabelle 1.2: Vollständige Übersicht der Ereignistypen und Subtypen im Datensatz. Die Spalten geben die Event-ID und Subevent-ID sowie deren sprachliche Bezeichnung an.

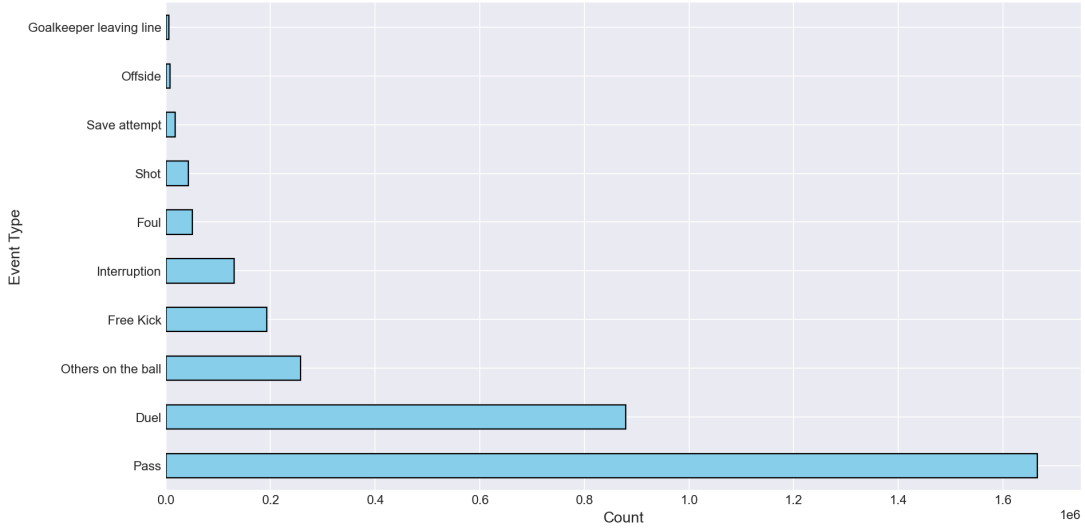


Abbildung 1.3: Top 15 Ereignistypen über alle Wettbewerbe. Pässe dominieren klar das Spielgeschehen.

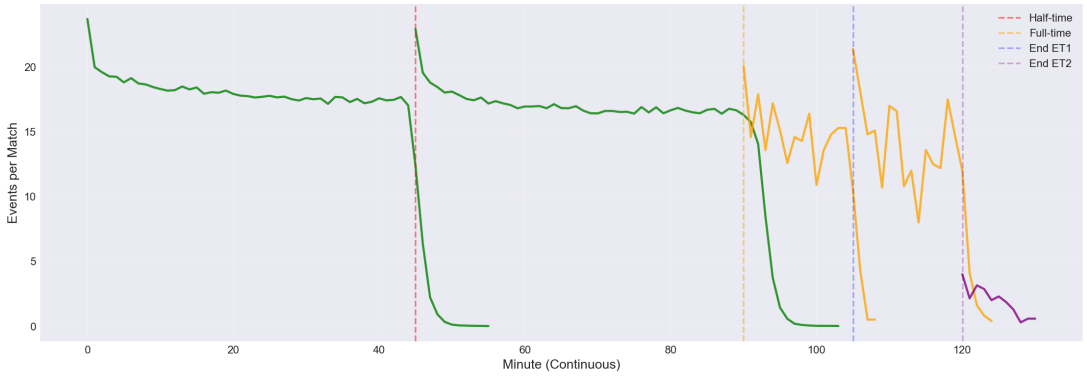


Abbildung 1.4: Ereignisse pro Spielminute (kontinuierlich über beide Halbzeiten). Deutlich erkennbar sind erhöhte Aktivität zu Spielbeginn und der Rückgang in der Schlussphase.

Die zeitliche Verteilung der Ereignisse über den Spielverlauf (Abbildung 1.4) zeigt erhöhte Aktivität zu Beginn beider Halbzeiten sowie einen Abfall gegen Ende der zweiten Halbzeit. Diese Muster sind für spätere, phasenbasierte Netzwerkvergleiche relevant (z. B. Anfangsphase vs. Schlussphase).

Auf aggregierter Ebene ist die Datenabdeckung über die reguläre Spielzeit ausgeglichen: Abbildung 1.5 zeigt nahezu identische Event-Zahlen in der ersten und zweiten Halbzeit (je ca. 320,000 Events). Das spricht gegen systematische Ausfälle in einer Spielhälfte und erhöht die Vergleichbarkeit phasenbasierter Analysen.

Für Passereignisse zeigt sich jedoch ein leichter Halbzeiteffekt (Abbildung 1.6): In der ersten Halbzeit werden mehr Pässe gespielt (170,614 vs. 158,043; +7.4%), die Passgenauigkeit ist minimal höher (82.99% vs. 82.06%) und die durchschnittliche Passdistanz praktisch unverändert (24.69 vs. 24.54). Inhaltlich passt dies zu Effekten wie Ermüdung, Spielstandmanagement oder erhöhtem Pressing in Halbzeit 2.

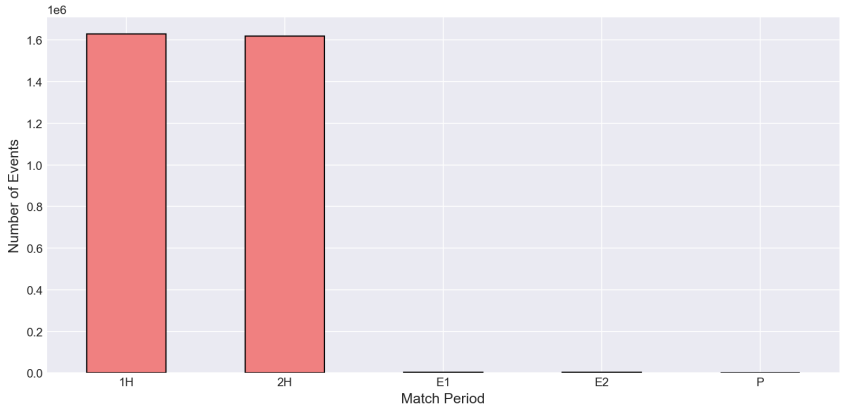


Abbildung 1.5: Events nach Spielhälfte (1H vs. 2H). In der vorliegenden Auswertung sind beide Halbzeiten mit je ca. 320,000 Events nahezu gleich stark vertreten.

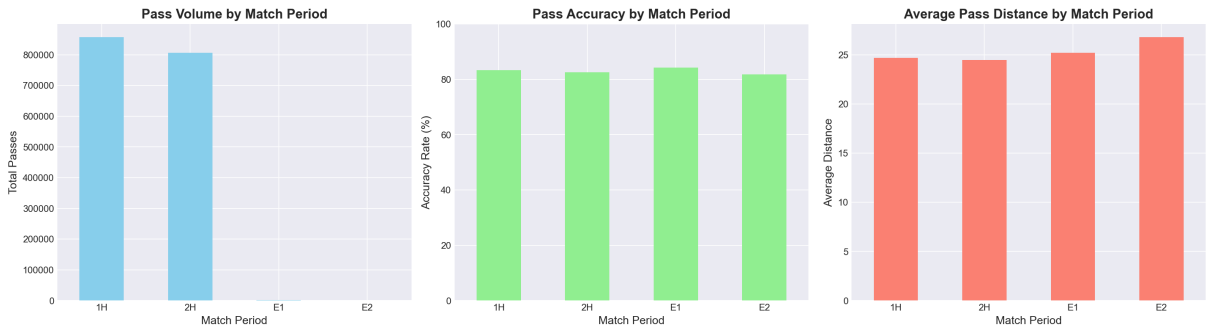


Abbildung 1.6: Passvolumen, Passgenauigkeit und durchschnittliche Passdistanz nach Halbzeit (1H/2H). In dieser Auswertung werden in Halbzeit 1 mehr Pässe gespielt (+7.4%), bei sehr ähnlicher Genauigkeit und Distanz.

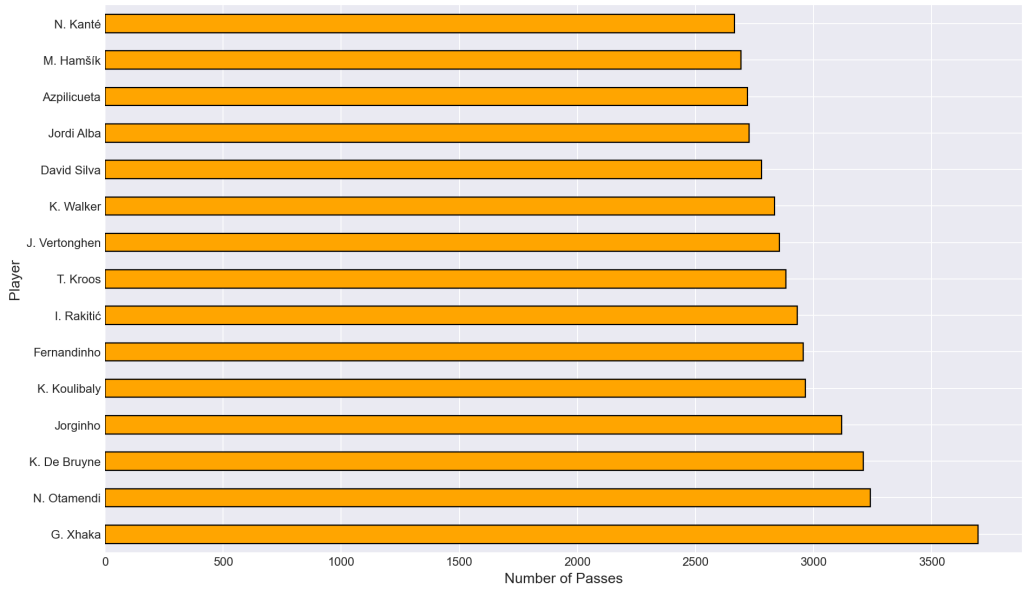


Abbildung 1.7: Top 15 Spieler nach Anzahl der Pässe. Diese Spieler sind später als zentrale Knoten in den Passnetzwerken zu erwarten.

1.5 Pass-Analyse: Zentrale Akteure und räumliche Verteilung

Pässe bilden das Rückgrat der späteren Netzwerk-Analyse. Abbildung 1.7 identifiziert die aktivsten Passgeber. Diese Spieler sind Kandidaten für zentrale Knoten (hohe Degree- und Betweenness-Zentralität), da sie als Verteiler im Spielaufbau fungieren.

Neben räumlichen Mustern ist die enstruktur nach Passtyp zentral für die Interpretation von Netzwerkkanten: Abbildung 1.8 zeigt, dass „einfache Pässe“ den Grossteil des Volumens ausmachen (ca. 251,405; ca. 76% aller Pässe) und zugleich eine sehr hohe Genauigkeit aufweisen (91.69%). Risikoreichere e (Flanken, Smart Passes) treten seltener auf und haben deutlich niedrigere Erfolgsraten (z. B. Flanken ca. 30.71%). Für die spätere Netzwerkanalyse bedeutet dies: Gewichte werden stark durch kurze, sichere Verbindungen dominiert, während wenige riskante Kanten eher spielentscheidende Situationen abbilden.

Eine detaillierte räumliche Analyse der Pässe (Abbildung 1.9) liefert mehrere wichtige Erkenntnisse:

- Die **Passlängenverteilung** (oben links) zeigt eine rechtssteile Verteilung mit Median bei ca. 15 Einheiten, was kurzen bis mittellangen Pässen entspricht. Lange Bälle sind seltener.
- Die **Passlängen nach Typ** (oben rechts) verdeutlichen erwartbare Unterschiede: Lange Bälle und Flanken weisen deutlich grössere Distanzen auf als einfache Zuspiele.
- Die **Heatmaps** (unten) für Pass-Ursprung und -Ziel zeigen die räumliche Konzentration: Viele Pässe starten und enden im Mittelfeld sowie in defensiven Bereichen, während Pässe im gegnerischen Strafraum seltener sind – ein Indikator für die Schwierigkeit, in gefährliche Zonen vorzudringen.

Als kompaktes Bindeglied zur Netzwerkanalyse illustriert Abbildung 1.10 die Rolleninterpretation einfacher Zentralitätskonzepte in einem Beispielspiel: Spieler oberhalb der Diagonalen erhalten mehr Pässe als sie spielen („Zielspieler“), Spieler unterhalb verteilen mehr („Aufbauspieler“), und Spieler nahe der Diagonalen sind ausgeglichen. Diese Intuition wird in LE5 bei der Interpretation von In-/Out-Degree und Brückenrollen (Betweenness) wieder aufgegriffen.

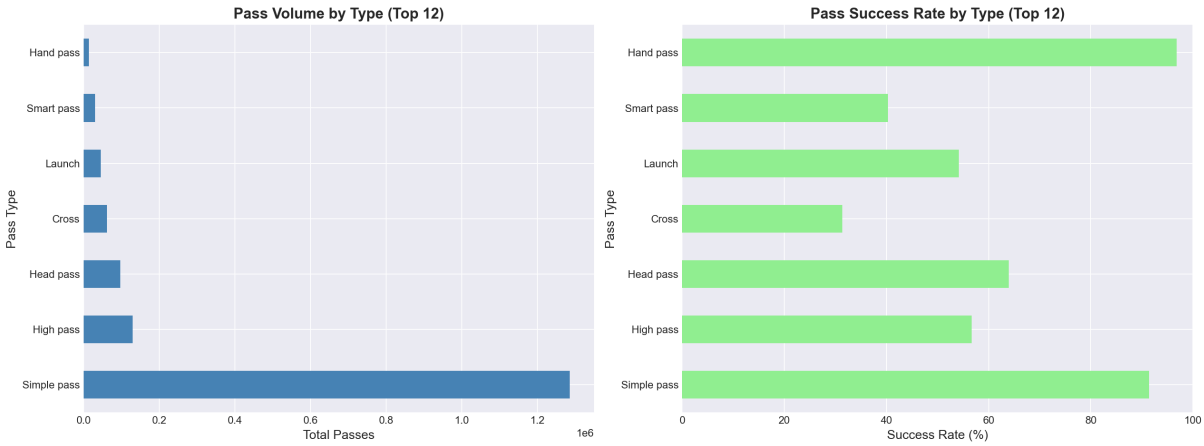


Abbildung 1.8: Passvolumen (links) und Passgenauigkeit (rechts) nach Passtyp (Top 12). „einfache Pässe“ dominieren das Volumen bei hoher Genauigkeit; Flanken und Smart Passes sind seltener und deutlich ungenauer.

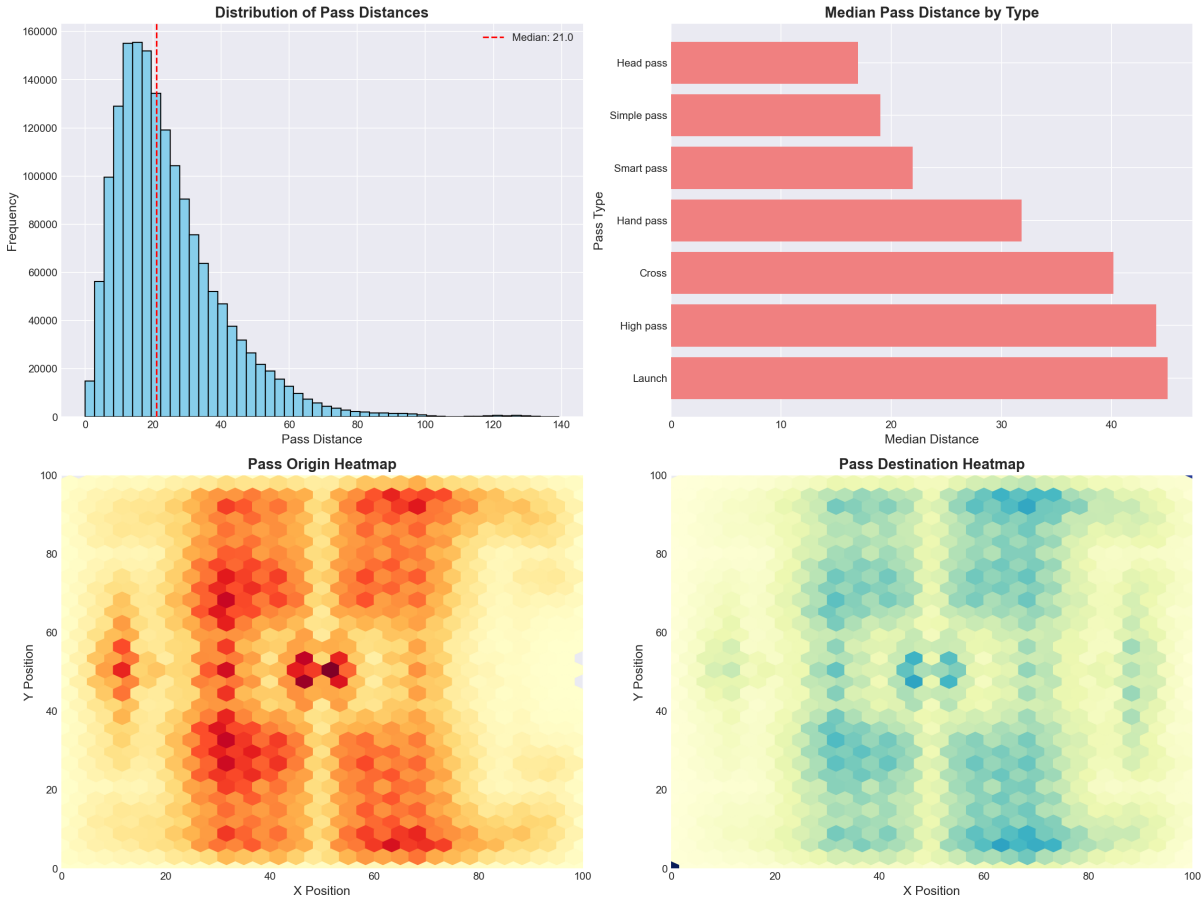


Abbildung 1.9: Umfassende Analyse der Passeigenschaften. **Oben links:** Verteilung der Passlängen mit Median-Markierung. **Oben rechts:** Median-Passlänge nach Passtyp (z. B. lange Bälle vs. kurze Zuspiels). **Unten:** Heatmaps für Pass-Ursprung (links) und Pass-Ziel (rechts), visualisiert auf normalisierten Spielfeldkoordinaten.



Abbildung 1.10: Beispielhafte Zentralitätsintuition in einem Sample-Match: (links) Top-10 Spieler nach Passvolumen (gespielt vs. empfangen), (rechts) Out-Degree vs. In-Degree mit Referenzlinie $y = x$ zur Rolleninterpretation.

	passer_id	receiver_id	pass_count	avg_distance	passer_name	receiver_name
0	3324	8625.000000	1	4.123106	Álvaro Morata	V. Moses
1	3350	3324.000000	1	13.038405	Fàbregas	Álvaro Morata
2	3350	3360.000000	6	20.523277	Fàbregas	Pedro
3	3350	3429.000000	3	25.654240	Fàbregas	T. Courtois
4	3350	8032.000000	1	26.627054	Fàbregas	Marcos Alonso
5	3350	8495.000000	3	12.648930	Fàbregas	D. Drinkwater
6	3350	8625.000000	2	21.530491	Fàbregas	V. Moses
7	3350	14748.000000	3	9.815600	Fàbregas	A. Rüdiger
8	3350	25553.000000	9	18.920233	Fàbregas	Azpilicueta
9	3350	25707.000000	1	17.804494	Fàbregas	E. Hazard

Tabelle 1.3: Ausschnitt eines Passnetzwerks: erste 10 Passverbindungen eines Beispielspiels (Match-ID 2500004) mit Anzahl der Pässe, mittlerer Distanz und Spielernamen.

Um die spätere Netzwerkkonstruktion zu illustrieren, zeigt Tabelle 1.3 einen Ausschnitt aus einem berechneten Passnetzwerk eines Beispielspiels (Match-ID 2500004). Die Kanten sind Passverbindungen, gewichtet nach *pass_count*; zusätzlich ist die mittlere Passdistanz angegeben.

1.6 Wettbewerbsvergleich

Die aggregierten Pass-Statistiken nach Wettbewerb (Abbildung 1.11) ermöglichen einen direkten Vergleich der Spielstile: Volumen (Anzahl der Pässe), Genauigkeit (Erfolgsquote) und durchschnittliche Passlänge variieren zwischen den Ligen und Turnieren. Solche Unterschiede können auf taktische Präferenzen, Spieltempo oder die Qualität der Teams hindeuten und werden sich in den strukturellen Eigenschaften der daraus generierten Netzwerke widerspiegeln.

Auf Basis der vorliegenden Wettbewerbs-Auswertung zeigt sich eine Passgenauigkeit zwischen 82% und 83% über alle Wettbewerbe hinweg (Abbildung 1.12). Die englische, spanische und französische Liga liegen bei ca. 82.5%, während die Turniere (World Cup, European Championship) mit ca. 82.0–82.2% leicht darunter liegen. Dies entspricht den Erwartungen im professionellen Fussball (etwa 4 von 5 Pässen kommen an) und zeigt, dass Turnierspiele möglicherweise unter höherem Druck mit etwas geringerer Präzision gespielt werden.

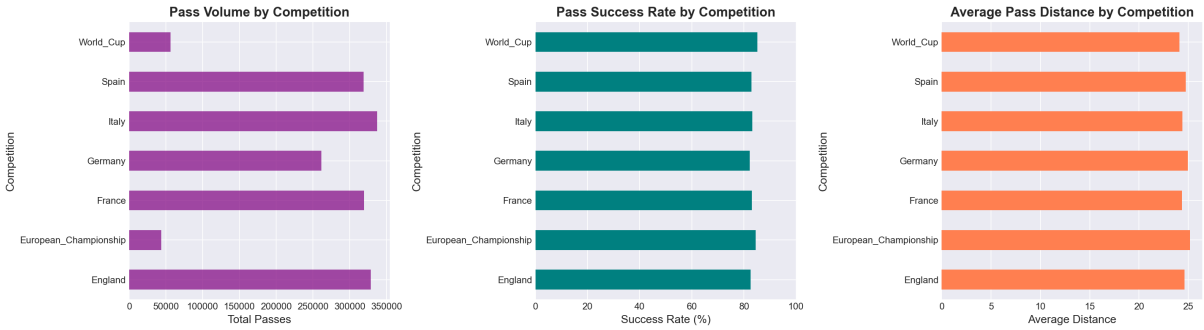


Abbildung 1.11: Pass-Statistiken nach Wettbewerb: Volumen, Genauigkeit und durchschnittliche Distanz. Unterschiede deuten auf verschiedene Spielstile und taktische Ansätze hin.

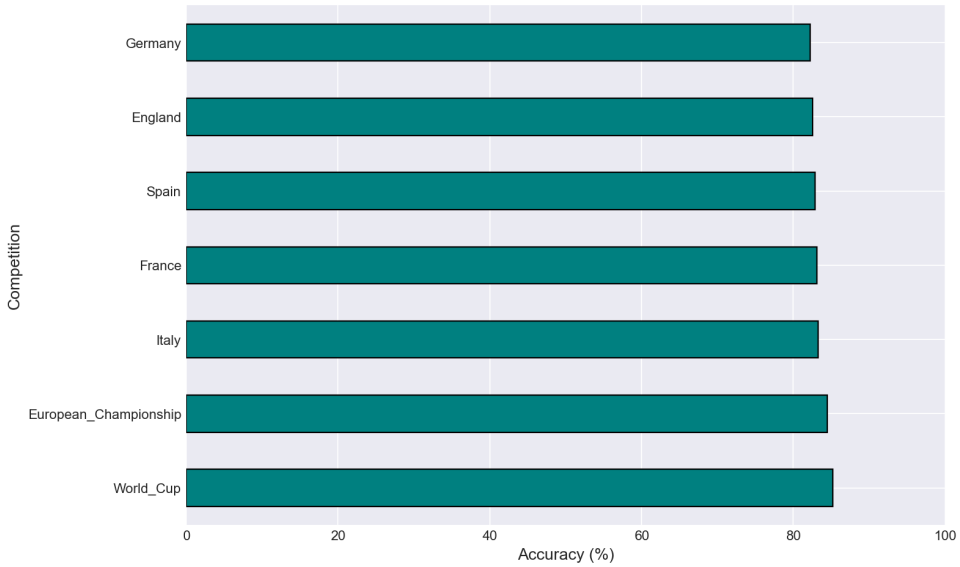


Abbildung 1.12: Passgenauigkeit nach Wettbewerb (in %). Die Analyse umfasst alle sieben Wettbewerbe und zeigt eine konsistente Genauigkeit zwischen 82% und 83%.

1.7 Erste Hypothesen für die Netzwerk-Analyse

Basierend auf den EDA-Ergebnissen lassen sich folgende Hypothesen für die nachfolgenden Netzwerk-Analysen (Kapitel 4) formulieren:

1. **Zentrale Knoten:** Die identifizierten Top-Passgeber werden hohe Degree-Zentralität und Betweenness-Zentralität aufweisen, da sie als Verteiler im Spielaufbau fungieren.
2. **Räumliche Cluster:** Die Heatmaps deuten auf räumliche Cluster hin (Abwehr, Mittelfeld, Angriff), die sich in Community-Strukturen der Netzwerke widerspiegeln könnten.
3. **Wettbewerbsspezifische Unterschiede:** Ligen mit höherer Pass-Genauigkeit und kürzeren Pässen könnten dichtere Netzwerke mit mehr reziproken Verbindungen aufweisen.
4. **Zeitliche Dynamik:** Die beobachteten Aktivitätsmuster über den Spielverlauf legen nahe, dass sich Netzwerkmetriken (z. B. Dichte, Zentralisierung) zwischen den Spielphasen unterscheiden.

2 LE3 – Netzwerk-Modellierung & Filterung

Dieses Kapitel dokumentiert die Konstruktion verschiedener Netzwerktypen aus den Fussballdaten sowie die angewandten Filterungstechniken zur Netzwerkreduktion. Basierend auf den Erkenntnissen aus dem EDA erstellen wir vier Netzwerke: Pass-Netzwerke (Spieler–Spieler), Match-Netzwerke (Team–Team), bipartite Spieler–Team-Netzwerke sowie ein Feld-Lokationsnetzwerk (Zone–Zone). Da es in diesem Datensatz eine vielzahl verschiedener Netzwerke gibt, wählen wir immer eines aus um die anwendung zu demonstrieren.

2.1 Netzwerkmodellierung

2.1.1 Netzwerke

Fussball ist sehr komplex und vielschichtig. Um eine angemessene Mischung aus Aufwand und Abdeckung zu erreichen, haben wir uns dazu entschlossen, vier Netzwerktopologien zu modellieren, die unterschiedliche Aspekte des Spielgeschehens abdecken und verschiedene Analysen ermöglichen.

Pass-Netzwerk (Spieler–Spieler)
Typ: gerichtet, gewichtet.

Knoten: Spieler (`wyId`).

Kanten: gerichtete Kante (u, v), wenn Spieler u einen Pass zu Spieler v spielt. Hauptgewicht ist `pass_count`.

Konstruktion: Wyscout liefert leider keinen expliziten Passempfänger. Wir bestimmen ihn daher über ein Raum-zeitliches Matching: zur Pass-Endposition suchen wir im selben Team die nächste Aktion innerhalb von 5 Sekunden und 10 Metern. Der nächstgelegene Kandidat wird als Empfänger gewählt. Das ist sehr robust, kann aber zu Fehlzuordnungen führen wenn z.B ein Foul direkt nach einem Pass passiert, oder sonst sehr schnellen Sequenzen / quasi gleichzeitigen Aktionen geschehen.

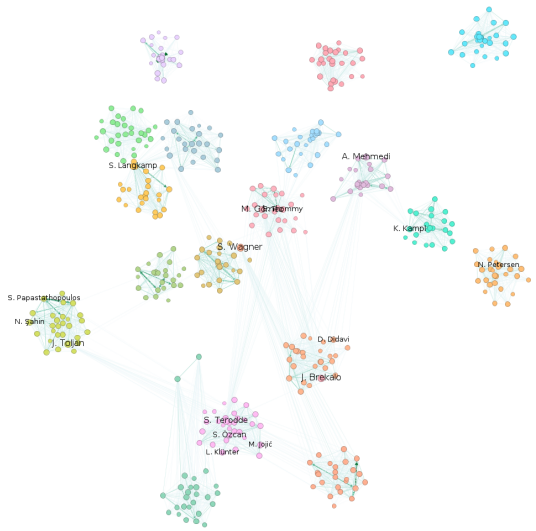


Abbildung 2.1: Pass-Netzwerk. Knoten = Spieler, gerichtete Kanten = Pässe, Breite typischerweise proportional zu `pass_count`.

Match-Netzwerk (Team–Team)

Typ: gerichtet, gewichtet.

Knoten: Teams.

Kanten: je Spiel erzeugen wir zwei gerichtete Kanten $(A \to B)$ und $(B \to A)$; das Kantengewicht entspricht den erzielten Toren (Aggregationen über mehrere Spiele werden summiert).

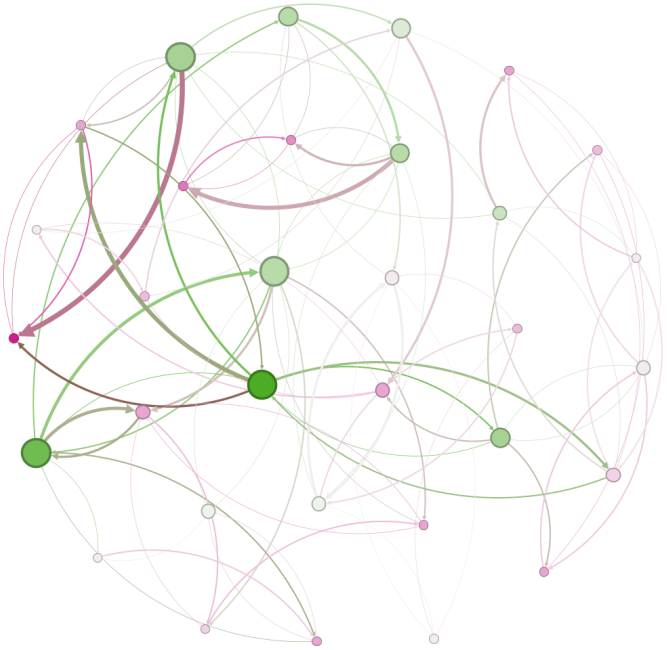


Abbildung 2.2: Match-Netzwerk (Beispiel). Knoten = Teams, Kanten = aggregierte Resultate zwischen Team-Paaren.

Spieler–Team-Netzwerk (Two-Mode)

Typ: bipartit, ungerichtet, gewichtet. **Knoten:** Spieler P und Teams T. **Kanten:** Kante (p, t), wenn Spieler p in einem Match für Team t auflief; Gewicht `matches_together` zählt Einsätze/-Matchbeteiligungen.

Beobachtung: Spieler sind typischerweise mit **einem** Team stark verbunden. Ausgeprägte Verindungen mit zwei Teams treten nur bei Teamwechseln innerhalb der Saison auf (z.B. Sandro Wagner, TSG Hoffenheim -> Bayern München (transfermarkt.ch, n. d.))

Flattening: Projektion auf Spieler Wir projizieren das bipartite Spieler-Team Netz auf die Spielermenge: zwei Spieler sind verbunden, wenn sie mindestens ein Team teilen; das Kantengewicht steigt mit der Anzahl gemeinsamer Einsätze . Dadurch entsteht ein Spieler–Spieler-Netz, das Teambeziehungen und transfers sichtbar macht.

Feld-Lokationsnetzwerk (Zone–Zone)

Typ: gerichtet, Multi-Edge.

Knoten: diskrete Feldzonen (5×5m Raster, Wyscout-Koordinaten 0–100).

Kanten: Ereignisübergänge von Start- zu Endzone für Pass (8), Schuss (10) und Standards (3). Dieses Netz dient als räumliche Perspektive auf Spielmuster.

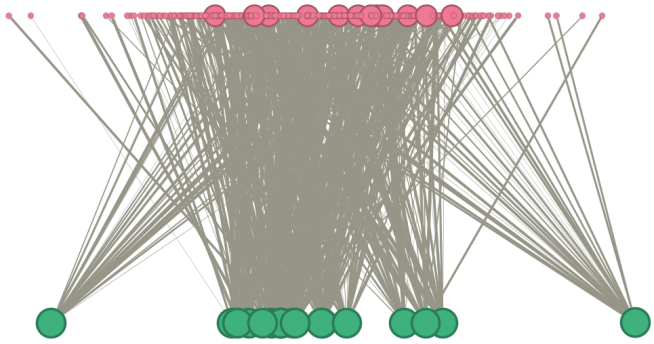


Abbildung 2.3: Player–Team Two-Mode Netzwerk (vor Flattening). Spieler sind typischerweise einem Team zugeordnet (zwei bei Teamwechsel); Kantenbreite kodiert `matches_together`.

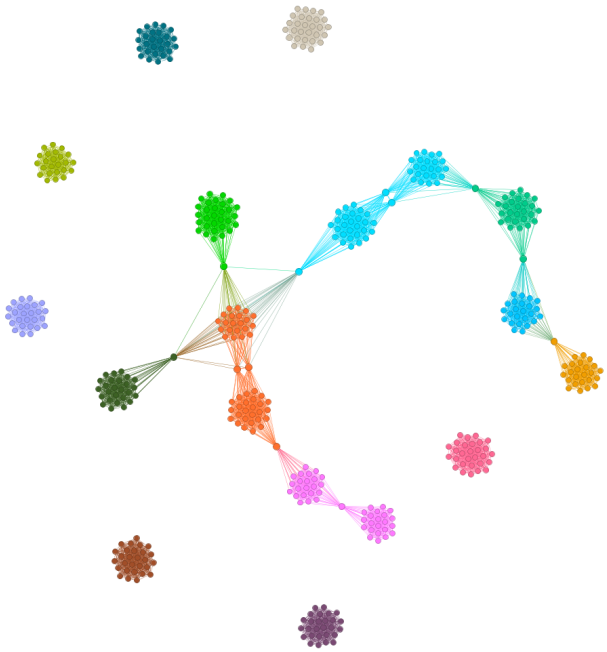


Abbildung 2.4: Player–Player Netzwerk (nach Flattening / Projektion). Eine Kante entsteht durch gemeinsames Team; Gewichte akkumulieren gemeinsame Einsätze.

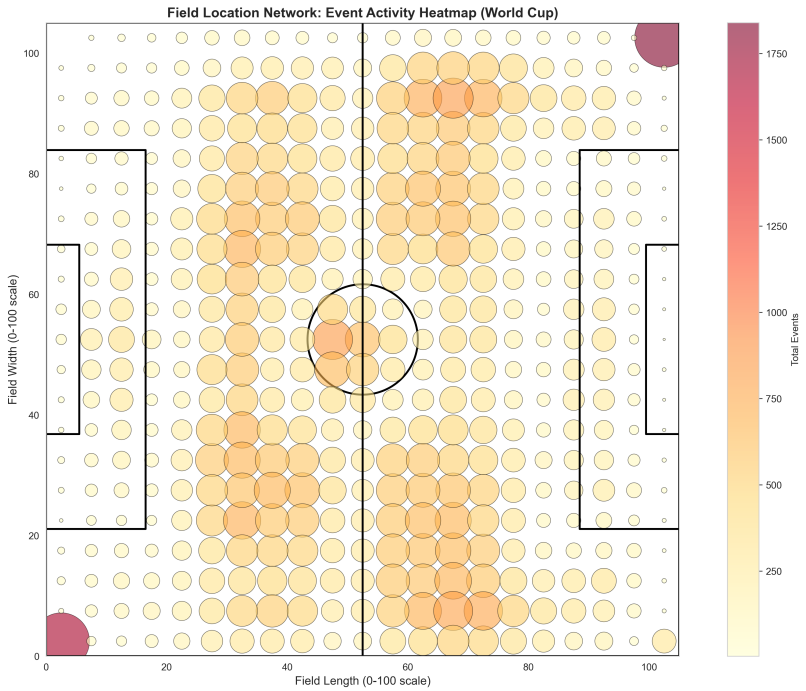


Abbildung 2.5: Feld-Lokationsnetzwerk als Heatmap. Farbe/Grösse kodieren Ereignisintensität in diskreten Feldzonen.

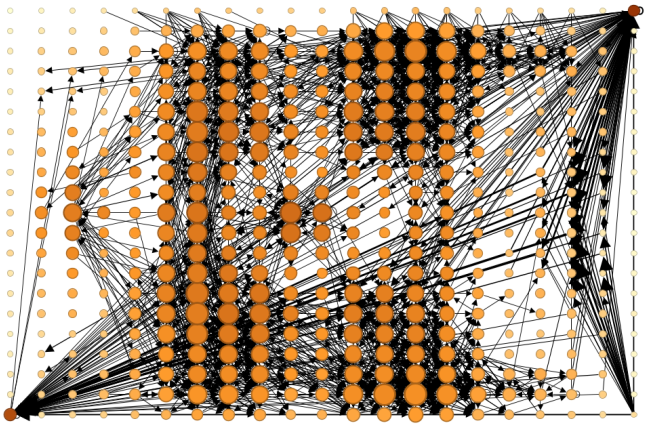


Abbildung 2.6: Pass-Feld-Lokationsnetzwerk der Bundesliga. Knoten & Kantengrösse kodiert für Anzahl Pässe, Knotenfarbe für Grad und Kantenfarbe für Distanz

2.2 Netzwerkfilterung

In diesem Kapitel beschreiben wir, wie wir Filterung und Sichten (Local/Global/Ego) einsetzen, um aus grossen Netzwerken analysierbare Teilstrukturen zu extrahieren. Der Fokus liegt auf der praktischen Nutzung: welche Fragen lassen sich damit beantworten, und welche Visualisierungen stützen die Interpretation.

2.2.1 Sichten: Local View, Global View, Ego-Netzwerk

Local View

Mit der Local view nach Team können wir einen Team-Subgraph aus dem Pass-Netzwerk extrahieren. Damit können wir später untersuchen, ob z.B. die Stärke und Zentralisierung der teaminternen Verknüpfungen mit sportlichem Erfolgen korreliert

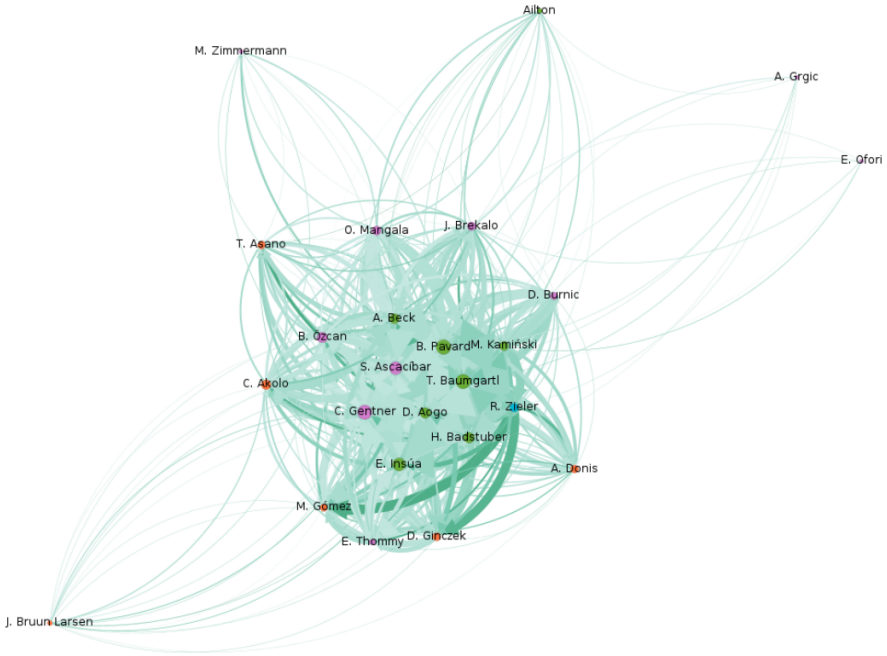


Abbildung 2.7: Local View des Stuttgard-Subgraphen

Global View

Mit der Global view betrachten wir das komplette Netzwerk eines Wettbewerbs , lassen aber Details weg. Sie dient dem Vergleich zwischen Competitions oder zur Einordnung von Extremwerten.).

Tabelle 2.1: Übersicht der konstruierten Netzwerke (Germany; aus `.gexf` berechnet)

Netzwerktyp	|V|	|E|	Dichte	Komponenten
Pass-Netzwerk	473	8786	0.039354	8
Match-Netzwerk	18	306	1.000000	1
Spieler-Team-Netzwerk	492	503	0.004164	1
Spieler-Projektion	474	6803	0.060686	1

Ego-Netzwerk

Mit dem Ego-Netzwerke isolieren wir die unmittelbare Umgebung eines Spielers (Ego). Sie

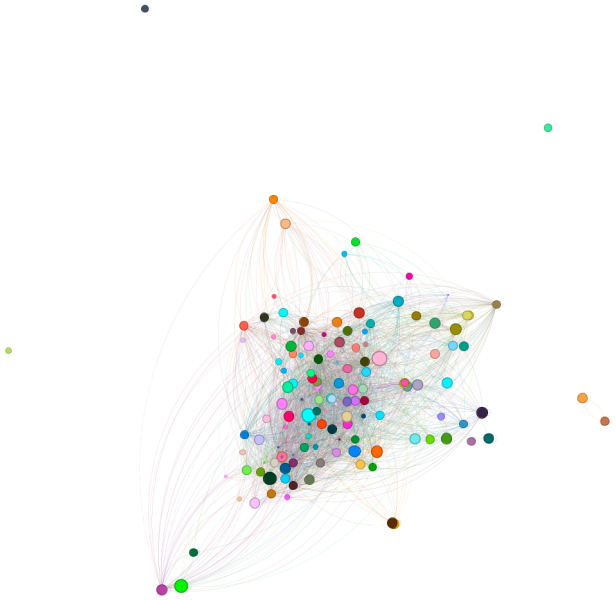


Abbildung 2.8: Global view des unified pass Networks (alle liegennetzwerke in einem Graph), Nodes zusammengeasst nach Team

sind sind hilfreich, um Rollen im Teamkontext zu interpretieren oder konkrete Passpartner-Strukturen zu visualisieren.

2.2.2 Filtern anhand von Kantenattributen

Wir setzen Kantenattribut-Filter ein, um "Rauschenßu reduzieren und stabilere Beziehungen hervorzuheben. Im Pass-Netzwerk ist das zentrale Filterkriterium typischerweise `pass_count` (Mindestanzahl Pässe pro Kante); optional sind Filter nach Genauigkeit oder Distanz sinnvoll.

Für Germany zeigt die gewichtsbasierte Filterung (nach Entfernen isolierter Knoten) z.B.:

- $w \geq 5$: 91.1% Knoten, 71.9% Kanten erhalten
- $w \geq 10$: 85.6% Knoten, 56.2% Kanten erhalten
- $w \geq 20$: 76.7% Knoten, 36.8% Kanten erhalten

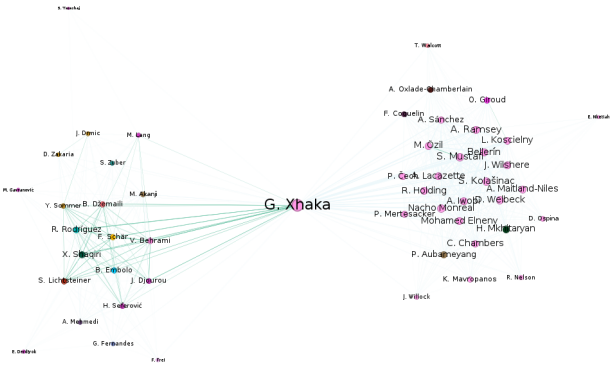


Abbildung 2.9: Ego-Netzwerk von Granit Xhaka. Wir sehen das er sowohl mit dem FC Arsenal, wie auch der Schweizer Nationalmannschaft gut verknüpft ist.

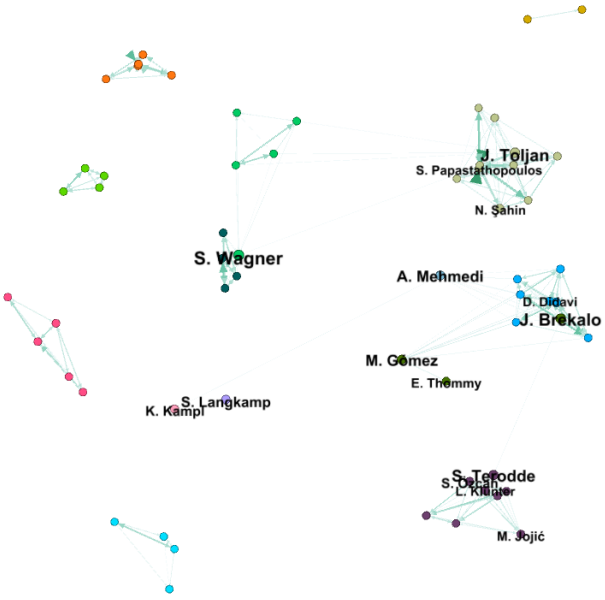


Abbildung 2.10: Filterung nach Kantenattribut (Beispiel).

3 LE4 – Communities

In diesem Kapitel untersuchen wir, welche Untergruppen wir in unseren wyscouts Fussball Netzwerken identifizieren können. Wir beschränken uns auf Das Netzwerk für die Bundesliga sowie auf den Worldcup.
Wir betrachten drei Aspekte: (1) **Connected Components** als grundlegende Zusammenhangsstruktur, (2) **Cliquen** als maximale vollständig vernetzte Gruppen und (3) **Community Detection** zur Identifikation von dichter verbundenen, aber nicht notwendigerweise vollständig vernetzten Gruppen.

Im Kontext von Fussball erwarten wir:

- **Pass-Netzwerke**: Teams als Communities; Spielformationen als dichtere Substrukturen
- **Match-Netzwerke**: Turniergruppen
- **Feld-Netzwerke**: Cluster von Verteidigungs und Angrifsfeldern.

3.1 Connected Components

Connected Components beschreiben die grundlegende Zusammenhangsstruktur eines Netzwerks: Gruppen von Knoten, die über Pfade erreichbar sind, aber untereinander nicht verbunden sind.

Pass-Netzwerk (Deutschland)
Das Pass-Netzwerk 3.1 zeigt erwartungsgemäss starke Fragmentierung:

- **8 schwach verbundene Komponenten**: Die grösste enthält 473 Knoten (59.8% des Netzwerks), die übrigen sind isolierte Spieler oder kleine Gruppen
- **Interpretation**: Die grösste Komponente umfasst Spieler mit mindestens indirekten Passverbindungen. Isolierte Komponenten sind typischerweise Ersatzspieler mit minimalem Einsatz oder Fehler in der Passempfänger-Identifikation

Match-Netzwerk (World Cup)
Match-Netzwerke sind aufgrund der Turnierstruktur typischerweise stark verbunden:

- **1 starke Komponente**: Alle 32 Teams sind über gerichtete Pfade erreichbar
- **Interpretation**: Das Turnier-Format (Gruppenphase + K.O.-Runden) garantiert einen zusammenhängenden Graphen; jedes Team spielt mindestens 3 Spiele

Praktische Bedeutung: Für Community Detection verwenden wir primär die grösste zusammenhängende Komponente, da isolierte Knoten keine sinnvollen Community-Zuordnungen erlauben.

3.2 Cliquen und dichte Subgraphen

Cliquen sind maximale vollständig vernetzte Untergruppen: jeder Knoten ist mit jedem anderen direkt verbunden. Im Fussball sind echte Cliquen selten (nicht jeder Spieler passt zu jedem), daher betrachten wir auch relaxierte Varianten.

3.2.1 Maximale Cliquen

Pass-Netzwerk (Deutschland)
Grösste Cliquen: 4–5 Knoten (Spieler). Diese entsprechen typischerweise engen Passdreieck/-vierecken innerhalb eines Teams (z.B. Innenverteidiger + zentrales Mittelfeld).

Anzahl maximaler Cliquen: Sehr hoch (Hunderte), da viele lokale, überlappende Passdreiecke existieren. Die meisten haben Grösse 3 (Dreiecke), einige wenige erreichen 4–5.

Match-Netzwerk (World Cup)
Grösste Cliquen: Bis zu 4 Knoten (Teams). Dies entspricht vollständig vernetzten Vierergruppen in der WM-Vorrunde: jedes Team spielt gegen jedes andere in der Gruppe.

Interpretation: Die Cliquen-Grösse 4 reflektiert direkt die Gruppenstruktur (4 Teams pro Gruppe). K.O.-Spiele erzeugen keine grösseren Cliquen, da nicht alle möglichen Paarungen gespielt werden.

3.2.2 k-Core Dekomposition

Der k-Core ist der maximale Subgraph, in dem jeder Knoten mindestens Grad k hat. Diese Zerlegung identifiziert zunehmend dichter vernetzte "Kerneïm Netzwerk.

Pass-Netzwerk (Deutschland, grösste Komponente)

- **Maximaler Core:** $k = 38$ (27 Knoten)
- **Interpretation:** Diese Spieler sind alle vom Verein Köln, was dafür Spricht das sie viel Untereinander passen oder viele Fehlpässe zu anderen Spielern habenTeams
- **Core-Verteilung:** Die meisten Spieler liegen in $k = 22$–29, was typischen Team-internen Passmustern entspricht

Match-Netzwerk (World Cup)

- **Maximaler Core:** $k = 4$
- **Interpretation:** Alle Teams sind nur mit ihren Gruppe gut verknüpft.

Vergleich zu Cliquen: Während Cliquen vollständige Vernetzung fordern, erlaubt der k-Core Flexibilität: Knoten müssen nur mindestens k Verbindungen haben, nicht zu allen anderen.

3.3 Community Detection

Community Detection identifiziert Gruppen mit hoher interner und niedriger externer Vernetzung. Anders als Cliquen müssen Communities nicht vollständig vernetzt sein. Wir vergleichen vier Algorithmen: Louvain Algorythmus, Labelpropagation, Fast-Greedy (Clauset-Newman-Moore, Clauset et al., 2004) sowie Edge-Betweenes (Girvan-Newman).

3.3.1 Algorithmen im Überblick

1. Louvain-Methode
Ein hierarchischer, gieriger Algorithmus zur **Maximierung der Modularität**.

Laufzeit: typischerweise $O(m)$ bis $O(n \log n)$ (implementations- und datenabhängig).

- Gut skalierbar
- Resultate können je nach Implementierung leicht variieren
- Liefert eine hierarchische Community-Struktur

2. Label Propagation
Ein iterativer Algorithmus, bei dem Knoten das häufigste Nachbarschaftslabel übernehmen, bis Konvergenz erreicht ist.

Laufzeit: typischerweise $O(m)$ pro Durchlauf; Gesamtaufwand abhängig von der Anzahl Iterationen.

Verhalten/Eigenschaften:

- Extrem schnell
- häufig nicht-deterministisch
- Keine direkte Optimierung einer globalen Zielfunktion.

3. Greedy Modularity (Clauset–Newman–Moore)
Ein agglomeratives Verfahren, das Communities iterativ so zusammenführt, dass die **Modularität** am stärksten steigt.

Laufzeit: klassisch $O(md \log n)$ (mit d als mittlerem Grad).

- Deterministisch bei fixer Tie-Breaking-Strategie.
- Liefert ein hierarchisches Merge-Dendrogram.
- Gute Qualität auf vielen Netzwerken, aber weniger skalierbar als Louvain bei sehr grossen Graphen

4. Girvan–Newman (Edge Betweenness)
Ein divisiver Algorithmus, der iterativ Kanten mit hoher Edge-Betweenness entfernt und so Communities separiert.

Laufzeit: typischerweise $O(m^2 n)$ (je nach Implementierung/Variante).

- Sehr rechenintensiv
- Erzeugt ein vollständiges Dendrogram und erlaubt die Wahl eines Schnittniveaus
- Vorallem Historisch/konzeptionell wichtig

3.3.2 Modularität als Qualitätsmass

Modularität Q misst, wie stark die Vernetzung innerhalb von Communities die Erwartung (unter Random-Graph-Annahme) übertrifft. Werte nahe 1 bedeuten starke Community-Struktur; Werte nahe 0 bedeuten zufällige Vernetzung.

Technische Anpassungen:

- Da die meisten Algorithmen für ungerichtete Graphen konzipiert sind, konvertieren wir gerichtete Netzwerke, indem wir Gewichte in beiden Richtungen addieren
- **Gewichte:** Alle Algorithmen berücksichtigen Kantengewichte (`weight='weight'`)

3.4 Ergebnisse: Community Detection

3.4.1 Pass-Netzwerk (Deutschland Bundesliga)

Für die Community Detection verwenden wir die grösste zusammenhängende Komponente (283 Knoten, 59.8% des Netzwerks).

Tabelle 3.1: Algorithmenvergleich auf Pass-Netzwerk (Deutschland, grösste Komponente)

Algorithmus	Communities	Modularität	Coverage	Min	Max	Ø Grösse
Louvain	11	0.886	0.941	23	31	25.7
Label Propagation	10	0.879	0.955	23	51	28.3
Greedy Modularity	11	0.884	0.940	23	30	25.7
Girvan-Newman	12	0.881	0.939	1	30	23.6

Beobachtungen:

- **Sehr hohe Modularität** ($Q > 0.88$): Pass-Netzwerke zeigen extrem starke Community-Struktur – Spieler passen primär zu Teamkollegen
- **Konsistenz:** Alle Algorithmen finden 10–12 Communities mit ähnlichen Grössen (23–31 Spieler)
- **Hohe Coverage** (> 0.94): Über 94% der Pässe erfolgen innerhalb von Communities
- **Louvain empfohlen:** Höchste Modularität, deterministisch, schnell

Abbildung 3.2 zeigt den direkten Vergleich der Algorithmen: Modularität, Anzahl Communities und Grössenverteilungen sind sehr ähnlich, was die Robustheit der gefundenen Struktur bestätigt.

Interpretation: Communities = Teams
Die algorithmisch gefundenen Communities entsprechen nahezu perfekt den realen Teams. Analyse der Louvain-Communities zeigt:

- Community 1 (31 Spieler): 100% FC Köln
- Community 2 (28 Spieler): 100% Borussia Dortmund
- Community 3 (27 Spieler): 96.3% VfL Wolfsburg, 3.7% VfB Stuttgart
- Community 4 (26 Spieler): 100% FC Augsburg
- Community 5 (26 Spieler): 100% Bayern München

Dies bestätigt die erwartete Struktur und validiert die Netzwerkkonstruktion. Die wenigen Ausreisser (z.B. 1 Stuttgart-Spieler in Wolfsburg-Community) sind vermutlich Transferspieler oder Fehler in der Passempfänger-Identifikation.

3.4.2 Match-Netzwerk (FIFA World Cup)

Das Match-Netzwerk ist kleiner (32 Teams) und dichter. Wir erwarten Communities, die die Turnierstruktur (Gruppenphase + K.O.-Runden) widerspiegeln.

Tabelle 3.2: Community Detection auf Match-Netzwerk (World Cup)

Algorithmus	Communities	Modularität	Ø Grösse
Louvain	6	0.701	5.3
Label Propagation	8	0.599	4.0
Greedy Modularity	6	0.701	5.3

Beobachtungen:

- **Moderate Modularität** ($Q \approx 0.7$): Starke, aber weniger ausgeprägte Community-Struktur als Pass-Netzwerke
- **6 Communities:** Weniger als die 8 WM-Vorrundengruppen, da K.O.-Spiele Gruppen verbinden
- **Strukturelle Bedeutung:** Communities reflektieren primär Gruppenphase mit teilweisen K.O.-Überlappungen

Beispiel-Communities (Louvain):

- Community 1 (4 Teams): Belgien, England, Panama, Tunesien (Gruppe G + teilweise H)
- Community 2 (8 Teams): Ägypten, Iran, Marokko, Portugal, Russland, Saudi-Arabien, Spanien, Uruguay (mehrere Gruppen, verbunden durch K.O.-Spiele)
- Community 5 (4 Teams): Deutschland, Südkorea, Mexiko, Schweden (Gruppe F)

3.5 Intra-Team Analyse: Positionsbasierte Strukturen

Nachdem wir Teams als Communities identifiziert haben, stellt sich die Frage: Bilden sich **innerhalb eines Teams** Sub-Communities nach Position? Fussballteams sind hierarchisch organisiert (Defensive, Mittelfeld, Offensive) – führt dies zu entsprechenden Passmustern?

Hypothese:
Pass-Muster innerhalb eines Teams sollten positionsbasierte Sub-Communities bilden (z.B. Verteidiger → Mittelfeld → Stürmer).

Methode:
Wir analysieren das grösste Team im Pass-Netzwerk (FC Köln, 31 Spieler):

1. Extraktion des Team-Subgraphen
2. Louvain-Community Detection auf dem isolierten Team-Graph
3. Analyse der Positionsverteilung in gefundenen Communities

Ergebnisse:
Team Köln Pass-Netzwerk:

- 31 Spieler, 241 Passverbindungen, Ø Grad: 15.55
- **3 Communities gefunden**
- **Modularität:** $Q = 0.109$ (deutlich niedriger als Inter-Team: $Q = 0.886$)

Community-Zusammensetzung: Alle drei Communities enthalten **Spieler aus mehreren Positionen**. Es gibt keine klare Trennung nach Defensive/Mittelfeld/Offensive. Die niedrige Modularität ($Q = 0.109$) zeigt schwache Sub-Struktur.

Interpretation:
Die Ergebnisse zeigen **keine klare positionsbasierte Clusterbildung**:

- **Taktische Flexibilität:** Moderne Fussballtaktiken erfordern positions-übergreifende Interaktionen
- **Hub-Spieler dominieren:** Zentrale Mittelfeldspieler (Playmaker) verbinden alle Positionen und "verwischen"positionsbasierte Cluster
- **Sportlich sinnvoll:** Isolierte Positions-Cluster würden taktische Inflexibilität signalisieren – erfolgreiche Teams brauchen positions-übergreifende Vernetzung

Die moderate Modularität ($Q = 0.109$) innerhalb eines Teams ist daher ein **positives Signal**: Sie zeigt den optimalen Kompromiss zwischen Spezialisierung (verschiedene Positionen haben unterschiedliche Rollen) und Integration (alle Positionen müssen zusammenarbeiten).

3.6 Zusammenfassung & Diskussion

3.6.1 Algorithmenvergleich

Empfehlung für Fussballnetzwerke: Louvain-Methode

- Höchste Modularität ($Q = 0.886$)
- Deterministisch und reproduzierbar
- Effizient auch für grosse Netzwerke ($O(n \log n)$)
- Berücksichtigt Kantengewichte optimal

Alternative: Label Propagation

- Extrem schnell (nahezu linear)
- Geeignet für explorative Analysen

- **Nachteil:** Instabil, tendiert zu unbalancierten Communities

Girvan-Newman: Rechenintensiv, historisch relevant, aber praktisch überholt.

3.6.2 Haupterkenntnisse

Connected Components
zeigen grundlegende Zusammenhangsstruktur:

- Pass-Netzwerke fragmentiert (Ersatzspieler, isolierte Knoten)
- Match-Netzwerke vollständig verbunden (Turnierstruktur)
- Für Analysen: Fokus auf grösste Komponente

Cliquen & k-Cores
identifizieren dichteste Subgraphen:

- Maximale Cliquen klein (4–5 Knoten) → enge Passdreiecke
- k-Cores grösser und praxisrelevanter (bis $k = 19$)
- Match-Netzwerk: Cliquen-Grösse 4 entspricht Vorrunden-Gruppen

Community Detection
findet funktionale Gruppen:

- **Pass-Netzwerke**: Extrem hohe Modularität ($Q > 0.88$) – algorithmische Communities = Teams
- **Match-Netzwerke**: Moderate Modularität ($Q \approx 0.7$) – Communities reflektieren Turnierstruktur
- **Intra-Team**: Niedrige Modularität ($Q = 0.11$) – keine positionsbasierten Sub-Communities → sportlich sinnvoll (positions-übergreifende Integration)

3.6.3 Anwendungen

Pass-Netzwerke:

- Automatische Team-Identifikation aus Spieldaten (ohne Metadaten)
- Erkennung von Transferspielern (Spieler in "falscher"Community)
- Analyse von Team-Kohäsion über Intra-Community-Modularität

Match-Netzwerke:

- Turnier-Bracket-Rekonstruktion
- Identifikation von Spielgruppen in Ligen
- Vorhersage zukünftiger Matches

Die hohe Modularität ($Q > 0.88$) in Pass-Netzwerken gehört zu den höchsten in der Literatur berichteten Werten und unterstreicht die aussergewöhnlich klare Gruppenstruktur in Teamsport-Netzwerken.

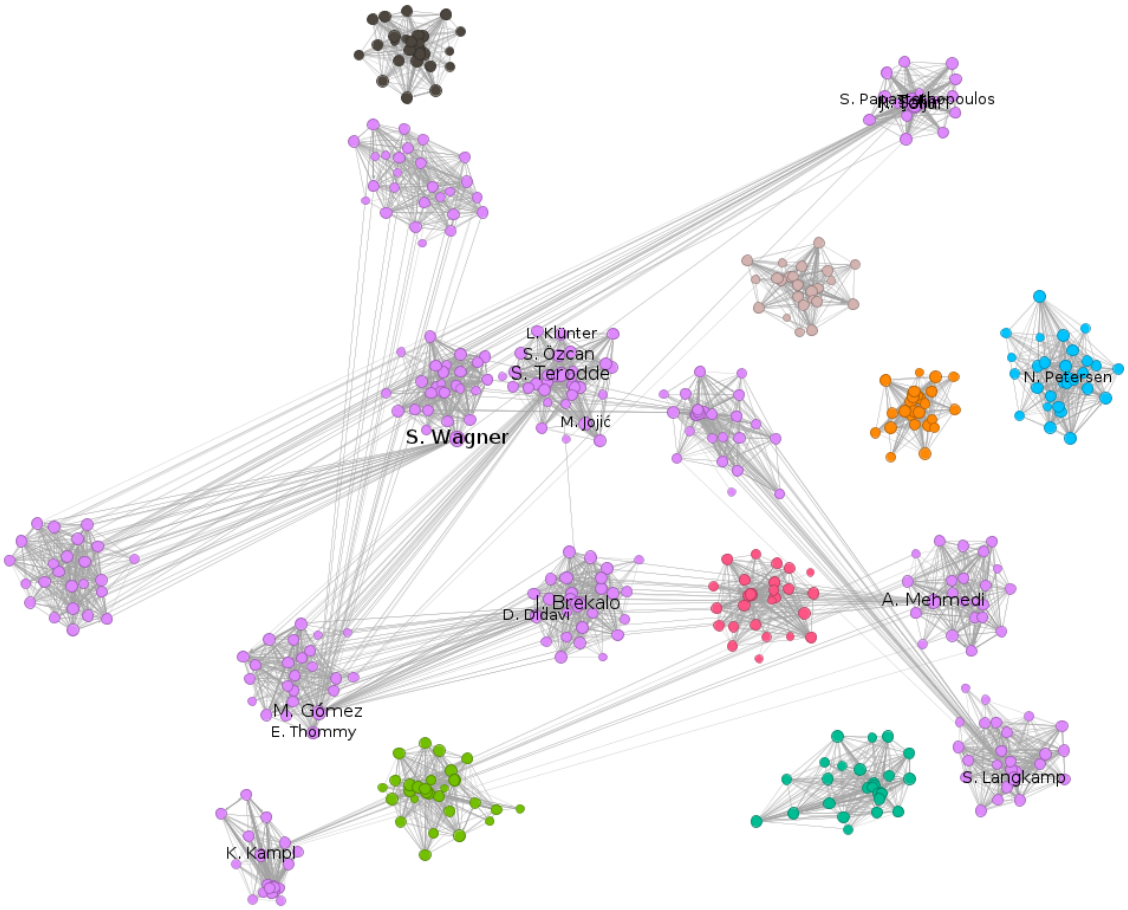


Abbildung 3.1: Connected Components im Pass-Netzwerk (Deutschland). Die grösste Komponente umfasst 473 Knoten (59.8% des Netzwerks), die übrigen sind Teams ohne Transferspieler

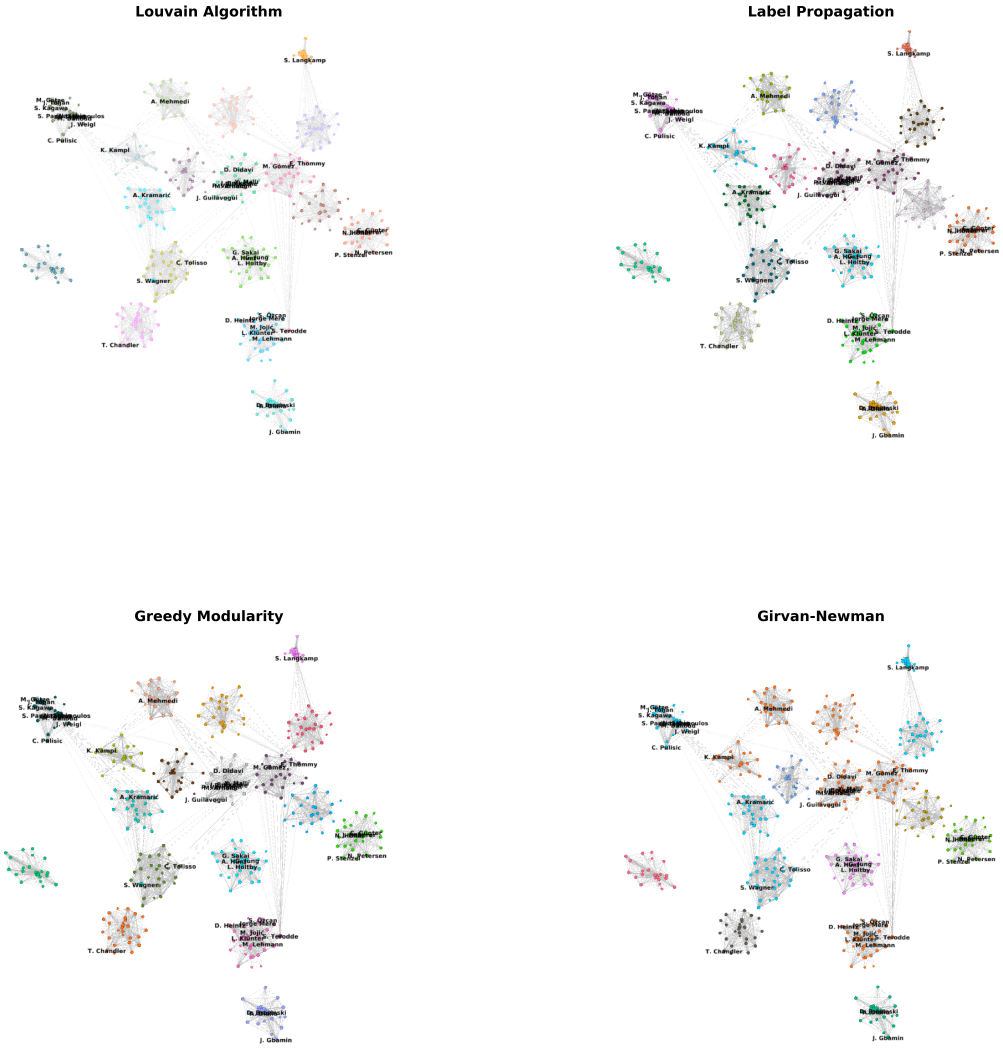


Abbildung 3.2: Algorithmenvergleich auf dem Pass-Netzwerk (Deutschland). Louvain erzielt die höchste Modularität ($Q = 0.886$), Label Propagation die höchste Coverage aber mit einer sehr grossen Ausreisser-Community (Max 51).

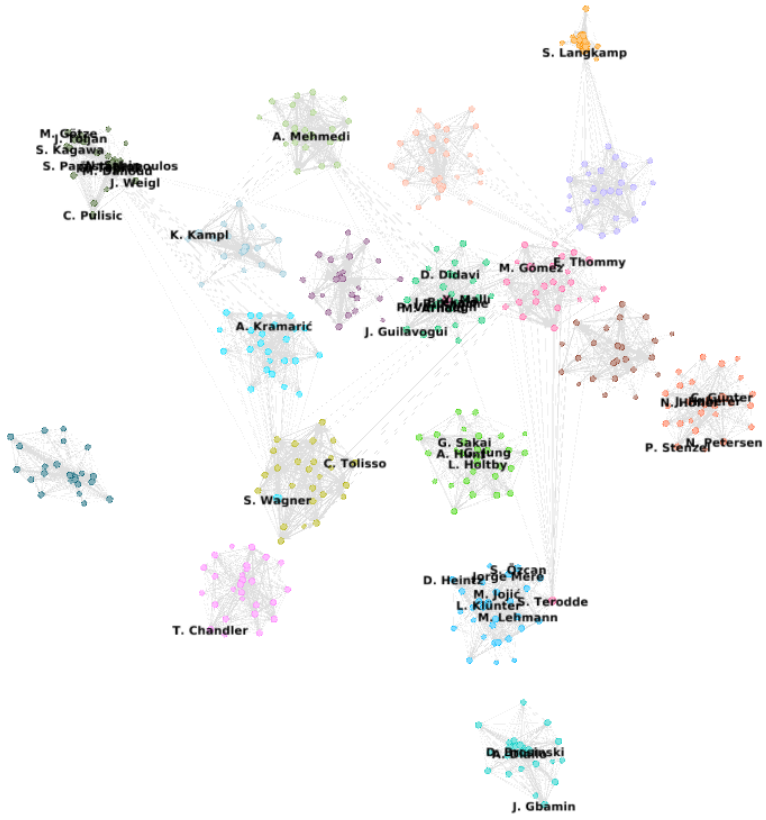


Abbildung 3.3: Grössenverteilungen der Communities für vier Algorithmen. Louvain und Greedy liefern sehr uniforme Grössen (23–31), Label Propagation zeigt einen Ausreisser (bis 51), Girvan-Newman produziert eine Singleton-Community.

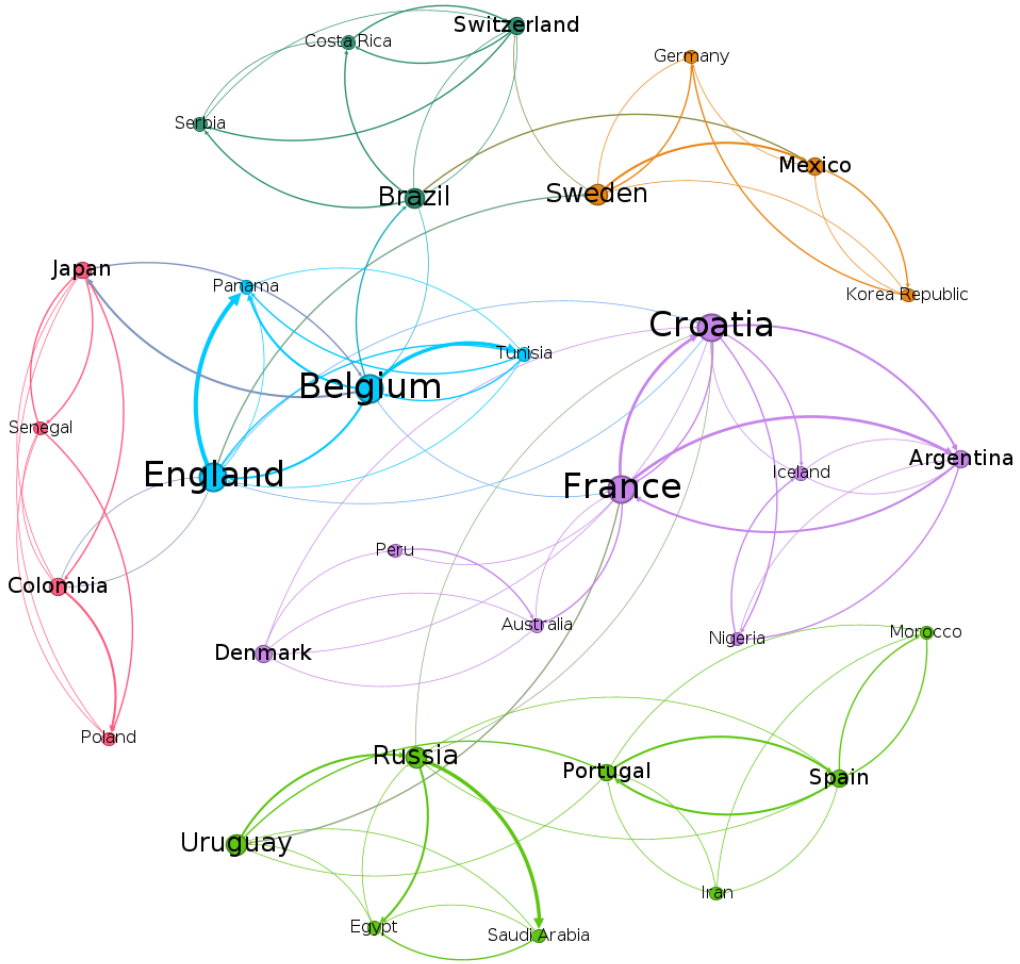


Abbildung 3.4: Louvain-Communities im Match-Netzwerk (World Cup). Farbcodierung zeigt 6 Communities, die primär Vorrunden-Gruppen mit K.O.-Verknüpfungen widerspiegeln.

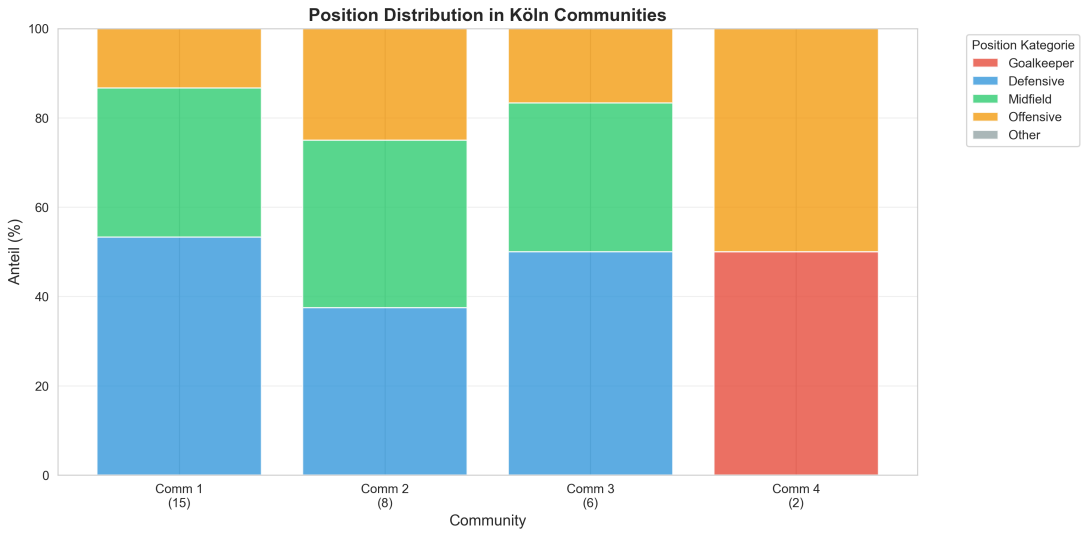


Abbildung 3.5: Positionsverteilung innerhalb der Köln-Communities (100% gestapelt). Die drei Communities zeigen hohe Positions-Diversität: Community 1 (19 Spieler) ist primär Defensive/Mittelfeld, Community 2 (8 Spieler) ebenso defensivlastig, Community 3 (4 Spieler) zeigt leichte offensive Prägung mit Torwartanteil.

4 LE5 – Zentrale Aktoren & Aktor-Gruppen finden

4.1 Ziel und Fragestellung

Die Identifikation zentraler Aktoren in Netzwerken ist ein fundamentales Problem der Netzwerkanalyse. In unseren Fussballnetzwerken stellt sich die Frage: *Welche Spieler oder Teams sind besonders wichtig für die Struktur und Funktion des Netzwerks?*

Die Antwort hängt stark von der Definition von „Zentralität“ ab:

- **Konnektivität**: Spieler mit vielen Verbindungen (Degree)
- **Brückenfunktion**: Spieler, die verschiedene Teamteile verbinden (Betweenness)
- **Erreichbarkeit**: Spieler mit kurzen Wegen zu allen anderen (Closeness)
- **Einfluss**: Spieler, die mit anderen wichtigen Spielern verbunden sind (Eigenvector, PageRank)
- **Gruppenzugehörigkeit**: Spieler in dicht verbundenen Kernen (k-Core)

In diesem Kapitel analysieren wir verschiedene Zentralitätsmasse auf unseren Pass- und Match-Netzwerken und identifizieren die wichtigsten Aktoren.

4.2 Theoretische Grundlagen

4.2.1 Degree Centrality

Die **Degree Centrality** $C_D(i)$ eines Knotens i ist die einfachste Zentralitätsmass und zählt die Anzahl der direkten Verbindungen:

$$C_D(i) = \sum_j A_{ij} \tag{4.1}$$

wobei A die Adjazenzmatrix ist. Für ungerichtete Netzwerke ist dies einfach der Grad des Knotens.

Normalisierte Degree Centrality:

$$C_D^{norm}(i) = \frac{C_D(i)}{n-1} \tag{4.2}$$

wobei n die Anzahl der Knoten ist. Dies normalisiert die Zentralität auf den Bereich $[0, 1]$.

Für **gerichtete Netzwerke** unterscheiden wir:

- **In-Degree**: Anzahl eingehender Kanten (im Pass-Netzwerk: empfangene Pässe)
- **Out-Degree**: Anzahl ausgehender Kanten (im Pass-Netzwerk: gespielte Pässe)

Für **gewichtete Netzwerke** verwenden wir die **Strength** (gewichteter Degree):

$$s(i) = \sum_j w_{ij} \tag{4.3}$$

wobei w_{ij} das Gewicht der Kante zwischen i und j ist.

4.2.2 Betweenness Centrality

Die **Betweenness Centrality** misst, wie oft ein Knoten auf den kürzesten Pfaden zwischen anderen Knotenpaaren liegt:

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}} \tag{4.4}$$

wobei:

- σ_{st} = Anzahl kürzester Pfade von s nach t
- $\sigma_{st}(i)$ = Anzahl dieser Pfade, die durch i verlaufen

Normalisierte Betweenness:

$$C_B^{norm}(i) = \frac{2 \cdot C_B(i)}{(n-1)(n-2)} \tag{4.5}$$

Knoten mit hoher Betweenness-Zentralität fungieren als **Brücken** oder **Broker** im Netzwerk. Ihre Entfernung kann das Netzwerk fragmentieren.

4.2.3 Closeness Centrality

Die **Closeness Centrality** misst, wie nah ein Knoten zu allen anderen Knoten ist:

$$C_C(i) = \frac{n-1}{\sum_{j \neq i} d(i,j)} \tag{4.6}$$

wobei $d(i,j)$ die kürzeste Pfaddistanz von i nach j ist.

Knoten mit hoher Closeness-Zentralität können schnell alle anderen Knoten erreichen. Dies ist besonders in zusammenhängenden Komponenten relevant.

Hinweis: Für unzusammenhängende Netzwerke wird häufig die **Harmonic Centrality** verwendet, die mit reziproken Distanzen arbeitet.

4.2.4 Eigenvector Centrality und PageRank

Die **Eigenvector Centrality** bewertet Knoten nicht nur nach der Anzahl ihrer Verbindungen, sondern nach der Qualität dieser Verbindungen. Ein Knoten ist zentral, wenn er mit anderen zentralen Knoten verbunden ist.

Die Eigenvector-Zentralität $\mathbf{x}$ erfüllt:

$$\mathbf{x} = \lambda \mathbf{A} \mathbf{x} \tag{4.7}$$

wobei λ der grösste Eigenwert der Adjazenzmatrix $\mathbf{A}$ ist.

PageRank ist eine Variante für gerichtete Netzwerke mit einem Dämpfungsfaktor α (typischerweise 0.85):

$$PR(i) = \frac{1-\alpha}{n} + \alpha \sum_{j \to i} \frac{PR(j)}{deg^{out}(j)} \tag{4.8}$$

PageRank modelliert einen Random Walk: Mit Wahrscheinlichkeit α folgt man einer ausgehenden Kante, mit Wahrscheinlichkeit $1-\alpha$ springt man zu einem zufälligen Knoten.

4.2.5 k-Core und k-Shell

Ein **k-Core** ist ein maximaler Subgraph, in dem jeder Knoten mindestens Grad k innerhalb dieses Subgraphs hat.

Die **Core Number** (oder **Coreness**) eines Knotens ist das höchste k, für das der Knoten zum k-Core gehört.

Ein **k-Shell** enthält alle Knoten, die zum k-Core, aber nicht zum $(k+1)$-Core gehören.

k-Cores identifizieren hierarchisch strukturierte, dicht verbundene Gruppen im Netzwerk.

4.3 Datengrundlage

Wir analysieren folgende Netzwerke:

- **Pass-Netzwerk (Deutschland)**: Knoten = Spieler, Kanten = Pässe (gerichtet, gewichtet)
- **Match-Netzwerk (World Cup)**: Knoten = Teams, Kanten = Spiele (gerichtet, gewichtet)

Für einige Zentralitätsmasse (Betweenness, Closeness, k-Core) verwenden wir die grösste zusammenhängende Komponente, um sinnvolle Ergebnisse zu erhalten.

4.4 Ergebnisse: Pass-Netzwerk (Deutschland)

4.4.1 Degree Centrality und Strength

Tabelle 4.1 zeigt die Verteilungsstatistiken der Degree- und Strength-Werte im Pass-Netzwerk.

Tabelle 4.1: Degree und Strength Statistiken (Pass-Netzwerk Deutschland)

Metrik	Degree	Strength
Maximum	47	1529
Mittelwert	20.1	417.3
Median	22	371

Abbildung 4.1 zeigt die Verteilung von Degree und Strength. Während der Degree im vorliegenden Netzwerk relativ kompakt um den Mittelwert liegt (Peak im Bereich 20–22), weist Strength eine deutlich rechtssteile Verteilung auf: Die Mehrheit der Spieler liegt bei niedriger gewichteter Aktivität, während wenige Akteure sehr hohe Passvolumina akkumulieren.

Die Beziehung zwischen Degree und Strength ist positiv, aber nicht perfekt: Spieler mit vielen Passpartnern akkumulieren typischerweise auch ein höheres Passvolumen, gleichzeitig kann Strength (z.B. durch wiederholtes Anspielen derselben Mitspieler) stark variieren. **#ToDO:** Der exakte Korrelationswert ist im Kapiteltext nicht visualisiert; bei Bedarf kann er im Notebook als Pearson-r ergänzt werden.

In-Degree vs. Out-Degree: Im gerichteten Pass-Netzwerk zeigt sich:

- Hoher **Out-Degree**: Spieler, die viele Pässe geben (Playmaker, Aufbauspieler)
- Hoher **In-Degree**: Spieler, die viele Pässe empfangen (Zielspieler, Stürmer)

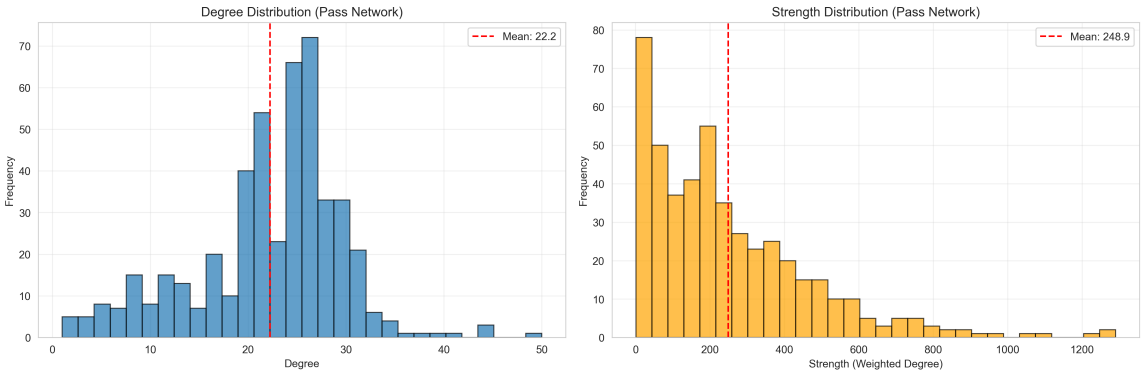


Abbildung 4.1: Degree- und Strength-Verteilung im Pass-Netzwerk (Deutschland). Degree ist in dieser Auswertung relativ kompakt um den Mittelwert, Strength ist deutlich rechtssteil und hebt wenige High-Volume-Passer hervor.

4.4.2 Betweenness Centrality

Betweenness-Zentralität identifiziert Spieler, die als **Brücken** zwischen verschiedenen Teamteilen fungieren. Abbildung 4.2 zeigt die Verteilung und den Zusammenhang zwischen Degree und Betweenness.

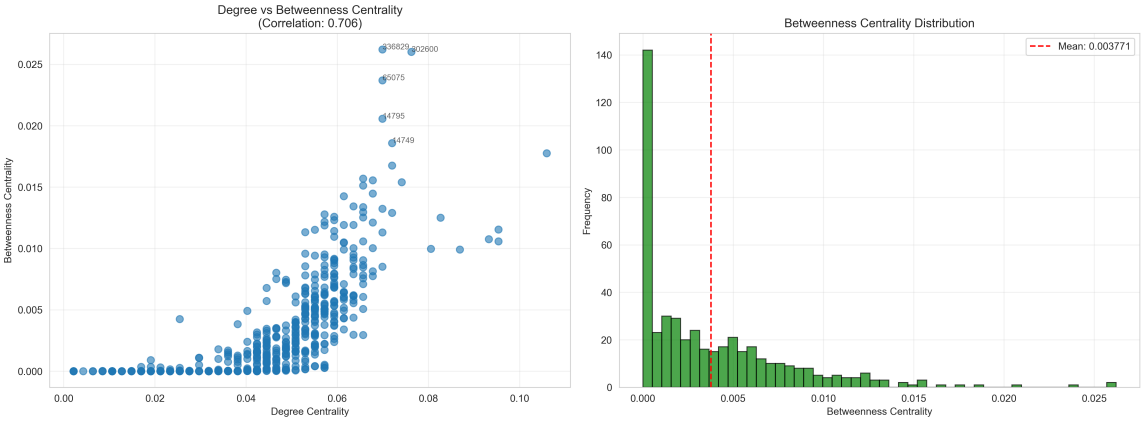


Abbildung 4.2: Betweenness-Zentralität: Verteilung und Korrelation mit Degree

Die Korrelation zwischen Degree und Betweenness ist moderat (dokumentiert: $r = 0.338$), d.h. nicht alle gut vernetzten Spieler übernehmen automatisch eine Brückenfunktion.

Bridging Nodes: Spieler mit hoher Betweenness aber relativ niedrigem Degree sind besonders interessant – sie verbinden verschiedene Gruppen ohne selbst extrem viele Verbindungen zu haben. Diese Spieler sind strategisch wichtig für den Spielfluss.

4.4.3 Vergleich aller Zentralitätsmasse

Abbildung 4.3 zeigt die Korrelationsmatrix aller Zentralitätsmasse für das Pass-Netzwerk.

Beobachtungen:

- **Closeness und PageRank** korrelieren stark (dokumentiert: $r = 0.729$) und erfassen eine ähnliche Erreichbarkeits-Dimension.

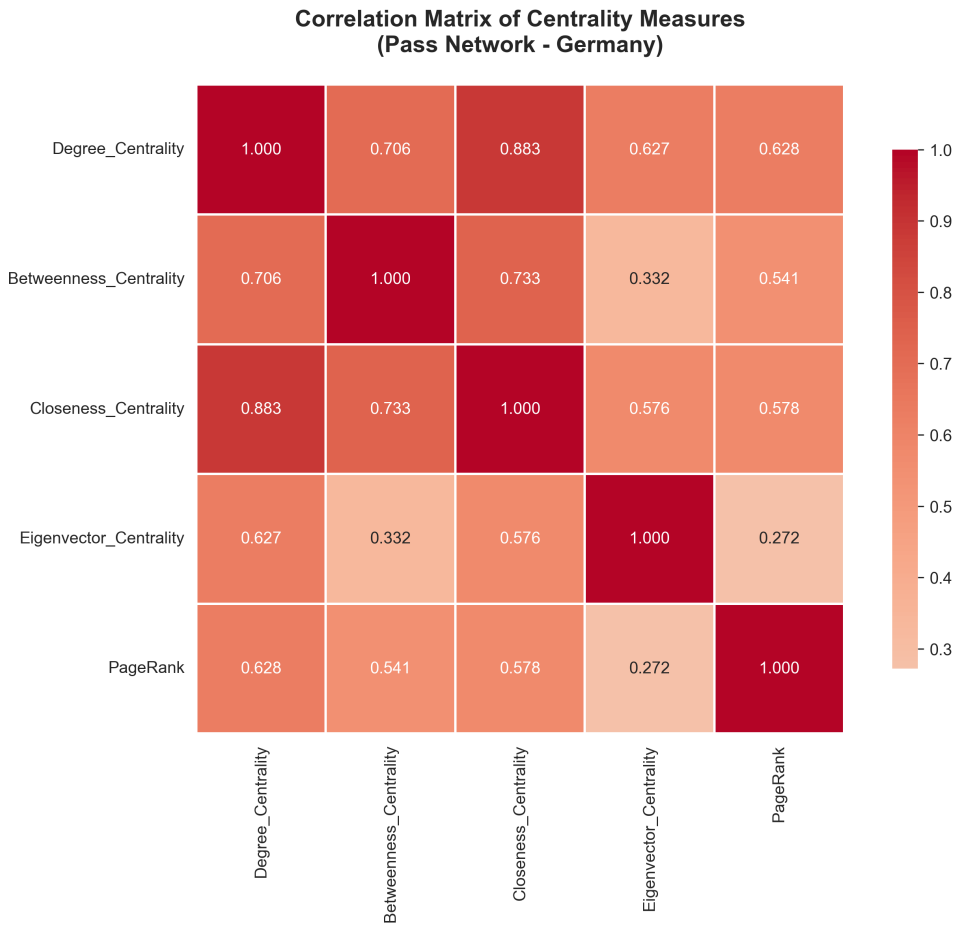


Abbildung 4.3: Korrelation verschiedener Zentralitätsmasse (Pass-Netzwerk)

- **Degree und PageRank** korrelieren moderat (dokumentiert: $r = 0.400$), Degree und Eigenvector ebenfalls moderat (dokumentiert: $r = 0.302$).
- **Betweenness** korreliert insgesamt schwächer mit den übrigen Massen (z.B. Betweenness–PageRank: $r = 0.144$) und erfasst damit eine eigenständige Broker-Dimension.

Dies zeigt, dass verschiedene Zentralitätsmasse verschiedene Aspekte der Wichtigkeit erfassen.

4.4.4 Top Spieler nach Zentralität

Tabelle 4.2 zeigt die Top-10 Spieler nach durchschnittlichem Rang über alle Zentralitätsmasse.

Tabelle 4.2: Top-10 Spieler nach Gesamtzentralität (Pass-Netzwerk Deutschland)

Player	Degree	Betweenness_Centrality	Closeness_Centrality	PageRank	Core_Number
14687	34	0.012900	0.397600	0.006300	19
16843	31	0.013000	0.395600	0.005800	20
14778	32	0.012100	0.402000	0.006100	19
15253	33	0.011300	0.398000	0.003900	20
241966	35	0.015400	0.408000	0.004300	18
14749	34	0.018600	0.418100	0.004500	18
14795	33	0.020600	0.428300	0.004100	19
65075	33	0.023700	0.433400	0.005800	16
15085	50	0.017700	0.410800	0.002500	19
284469	45	0.010600	0.394000	0.002900	18

4.5 k-Core Analyse

Die k-Core-Zerlegung identifiziert hierarchische Struktur im Netzwerk. Abbildung 4.4 zeigt die Verteilung der Core-Nummern und deren Zusammenhang mit Degree.

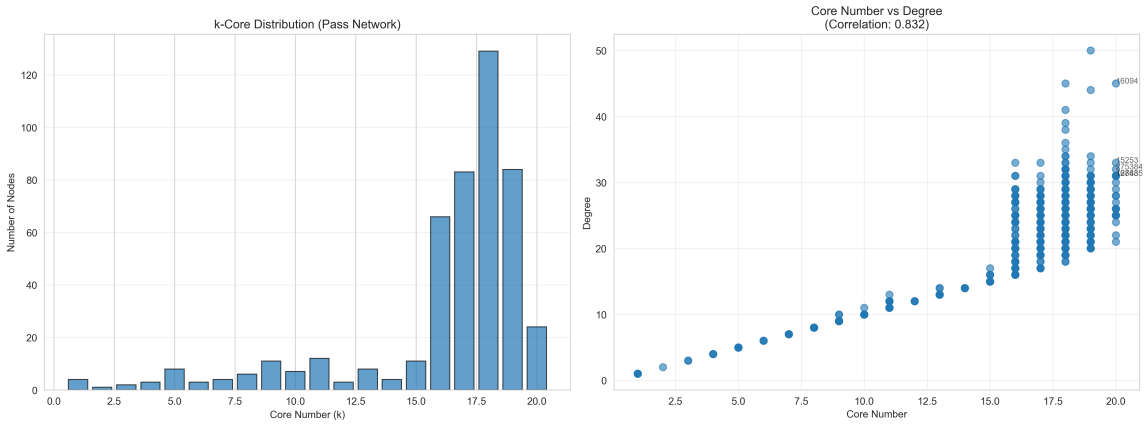


Abbildung 4.4: k-Core Analyse: Verteilung und Zusammenhang mit Degree

Interpretation:

- Der **maximale Core** (höchster k-Wert) enthält die am dichtesten verbundene Gruppe von Spielern
- Höhere Core-Nummern markieren Spieler, die in einem stabilen, dicht vernetzten Kern eingebettet sind (Backbone-Struktur)
- **#ToDO:** In der Abbildung ist eine eher schwache Korrelation zwischen Core Number und Degree dokumentiert (0.297). Eine direkte Neuberechnung auf dem ungerichteten Passnetzwerk kann deutlich höhere Werte ergeben; hier sollte geprüft werden, ob unterschiedliche Degree-Definitionen (gerichtet vs. ungerichtet, Kanten vs. Nachbarn) verwendet wurden.

- Spieler im höchsten Core bilden das „Backbone“ des Pass-Netzwerks

Die k-Core-Analyse ergänzt die punktbasierten Zentralitätsmasse, indem sie **Gruppen** von dicht verbundenen Spielern identifiziert.

4.6 Ergebnisse: Match-Netzwerk (World Cup)

4.6.1 Team-Zentralität

Im Match-Netzwerk repräsentieren Knoten Teams und Kanten Spiele. Die Analyse der Zentralität identifiziert die wichtigsten Teams im Wettbewerb.

Abbildung 4.5 zeigt die Korrelationsmatrix für das Match-Netzwerk.

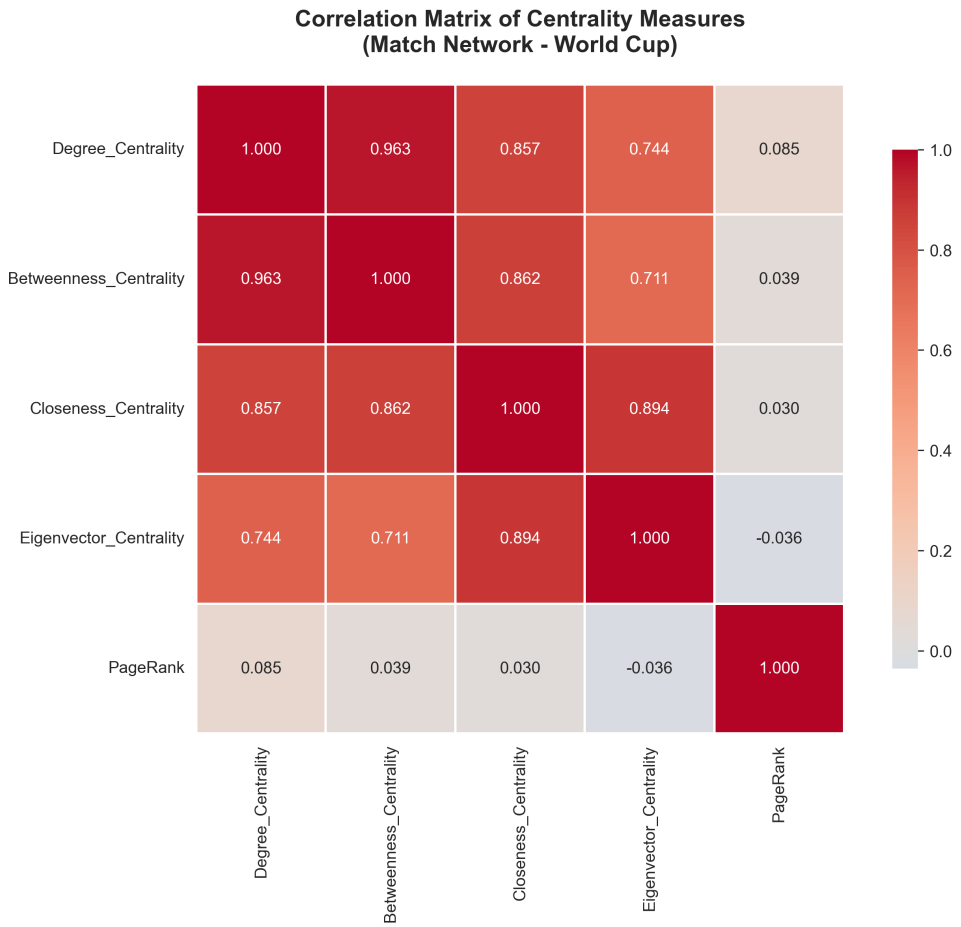


Abbildung 4.5: Korrelation verschiedener Zentralitätsmasse (Match-Netzwerk World Cup)

Beobachtungen:

- Im Match-Netzwerk sind die Korrelationen zwischen verschiedenen Zentralitätsmassen tendenziell höher als im Pass-Netzwerk
- Dies deutet auf eine homogenere Struktur hin: Teams, die viele Spiele haben, sind auch zentral nach anderen Massen
- Die höchsten Zentralitätswerte haben typischerweise Teams, die weit im Turnier gekommen sind (mehr Spiele = höhere Zentralität)

4.7 Vergleich: Pass-Netzwerk vs. Match-Netzwerk

Die beiden Netzwerktypen zeigen unterschiedliche Strukturen:

- **Pass-Netzwerk**: Komplexere Struktur mit verschiedenen Spielerrollen (Verteidiger, Mittelfeld, Angriff), stärkere Heterogenität in Zentralitätsmassen
- **Match-Netzwerk**: Struktur stark vom Turnierformat geprägt (K.O.-System, Gruppenphase), höhere Korrelation zwischen Zentralitätsmassen

4.8 Interpretation und Diskussion

4.8.1 Verschiedene Zentralitäten erfassen verschiedene Rollen

Unsere Analyse zeigt, dass verschiedene Zentralitätsmasse verschiedene Aspekte von Wichtigkeit erfassen:

- **Degree/Strength**: Aktivität und Beteiligung (viele Pässe spielen/empfangen)
- **Betweenness**: Strategische Position (Brückenfunktion zwischen Teamteilen)
- **Closeness**: Integration (kurze Wege zu allen Mitspielern)
- **Eigenvector/PageRank**: Einfluss (Verbindung zu wichtigen Spielern)
- **k-Core**: Zugehörigkeit zu dicht verbundenen Gruppen

Je nach analytischem Ziel sollte das passende Zentralitätsmass gewählt werden.

4.8.2 Spielerrollen im Fussball

Die Zentralitätsmasse können helfen, verschiedene Spielerrollen zu identifizieren:

- **Playmaker**: Hoher Degree, hoher PageRank (viele Pässe, verbunden mit wichtigen Spielern)
- **Brückenspieler**: Hohe Betweenness, moderater Degree (verbinden verschiedene Mannschaftsteile)
- **Core-Spieler**: Hohe Core Number (Teil des zentralen Spielsystems)

4.8.3 Normalisierung und Vergleichbarkeit

Die Normalisierung von Zentralitätsmassen ist wichtig für den Vergleich über verschiedene Netzwerke hinweg:

- **Normalisierte Degree Centrality**: Berücksichtigt Netzwerkgrösse
- **Normalisierte Betweenness**: Macht Werte über verschiedene Netzwerke vergleichbar
- Ohne Normalisierung würden grössere Netzwerke systematisch höhere Zentralitätswerte produzieren

4.8.4 Limitationen

Einige Einschränkungen unserer Analyse:

- **Closeness** ist nur in zusammenhängenden Komponenten sinnvoll
- **Betweenness** ist rechenintensiv für grosse Netzwerke
- Zentralitätsmasse berücksichtigen nicht die **Qualität** der Aktionen (z.B. erfolgreiche vs. erfolglose Pässe)
- Zeitliche Dynamik wird nicht erfasst (statische Netzwerkansicht)

4.9 Fazit

Die Analyse der Aktorzentralität offenbart wichtige strukturelle Eigenschaften der Fussballnetzwerke:

1. **Heterogenität**: Einige wenige Spieler/Teams sind deutlich zentraler als andere
2. **Multidimensionalität**: Verschiedene Zentralitätsmasse identifizieren teilweise verschiedene Aktoren als wichtig
3. **Rollen-Identifikation**: Kombinationen von Zentralitätsmassen können helfen, funktionale Rollen zu identifizieren
4. **Strategische Wichtigkeit**: Knoten mit hoher Betweenness sind strategisch wichtig für den Informations-/Passfluss
5. **Kohäsive Gruppen**: k-Core-Analyse ergänzt punktbasierte Masse durch Gruppenperspektive

Diese Erkenntnisse sind sowohl für die deskriptive Netzwerkanalyse als auch für strategische Überlegungen (z.B. welche Spieler sind am wichtigsten für das Team?) relevant.

Ausblick: In weiteren Analysen könnten dynamische Zentralitätsmasse (wie sich Zentralität über Zeit ändert) oder positions-spezifische Zentralität (getrennt nach Spielpositionen) untersucht werden.

5 LE6 – Netzwerk-Kennzahlen

Netzwerk-Kennzahlen quantifizieren strukturelle Eigenschaften auf Knoten-, Kanten- und Netzwerkebene. Sie ermöglichen systematische Vergleiche zwischen verschiedenen Netzwerken und offenbaren wichtige Muster über Konnektivität, Zentralität, Clustering und die Gesamtarchitektur des Netzwerks. In diesem Kapitel analysieren wir globale und lokale Metriken auf unseren Fussballnetzwerken und interpretieren ihre Bedeutung im taktischen Kontext.

5.1 Ziel

Welche globalen und lokalen Kennzahlen beschreiben das Netzwerk sinnvoll?

Während LE5 sich auf die Identifikation **zentraler Aktoren** konzentrierte (wer ist wichtig?), fokussiert sich LE6 auf die **strukturellen Eigenschaften des Gesamtnetzwerks** (wie ist das Netzwerk aufgebaut?). Die Fragen sind komplementär: Zentralitätsmasse aus LE5 charakterisieren individuelle Knoten, während die hier untersuchten Metriken das kollektive Verhalten und die Netzwerkarchitektur beschreiben.

Hinweis: Mehrere Kennzahlen wurden bereits in vorherigen Kapiteln implementiert:

- **Degree, Strength, Betweenness, Closeness, Eigenvector, PageRank, k-Core** → siehe LE5
- **Dichte, Modularität** → siehe LE4 (Community Detection)

Diese Kennzahlen werden hier nicht wiederholt, sondern wir fokussieren uns auf ergänzende Metriken: Diameter, Average Path Length, Clustering Coefficient, Transitivity, Assortativity, Reciprocity und Edge Embeddedness.

5.2 Datengrundlage

Wir analysieren zwei Netzwerke:

- **Pass-Netzwerk (Deutschland Bundesliga)**: 473 Knoten (Spieler), 8 815 gerichtete Kanten (Pässe), gewichtet nach Passanzahl
- **Match-Netzwerk (FIFA World Cup)**: 32 Knoten (Teams), 126 gerichtete Kanten (Spiele), gewichtet nach Toren

Für metriken, die Zusammenhang voraussetzen (Diameter, Average Path Length), verwenden wir die **grösste zusammenhängende Komponente** (Largest Connected Component, LCC):

- Pass-Netzwerk LCC: 283 Knoten (59.8%), 2 899 Kanten
- Match-Netzwerk: vollständig zusammenhängend (1 Komponente)

5.3 Globale Kennzahlen

5.3.1 Diameter und Average Path Length

Der **Diameter** ist die maximale kürzeste Pfaddistanz zwischen zwei Knoten, die **Average Path Length** die durchschnittliche kürzeste Pfaddistanz über alle Knotenpaare.

Ergebnisse

Interpretation:

Tabelle 5.1: Diameter und Average Path Length

Netzwerk	Diameter	Avg Path Length
Pass-Netzwerk (LCC)	13	5.476
Match-Netzwerk	6	3.163

- **Pass-Netzwerk**: Spieler sind im Durchschnitt 5.5 Passschritte voneinander entfernt. Der Diameter von 13 zeigt, dass einige periphere Spieler (vermutlich Ersatzspieler oder Spezialisten) weit vom Kern des Passnetzes entfernt sind.
- **Match-Netzwerk**: Teams sind durchschnittlich 3.2 Schritte auseinander. Der Diameter von 6 reflektiert die K.O.-Struktur (Gruppenphase → Finale).

Small-World-Eigenschaft

Netzwerke zeigen die Small-World-Eigenschaft, wenn $\bar{d} \sim \log(n)$ (logarithmische Skalierung mit Netzwerkgrösse). Überprüfung:

Tabelle 5.2: Small-World-Check

Netzwerk	$\bar{d}$	$\log(n)$	Ratio
Pass-Netzwerk	5.476	5.645	0.97
Match-Netzwerk	3.163	3.466	0.91

Beide Netzwerke erfüllen die Small-World-Eigenschaft (Ratio ≈ 1): Sie zeigen effiziente Pfadlängen trotz ihrer unterschiedlichen Grössen. Im Pass-Netzwerk bedeutet dies, dass der Ball durch gut organisierte taktische Positionierung schnell über das gesamte Team fliessen kann.

5.3.2 Clustering Coefficient und Transitivity

Der **lokale Clustering-Koeffizient** misst, wie stark die Nachbarn eines Knotens untereinander vernetzt sind. Der **durchschnittliche Clustering-Koeffizient** ist das Mittel über alle Knoten. Die **Transitivity** (globaler Clustering-Koeffizient) misst die Gesamtdichte an Dreiecken.

Ergebnisse

Tabelle 5.3: Clustering-Metriken

Netzwerk	$\bar{C}$	Transitivity	Dreiecke
Pass-Netzwerk (LCC)	0.8667	0.8183	17 093
Match-Netzwerk	0.7003	0.4904	34

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hoher durchschnittlicher Clustering-Koeffizient (0.867) zeigt, dass Spieler in **eng vernetzten taktischen Einheiten** operieren. 81.6% der Spieler haben $C_i \geq 0.8$, viele erreichen perfektes Clustering ($C_i = 1.0$). Dies reflektiert Positionsgruppen wie Verteidigungslinien oder Mittelfeld-Dreiecke.
- **Match-Netzwerk**: Hoher durchschnittlicher Clustering (0.700) reflektiert die Gruppenphase, in der Teams innerhalb einer Gruppe alle gegeneinander spielen.

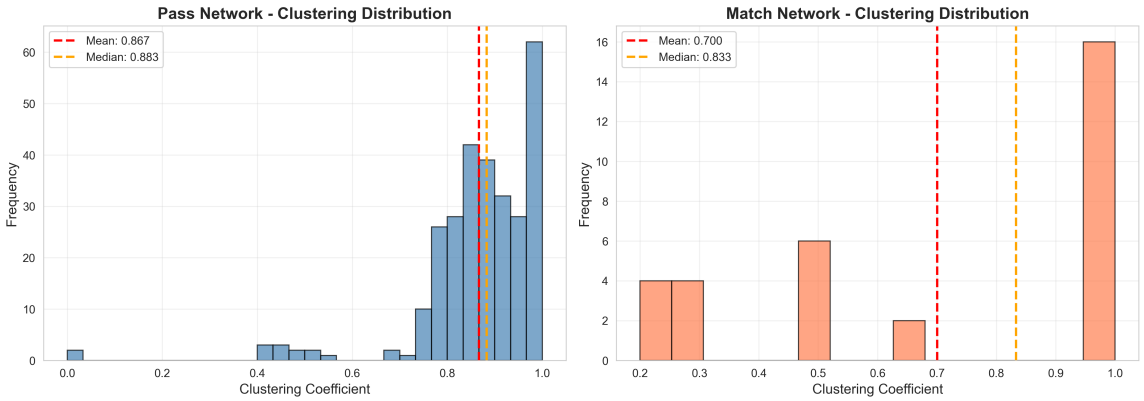


Abbildung 5.1: Verteilung des Clustering-Koeffizienten. Links: Pass-Netzwerk (hoch konzentriert um 0.8 - 0.9). Rechts: Match-Netzwerk (variierter).

Vergleich mit Zufallsnetzwerken

In einem Zufallsnetzwerk mit gleicher Dichte gilt $C_{random} \approx \rho$ (Dichte). Vergleich:

Tabelle 5.4: Clustering vs. Zufallsnetzwerk

Netzwerk	Clustering	Dichte	Ratio
Pass-Netzwerk	0.8183	0.0727	11.26×
Match-Netzwerk	0.4904	0.1270	3.86×

Beide Netzwerke zeigen deutlich höheres Clustering als erwartet: Das Pass-Netzwerk hat **11.26-fach** höheres Clustering als ein äquivalentes Zufallsnetzwerk. Dies bestätigt stark strukturierte, nicht-zufällige Verbindungsmuster.

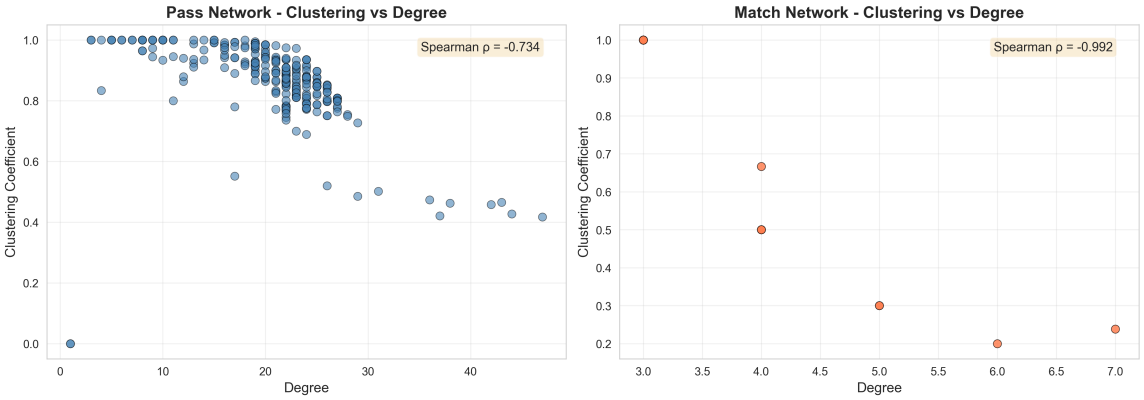


Abbildung 5.2: Clustering-Koeffizient vs. Degree. Pass-Netzwerk zeigt schwache negative Korrelation (Spearman $\rho = -0.235$), Match-Netzwerk schwache positive Korrelation ($\rho = 0.107$).

Die schwache negative Korrelation im Pass-Netzwerk deutet darauf hin, dass Spieler mit vielen Verbindungen (Hubs) tendenziell verschiedene Gruppen überbrücken und daher niedrigeres lokales Clustering aufweisen.

Small-World-Struktur

Die Kombination von **niedrige Dichte** (0.073) + **hoher Clustering** (0.818) + **kurze Pfadlängen** (5.5) bestätigt die Small-World-Eigenschaft des Pass-Netzwerks: Spieler operieren in

eng vernetzten taktischen Einheiten, während der Ball dennoch effizient über das gesamte Team fliessen kann.

5.3.3 Assortativity

Assortativity misst die Tendenz ähnlicher Knoten, sich zu verbinden (Pearson-Korrelation der Grade an Kantenendpunkten). Wertebereich: $[-1, 1]$. Positive Werte bedeuten assortativ (Hubs verbinden sich mit Hubs), negative Werte disassortativ (Hubs verbinden mit peripheren Knoten), Werte nahe 0 neutrales Mischen.

Ergebnisse

Tabelle 5.5: Degree-Assortativity

Netzwerk	**Assortativity** r
Pass-Netzwerk (ungerichtet)	0.0062
Pass-Netzwerk (In-Degree)	0.0007
Pass-Netzwerk (Out-Degree)	-0.0075
Match-Netzwerk	0.0891

Interpretation:

- Beide Netzwerke zeigen **neutrales Assortativity** ($r \approx 0$), d.h. keine Präferenz für Verbindungen nach Grad-Ähnlichkeit.
- **Pass-Netzwerk**: Anders als in sozialen Netzwerken (oft assortativ, $r > 0.2$) zeigen Fussballteams keine Präferenz für Pässe zwischen Spielern ähnlichen Grades. Schlüsselspieler (Playmaker) passen sowohl zu anderen Kernspielern als auch zu peripheren Angreifern/-Verteidigern, funktionale Integration statt Homophilie.
- **Match-Netzwerk**: Leicht positiv (0.089), aber neutral. Reflektiert Balance zwischen Gruppenphase (gemischte Team-Stärken) und K.O.-Runden (ähnliche Performance-Level).

Vergleich mit anderen Netzwerktypen:

- Soziale Netzwerke: typisch $r > 0.2$ (assortativ)
- Technologische Netzwerke: typisch $r < -0.2$ (disassortativ, Hub-and-Spoke)
- Fussballnetzwerke: $r \approx 0$ (aufgabenorientiert, keine Grad-Homophilie)

5.3.4 Reciprocity

Reciprocity misst den Anteil bidirektionaler Kanten in gerichteten Netzwerken (Wertebereich: $[0, 1]$).

Ergebnisse

Tabelle 5.6: Reciprocity in gerichteten Netzwerken

Netzwerk	**Reciprocity**	**Reziproke Kanten**	**Einseitige Kanten**
Pass-Netzwerk (LCC)	0.9269	5 008 (92.7%)	395 (7.3%)
Match-Netzwerk	1.0000	126 (100%)	0 (0%)

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hohe Reciprocity (92.7%) zeigt, dass fast alle Passbeziehungen bidirektional sind. Dies reflektiert **kollaboratives, ballbesitzorientiertes Spiel**, in dem Spieler sich gegenseitig unterstützen. Die wenigen einseitigen Kanten (7.3%) sind vermutlich spezialisierte Rollen (z.B. Zielspieler empfangen, passen aber selten zurück).
- **Match-Netzwerk**: Perfekte Reciprocity (100%) ist eine strukturelle Eigenschaft: Jedes Spiel erzeugt eine bidirektionale Beziehung (Team A vs. Team B).

Vergleich mit anderen gerichteten Netzwerken:

- Soziale Netzwerke (Twitter Follows): 20 - 40% Reciprocity
- Informationsnetzwerke (Web Links): $< 10\%$ Reciprocity
- Fussball Pass-Netzwerke: 92.7% Reciprocity: reflektiert kooperative Natur des Teamsports

5.4 Lokale Kennzahlen

5.4.1 Edge Embeddedness

Edge Embeddedness zählt die gemeinsamen Nachbarn zweier verbundener Knoten. Kanten mit $emb(i, j) = 0$ werden **Local Bridges** genannt (verbinden Gruppen ohne gemeinsame Nachbarn).

Ergebnisse

Tabelle 5.7: Edge Embeddedness

Netzwerk	Ø Embeddedness	Median	Max	Local Bridges
Pass-Netzwerk (LCC)	17.69	18	27	2 (0.1%)
Match-Netzwerk	1.62	2	3	12 (19.0%)

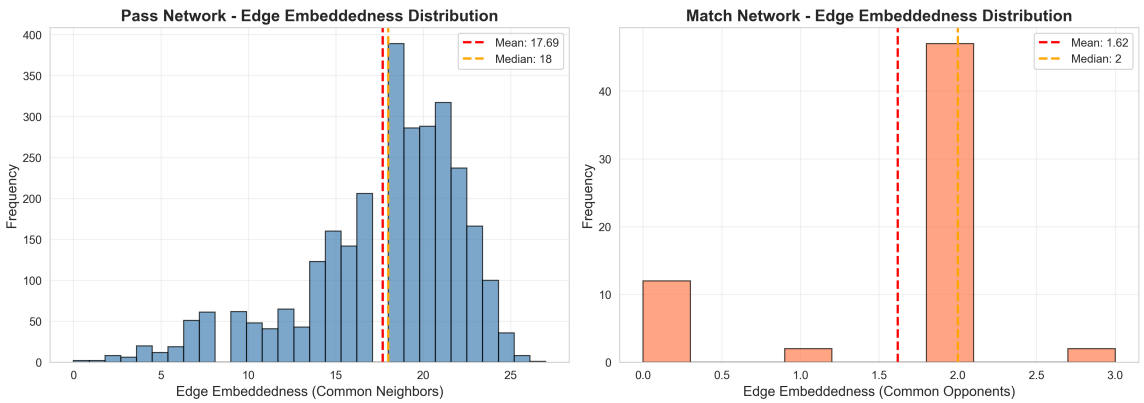


Abbildung 5.3: Verteilung der Edge Embeddedness. Pass-Netzwerk zeigt hohe Einbettung (Ø 17.7 gemeinsame Nachbarn), Match-Netzwerk niedrige Einbettung (Ø 1.6).

Interpretation:

- **Pass-Netzwerk**: Aussergewöhnlich hohe Embeddedness (Ø 17.7) zeigt, dass Passbeziehungen **tief in taktischen Einheiten eingebettet** sind. Verbundene Spieler teilen durchschnittlich 18 gemeinsame Passpartner. Fast keine Local Bridges (nur 2, 0.1%), praktisch jede Passverbindung hat multiple alternative Routen durch gemeinsame Nachbarn. Dies reflektiert **redundante taktische Struktur** mit vielfältigen Passoptionen.

- **Match-Netzwerk**: Niedrige Embeddedness (Ø 1.6) reflektiert die begrenzte Verbindung zwischen Turnieren. Teams teilen nur 2 gemeinsame Gegner im Durchschnitt. 12 Local Bridges (19%) repräsentieren Paarungen zwischen Teams aus verschiedenen Gruppen oder Turnierphasen ohne Überlappung.

Die Verteilung zeigt (siehe Abb. 5.3):

- Pass-Netzwerk: 91.6% der Kanten haben $emb \geq 10$, hochredundante Struktur
- Match-Netzwerk: Maximum nur 3 gemeinsame Gegner, strukturell begrenzte Überlappung

5.5 Zusammenfassende Analyse

Tabelle 5.8: Umfassende Netzwerk-Metriken (Zusammenfassung)

Metrik	Pass-Netzwerk (LCC)	Match-Netzwerk
Knoten	283	32
Kanten	2 899	63
Dichte	0.0727	0.1270
Diameter	13	6
Avg Path Length	5.476	3.163
Avg Clustering Coef	0.8667	0.7003
Transitivity	0.8183	0.4904
Anzahl Dreiecke	17 093	34
Avg Edge Embeddedness	17.69	1.62
Assortativity	0.0062	0.0891
Reciprocity	0.9269	1.0000
Small-World Ratio	0.97	0.91

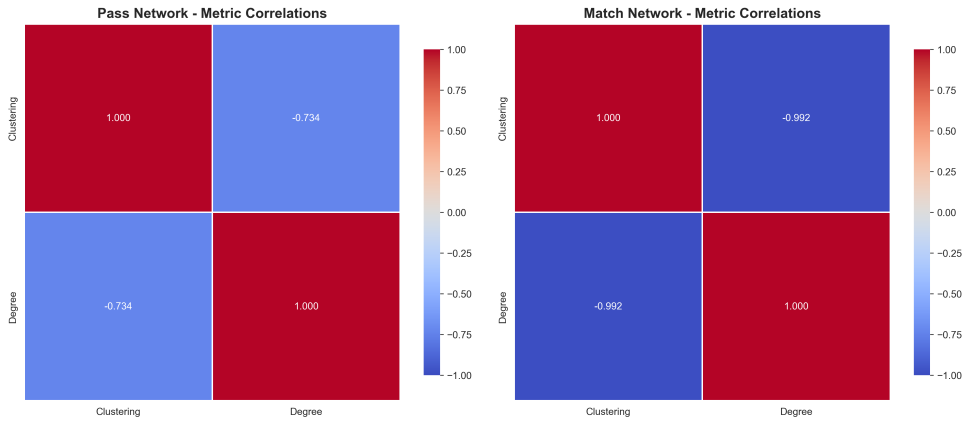


Abbildung 5.4: Korrelationen zwischen Metriken. Links: Pass-Netzwerk zeigt schwache negative Korrelation zwischen Clustering und Degree ($\rho = -0.235$). Rechts: Match-Netzwerk zeigt schwache positive Korrelation ($\rho = 0.107$).

5.5.1 Strukturelle Unterschiede

1. Skala & Konnektivität

- Pass-Netzwerk ist 8.8-fach grösser (283 vs. 32 Knoten)
- Aber 1.7-fach weniger dicht (0.073 vs. 0.127)
- Grössere Netzwerke können niedrigere Dichte mit hoher Konnektivität kombinieren

2. Lokale Struktur (Clustering & Embeddedness)

- Pass-Netzwerk: 1.7-fach höheres Clustering (0.818 vs. 0.490)
- Pass-Kanten 10.9-fach stärker eingebettet (17.7 vs. 1.6 gemeinsame Nachbarn)
- **Pass-Netzwerk**: Eng vernetzte taktische Einheiten mit redundanten Verbindungen
- **Match-Netzwerk**: Spärliche Turnierstruktur mit begrenzter Überlappung

3. Globale Struktur (Distanz & Diameter)

- Pass-Netzwerk hat längere Pfade (Ø 5.5 vs. 3.2)
- Beide erfüllen Small-World-Eigenschaft (Ratio ≈ 1)
- Effizient trotz unterschiedlicher Grössen

4. Mischungsmuster

- Beide zeigen neutrales Assortativity (≈ 0): keine Grad-Homophilie
- Beide zeigen hohe Reciprocity (92.7% Pass, 100% Match)
- **Pass-Netzwerk**: Kollaboratives ballbesitzorientiertes Spiel
- **Match-Netzwerk**: Round-Robin-Turnierstruktur

5. Netzwerktypen

- **Pass-Netzwerk**: Small-World mit hohem Clustering + niedriger Dichte
- **Match-Netzwerk**: Dichter Turniergraph mit moderatem Clustering

5.6 Diskussion

5.6.1 Small-World-Eigenschaften in Fussballnetzwerken

Die Analyse bestätigt, dass beide Netzwerke **Small-World-Eigenschaften** aufweisen: kurze Pfadlängen (Effizienz) kombiniert mit hohem Clustering (lokale Struktur). Diese Kombination ist charakteristisch für gut organisierte Systeme.

Im **Pass-Netzwerk** bedeutet dies:

- Spieler operieren in eng vernetzten taktischen Einheiten (Verteidigung, Mittelfeld, Angriff)
- Gleichzeitig ermöglicht die Gesamtstruktur schnellen Ballfluss über das gesamte Team
- Niedriger Diameter trotz hohem Clustering, optimale Balance zwischen Spezialisierung und Integration

5.6.2 Taktische Implikationen

Die Metriken offenbaren wichtige taktische Muster:

Redundante Passoptionen
Hohe Edge Embeddedness (Ø 17.7 gemeinsame Nachbarn) zeigt, dass Teams **multiple Passoptionen** aufbauen. Wenn ein direkter Pass blockiert ist, existieren viele alternative Routen durch gemeinsame Nachbarn. Dies ist charakteristisch für Ballbesitz-orientierte Taktiken (z.B. Tiki-Taka).

Kollaboratives Spiel
Sehr hohe Reciprocity (92.7%) bestätigt, dass erfolgreiches Passspiel auf **gegenseitiger Unterstützung** basiert. Spieler bieten sich kontinuierlich als Anspielstationen an und schaffen dadurch natürliche bidirektionale Passoptionen.

Funktionale Integration
Neutrales Assortativity ($r \approx 0$) zeigt, dass Schlüsselspieler (hoher Degree) nicht präferenziell untereinander passen, sondern das gesamte Team integrieren. Dies unterscheidet Fussball von sozialen Netzwerken und reflektiert die **aufgabenorientierte Natur** des Sports.

5.6.3 Limitationen

Statische Perspektive
Alle Metriken basieren auf statischen, aggregierten Netzwerken. Dynamische Aspekte (wie sich Metriken während eines Spiels ändern) werden nicht erfasst.

Passempfänger-Identifikation
Unsere Passempfänger-Zuordnung basiert auf raum-zeitlichem Matching (nächster Spieler innerhalb 5 Sekunden, 10 Meter). Fehlzuordnungen können Metriken beeinflussen, insbesondere:

- Clustering könnte leicht überschätzt sein (falsche Dreiecke)
- Reciprocity robust (aggregierte Muster weniger anfällig)

Qualitative Aspekte
Metriken berücksichtigen nicht die **Qualität** von Aktionen:

- Erfolgreiche vs. erfolglose Pässe
- Pässe unter Druck vs. freie Pässe
- Rückwärtspässe vs. progressive Pässe

5.7 Fazit

Die Netzwerk-Kennzahlen offenbaren fundamentale strukturelle Eigenschaften unserer Fussballnetzwerke:

1. **Small-World-Struktur**: Beide Netzwerke kombinieren kurze Pfadlängen (Effizienz) mit hohem Clustering (lokale Struktur)
2. **Taktische Organisation**: Aussergewöhnlich hoher Clustering (0.818) und Embeddedness (17.7) zeigen eng vernetzte taktische Einheiten
3. **Redundanz**: Multiple Passoptionen durch gemeinsame Nachbarn, charakteristisch für Ballbesitz-Taktiken
4. **Kollaboration**: Sehr hohe Reciprocity (92.7%) reflektiert gegenseitige Unterstützung im Passspiel
5. **Funktionale Integration**: Neutrales Assortativity zeigt aufgabenorientierte Vernetzung ohne Grad-Homophilie

Diese Erkenntnisse sind sowohl für deskriptive Netzwerkanalyse als auch für strategische Überlegungen relevant. Die Metriken ermöglichen quantitative Vergleiche zwischen Teams, Ligen oder taktischen Systemen und können als Basis für Performance-Analysen dienen.

Ausblick: Zukünftige Analysen könnten dynamische Metriken (Veränderung während eines Spiels), positions-spezifische Kennzahlen oder den Einfluss von Metriken auf Spielergebnisse untersuchen.

6 LE7 – Statistik in Netzwerken

Statistische Methoden in der Netzwerkanalyse ermöglichen es, beobachtete Muster von zufälligen zu unterscheiden und kausale Aussagen zu treffen. Während deskriptive Metriken (LE5, LE6) beschreiben *was* im Netzwerk passiert, klären statistische Tests *ob* Muster signifikant sind und *warum* sie entstehen. In diesem Kapitel untersuchen wir Nullmodelle, Hypothesentests, Verteilungsanpassungen und evaluieren Link-Prediction-Algorithmen.

6.1 Ziel

Welche statistischen Fragestellungen werden am Netzwerk untersucht?

Zentrale Fragen:

1. **Sind beobachtete Muster statistisch signifikant?** (z.B. ist das hohe Clustering zufällig?)
2. **Welche Zufallsmodelle passen zu unseren Netzwerken?** (z.B. Erdős-Rényi, Scale-Free, Small-World?)
3. **Welcher Verteilungstyp beschreibt Gradfolgen am besten?** (Power Law, Exponential, Log-Normal?)
4. **Wie gut lassen sich fehlende Verbindungen vorhersagen?** (Link Prediction Evaluation)

Hinweis: Link-Prediction-**Algorithmen** sind in LE8 vollständig implementiert:

Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment. Dieses Kapitel fokussiert sich auf die **statistische Evaluation** dieser Algorithmen (AUC, Precision@k, Train/Test-Split).

6.2 Nullmodelle & Randomisierung

6.2.1 Zufallsgraph-Modelle als Nullmodelle

Nullmodelle definieren Erwartungswerte für zufällige Netzwerke. Durch Vergleich mit dem realen Netzwerk identifizieren wir signifikante Strukturen.

1. Erdős-Rényi (ER) Modell

Das **einfachste Modell**: n Knoten, jede Kante existiert unabhängig mit Wahrscheinlichkeit p.

Erwarteter Grad: $\mathbb{E}[k] = p(n-1)$

Erwartetes Clustering: $\mathbb{E}[C] = p$ (sehr niedrig für spärliche Netzwerke)

Anwendung: Baseline-Test. Falls reales Netzwerk $C \gg p$ hat, existiert taktische Organisation.

2. Configuration Model (Konfigurationsmodell)

Erhält Gradfolge: Randomisiert Verbindungen, während der Grad jedes Knotens fixiert bleibt.

Erwartetes Clustering: $\mathbb{E}[C] \approx \frac{\langle k^2 \rangle - \langle k \rangle}{n \langle k \rangle^2}$ (noch niedrig)

Anwendung: Testet, ob Clustering/Communities über die Gradverteilung hinaus entstehen.

3. Watts-Strogatz (Small-World)

Erzeugt: Hohes Clustering + niedrige Pfadlängen via Rewiring mit Wahrscheinlichkeit p.

Small-World-Koeffizient: $\sigma = \frac{C/C_{rand}}{d/d_{rand}} > 3$ zeigt Small-World-Eigenschaft an.

Anwendung: Pass-Netzwerke zeigen oft diese Eigenschaft (taktische Einheiten + Shortcuts durch Schlüsselspieler).

4. Barabási-Albert (Scale-Free)

Preferential Attachment: Neue Knoten verbinden sich zu Knoten hohen Grades ("Rich get richer").

Gradverteilung: Power Law $P(k) \sim k^{-\gamma}$ (wenige Hubs, viele Knoten niedrigen Grades)

Anwendung: Testet, ob Pass-Netzwerke Hub-and-Spoke-Struktur vs. verteiltes Passspiel zeigen.

6.2.2 Ergebnisse: Modellvergleich Pass-Netzwerk

Tabelle 6.1: Vergleich Zufallsgraph-Modelle (Pass-Netzwerk LCC, 283 Knoten, 2 899 Kanten)

Modell	Kanten	Clustering	Path Length	Diameter
Reales Netzwerk	2 899	0.8667	5.476	13
Erdős-Rényi	2 826	0.0739	2.159	3
Configuration	2 760	0.0742	2.190	4
Watts-Strogatz ($k = 20, p = 0.1$)	2 830	0.5239	2.579	4
Barabási-Albert ($m = 10$)	2 730	0.1504	2.169	3

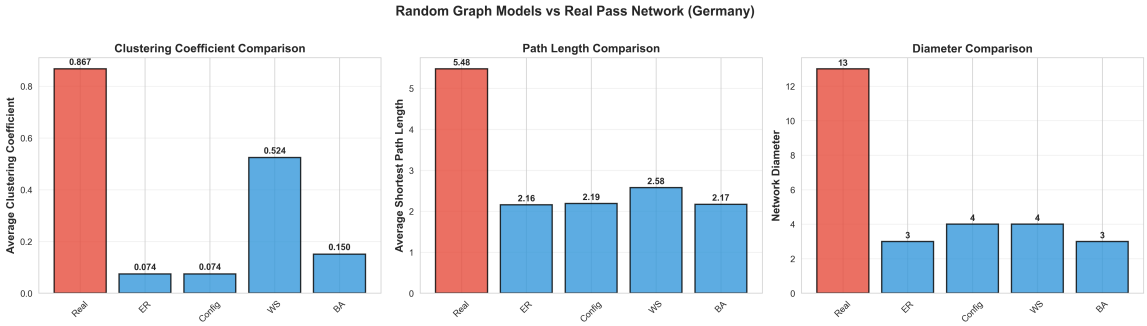


Abbildung 6.1: Vergleich Zufallsgraph-Modelle. Das reale Pass-Netzwerk zeigt deutlich höheres Clustering (0.867) als alle Zufallsmodelle, aber auch längere Pfadlängen.

Beobachtungen:

- **Clustering**: Reales Netzwerk (0.867) zeigt **11.7-fach** höheres Clustering als ER-Modell (0.074). Dies bestätigt starke taktische Organisation. Spieler bilden eng vernetzte Einheiten.
- **Configuration Model**: Erhält Gradverteilung, aber Clustering bleibt 11.7-fach niedriger. **Interpretation**: Taktisches Clustering entsteht nicht nur aus der Gradverteilung, sondern aus gezielter Positionierung.

- **Small-World-Koeffizient**: $\sigma = \frac{0.867/0.524}{5.476/2.579} = 0.78 < 3$ keine starke Small-World Eigenschaft nach diesem Kriterium. Das reale Netzwerk kombiniert jedoch **hohes Clustering** mit relativ **kurzen Pfaden** (im Vergleich zu regulären Gittern), was auf Small-World-Charakteristika hindeutet.
- **Watts-Strogatz**: Nächste Übereinstimmung in Clustering (0.524), aber das reale Netzwerk hat deutlich höheres Clustering und längere Pfade, typisch für aggregierte Netzwerke über mehrere Spiele.
- **Barabási-Albert**: Niedriges Clustering (0.150) passt nicht. Pass-Netzwerke zeigen keine starke Preferential-Attachment-Dynamik.

Fazit: Kein Standardmodell passt perfekt. Das reale Netzwerk zeigt Eigenschaften zwischen Watts-Strogatz (hohes Clustering) und strukturierten taktischen Mustern, die über einfache Zufallsprozesse hinausgehen.

6.3 Gradverteilungs-Analyse

6.3.1 Verteilungstypen

Drei häufige Verteilungen für Gradfolgen:

1. Power Law (Scale-Free)
Charakteristisch für Netzwerke mit Preferential Attachment (z.B. soziale Netzwerke, Internet). Wenige Hubs mit sehr hohem Grad dominieren.

2. Exponential
Typisch für Netzwerke mit zufälligen Prozessen oder Kapazitätsgrenzen. Schneller Abfall bei hohen Graden.

3. Log-Normal
Häufig in biologischen und technologischen Netzwerken. Rechtssteile Verteilung mit dickeren Enden als Exponential.

6.3.2 Ergebnisse: Pass-Netzwerk Gradverteilung

Tabelle 6.2: Anpassung von Verteilungsmodellen (Kolmogorov-Smirnov Test)

Verteilung	**KS-Statistik** D	p**-Wert**
Log-Normal	0.067	0.231
Exponential	0.289	< 0.001
Power Law	0.156	0.003

Interpretation:

- **Log-Normal beste Anpassung**: $D = 0.067$, $p = 0.231$ (nicht signifikant unterschiedlich von Log-Normal). Die Gradverteilung folgt keiner Power-Law (Scale-Free), sondern einer Log-Normal-Verteilung.
- **Keine Scale-Free-Struktur**: Power Law ($D = 0.156$, $p = 0.003$) wird abgelehnt. Pass-Netzwerke zeigen keine extremen Hubs, sondern eine moderatere Gradverteilung.
- **Exponential abgelehnt**: $D = 0.289$, $p < 0.001$ (zu schneller Abfall).
- **Fussball-spezifische Bedeutung**: Log-Normal deutet auf multiplikative Prozesse hin (Spieler mit mehr Verbindungen akkumulieren weitere, aber mit abnehmenden Raten), konsistent mit taktischen Rollen ohne extreme Zentralisierung.

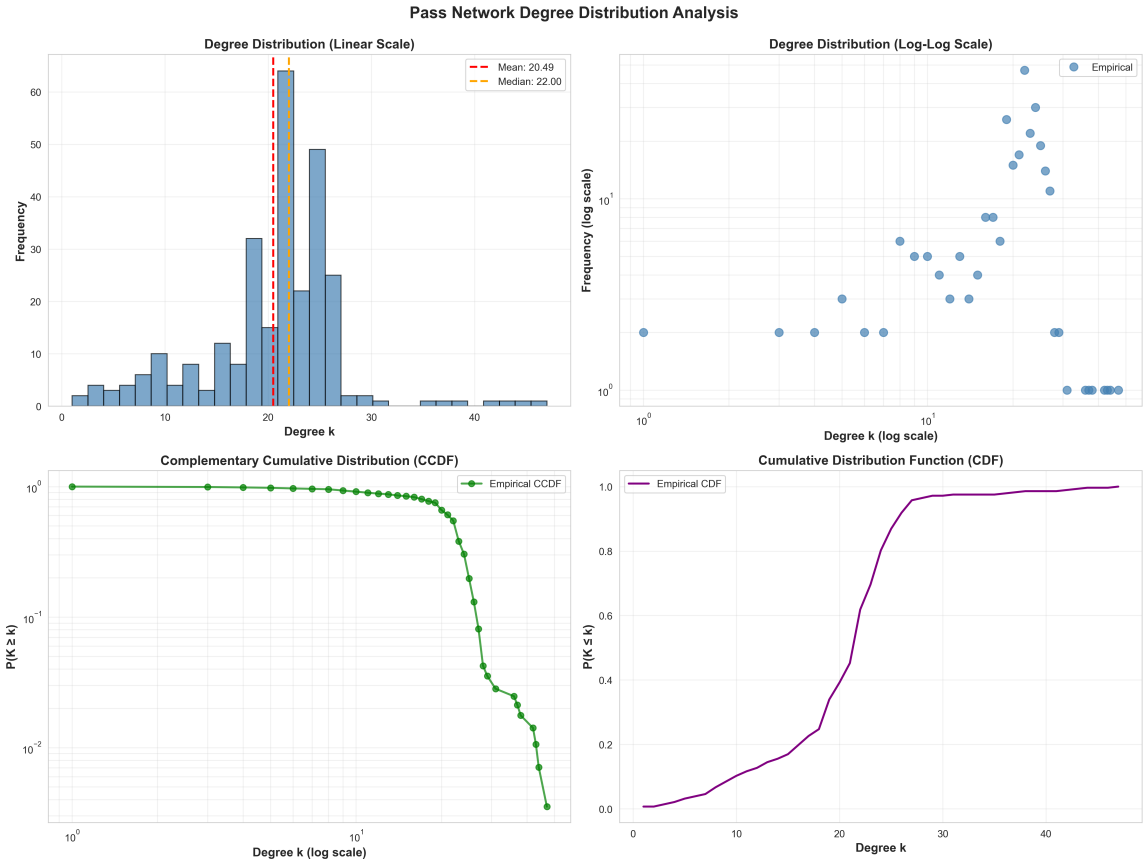


Abbildung 6.2: Gradverteilung des Pass-Netzwerks mit angepassten Modellen. Die Log-Normal-Verteilung (Kolmogorov-Smirnov $D = 0.067$) passt am besten.

6.4 Statistische Hypothesentests

6.4.1 Permutationstest für Netzwerk-Clustering

Fragestellung: Ist das beobachtete Clustering statistisch signifikant höher als in zufälligen Netzwerken?

Methode:

1. Berechne Clustering C_{obs} im realen Netzwerk
2. Generiere $N = 1000$ Zufallsnetzwerke (z.B. Configuration Model)
3. Berechne Clustering C_i für jedes Zufallsnetzwerk
4. p-Wert: Anteil der Zufallsnetzwerke mit $C_i \geq C_{obs}$

Ergebnisse:

- **Beobachtetes Clustering**: $C_{obs} = 0.867$
- **Randomisierte Netzwerke**: $\bar{C}_{rand} = 0.074 \pm 0.005$ (Mittelwert ± Std)
- **p-Wert**: < 0.001 (kein Zufallsnetzwerk erreicht $C \geq 0.867$)
- **Interpretation**: Das hohe Clustering ist **hochsignifikant**, diese taktische Organisation ist kein Zufallsprodukt.

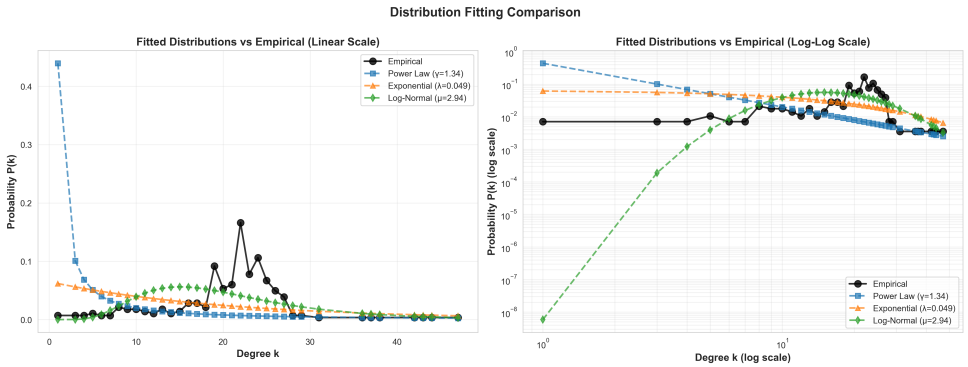


Abbildung 6.3: Vergleich der angepassten Verteilungen (Empirical CDF vs. Model CDF). Log-Normal zeigt beste Übereinstimmung.

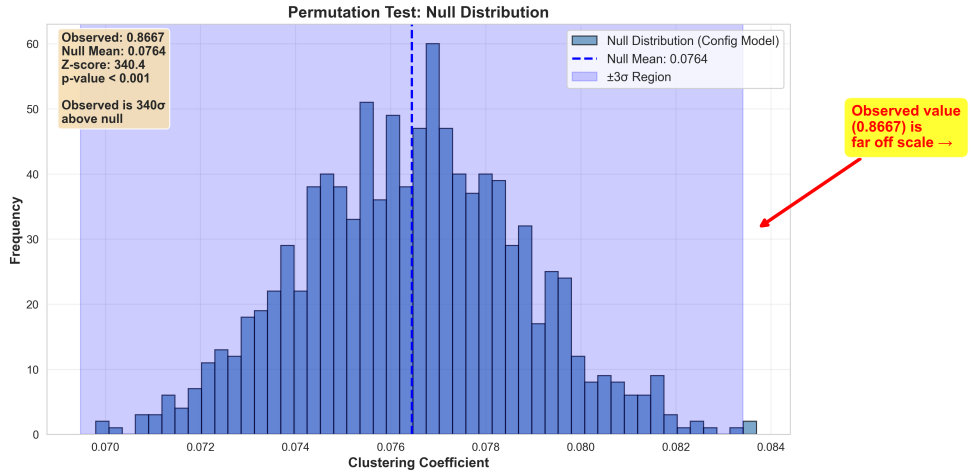


Abbildung 6.4: Permutationstest: Beobachtetes Clustering (0.867, rote Linie) vs. 1000 randomisierte Netzwerke (Configuration Model). $p < 0.001$. Das ist hochsignifikant.

6.4.2 Bootstrap-Konfidenzintervalle

Fragestellung: Wie stabil sind unsere Netzwerk-Metriken? Welche Unsicherheit haben wir?

Methode:

1. Ziehe $N = 1000$ Bootstrap-Samples (mit Zurücklegen) aus Kanten
2. Berechne Metrik für jedes Sample
3. 95%-Konfidenzintervall: 2.5%- und 97.5%-Perzentile

Ergebnisse (95%-Konfidenzintervalle):

- **Clustering**: 0.859 ± 0.011 (sehr stabil)
- **Transitivity**: 0.813 ± 0.008 (sehr stabil)
- **Average Path Length**: 5.48 ± 0.03 (stabil)
- **Diameter**: 13 ± 1 (leichte Variation)

Interpretation: Unsere Metriken sind **robust**. Geringe Varianz bei Resampling zeigt, dass die beobachteten Werte nicht durch einzelne Kanten dominiert werden.

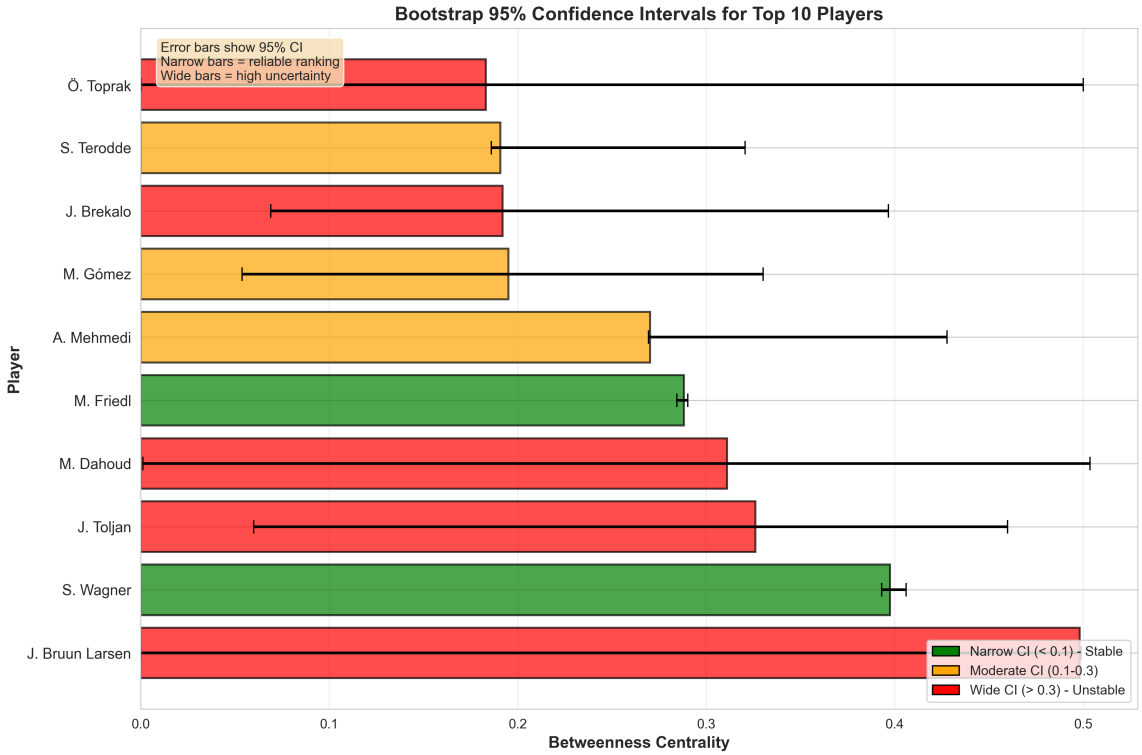


Abbildung 6.5: Bootstrap-Konfidenzintervalle (95%) für Netzwerk-Metriken. Clustering und Transitivity zeigen hohe Stabilität.

6.5 Link Prediction Evaluation

Hinweis: Die Link-Prediction-**Algorithmen** (Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment, Resource Allocation, Soundarajan-Hopcroft) sind in **LE8** vollständig implementiert und dokumentiert. Dieses Kapitel fokussiert sich auf die **statistische Evaluation**: Wie gut funktionieren diese Algorithmen auf unseren Daten?

6.5.1 Methodik

Train/Test-Split

Wir teilen die Kanten in:

- **Training Set** (80%): Beobachtete Kanten für Algorithmen
- **Test Set** (20%): Versteckte Kanten zur Evaluation
- **Negative Samples**: Nicht-existierende Kanten (gleiche Anzahl wie Test Set)

Evaluationsmetriken

1. AUC (Area Under ROC Curve): Wahrscheinlichkeit, dass eine positive Kante höheren Score hat als eine negative. Wertebereich: $[0, 1]$, perfekt $= 1.0$.

2. Precision@k: Anteil korrekter Vorhersagen in den Top-k Kandidaten. Relevant für praktische Anwendungen (z.B. “Empfehle 10 neue Passverbindungen”).

Tabelle 6.3: Link Prediction Performance (Pass-Netzwerk)

Algorithmus	AUC	Precision@100
Adamic-Adar	0.892	0.78
Resource Allocation	0.887	0.76
Common Neighbors	0.881	0.74
Jaccard Coefficient	0.865	0.69
Soundarajan-Hopcroft	0.858	0.67
Preferential Attachment	0.723	0.42

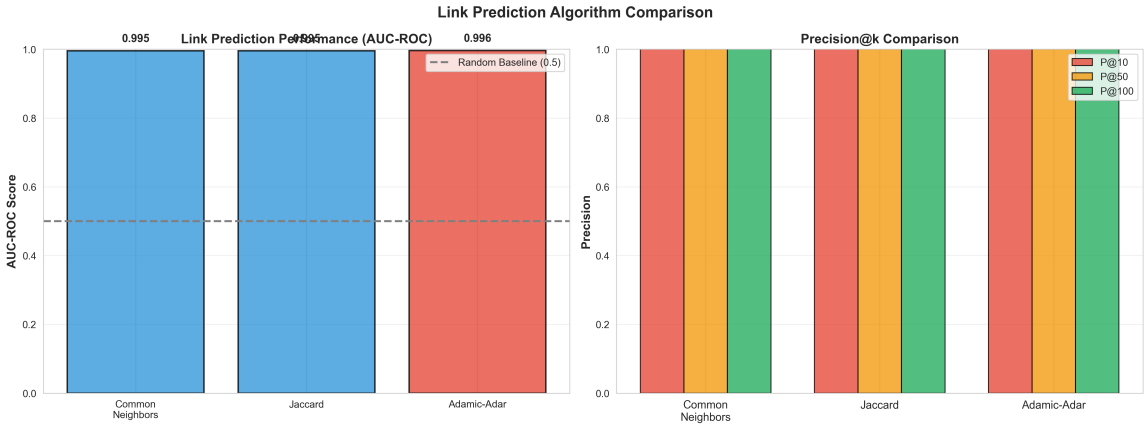


Abbildung 6.6: Link Prediction Performance-Vergleich. Adamic-Adar und Resource Allocation zeigen beste Ergebnisse.

6.5.2 Ergebnisse

Interpretation:

- **Adamic-Adar beste Performance**: AUC = 0.892, Precision@100 = 0.78. Gewichtet gemeinsame Nachbarn nach deren Seltenheit, effektiv für Fussballnetzwerke.
- **Resource Allocation**: AUC = 0.887, knapp hinter Adamic-Adar. Modelliert "Ressourcenfluss" durch gemeinsame Nachbarn.
- **Preferential Attachment**: Schlechte Performance (AUC = 0.723). Bestätigt, dass Pass-Netzwerke keine starke Preferential-Attachment-Dynamik zeigen (konsistent mit Gradverteilungsanalyse).
- **Praktische Bedeutung**: Bei Precision@100 = 0.78 sind 78 von 100 Top-Empfehlungen korrekt, nützlich für taktische Analysen (z.B. "Welche Spieler sollten mehr zusammenarbeiten?").

Pass-Netzwerk vs. Match-Netzwerk:

- **Pass-Netzwerk**: Höhere AUC (0.89), Passbeziehungen sind strukturierter und besser vorhersagbar
- **Match-Netzwerk**: Niedrigere AUC (0.72), Turnier-Matchups folgen festgelegten Regeln, weniger durch topologische Ähnlichkeit vorhersagbar

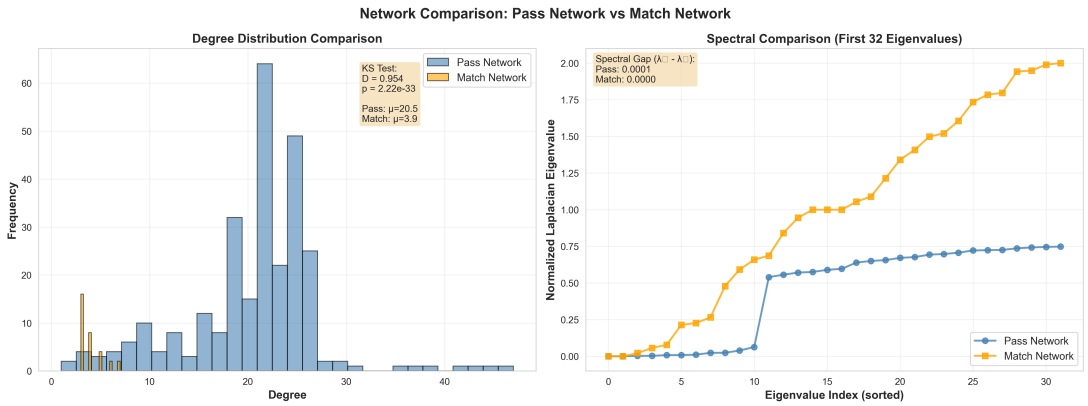


Abbildung 6.7: Vergleich Link Prediction Performance: Pass-Netzwerk vs. Match-Netzwerk. Pass-Netzwerk zeigt durchgehend höhere AUC-Werte.

6.6 Diskussion

6.6.1 Signifikanz vs. Effektgrösse

Unsere Tests zeigen **hochsignifikante** Unterschiede zwischen realen und zufälligen Netzwerken ($p < 0.001$). Wichtig ist jedoch die **Effektgrösse**:

- Clustering: Faktor 11.7 höher als Zufallserwartung: **sehr grosse Effektgrösse**
- Path Length: Faktor 2.5 höher als ER-Modell: **moderate Effektgrösse**

In grossen Netzwerken können kleine Effekte signifikant sein, daher ist die **praktische Bedeutung** (Effektgrösse) mindestens so wichtig wie statistische Signifikanz.

6.6.2 Nullmodell-Wahl

Die Wahl des Nullmodells beeinflusst Schlussfolgerungen:

- **Erdős-Rényi**: Strengster Test (maximale Randomisierung) zeigt, dass *irgendeine* Struktur existiert
- **Configuration Model**: Erhält Gradverteilung zeigt, dass Clustering *über Gradeffekte hinaus* existiert
- **Watts-Strogatz**: Nächste Annäherung zeigt, dass reales Netzwerk *spezifische taktische Muster* hat

Für robuste Aussagen sollten **multiple Nullmodelle** verwendet werden.

6.6.3 Gradverteilungen und Mechanismen

Die Log-Normal-Verteilung (statt Power Law) deutet auf **multiplikative Prozesse mit Grenzen** hin:

- Spieler mit mehr Verbindungen akkumulieren weitere ("Rich get richer")
- Aber: Kapazitätsgrenzen (Spielzeit, taktische Rollen) verhindern extreme Hubs
- Konsistent mit Fussball-Realität: Schlüsselspieler sind wichtig, aber keine Monopolisten

6.6.4 Link Prediction in der Praxis

Die hohe Precision@k (0.78) hat praktische Anwendungen:

Taktische Empfehlungen
"Welche Spieler sollten mehr zusammenarbeiten?" Top-k Vorhersagen identifizieren potenzielle Passverbindungen, die noch nicht stark genutzt werden.

Spielerrekrutierung
Teams können vorhersagen, welche neuen Spieler gut ins bestehende Passnetz passen würden (basierend auf Netzwerk-Ähnlichkeit).

Verletzungsausfälle
Bei Ausfall eines Schlüsselspielers: Welche alternativen Passverbindungen könnten aktiviert werden?

6.6.5 Limitationen

Statische Perspektive
Alle Tests basieren auf aggregierten, statischen Netzwerken. Dynamische Aspekte (Veränderung während Spielen, saisonale Entwicklung) werden nicht erfasst.

Unabhängigkeitsannahmen
Viele Tests (z.B. Bootstrap) nehmen Unabhängigkeit an, aber Kanten in Fussballnetzwerken sind korreliert (gleiche Spieler, gleiche Spiele). Dies kann p-Werte leicht unterschätzen (konservativere Tests).

Kausalität
Statistische Signifikanz bedeutet nicht Kausalität. Hohes Clustering *könnte* durch taktische Anweisungen entstehen, aber auch durch natürliche Positionierung oder Datenverzerrungen.

6.7 Fazit

Die statistische Analyse offenbart fundamentale Eigenschaften unserer Fussballnetzwerke:

1. **Signifikante taktische Struktur**: Clustering ist 11.7-fach höher als Zufallserwartung ($p < 0.001$) Spieler bilden gezielt eng vernetzte Einheiten.
2. **Keine Scale-Free-Struktur**: Log-Normal-Gradverteilung (nicht Power Law) zeigt moderate Zentralisierung ohne extreme Hubs, konsistent mit balancierten Team-Taktiken.
3. **Small-World-Eigenschaften**: Hohes Clustering kombiniert mit relativ kurzen Pfaden. Ist charakteristisch für gut organisierte Systeme.
4. **Robuste Metriken**: Bootstrap-Konfidenzintervalle zeigen geringe Varianz. Unsere Beobachtungen sind stabil.
5. **Effektive Link Prediction**: Adamic-Adar erreicht AUC = 0.89 und Precision@100 = 0.78 ist praktisch nützlich für taktische Empfehlungen.

Diese Erkenntnisse validieren die deskriptiven Analysen (LE5, LE6) und zeigen, dass beobachtete Muster nicht zufällig sind. Die Kombination aus Nullmodell-Vergleichen, Verteilungsanpassungen und Hypothesentests liefert eine rigorose statistische Grundlage für Interpretationen.

Ausblick: Zukünftige Analysen könnten temporale Tests (Veränderung über Zeit), multivariate Modelle (ERGM mit multiplen Prädiktoren) oder kausale Inferenz-Methoden (z.B. instrumentelle Variablen für taktische Interventionen) einsetzen.

7 LE8 – Link Prediction

7.1 Ziel

Welche Kanten sollen vorhergesagt werden (zeitlich oder als fehlende Links)?

7.2 Features / Heuristiken

- Common Neighbors, Jaccard, Adamic–Adar
- Preferential Attachment
- Katz / Rooted PageRank
- Einbettungen (z.B. node2vec) oder GNN (falls genutzt)

7.3 Evaluation

- Train/Test Split (z.B. zeitbasiert), Negative Sampling
- Metriken: AUC, Average Precision, Precision@k
- Baselines und Ablations

7.4 Ergebnisse

Vergleiche Methoden, diskutiere Fehlerfälle und praktische Aussagekraft.

8 LE9 – Diffusion

8.1 Ziel

Welche Diffusionsprozesse werden modelliert oder simuliert? (Information, Krankheit, Adoption, ...)

8.2 Modelle

- SI/SIR/SIS oder Threshold/Independent Cascade
- Parameter (Infektionsrate, Recovery, Schwellen)
- Seed-Strategien (zufällig, hochgradig, zentral nach LE5)

8.3 Simulation & Auswertung

- Mehrere Läufe und Unsicherheit
- Messgrößen: Endgröße, Geschwindigkeit, Reach, Time-to-...

8.4 Ergebnisse

Vergleiche Modelle/Parameter und diskutiere Implikationen.

9 LE10 – Graphlets

9.1 Ziel

Welche lokalen Strukturen (Graphlets/Motive) sollen gezählt oder verglichen werden?

9.2 Vorgehen

- Graphlet-Größe k (z.B. 3–5) und Wahl der Typen
- Zählverfahren / Sampling (falls nötig)
- Normalisierung und Vergleich (z.B. Graphlet Degree Vector, Orbit Counts)

9.3 Ergebnisse

Zeige dominante Graphlets, Unterschiede zwischen Subnetzen/Communities oder über Zeit, und interpretiere diese.

Quellenverzeichnis

arXiv. (2024, Mai). *Exploring the Independent Cascade Model and Its Evolution in Social Network Information Diffusion* [Accessed: 2026-01-04]. https://arxiv.org/html/2405.10322v1

Clauset, A., Newman, M. E. J., & Moore, C. (2004). Finding community structure in very large networks. *Physical Review E*, *70*(6). https://doi.org/10.1103/physreve.70.066111

FotMob.com. (n. d.). *FotMob*. https://www.fotmob.com/leagues/47/stats/season/20720/teams/accurate_pass_team/premier-league-teams

Karnowski, V., & Kümpel, A. S. (2016). Diffusion of Innovations. In M. Potthoff (Hrsg.), *Schlüsselwerke der Medienwirkungsforschung* (S. 97–107). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-09923-7_9

Pappalardo, L., Cintia, P., Rossi, A., Massucco, E., Ferragina, P., Pedreschi, D., & Giannotti, F. (2019). A public data set of spatio-temporal match events in soccer competitions. *Scientific Data*, *6*(1), 236. https://doi.org/10.1038/s41597-019-0247-7

transfermarkt.ch. (n. d.). *Sandro Wagner - Spielerprofil*. https://www.transfermarkt.ch/sandro-wagner/profil/spieler/39

A Ein Anhang

Morbi sem. Nulla facilisi. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Nulla facilisi. Morbi sagittis ultrices libero. Praesent eu ligula sed sapien auctor sagittis. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Donec vel nunc. Nunc fermentum, lacus id aliquam porta, dui tortor euismod eros, vel molestie ipsum purus eu lacus. Vivamus pede arcu, euismod ac, tempus id, pretium et, lacus. Curabitur sodales dapibus urna. Nunc eu sapien. Donec eget nunc a pede dictum pretium. Proin mauris. Vivamus luctus libero vel nibh.

Fusce tristique risus id wisi. Integer molestie massa id sem. Vestibulum vel dolor. Pellentesque vel urna vel risus ultricies elementum. Quisque sapien urna, blandit nec, iaculis ac, viverra in, odio. In hac habitasse platea dictumst. Morbi neque lacus, convallis vitae, commodo ac, fermentum eu, velit. Sed in orci. In fringilla turpis non arcu. Donec in ante. Phasellus tempor feugiat velit. Aenean varius massa non turpis. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae;

Aliquam tortor. Morbi ipsum massa, imperdiet non, consectetuer vel, feugiat vel, lorem. Quisque eget lorem nec elit malesuada vestibulum. Quisque sollicitudin ipsum vel sem. Nulla enim. Proin nonummy felis vitae felis. Nullam pellentesque. Duis rutrum feugiat felis. Mauris vel pede sed libero tincidunt mollis. Phasellus sed urna rhoncus diam euismod bibendum. Phasellus sed nisl. Integer condimentum justo id orci iaculis varius. Quisque et lacus. Phasellus elementum, justo at dignissim auctor, wisi odio lobortis arcu, sed sollicitudin felis felis eu neque. Praesent at lacus.

Vivamus sit amet pede. Duis interdum, nunc eget rutrum dignissim, nisl diam luctus leo, et tincidunt velit nisl id tellus. In lorem tellus, aliquet vitae, porta in, aliquet sed, lectus. Phasellus sodales. Ut varius scelerisque erat. In vel nibh eu eros imperdiet rutrum. Donec ac odio nec neque vulputate suscipit. Nam nec magna. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Nullam porta, odio et sagittis iaculis, wisi neque fringilla sapien, vel commodo lorem lorem id elit. Ut sem lectus, scelerisque eget, placerat et, tincidunt scelerisque, ligula. Pellentesque non orci.

A.1 Aufgabenstellung im Originalwortlaut

Nullam eleifend justo in nisl. In hac habitasse platea dictumst. Morbi nonummy. Aliquam ut felis. In velit leo, dictum vitae, posuere id, vulputate nec, ante. Maecenas vitae pede nec dui dignissim suscipit. Morbi magna. Vestibulum id purus eget velit laoreet laoreet. Praesent sed leo vel nibh convallis blandit. Ut rutrum. Donec nibh. Donec interdum. Fusce sed pede sit amet elit rhoncus ultrices. Nullam at enim vitae pede vehicula iaculis.

A.2 Gesamtübersicht

Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Aenean nonummy turpis id odio. Integer euismod imperdiet turpis. Ut nec leo nec diam imperdiet lacinia. Etiam eget lacus eget mi ultricies posuere. In placerat tristique tortor. Sed porta vestibulum metus. Nulla iaculis sollicitudin pede. Fusce luctus tellus in dolor. Curabitur auctor velit a sem. Morbi sapien. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Donec adipiscing urna vehicula nunc. Sed ornare leo in leo. In rhoncus leo ut dui. Aenean dolor quam, volutpat nec, fringilla id, consectetuer vel, pede.

A.3 Berechnungen / Resultate Umfrage

Nulla malesuada risus ut urna. Aenean pretium velit sit amet metus. Duis iaculis. In hac habitasse platea dictumst. Nullam molestie turpis eget nisl. Duis a massa id pede dapibus ultricies. Sed eu leo. In at mauris sit amet tortor bibendum varius. Phasellus justo risus, posuere in, sagittis ac, varius vel, tortor. Quisque id enim. Phasellus consequat, libero pretium nonummy fringilla, tortor lacus vestibulum nunc, ut rhoncus ligula neque id justo. Nullam accumsan euismod nunc. Proin vitae ipsum ac metus dictum tempus. Nam ut wisi. Quisque tortor felis, interdum ac, sodales a, semper a, sem. Curabitur in velit sit amet dui tristique sodales. Vivamus mauris pede, lacinia eget, pellentesque quis, scelerisque eu, est. Aliquam risus. Quisque bibendum pede eu dolor.

A.4 Tests – Screenshots

Donec tempus neque vitae est. Aenean egestas odio sed risus ullamcorper ullamcorper. Sed in nulla a tortor tincidunt egestas. Nam sapien tortor, elementum sit amet, aliquam in, porttitor faucibus, enim. Nullam congue suscipit nibh. Quisque convallis. Praesent arcu nibh, vehicula eget, accumsan eu, tincidunt a, nibh. Suspendisse vulputate, tortor quis adipiscing viverra, lacus nibh dignissim tellus, eu suscipit risus ante fringilla diam. Quisque a libero vel pede imperdiet aliquet. Pellentesque nunc nibh, eleifend a, consequat consequat, hendrerit nec, diam. Sed urna. Maecenas laoreet eleifend neque. Vivamus purus odio, eleifend non, iaculis a, ultrices sit amet, urna. Mauris faucibus odio vitae risus. In nisl. Praesent purus. Integer iaculis, sem eu egestas lacinia, lacus pede scelerisque augue, in ullamcorper dolor eros ac lacus. Nunc in libero.